



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
ΣΧΟΛΗ ΤΕΧΝΟΛΟΓΙΩΝ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ
ΕΠΙΚΟΙΝΩΝΙΩΝ ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ

Πτυχιακή Εργασία

Τίτλος Πτυχιακής Εργασίας	Εφαρμογή μεθόδων Επεξεργασίας Φυσικής Γλώσσας για τη δημιουργία σύνοψης, εξαγωγής πληροφοριών, καθώς και την ανάλυση συναισθήματος από δεδομένα σε μορφή κειμένου Application of Natural Language Processing Methods for Summarization, Information Extraction, and Sentiment Analysis from Textual Data
Ονοματεπώνυμο Φοιτητή	Στέφανος Αρναουτίδης
Πατρώνυμο	Κωνσταντίνος
Αριθμός Μητρώου	Π22016
Επιβλέπων	Κωνσταντίνος Λιαγκούρας, Επίκουρος Καθηγητής

Ημερομηνία Παράδοσης

Ιούνιος 2026

Copyright

Η παρούσα πτυχιακή εργασία προστατεύεται από τη νομοθεσία περί πνευματικής ιδιοκτησίας. Απαγορεύεται αυστηρά η αντιγραφή, αποθήκευση, αναπαραγωγή και διανομή του παρόντος έργου, εξ ολοκλήρου ή τμηματικά, για οποιονδήποτε εμπορικό ή κερδοσκοπικό σκοπό. Αντιθέτως, επιτρέπεται η χρήση, αναδημοσίευση και αποθήκευσή της για αυστηρά ακαδημαϊκούς, εκπαιδευτικούς και ερευνητικούς σκοπούς, υπό την προϋπόθεση να γίνεται σαφής και ορθή αναφορά στην πηγή προέλευσης και στον αρχικό δημιουργό. Η χρήση του έργου ως ιδίου χωρίς τη δέουσα παραπομπή συνιστά παραβίαση των δικαιωμάτων πνευματικής ιδιοκτησίας.

Οι απόψεις, τα αποτελέσματα και τα συμπεράσματα που διατυπώνονται στο παρόν έγγραφο εκφράζουν αποκλειστικά τον συγγραφέα και σε καμία περίπτωση δεν αντιπροσωπεύουν τις επίσημες θέσεις του Πανεπιστημίου Πειραιώς.

Ως συγγραφέας της παρούσας εργασίας, δηλώνω πως το κείμενο αυτό δεν αποτελεί προϊόν λογοκλοπής και δεν περιέχει υλικό από μη αναφερόμενες πηγές

Ευχαριστίες

Αρχικά, θα ήθελα να ευχαριστήσω τον επιβλέποντα καθηγητή μου, κ. Κωνσταντίνο Λιαγκούρα για τις πολύτιμες κατευθύνσεις και τον χρόνο τον οποίο μου αφιέρωσε για την επίλυση των αποριών που μου δημιουργήθηκαν καθ' όλη την διάρκεια της συγγραφής της παρούσας εργασίας.

Σε προσωπικό επίπεδο οφείλω να αναγνωρίσω και να ευχαριστήσω την ψυχολογική στήριξη που δέχτηκα από την μητέρα μου, Στελούτα Λενάρτ, κατά την διάρκεια υλοποίησης της πτυχιακής εργασίας.

Τέλος οφείλω να εκφράσω την ευγνωμοσύνη μου στη σύντροφό μου Αναστασία Βογιατζή για την βοήθεια που μου παρείχε στο κομμάτι της συντακτικής και ορθογραφικής επιμέλειας του τελικού κειμένου.

Περίληψη

Η παρούσα πτυχιακή εργασία πραγματεύεται την ενσωμάτωση σύγχρονων τεχνικών Επεξεργασίας Φυσικής Γλώσσας (NLP) στον τομέα της ψηφιακής δημοσιογραφίας, με στόχο την αντιμετώπιση του φαινομένου της πληροφοριακής υπερφόρτωσης. Χρησιμοποιώντας ως πρωτογενές υλικό ένα σύνολο ειδησεογραφικών άρθρων από το δίκτυο του BBC, η έρευνα αναπτύσσεται πάνω σε δύο βασικούς μεθοδολογικούς άξονες: την ανάλυση συναισθηματικής πολικότητας και την αυτόματη παραγωγή περίληψης. Αρχικά, πραγματοποιείται μια συγκριτική αξιολόγηση μεταξύ του παραδοσιακού, λεξικοκεντρικού συστήματος VADER και του προηγμένου γλωσσικού μοντέλου RoBERTa, προκειμένου να διαπιστωθεί η δυνατότητά τους να αποκωδικοποιούν τον επαγγελματικό και συχνά ουδέτερο ειδησεογραφικό λόγο. Στη συνέχεια, εξετάζεται η δυναμική της αρχιτεκτονικής BART στη δημιουργία αφαιρετικών συνόψεων, ικανών να αποδώσουν τον πυρήνα της είδησης με φυσικότητα, παρακάμπτοντας τη μηχανική συρραφή προτάσεων. Η αξιολόγηση των πειραματικών αποτελεσμάτων, με τη χρήση καθιερωμένων μετρικών όπως το ROUGE, αναδεικνύει την υπεροχή των μοντέλων Βαθιάς Μάθησης. Ειδικότερα, τα δίκτυα τύπου Transformer ανταποκρίθηκαν με ακρίβεια στη σημασιολογική πολυπλοκότητα των κειμένων, αναδεικνύοντας τις συγκεκριμένες τεχνολογίες ως πολύτιμα, εφαρμόσιμα εργαλεία για τον εκσυγχρονισμό και την αυτοματοποίηση της καθημερινής ροής στις σύγχρονες αίθουσες σύνταξης.

Λέξεις-Κλειδιά: Επεξεργασία Φυσικής Γλώσσας, Ανάλυση Συναισθήματος, Αυτόματη Περίληψη, Βαθιά Μάθηση, Ψηφιακή Δημοσιογραφία, Transformers

Abstract

This thesis explores the integration of modern Natural Language Processing (NLP) techniques within the field of digital journalism, aiming to address the phenomenon of information overload. Utilizing a dataset of news articles from the BBC network, the research is developed across two primary methodological axes: sentiment polarity analysis and automatic text summarization. Initially, a comparative evaluation is conducted between the traditional, lexicon-based VADER system and the advanced RoBERTa language model, in order to determine their ability to decode professional and often neutral journalistic discourse. Subsequently, the potential of the BART architecture in generating abstractive summaries is examined, focusing on its capacity to convey the core information of a news story with linguistic naturalness, while bypassing simple mechanical sentence extraction. The evaluation of experimental results, using established metrics such as ROUGE, demonstrates the superiority of Deep Learning models. Specifically, Transformer-based networks responded with exceptional precision to the semantic complexity of the texts, highlighting these technologies as valuable, applicable tools for modernizing and automating daily workflows in contemporary newsrooms.

Keywords: Natural Language Processing, Sentiment Analysis, Text Summarization, Deep Learning, Digital Journalism, Transformers

Πίνακας Περιεχομένων

Copyright	ii
Ευχαριστίες	iii
Περίληψη	iv
Abstract	iv
Πίνακας Περιεχομένων	v
Κατάλογος Εικόνων	ix
Εισαγωγή	1
1.1 Περιγραφή και Σημασία του Αντικειμένου	1
1.2 Ερευνητική Στόχευση και Μεθοδολογική Προσέγγιση	1
1.3 Επιμέρους Στόχοι και Επιστημονική Συνεισφορά	2
1.4 Διάρθρωση της Πτυχιακής Εργασίας	2
Κεφάλαιο 2: Βιβλιογραφική Ανασκόπηση	4
2.1 Εισαγωγή	4
2.2 Ορισμός και Επίπεδα Γλωσσικής Ανάλυσης	4
2.3 Ιστορική Εξέλιξη και Βασικοί Πυλώνες Εφαρμογών	5
2.4 Ανάλυση Συναισθήματος (Sentiment Analysis)	7
2.4.1 Συγκριτική Ανάλυση Παραδοσιακών Μεθοδολογιών	8
2.4.2 Η Μετάβαση στις Αρχιτεκτονικές Βαθιάς Μάθησης (Deep Learning)	9
2.4.3 Η Επανάσταση των Transformers και το Μοντέλο BERT	10
2.5 Αυτόματη Περίληψη Κειμένου (Automatic Text Summarization)	11
2.5.1 Εξαγωγικές Μέθοδοι (Extractive Methods)	12
2.5.2 Αφαιρετικές Μέθοδοι (Abstractive Methods)	14
2.6 Αναγνώριση Οντοτήτων (Named Entity Recognition - NER)	15
2.6.1 Κατανεμημένες Αναπαραστάσεις Εισόδου (Distributed Representations for Input)	17
2.6.2 Αρχιτεκτονικές Κωδικοποίησης Συγκειμένου (Context Encoder Architectures)	18
2.6.3 Αποκωδικοποίηση Ετικετών (Tag Decoder Architectures)	20
2.7 Μετρικές Αξιολόγησης (Evaluation Metrics)	21
2.7.1 Μετρικές Ταξινόμησης ενός Επιπέδου (Single-label Metrics)	23
2.7.2 Μετρικές Πολλαπλών Ετικετών (Multi-label Metrics)	24

2.7.3 Μετρικές Παραγωγής Κειμένου (Text Generation Metrics)	26
2.8 Προκλήσεις και Ηθικά Ζητήματα (Challenges and Ethical Considerations).....	28
2.8.1 Μεροληψία και Δικαιοσύνη (Bias and Fairness)	29
2.8.2 Παραισθήσεις των Μοντέλων (Hallucinations)	31
2.8.3 Ηθικά Ζητήματα και Τεχνολογικοί Περιορισμοί (Ethical Considerations and Limitations).....	32
2.9 Σύγχρονες Τάσεις: Μεγάλα Γλωσσικά Μοντέλα (Large Language Models)	33
2.9.1 Από τα Συμβατικά Μοντέλα στις Αρχιτεκτονικές Transformer	34
2.9.2 Αναδυόμενες Ικανότητες: Μάθηση Μηδενικής Βολής (Zero-Shot Learning) και Μηχανική Προτροπών (Prompt Engineering)	35
2.9.3 Το Παράδοξο της Γενίκευσης: Ευελιξία έναντι Εξειδίκευσης	36
Κεφάλαιο 3: Μεθοδολογία	38
3.1 Εισαγωγή	38
3.2 Σκοπός και Αντικείμενο της Πειραματικής Διαδικασίας	38
3.3 Περιγραφή και Ανάλυση Δεδομένων (Dataset Description)	39
3.4 Προεπεξεργασία και Καθαρισμός Δεδομένων (Data Preprocessing).....	40
3.5 Επιλογή Μοντέλων και Αρχιτεκτονική (Model Selection & Architecture).....	41
3.5.1 Εξαγωγή Πληροφορίας: Αναγνώριση Οντοτήτων μέσω της βιβλιοθήκης spaCy	43
3.5.2 Ανάλυση Συναισθήματος: Συγκριτική Αξιολόγηση VADER και RoBERTa	44
3.5.3 Αυτόματη Περίληψη Κειμένου: Η αρχιτεκτονική BART	45
3.6 Μετρικές Αξιολόγησης και Κριτήρια Απόδοσης (Evaluation Metrics & Performance Criteria).....	46
3.6.1 Μετρικές Αξιολόγησης Ταξινόμησης (Classification Metrics)	47
3.6.2 Μετρικές Αξιολόγησης Παραγωγής Κειμένου (Text Generation Metrics)	48
Κεφάλαιο 4: Αποτελέσματα και Συζήτηση	50
4.1 Εισαγωγή	50
4.2 Περιβάλλον Ανάπτυξης και Εργαλεία Υλοποίησης.....	50
4.2.1 Υπολογιστικοί Πόροι και Υποδομές (Hardware & Infrastructure)	51
4.2.2 Γλώσσα Προγραμματισμού και Διαχείριση Δεδομένων	52
4.2.3 Βιβλιοθήκες Μηχανικής Μάθησης και Οπτικοποίησης Δεδομένων	53
4.3 Πειραματική Εφαρμογή: Αναγνώριση Ονοματισμένων Οντοτήτων (NER)	53

4.3.1 Μεθοδολογική Προσέγγιση και Προγραμματιστική Υλοποίηση.....	54
4.3.2 Οπτικοποίηση Ευρημάτων και Στατιστική Κατανομή.....	55
4.3.3 Κριτική Αποτίμηση Ευρημάτων και Διαπίστωση Αλγοριθμικών Περιορισμών.....	58
4.4 Ανάλυση Συναισθήματος με Χρήση Λεξικογραφικών Μεθόδων (VADER).....	58
4.4.1 Προεπεξεργασία Δεδομένων και Υπολογισμός Πολικότητας	59
4.4.2 Οπτικοποίηση και Αξιολόγηση Συνολικής Κατανομής	60
4.4.3 Διασταυρούμενη Ανάλυση ανά Θεματική Κατηγορία.....	62
4.4.4 Ποιοτική Αξιολόγηση και Ανάλυση Σφαλμάτων (Error Analysis)	63
4.5 Ανάλυση Συναισθήματος με Βαθιά Μάθηση (RoBERTa)	64
4.5.1 Προγραμματιστική Υλοποίηση και Παραμετροποίηση	65
4.5.2 Οπτικοποίηση Ευρημάτων και Στατιστική Κατανομή.....	66
4.5.3 Συγκριτική Ανάλυση (RoBERTa vs. VADER) και Ποιοτική Αποτίμηση.....	68
4.6 Αυτόματη Παραγωγή Περίληψης (Text Summarization).....	69
4.6.1 Προγραμματιστική Υλοποίηση και Μοντέλο BART	70
4.6.2 Ποσοτική Αξιολόγηση μέσω Μετρικών ROUGE.....	71
4.7 Μελέτη Περιπτώσεων (Case Studies)	72
4.7.1 Μελέτη Περίπτωσης 1: Θεματική Κατηγορία «Αθλητισμός» (Sport).....	72
4.7.2 Μελέτη Περίπτωσης 2: Θεματική Κατηγορία «Τεχνολογία» (Tech)	73
4.8 Συζήτηση Αποτελεσμάτων (Discussion).....	74
4.8.1 Αξιολόγηση των Μοντέλων Συναισθηματικής Ανάλυσης	75
4.8.2 Αξιολόγηση της Αυτόματης Παραγωγής Περίληψης.....	76
4.8.3 Περιορισμοί της Έρευνας (Limitations).....	77
Κεφάλαιο 5: Συμπεράσματα και Μελλοντική Έρευνα.....	78
5.1 Εισαγωγή.....	78
5.2 Βασικά Συμπεράσματα	78
5.3 Προτάσεις για Μελλοντική Έρευνα	79
Κεφάλαιο 6: Μεθοδολογία Βιβλιογραφικής Αναζήτησης και Βιβλιομετρική Ανάλυση	81
6.1 Πρωτόκολλο Αναζήτησης και Κριτήρια Ένταξης.....	81
6.2 Χρονική Κατανομή Βιβλιογραφικών Πηγών	81
6.3 Προέλευση και Κατανομή Επιστημονικών Πηγών.....	83
6.4 Ποιοτική Αξιολόγηση και Επιστημονικός Αντίκτυπος Πηγών.....	84

6.5 Συγγραφική Παραγωγή και Ερευνητική Διασπορά	85
Παράρτημα	87
Πηγαίος Κώδικας:	87
Πίνακας συντομεύσεων – αρτικόλεξο	93
Πίνακας ορολογίας.....	94
Βιβλιογραφία	107

Κατάλογος Εικόνων

Εικόνα 2.1: Βασική αλυσιδωτή αρχιτεκτονική ενός αναδρομικού νευρωνικού δικτύου για την επεξεργασία ακολουθιών	9
Εικόνα 2.2: Συγκριτική απεικόνιση της αμφίδρομης αρχιτεκτονικής του BERT έναντι των μονόδρομων μοντέλων.....	11
Εικόνα 2.3: Τυπική αρχιτεκτονική και ροή εκτέλεσης ενός συστήματος εξαγωγικής περίληψης κειμένου.	13
Εικόνα 2.4: Αρχιτεκτονική Κωδικοποιητή-Αποκωδικοποιητή (Encoder-Decoder) με ενσωμάτωση Μηχανισμού Προσοχής για την παραγωγή αφαιρετικής περίληψης.....	15
Εικόνα 2.5: Παράδειγμα επισήμανσης ακολουθιών μέσω του σχήματος BIO για την αναγνώριση προσώπων και οργανισμών.....	16
Εικόνα 2.6: Διαδικασία εξαγωγής και συνένωσης υβριδικών χαρακτηριστικών (λέξης, χαρακτήρων και POS) για τη δημιουργία της τελικής καταταξιμένης αναπαράστασης.....	18
Εικόνα 2.7: Αρχιτεκτονική Αμφίδρομου Νευρωνικού Δικτύου (BiLSTM), όπου η τελική αναπαράσταση προκύπτει από τη συνένωση της ορθόδρομης και ανάδρομης ανάλυσης	19
Εικόνα 2.8: Συγκριτική απεικόνιση της ανεξάρτητης ταξινόμησης ετικετών (CRF, αριστερά) σε σχέση με την ολιστική μοντελοποίηση ακολουθίας και πιθανοτήτων μετάβασης (Softmax, δεξιά).).....	21
Εικόνα 2.9: Οπτική αναπαράσταση του Πίνακα Σύγχυσης (Confusion Matrix), ο οποίος διαχωρίζει τις προβλέψεις του μοντέλου σε σχέση με την πραγματική κλάση των δεδομένων.).....	23
Εικόνα 2.10: Συγκριτική απεικόνιση της ροής υπολογισμού μεταξύ της στρατηγικής Micro-Averaging (αριστερά/κάτω) και Macro-Averaging (δεξιά).).....	25
Εικόνα 2.11: Εννοιολογική αναπαράσταση της λειτουργίας των μετρικών n-gram overlap, όπου ταυτοποιούνται κοινές λέξεις και ακολουθίες μεταξύ του Κειμένου Αναφοράς και της Πρόβλεψης του Μοντέλου.....	28
Εικόνα 2.12: Απεικόνιση των σταδίων ανάπτυξης ενός συστήματος Τεχνητής Νοημοσύνης και η αντιστοίχισή τους με τις κύριες ηθικές και τεχνικές προκλήσεις.....	29
Εικόνα 2.13: Ο κύκλος ανατροφοδότησης της αλγοριθμικής μεροληψίας, όπου τα μολυσμένα δεδομένα οδηγούν σε μεροληπτικές αποφάσεις, οι οποίες με τη σειρά τους παράγουν νέα προκατειλημμένα δεδομένα για μελλοντικά συστήματα.....	30
Εικόνα 2.14: Παράδειγμα ταξινόμησης των παραισθήσεων κατά την παραγωγή κειμένου, αναδεικνύοντας τη διάκριση μεταξύ εγγενούς αλλοίωσης και εξωγενούς προσθήκης πληροφοριών.....	32
Εικόνα 2.15: Εννοιολογικός χάρτης (MindMap) που συνοψίζει τις τρεις κύριες κατηγορίες προκλήσεων κατά την ανάπτυξη και εφαρμογή σύγχρονων μοντέλων Επεξεργασίας Φυσικής Γλώσσας.....	33
Εικόνα 2.16: Σχηματική σύγκριση μεταξύ του παραδοσιακού παραδείγματος εξειδικευμένων μοντέλων (task-specific) και της σύγχρονης προσέγγισης των Μοντέλων Θεμελίωσης (LLMs), όπου μια ενιαία αρχιτεκτονική εξυπηρετεί πολλαπλές εργασίες NLP.....	35
Εικόνα 2.17: Πρακτική σύγκριση των τεχνικών Μηδενικής Βολής (Zero-Shot) και Ελάχιστων Παραδειγμάτων (Few-Shot) κατά την καθοδήγηση ενός Μεγάλου Γλωσσικού Μοντέλου σε εργασία ανάλυσης συναισθήματος.....	36

Εικόνα 2.18: Η σχέση αντιστάθμισης (trade-off) ανάμεσα στα Μεγάλα Γλωσσικά Μοντέλα γενικού σκοπού και τις εξειδικευμένες αρχιτεκτονικές, αποτυπώνοντας τα πλεονεκτήματα και τους περιορισμούς κάθε προσέγγισης.....	37
Εικόνα 3.1: Κατανομή πλήθους άρθρων ανά θεματική κατηγορία στο σύνολο δεδομένων BBC News. Παρατηρείται η σχεδόν ισομερής αντιπροσώπευση (class balance) των εγγραφών.....	39
Εικόνα 3.2: Συνολική Αρχιτεκτονική του Προτεινόμενου Συστήματος. Απεικονίζεται η ροή των δεδομένων από το αρχικό dataset, τα στάδια προεπεξεργασίας, οι τρεις διακριτοί ερευνητικοί άξονες και η τελική εξαγωγή συμπερασμάτων.....	42
Εικόνα 3.3: Παράδειγμα οπτικοποίησης της Αναγνώρισης Ονοματισμένων Οντοτήτων (NER) με χρήση του ενσωματωμένου εργαλείου displaCy της βιβλιοθήκης spaCy.....	43
Εικόνα 3.4: Αρχιτεκτονική τοπολογία του μοντέλου BART (Bidirectional and Auto-Regressive Transformers).....	46
Εικόνα 4.1: Βασικός προγραμματιστικός βρόχος για την ταχεία εξαγωγή οντοτήτων και την εφαρμογή κανόνων καθαρισμού.....	55
Εικόνα 4.2: Στατιστική κατανομή των δέκα επικρατέστερων Φυσικών Προσώπων (PERSON) στο σύνολο δεδομένων.....	56
Εικόνα 4.3: Στατιστική κατανομή των δέκα επικρατέστερων Οργανισμών (ORG) στο σύνολο δεδομένων..	57
Εικόνα 4.4: Στατιστική κατανομή των δέκα επικρατέστερων Γεωπολιτικών Τοποθεσιών (GPE) στο σύνολο δεδομένων.....	57
Εικόνα 4.5: Προγραμματιστική ρουτίνα υπολογισμού του κανονικοποιημένου δείκτη (compound score) και κατηγοριοποίησης της συναισθηματικής πολικότητας βάσει των καθιερωμένων κατωφλίων του αλγορίθμου VADER.....	60
Εικόνα 4.6: Συνολική κατανομή συναισθηματικής πολικότητας στο BBC News Dataset μέσω του αλγορίθμου VADER.....	61
Εικόνα 4.7: Κατανομή συναισθηματικής πολικότητας ανά θεματική κατηγορία στο BBC News Dataset.....	62
Εικόνα 4.8: Φόρτωση και εφαρμογή του γλωσσικού μοντέλου RoBERTa.....	66
Εικόνα 4.9: Κυκλικό διάγραμμα συνολικής κατανομής συναισθήματος με χρήση του μοντέλου RoBERTa.	67
Εικόνα 4.10: Κατανομή συναισθηματικής πολικότητας ανά θεματική κατηγορία (RoBERTa).....	68
Εικόνα 4.11: Υλοποίηση της αυτόματης παραγωγής περίληψης (BART) και εφαρμογή του αλγορίθμου Beam Search μέσω της βιβλιοθήκης Transformers.....	71
Εικόνα 6.1: Χρονική κατανομή των βιβλιογραφικών αναφορών.....	82
Εικόνα 6.2: Οι οκτώ κορυφαίες πηγές προέλευσης της βιβλιογραφίας.....	84
Εικόνα 6.3: Τα Rankings των αναφορών.....	85

.

Κατάλογος Πινάκων

Πίνακας 4.1: Συγκριτική κατανομή συναισθηματικής πολικότητας στο σύνολο των άρθρων του BBC News.....	69
Πίνακας 4.2: Μέσοι όροι απόδοσης του προεκπαιδευμένου μοντέλου BART βάσει των μετρικών ROUGE.....	71
Πίνακας 6.1: Χρονική κατανομή των βιβλιογραφικών αναφορών.....	82
Πίνακας 6.2: Οι οκτώ κορυφαίες πηγές προέλευσης της βιβλιογραφίας.....	83
Πίνακας 6.3: Κατάταξη των συγγραφέων με τη μεγαλύτερη ερευνητική παρουσία στη βιβλιογραφία....	85

.

Εισαγωγή

1.1 Περιγραφή και Σημασία του Αντικειμένου

Η ραγδαία εξέλιξη των τεχνολογιών πληροφορικής και η καθολική μετάβαση των μέσων μαζικής ενημέρωσης στο ψηφιακό περιβάλλον έχουν μετασχηματίσει ριζικά το σύγχρονο επικοινωνιακό τοπίο. Στη σημερινή εποχή, ο ημερήσιος όγκος των παραγόμενων ειδήσεων σε παγκόσμια κλίμακα αγγίζει πρωτοφανή μεγέθη, δημιουργώντας ένα πυκνό και χαοτικό δίκτυο πληροφοριών. Το φαινόμενο αυτό, ευρύτερα γνωστό ως «πληροφοριακή υπερφόρτωση» (information overload), εγείρει σημαντικές προκλήσεις όχι μόνο για το αναγνωστικό κοινό που ενημερώνεται για την επικαιρότητα, αλλά πρωτίστως για τους ίδιους τους αρθρογράφους [1]. Οι παραδοσιακές πρακτικές χειροκίνητης αποδελτίωσης, ταξινόμησης και ανάγνωσης των ρεπορτάζ αδυνατούν πλέον στην πράξη να συμβαδίσουν με τους γρήγορους ρυθμούς ζωής οι οποίοι διαμορφώνουν αντίστοιχα και τη ροή των γεγονότων.

Μπροστά σε αυτό το αυξανόμενο αδιέξοδο, η σύμπραξη της Επιστήμης των Υπολογιστών με τη δημοσιογραφία, η οποία έχει καθιερωθεί ακαδημαϊκά ως Υπολογιστική Δημοσιογραφία (Computational Journalism), αναδεικνύεται ως η πλέον βιώσιμη διέξοδος [2]. Σημαντικό ρόλο σε αυτή τη νέα πραγματικότητα διαδραματίζει η Τεχνητή Νοημοσύνη (AI) και, ειδικότερα, ο κλάδος της Επεξεργασίας Φυσικής Γλώσσας (NLP). Μέσω της ενσωμάτωσης έξυπνων αλγορίθμων, εμφανίζεται για πρώτη φορά η δυνατότητα των υπολογιστικών συστημάτων να "κατανοούν" τα κείμενα που αποθηκεύουν, αποκωδικοποιώντας το νόημά τους και να τα συμπυκνώνουν. Κατά συνέπεια, η εφαρμογή τέτοιων καινοτόμων τεχνολογιών μετατρέπεται σταδιακά σε ένα σημαντικό δομικό εργαλείο για την εύρυθμη λειτουργία των σύγχρονων αιθουσών σύνταξης (newsrooms).

Μια επισκόπηση της σύγχρονης διεθνούς βιβλιογραφίας επιβεβαιώνει πως ο συγκεκριμένος επιστημονικός τομέας διανύει μια περίοδο ριζικών μεταβάσεων [3]. Μέχρι πρότινος, η ακαδημαϊκή έρευνα γύρω από την επεξεργασία κειμένων στηριζόταν κατά κύριο λόγο σε προσεγγίσεις βασισμένες σε στατικούς κανόνες (rule-based) ή προκαθορισμένα λεξικά (lexicon-based). Παρότι τα αντίστοιχα συστήματα προσέφεραν ένα πρώιμο λειτουργικό πλαίσιο, γρήγορα ήρθαν αντιμέτωπα με τα όριά τους, καθώς αδυνατούσαν να διαχειριστούν την εγγενή πολυσημία, τον συγκαλυμμένο σαρκασμό και τις λεπτές υφολογικές αποχρώσεις σε διάφορα πλαίσια επικοινωνίας.

Ως απάντηση στις παραπάνω ελλείψεις, το ερευνητικό ενδιαφέρον έχει πλέον μετατοπιστεί προς τις προηγμένες αρχιτεκτονικές της Βαθιάς Μάθησης (Deep Learning). Ειδικότερα, η έλευση των δικτύων τύπου Transformer έχει αλλάξει τα δεδομένα, εξοπλίζοντας τους υπολογιστές με τη μηχανική ευφυΐα μέσω της οποίας αφομοιώνουν τα ευρύτερα συμφραζόμενα (context) μιας πρότασης [3].

1.2 Ερευνητική Στόχευση και Μεθοδολογική Προσέγγιση

Έχοντας οριοθετήσει το ευρύτερο θεωρητικό πλαίσιο, ο κεντρικός πυρήνας της παρούσας πτυχιακής εργασίας εστιάζει στην πρακτική εφαρμογή και αξιολόγηση σύγχρονων γλωσσικών μοντέλων σε ρεαλιστικές συνθήκες. Για να διασφαλιστεί η αυθεντικότητα και η χρηστικότητα του πειράματος, ως πρωτογενές υλικό επιλέχθηκε ένα αντιπροσωπευτικό σύνολο ειδησεογραφικών άρθρων (dataset) προερχόμενο από το διεθνές δίκτυο του BBC. Τα κείμενα του αντίστοιχου συνόλου δεδομένων συνιστούν το κατάλληλο "πεδίο δοκιμών" για την εξαγωγή ασφαλών επιστημονικών συμπερασμάτων, λόγω της ποικιλίας όσον αφορά τη θεματολογία τους και της εξεζητημένης γλωσσικής έκφρασης στο μεγαλύτερο μέρος του περιεχομένου τους.

Για την αποτελεσματικότερη διαχείριση αυτού του όγκου πληροφοριών, η ερευνητική στρατηγική αναπτύσσεται πάνω σε δύο διακριτούς, αλλά συμπληρωματικούς μεθοδολογικούς άξονες. Ο πρώτος άξονας αφορά την πρόκληση της Εξόρυξης Συναισθήματος (Sentiment Analysis). Στο στάδιο αυτό, επιχειρείται μια αντιπαραβολή μεταξύ δύο εντελώς διαφορετικών υπολογιστικών «κόσμων». Από τη μία πλευρά, τίθεται στο μικροσκόπιο ο παραδοσιακός, λεξικοκεντρικός (lexicon-based) αλγόριθμος VADER και, από την άλλη, η εξελιγμένη αρχιτεκτονική του νευρωνικού δικτύου RoBERTa. Ζητούμενο αποτελεί η αξιολόγηση της δυνατότητάς τους να αποκωδικοποιούν τη συναισθηματική πολικότητα (sentiment polarity) μέσα στον δημοσιογραφικό λόγο, διαχωρίζοντας τις αντικειμενικές περιγραφές δυσάρεστων γεγονότων από την υποκειμενική στάση του ίδιου του συντάκτη.

Στη συνέχεια, ο δεύτερος μεθοδολογικός πυλώνας αφορά την αντιμετώπιση του φαινομένου της πληροφοριακής υπερφόρτωσης, μέσω της λειτουργίας της Αυτόματης Παραγωγής Περίληψης (Text Summarization). Για τον σκοπό αυτό, επιστρατεύεται το προηγμένο γλωσσικό μοντέλο BART. Σε αντίθεση με τις απλοϊκές μεθόδους που αποσπούν και συρράπτουν υπάρχουσες προτάσεις (extractive), το συγκεκριμένο δίκτυο καλείται να φέρει εις πέρας την απαιτητική διαδικασία της αφαιρετικής σύνοψης (abstractive). Αξιολογείται, δηλαδή, η δυνατότητά του να αφομοιώνει το αρχικό έγγραφο και να συνθέτει ένα εντελώς νέο, φυσικό και ρέον κείμενο, το οποίο θα διασώζει στο ακέραιο τον ειδησεογραφικό πυρήνα του εκάστοτε ρεπορτάζ.

1.3 Επιμέρους Στόχοι και Επιστημονική Συνεισφορά

Βάσει της μεθοδολογίας που περιγράφηκε, η παρούσα πτυχιακή εργασία αποσκοπεί στην εκπλήρωση μιας σειράς στοχευμένων επιδιώξεων. Συγκεκριμένα, οι επιμέρους άξονες του εγχειρήματος αναλύονται ως εξής:

- **Ποσοτική και Ποιοτική Αποτίμηση:** Η αυστηρή μέτρηση των επιδόσεων (μέσω δεικτών όπως οι μετρικές ROUGE) και η σύγκριση της υπολογιστικής απαίτησης μεταξύ παλαιότερων συστημάτων και σύγχρονων μοντέλων βαθιάς μάθησης (Deep Learning).
- **Ανάδειξη Σημασιολογικής Κατανόησης:** Η έμφαση στη δυνατότητα των εξελιγμένων δικτύων να εντοπίζουν τον πυρήνα μιας είδησης και να παράγουν αυτόνομα, συνεκτικά κείμενα, χωρίς να αλλοιώνουν τα πραγματικά γεγονότα.
- **Δημιουργία Ενιαίας Ροής Εργασίας (Pipeline):** Η επιτυχής ενοποίηση της ανίχνευσης πολικότητας (sentiment detection) και της αφαιρετικής σύνοψης (abstractive summarization) σε ένα κοινό, λειτουργικό υπολογιστικό περιβάλλον, με τη δυνατότητα να διαχειρίζεται ακατέργαστα δεδομένα.

Με βάση το συμπέρασμα που προκύπτει από την επίτευξη του παραπάνω στοχοθετικού πλαισίου, η παρούσα εργασία συμβάλλει στη γεφύρωση της θεωρητικής πληροφορικής με την καθημερινή δημοσιογραφική πρακτική. Ο ευρύτερος στόχος είναι η ανάδειξη της δυνατότητας ενσωμάτωσης των τεχνολογιών ανοιχτού κώδικα (open-source) σε πραγματικές συνθήκες εργασίας. Με τον τρόπο αυτό καθίσταται δυνατός ο εκσυγχρονισμός των μέσων ενημέρωσης, ο οποίος συνίσταται στην απαλλαγή των συντακτών από χρονοβόρες διαδικασίες ρουτίνας, επιτρέποντάς τους να επικεντρωθούν στην καθαρά ερευνητική πλευρά της δουλειάς τους.

1.4 Διάρθρωση της Πτυχιακής Εργασίας

Το κυρίως κείμενο της εργασίας δομείται σε τέσσερα επιπλέον διακριτά κεφάλαια, η αλληλουχία των οποίων έχει ως εξής:

- **Στο Κεφάλαιο 2** αναλύεται το θεωρητικό πλαίσιο. Γίνεται εκτενής αναφορά στην ιστορική εξέλιξη της Επεξεργασίας Φυσικής Γλώσσας (NLP), εξηγούνται οι βασικές αρχές λειτουργίας των μηχανισμών προσοχής (attention mechanisms) και περιγράφεται η τεχνολογική μετάβαση προς τα σύγχρονα γλωσσικά μοντέλα (Transformers).

- **Το Κεφάλαιο 3** εστιάζει στην περιγραφή της μεθοδολογίας. Παρουσιάζονται τα τεχνικά χαρακτηριστικά του πρωτογενούς συνόλου δεδομένων (dataset) από το ειδησεογραφικό δίκτυο του BBC και τεκμηριώνονται οι λόγοι επιλογής των εργαλείων VADER, RoBERTa και BART. Παράλληλα, καταγράφονται τα βήματα υλοποίησης του πειραματικού κώδικα στο υπολογιστικό περιβάλλον του Google Colab.
- **Στο Κεφάλαιο 4** ακολουθεί η αναλυτική παράθεση και η κριτική αποτίμηση των αποτελεσμάτων. Μέσα από τη χρήση καθιερωμένων στατιστικών μετρικών, όπως το σύστημα ROUGE, και την εξέταση συγκεκριμένων μελετών περίπτωσης (case studies), συγκρίνονται οι επιδόσεις των αλγορίθμων και ερμηνεύεται η συμπεριφορά τους απέναντι στον δημοσιογραφικό λόγο.
- **Τέλος, στο Κεφάλαιο 5** διατυπώνονται τα τελικά πορίσματα της μελέτης. Η εργασία ολοκληρώνεται με τη συνοπτική αναφορά στους εγγενείς τεχνικούς περιορισμούς, καθώς και με την κατάθεση στοχευμένων προτάσεων για μελλοντικές ερευνητικές επεκτάσεις (future work) στον ευρύτερο κλάδο της ψηφιακής ενημέρωσης.

Κεφάλαιο 2: Βιβλιογραφική Ανασκόπηση

2.1 Εισαγωγή

Το παρόν κεφάλαιο αποτελεί τον θεωρητικό κορμό της πτυχιακής εργασίας. Σκοπός του είναι να αναλύσει τη σχετική βιβλιογραφία και να θέσει τις κατάλληλες βάσεις για τη μεθοδολογία που εφαρμόστηκε στη συνέχεια. Αντί να περιοριστεί σε μια απλή παράθεση τεχνικών εννοιών, η ενότητα αυτή επιδιώκει να εντάξει το ερευνητικό πρόβλημα της εργασίας στο ευρύτερο και διαρκώς εξελισσόμενο πεδίο της Επεξεργασίας Φυσικής Γλώσσας (NLP).

Αρχικά, είναι απαραίτητο να γίνει αποσαφήνιση των βασικών επιπέδων γλωσσικής και συντακτικής ανάλυσης, τα οποία αποτελούν θεμελιώδεις έννοιες της υπολογιστικής γλωσσολογίας (computational linguistics). Αμέσως μετά, πραγματοποιείται μια στοχευμένη ιστορική αναδρομή. Εξετάζουμε πώς ο κλάδος πέρασε από τα πρώιμα συστήματα που βασίζονταν σε αυστηρούς κανόνες (rule-based), στα παραδοσιακά στατιστικά μοντέλα (statistical models), καταδεικνύοντας στην πράξη τους τεχνικούς περιορισμούς που οδήγησαν στην αναζήτηση νέων, πιο προηγμένων λύσεων.

Στη συνέχεια, δίνεται έμφαση στην ανατροπή που έφερε η έλευση της Βαθιάς Μάθησης (Deep Learning). Ιδιαίτερη έμφαση δίνεται στην επαναστατική αρχιτεκτονική των δικτύων Transformer και στον μηχανισμό αυτό-προσοχής (self-attention). Η συγκεκριμένη τεχνολογική καινοτομία επέτρεψε στα συστήματα να ξεφύγουν από τη μεμονωμένη ανάλυση λέξεων και να αποκτήσουν τη δυνατότητα να «αντιλαμβάνονται» τα ευρύτερα συμφραζόμενα (context) μιας ολόκληρης παραγράφου.

Η μελέτη αυτών των εννοιών κρίνεται αναγκαία, διότι οι αντίστοιχες αρχιτεκτονικές αποτελούν τον δομικό πυρήνα των εργαλείων που θα αξιοποιηθούν πειραματικά στα επόμενα στάδια της εργασίας. Κατανοώντας τη θεωρία πίσω από τους Transformers, γίνεται ξεκάθαρο πώς προηγμένα γλωσσικά μοντέλα, όπως το RoBERTa και το BART, καταφέρνουν να φέρουν εις πέρας απαιτητικές διεργασίες. Με αυτόν τον τρόπο, εξασφαλίζεται η ομαλή σύνδεση της καθαρής θεωρίας της Πληροφορικής με την πρακτική επίλυση προβλημάτων, όπως είναι η ακριβής ανίχνευση της δημοσιογραφικής ουδετερότητας και η δημιουργία αυτόματων, συνεκτικών περιλήψεων.

2.2 Ορισμός και Επίπεδα Γλωσσικής Ανάλυσης

Η Επεξεργασία Φυσικής Γλώσσας (Natural Language Processing - NLP) αποτελεί έναν από τους πιο απαιτητικούς κλάδους της Τεχνητής Νοημοσύνης, καθώς βρίσκεται στην τομή της Πληροφορικής, της Γλωσσολογίας και της Μηχανικής Μάθησης. Ο θεμελιώδης στόχος του πεδίου είναι η υπολογιστική αναπαράσταση και ανάλυση της ανθρώπινης επικοινωνίας. Σε αντίθεση με τις αυστηρά δομημένες γλώσσες προγραμματισμού, ο καθημερινός λόγος χαρακτηρίζεται από ασάφεια, διαρκώς εξελισσόμενη αργκό και πολυσημία. Σύμφωνα με τους Khurana et al. [4], το NLP επιχειρεί να γεφυρώσει αυτό ακριβώς το χάσμα: να μεταφράσει την αδόμητη ανθρώπινη έκφραση σε μαθηματικά μοντέλα που μπορούν να αποκωδικοποιηθούν από τις μηχανές.

Για να αντιμετωπιστεί αυτή η πολυπλοκότητα, η υπολογιστική γλωσσολογία δεν προσεγγίζει το κείμενο ως μια ενιαία, αδιαίρετη οντότητα. Όπως τεκμηριώνεται από τους Jurafsky & Martin [5], η διαδικασία της μηχανικής κατανόησης δομείται σε διακριτά, αλλά αυστηρά αλληλένδετα ιεραρχικά επίπεδα. Κάθε ένα από αυτά τα στάδια επιλύει προβλήματα διαφορετικής φύσης:

- **Μορφολογία (Morphology):** Αποτελεί το αρχικό θεμέλιο της ανάλυσης, εστιάζοντας στην εσωτερική δομή και τον σχηματισμό των λέξεων. Σε αυτό το επίπεδο, οι αλγόριθμοι διασπούν το λεξιλόγιο στις μικρότερες δυνατές σημασιολογικές μονάδες (τα μορφώματα), αναγνωρίζοντας ρίζες, προθήματα και καταλήξεις. Πρακτικά, η

μορφολογική επεξεργασία υλοποιείται μέσω δύο βασικών υπολογιστικών τεχνικών: της Θεματικής Αποκοπής (Stemming), όπου αφαιρούνται μηχανικά οι καταλήξεις για την ταχεία εύρεση του θέματος, και της Λημματοποίησης (Lemmatization), μιας σαφώς πιο εξελιγμένης μεθόδου που χρησιμοποιεί μορφολογικά λεξικά για να επαναφέρει κλιτούς τύπους στην αρχική τους μορφή (π.χ. αναγνωρίζοντας ότι ο τύπος «έτρεξα» ανάγεται στο λήμμα «τρέχω»).

- **Σύνταξη (Syntax):** Το αμέσως επόμενο βήμα μετατοπίζει το ενδιαφέρον από τις μεμονωμένες λέξεις στους γραμματικούς κανόνες που διέπουν τη δομή ολόκληρων προτάσεων. Εδώ, το σύστημα δεν εξετάζει το εννοιολογικό βάθος, αλλά την ορθότητα της τοποθέτησης των όρων και τις σχέσεις εξάρτησης μεταξύ τους (όπως υποκείμενο, ρήμα, αντικείμενο). Για την επίτευξη αυτού του σκοπού, επιστρατεύεται η Συντακτική Ανάλυση (Parsing), κατά την οποία ο αλγόριθμος δημιουργεί Συντακτικά Δέντρα (Syntax Trees). Αυτές οι ιεραρχικές δενδρικές δομές χαρτογραφούν αλγοριθμικά τον τρόπο με τον οποίο οι λέξεις συνδέονται για να παραγάγουν μια έγκυρη ροή λόγου.
- **Σημασιολογία (Semantics):** Στο πλαίσιο της σημασιολογίας η επεξεργασία υπεισέρχεται στην αποκωδικοποίηση του πραγματικού νοήματος των λέξεων και των φράσεων. Η κεντρική πρόκληση σε αυτό το στάδιο είναι η διαχείριση της λεξιλογικής πολυσημίας. Για παράδειγμα, η λέξη «τράπεζα» φέρει εντελώς διαφορετικό εννοιολογικό φορτίο ανάλογα με το αν αναφέρεται σε ένα χρηματοπιστωτικό ίδρυμα ή σε ένα έπιπλο. Προκειμένου να επιλύσουν τέτοιες ασάφειες, τα συστήματα ενσωματώνουν μεθοδολογίες όπως η Αποσαφήνιση Έννοιας της Λέξης (Word Sense Disambiguation). Η συγκεκριμένη λειτουργία επιτρέπει στον υπολογιστή να επιλέξει την ορθή ερμηνεία μελετώντας τους γειτονικούς όρους της πρότασης, ένα ερευνητικό πεδίο που γνωρίζει αλματώδη πρόοδο χάρη στις σύγχρονες αρχιτεκτονικές βαθιάς μάθησης [6].
- **Πραγματολογία και Ανάλυση Λόγου (Pragmatics & Discourse Analysis):** Πρόκειται για το υψηλότερο και πλέον απαιτητικό επίπεδο μηχανικής κατανόησης. Σε αυτό το πλαίσιο η έρευνα ξεπερνά τα όρια της αυστηρής κυριολεξίας και επιχειρεί να διαγνώσει την υποκείμενη πρόθεση του συντάκτη, συνυπολογίζοντας το ευρύτερο συγκείμενο (context) και την εξωγλωσσική πραγματικότητα. Εκτελούνται κρίσιμες διεργασίες, όπως η Επίλυση Συμπεραναφοράς (Coreference Resolution). Μέσω αυτής, το μοντέλο αντιλαμβάνεται σε ποια προηγούμενη οντότητα αναφέρεται μια αντωνυμία (π.χ. «αυτός», «εκείνη»), διατηρώντας έτσι τη συνοχή ολόκληρου του εγγράφου, ένα πρόβλημα που πλέον επιλύεται αποδοτικά με τη χρήση νευρωνικών δικτύων [7]. Η πραγματολογική ανάλυση είναι ζωτικής σημασίας για την ανίχνευση λεπτών υπολογιστικών αποχρώσεων, όπως ο σαρκασμός, το χιούμορ και ο μεταφορικός λόγος. Ως εκ τούτου, είναι σημαντική για εφαρμογές όπως η Ανάλυση Συναισθήματος (Sentiment Analysis), όπου το ζητούμενο δεν περιορίζεται στην καταγραφή των λέξεων, αλλά επεκτείνεται στην ακριβή αποτύπωση της στάσης που τηρεί ο αρθρογράφος απέναντι στα γεγονότα.

2.3 Ιστορική Εξέλιξη και Βασικοί Πυλώνες Εφαρμογών

Η ιστορική διαδρομή της Επεξεργασίας Φυσικής Γλώσσας (NLP) δεν συνιστά μια απλή, γραμμική τεχνολογική πρόοδο, αλλά χαρακτηρίζεται από ριζικές αναθεωρήσεις στον τρόπο με τον οποίο οι μηχανές προσεγγίζουν την ανθρώπινη επικοινωνία. Όπως αναλύεται από τους Khurana et al. [4], όπως και επιβεβαιώνεται από την μελέτη των Otter et al. [8], η εξέλιξη του κλάδου χαρτογραφείται σε τρεις διακριτές περιόδους. Η αφετηρία αυτής της πορείας τοποθετείται ιστορικά στη δεκαετία του 1950, όταν ο Alan Turing, μέσω του θεμελιώδους έργου του, έθεσε τα πρώτα θεωρητικά ερωτήματα σχετικά με την ικανότητα των υπολογιστικών συστημάτων να επιδεικνύουν ευφυή γλωσσική συμπεριφορά.

Αρχικά, το ερευνητικό τοπίο διαμορφώθηκε από την εποχή του Συμβολικού NLP (Symbolic NLP), η οποία διήρκεσε περίπου από τη δεκαετία του 1950 έως τα τέλη του 1980. Σε αυτή την πρώιμη φάση, η επιστημονική προσέγγιση ήταν αυστηρά βασισμένη σε κανόνες (rule-based). Γλωσσολόγοι και επιστήμονες της πληροφορικής συνεργάζονταν στενά με σκοπό να

κωδικοποιήσουν τη γραμματική, το συντακτικό και το λεξιλόγιο σε πολύπλοκα, χειροκίνητα συστήματα αποφάσεων της λογικής μορφής «if-then-else». Χαρακτηριστικό παράδειγμα αυτής της πρώιμης λογικής αποτέλεσε το πρόγραμμα ELIZA (1966) του MIT, το οποίο προσομοίωνε μια βασική μορφή ανθρώπινου διαλόγου αναγνωρίζοντας συγκεκριμένα μοτίβα λέξεων (pattern matching), θέτοντας τα θεμέλια για τα σύγχρονα συστήματα conversational AI [9]. Παρόλο που τα συγκεκριμένα συστήματα προσέφεραν το πλεονέκτημα της πλήρους ερμηνευσιμότητας, καθώς κάθε απόφαση του αλγορίθμου ήταν απολύτως ιχνηλάσιμη από τον προγραμματιστή, αποδείχθηκαν στην πράξη δυσκίνητα. Η αδυναμία τους να διαχειριστούν τη φυσική αμφισημία, τον σαρκασμό, την αργκό και τις αμέτρητες εξαιρέσεις που χαρακτηρίζουν τον καθημερινό λόγο, οδήγησε αναπόφευκτα σε τελματώδη σημεία (bottlenecks), καθιστώντας σαφή την ανάγκη για νέες μεθοδολογίες.

Η υπέρβαση των παραπάνω περιορισμών συντελέστηκε σταδιακά κατά τη δεκαετία του 1990, σηματοδοτώντας τη μετάβαση στην εποχή του Στατιστικού NLP (Statistical NLP). Καταλύτης για αυτή την ανατροπή υπήρξε η ραγδαία αύξηση της διαθέσιμης υπολογιστικής ισχύος, σε συνδυασμό με την εμφάνιση εκτενών, ψηφιοποιημένων σωμάτων κειμένων (corpora). Η ερευνητική εστίαση μετατοπίστηκε πλέον από τη χειροκίνητη κατασκευή άκαμπτων κανόνων στην αυτόματη εξαγωγή γλωσσικών προτύπων. Οι νέοι αλγόριθμοι υιοθέτησαν πιθανοθεωρητικές προσεγγίσεις, αξιοποιώντας στοχαστικά μοντέλα, όπως τα n-grams και τα Κρυφά Μαρκοβιανά Μοντέλα (Hidden Markov Models), προκειμένου να προβλέψουν την επόμενη λέξη μιας ακολουθίας ή να επιλύσουν συντακτικές ασάφειες. Σύμφωνα με τους Khurana et al. [4], η ενσωμάτωση αυτών των μαθηματικών μεθόδων προσέφερε πρωτόγνωρη ευελιξία, επιτρέποντας στα συστήματα να εξαγουν συμπεράσματα βασισμένα στη στατιστική συχνότητα των όρων, παρά σε προκαθορισμένες γραμματικές νόρμες.

Ωστόσο, η πραγματική επιστημονική επανάσταση, η οποία διαμόρφωσε το σημερινό τεχνολογικό τοπίο, επήλθε με την επικράτηση του Νευρωνικού NLP (Neural NLP). Όπως αναδεικνύεται από τους Otter et al. [8], η εισαγωγή της Βαθιάς Μάθησης (Deep Learning) κατήργησε οριστικά τα όρια των παραδοσιακών στατιστικών τεχνικών. Σημαντικός παράγοντας αυτής της μετάβασης ήταν η ανάπτυξη των πυκνών διανυσματικών αναπαραστάσεων (word embeddings), οι οποίες άλλαξαν ριζικά τον τρόπο αναπαράστασης του κειμένου [10]. Σε αντίθεση με τις προγενέστερες μεθόδους που αντιμετώπιζαν το λεξιλόγιο ως απομονωμένα, ανεξάρτητα σύμβολα, τα τεχνητά νευρωνικά δίκτυα άρχισαν να χαρτογραφούν τις λέξεις ως διανύσματα σε έναν πολυδιάστατο, συνεχή χώρο. Αυτή η ριζοσπαστική καινοτομία έδωσε στις μηχανές την ικανότητα να «αντιλαμβάνονται» τις βαθιές σημασιολογικές συσχετίσεις μεταξύ των εννοιών, εκτοξεύοντας την απόδοση των υπολογιστικών μοντέλων σε επίπεδα που συχνά ανταγωνίζονται την ανθρώπινη αντιληπτική ικανότητα.

Έχοντας διανύσει αυτή τη μακρά θεωρητική και τεχνολογική διαδρομή, το σύγχρονο τοπίο του NLP διακρίνεται πλέον για την πρακτική επίλυση σύνθετων προβλημάτων. Βασίζόμενοι στη μελέτη των Khurana et al. [4], εντοπίζουμε τρεις κυρίαρχους πυλώνες εφαρμογών, οι οποίοι βρίσκονται στο επίκεντρο του σύγχρονου ερευνητικού ενδιαφέροντος και συγκροτούν, παράλληλα, τον πειραματικό και μεθοδολογικό πυρήνα της παρούσας εργασίας:

1. **Εξαγωγή Πληροφοριών (Information Extraction):** Πρόκειται για την αυτοματοποιημένη διαδικασία εντοπισμού και ανάκτησης συγκεκριμένων, δομημένων δεδομένων μέσα από εκτενή, αδόμητα κείμενα. Μέσω προηγμένων τεχνικών, όπως η Αναγνώριση Οντοτήτων (Named Entity Recognition - NER), τα μοντέλα καθίστανται ικανά να απομονώνουν κρίσιμες αναφορές σε πρόσωπα, γεωγραφικές τοποθεσίες και οργανισμούς. Η λειτουργία αυτή είναι ζωτικής σημασίας για τη μετατροπή του αχανούς όγκου των ειδησεογραφικών άρθρων σε οργανωμένες βάσεις γνώσης, έτοιμες προς περαιτέρω στατιστική επεξεργασία.
2. **Αυτόματη Περίληψη Κειμένου (Text Summarization):** Σε μια εποχή που χαρακτηρίζεται από ραγδαία ψηφιακή υπερπληροφόρηση, η ικανότητα συμπίκνωσης εγγράφων αναδεικνύεται σε επιτακτική ανάγκη. Τα σύγχρονα συστήματα αναλαμβάνουν να παραγάγουν νέο, συνεκτικό λόγο διατηρώντας ακέραιο το αρχικό νόημα του

κειμένου-πηγής. Στα επόμενα κεφάλαια, αυτή η αλγοριθμική διεργασία θα μελετηθεί πρακτικά, εστιάζοντας στη δημιουργία ακριβών, αφαιρετικών συνόψεων από εκτενή δημοσιογραφικά ρεπορτάζ.

3. **Ανάλυση Συναισθήματος (Sentiment Analysis):** Ο τελευταίος μεθοδολογικός άξονας επικεντρώνεται στην αποκωδικοποίηση της υποκειμενικής στάσης που υιοθετεί ο εκάστοτε συντάκτης. Ταξινομώντας τη γλωσσική φόρτιση σε θετική, αρνητική ή ουδέτερη, τα μοντέλα Τεχνητής Νοημοσύνης παρέχουν ένα σημαντικό αναλυτικό εργαλείο. Στην προκειμένη έρευνα, η συγκεκριμένη τεχνολογία θα αξιοποιηθεί εκτενώς προκειμένου να ελεγχθεί ποσοτικά η αντικειμενικότητα και η δημοσιογραφική ουδετερότητα σε πραγματικά σύνολα δεδομένων.

2.4 Ανάλυση Συναισθήματος (Sentiment Analysis)

Η σύγχρονη ψηφιακή εποχή χαρακτηρίζεται από μια εκθετική αύξηση στην παραγωγή δεδομένων. Πλατφόρμες κοινωνικής δικτύωσης, ιστολόγια και ειδησεογραφικά δίκτυα λειτουργούν πλέον ως παγκόσμιοι δέκτες της κοινής γνώμης. Αυτή η διαρκής συσσώρευση αδόμητης πληροφορίας κατέστησε επιτακτική την ανάγκη για αυτοματοποιημένη επεξεργασία του υποκειμενικού λόγου, οδηγώντας στη ραγδαία ανάπτυξη του πεδίου της Ανάλυσης Συναισθήματος (Sentiment Analysis), ευρέως γνωστής και ως Εξόρυξης Γνώμης (Opinion Mining).

Σύμφωνα με την μελέτη των Wankhade et al. [11], το συγκεκριμένο ερευνητικό πεδίο επικεντρώνεται στην υπολογιστική ανίχνευση, εξαγωγή και ταξινόμηση των ανθρώπινων τοποθετήσεων απέναντι σε ποικίλες οντότητες, όπως προϊόντα, οργανισμούς ή κοινωνικοπολιτικά γεγονότα. Η αξία αυτής της διαδικασίας θεωρείται στρατηγικής σημασίας, καθώς επιτρέπει τη μετατροπή του χαώδους ψηφιακού αποτυπώματος των χρηστών σε αξιοποιήσιμη, ποσοτική γνώση, διευκολύνοντας τη λήψη αποφάσεων βάσει δεδομένων (data-driven decision making).

Ωστόσο, παρά τη φαινομενική απλότητα του ορισμού της, η μηχανική αποκωδικοποίηση του συναισθήματος αποτελεί ένα εξαιρετικά περίπλοκο εγχείρημα. Σύμφωνα με την ανάλυση των Nandwani & Verma [12], τα υπολογιστικά συστήματα καλούνται να διαχειριστούν εγγενείς γλωσσολογικές προκλήσεις. Φαινόμενα όπως η λεπτή ειρωνεία, ο σαρκασμός, οι διπλές αρνήσεις, καθώς και η απόλυτη εξάρτηση του νοήματος από το ευρύτερο συγκείμενο (context), συχνά αντιστρέφουν την πολικότητα μιας πρότασης. Η αποτελεσματική άρση αυτών των ασαφειών συνιστά το μεγαλύτερο εμπόδιο του κλάδου και τον κύριο κινητήριο μοχλό για τη συνεχή βελτίωση των αλγοριθμικών προσεγγίσεων.

Για την αντιμετώπιση αυτού του σύνθετου προβλήματος, η ερευνητική κοινότητα έχει αναπτύξει διάφορες μεθοδολογίες, οι οποίες παραδοσιακά κατηγοριοποιούνται σε τρεις διακριτούς άξονες:

- **Προσεγγίσεις Βασισμένες στο Λεξικό (Lexicon-based):** Αποτελούν την πλέον παραδοσιακή, αλλά εξαιρετικά αξιόπιστη μέθοδο, η οποία εδράζεται στη χρήση προκαθορισμένων γλωσσικών πόρων (sentiment lexicons). Σε αυτό το πλαίσιο, η τελική πολικότητα ενός εγγράφου υπολογίζεται αθροιστικά, βάσει του συναισθηματικού βάρους που φέρει η κάθε μεμονωμένη λέξη. Η προσέγγιση αυτή υλοποιείται είτε μέσω έτοιμων λεξικών (dictionary-based) είτε μέσω στατιστικών προτύπων που εξαγονται από σώματα κειμένων (corpus-based). Όπως καταδεικνύεται στην μελέτη του Nkongolo Wa Nkongolo [13], σύγχρονα εργαλεία αυτής της κατηγορίας, με εξέχον παράδειγμα το VADER (Valence Aware Dictionary and sEntiment Reasoner), έχουν εξελίξει την τεχνική, ενσωματώνοντας ευρετικούς κανόνες ικανούς να αναγνωρίζουν την ένταση του συναισθήματος με υψηλή ακρίβεια, ακόμα και σε ανεπίσημο ή αυστηρό ειδησεογραφικό λόγο.
- **Προσεγγίσεις Μηχανικής Μάθησης (Machine Learning):** Εδώ, η διαδικασία εξόρυξης γνώμης μετασχηματίζεται σε ένα αμιγώς στατιστικό πρόβλημα ταξινόμησης

(classification). Αλγόριθμοι επιβλεπόμενης μάθησης (supervised learning) εκπαιδεύονται πάνω σε εκτενή, ήδη επισημειωμένα σύνολα δεδομένων (labeled datasets), προκειμένου να μάθουν να αναγνωρίζουν κρυφά μοτίβα. Αντί για έτοιμα λεξικά, χρησιμοποιούνται τεχνικές εξαγωγής χαρακτηριστικών (όπως τα n-grams ή το TF-IDF) για να τροφοδοτήσουν κλασικά μαθηματικά μοντέλα, όπως οι Μηχανές Διανυσμάτων Υποστήριξης (Support Vector Machines - SVM) και ο Αφελής Ταξινομητής Bayes (Naive Bayes). Τα συστήματα αυτά διακρίνονται για την υψηλή προσαρμοστικότητά τους σε διαφορετικούς τομείς.

- **Υβριδικές Προσεγγίσεις (Hybrid):** Πρόκειται για προηγμένες, συνδυαστικές αρχιτεκτονικές που επιχειρούν να γεφυρώσουν τα πλεονεκτήματα των δύο προηγούμενων κατηγοριών. Όπως υπογραμμίζουν οι Jassim et al. [14], στόχος αυτών των μοντέλων είναι να συγκεράσουν τη ντετερμινιστική σταθερότητα και τη γλωσσολογική ακρίβεια των λεξικών κανόνων με την ευελιξία των αλγορίθμων στατιστικής μάθησης, μεγιστοποιώντας έτσι τη συνολική απόδοση και αντισταθμίζοντας τις μεμονωμένες αδυναμίες κάθε τεχνικής.

2.4.1 Συγκριτική Ανάλυση Παραδοσιακών Μεθοδολογιών

Εμβαθύνοντας στους άξονες που προαναφέρθηκαν, κρίνεται σκόπιμο να αναλυθούν τα πλεονεκτήματα και οι εγγενείς περιορισμοί των συμβατικών προσεγγίσεων. Όπως τεκμηριώνεται από τους Birjali et al. [15], αλλά και στη μελέτη των Van Atteveldt et al. [16], η κατανόηση αυτών των πρώιμων μεθοδολογιών αποτελεί απαραίτητο θεωρητικό βήμα για την ανάδειξη της αναγκαιότητας των σύγχρονων μοντέλων.

Ιστορικά, οι Λεξικολογικές Τεχνικές (Lexicon-based) αποτέλεσαν την πρώτη επιλογή στην εξόρυξη γνώμης. Το κύριο πλεονέκτημά τους έγκειται στην υπολογιστική τους απλότητα και την ταχύτητα εκτέλεσης, καθώς δεν προϋποθέτουν κοστοβόρες διαδικασίες εκπαίδευσης αλγορίθμων. Η μεθοδολογία αυτή βασίζεται στην αξιολόγηση του κειμένου μέσω στατικών πόρων, όπως το ευρέως διαδεδομένο SentiWordNet. Στο αντίστοιχο εργαλείο, κάθε λέξη βαθμολογείται εκ των προτέρων με συγκεκριμένα, αμετάβλητα σκορ θετικότητας, αρνητικότητας ή αντικειμενικότητας.

Ωστόσο, αυτή ακριβώς η στατική φύση των λεξικών συνεπάγεται συγκεκριμένες αδυναμίες. Σύμφωνα με τους Dervenis et al. [17], οι προσεγγίσεις αυτές καθίστανται εξαιρετικά ευάλωτες απέναντι στη γλωσσική αμφισημία. Αδυνατούν να αποκωδικοποιήσουν το ευρύτερο πλαίσιο (context) μέσα στο οποίο εντάσσεται ένας όρος, με αποτέλεσμα να υπολειτουργούν συστηματικά όταν καλούνται να διαχειριστούν σαρκασμό, μεταφορικό λόγο ή ιδιωτισμούς που αλλοιώνουν την αρχική πολικότητα της πρότασης.

Στον αντίποδα των λεξικολογικών προσεγγίσεων, η Παραδοσιακή Μηχανική Μάθηση (Traditional Machine Learning) επιχείρησε να αντιμετωπίσει αυτούς τους περιορισμούς μετατρέποντας την εξόρυξη συναισθήματος σε ένα πρόβλημα στατιστικής ταξινόμησης (classification). Κλασικοί αλγόριθμοι, όπως οι Μηχανές Διανυσμάτων Υποστήριξης (Support Vector Machines - SVM) και ο Αφελής Ταξινομητής Bayes (Naive Bayes), προσφέρουν υψηλότερη ακρίβεια, καθώς διαθέτουν την ικανότητα να «μαθαίνουν» και να προσαρμόζονται αναγνωρίζοντας μοτίβα μέσα από μεγάλα, επισημειωμένα σύνολα δεδομένων (labeled datasets).

Εντούτοις, η αποδοτικότητα αυτών των αλγορίθμων εξαρτάται απόλυτα από τη χειροκίνητη και χρονοβόρα διαδικασία εξαγωγής χαρακτηριστικών (feature engineering). Κλασικές τεχνικές μαθηματικής αναπαράστασης του κειμένου, όπως το Bag-of-Words (BoW) και το TF-IDF (Term Frequency-Inverse Document Frequency), αν και λειτουργικές, πάσχουν από ένα θεμελιώδες μειονέκτημα: αγνοούν πλήρως τη συντακτική δομή και τη σειριακή αλληλουχία των λέξεων μέσα στην πρόταση. Επιπρόσθετα, όπως υπογραμμίζουν οι Birjali et al. [15], τα μοντέλα αυτά χαρακτηρίζονται από αδυναμία γενίκευσης σε διαφορετικά θεματικά πεδία (domain adaptation). Όπως εξηγείται στην έρευνα των Singh et al. [18], η μεταφορά γνώσης (transfer learning) μεταξύ ετερογενών τομέων απαιτεί εξολοκλήρου νέα εκπαίδευση όταν ένα μοντέλο μεταφέρεται,

για παράδειγμα, από τον τομέα των κριτικών κινηματογράφου στην ανάλυση πολιτικών ειδήσεων.


Ως ενδιάμεση λύση στις παραπάνω αδυναμίες, η ερευνητική κοινότητα ανέπτυξε τα Υβριδικά Μοντέλα (Hybrid models) πρώτης γενιάς. Η συγκεκριμένη αρχιτεκτονική επιχειρεί να συγκεράσει την *a priori* γλωσσολογική γνώση των λεξικών με τη στατιστική προσαρμοστικότητα της μηχανικής μάθησης. Πρακτικά, το συναισθηματικό σκορ ενός εργαλείου (π.χ. VADER) μπορεί να τροφοδοτηθεί ως ένα επιπλέον, ισχυρό μαθηματικό χαρακτηριστικό στην είσοδο ενός ταξινομητή SVM. Αυτή η συνέργεια αποδείχθηκε εξαιρετικά ωφέλιμη στην ενίσχυση της τελικής ακρίβειας, προσφέροντας μια αξιόπιστη διέξοδο κυρίως σε ερευνητικά σενάρια όπου τα διαθέσιμα δεδομένα εκπαίδευσης είναι περιορισμένα.

2.4.2 Η Μετάβαση στις Αρχιτεκτονικές Βαθιάς Μάθησης (Deep Learning)

Παρόλο που οι παραδοσιακές τεχνικές έθεσαν τα στερεά θεμέλια για την ανάλυση συναισθήματος, η αύξηση των αδόμητων δεδομένων στο διαδίκτυο ανέδειξε ταχύτατα τους υπολογιστικούς τους περιορισμούς. Οι ερευνητές βρέθηκαν αντιμέτωποι με τεράστιους όγκους πληροφορίας, γεγονός που καθιστούσε τη χειροκίνητη εξαγωγή χαρακτηριστικών (feature extraction) μια απαγορευτική διαδικασία.

Η οριστική λύση σε αυτό το μεθοδολογικό αδιέξοδο δόθηκε μέσα από τη μετάβαση στις αρχιτεκτονικές της Βαθιάς Μάθησης (Deep Learning). Σύμφωνα με τους Minaee et al. [19], το πρώτο καθοριστικό βήμα για αυτή την αλλαγή παραδείγματος ήταν η υιοθέτηση των πυκνών διανυσματικών αναπαραστάσεων (Word Embeddings, όπως τα Word2Vec και GloVe). Σε αντίθεση με τα αραιά διανύσματα του TF-IDF, τα νέα μοντέλα άρχισαν να απεικονίζουν τις λέξεις σε έναν συνεχή μαθηματικό χώρο, επιτρέποντας στους αλγόριθμους να συλλαμβάνουν τις μεταξύ τους σημασιολογικές συσχετίσεις.

Πάνω σε αυτή τη βάση, αναπτύχθηκαν τα Αναδρομικά Νευρωνικά Δίκτυα (Recurrent Neural Networks - RNNs) και, κυρίως, η εξελιγμένη παραλλαγή τους, τα δίκτυα Μακράς Βραχυπρόθεσμης Μνήμης (Long Short-Term Memory - LSTM). Όπως αποτυπώνεται στην Εικόνα 2.1, η αλυσιδωτή δομή αυτών των δικτύων τους επιτρέπει να επεξεργάζονται το κείμενο ακολουθιακά, λέξη προς λέξη. Διαθέτοντας έναν εσωτερικό μηχανισμό «μνήμης», τα LSTM κατάφεραν να επιλύσουν το πρόβλημα της διατήρησης της πληροφορίας, αναγνωρίζοντας το ευρύτερο συντακτικό πλαίσιο (context) μιας πρότασης.



Εικόνα 2.1: Βασική αλυσιδωτή αρχιτεκτονική ενός αναδρομικού νευρωνικού δικτύου για την επεξεργασία ακολουθιών. Πηγή: Minaee et al. [19]

Παράλληλα με τα αναδρομικά δίκτυα, σημαντική ώθηση στην κατανόηση του φυσικού λόγου προσέφεραν και τα Συνελικτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks - CNNs). Αν

και παραδοσιακά συνδέονται με την όραση υπολογιστών, όπως επισημαίνουν οι Diwan & Tembhurne [20], στην ανάλυση κειμένου αποδείχθηκαν εξαιρετικά αποτελεσματικά στον ταχύτατο εντοπισμό τοπικών μορφολογικών μοτίβων (n-grams) και φράσεων που φέρουν ισχυρό συναισθηματικό βάρος.

Μια εξίσου κρίσιμη παράμετρος αυτής της τεχνολογικής ωρίμανσης, όπως αναλύεται στη μελέτη των Yadav & Vishwakarma [21], είναι η μετάβαση από τη γενικευμένη στην κατευθυνόμενη εξόρυξη γνώμης (Aspect-based Sentiment Analysis - ABSA). Όπως τονίζουν οι Chauhan et al. [22], τα σύγχρονα βαθιά δίκτυα δεν εγκλωβίζονται στον επιφανειακό χαρακτηρισμό ολόκληρου του εγγράφου ως «αρνητικού» (document-level). Αντιθέτως, απομονώνουν επιμέρους οντότητες (όπως η «οθόνη» ή η «μπαταρία» ενός υπολογιστή) και υπολογίζουν διακριτά σκορ πολικότητας για καθεμία από αυτές. Επιπλέον, διευκόλυναν τη λεπτομερέστερη (fine-grained) ταξινόμηση, ξεφεύγοντας από το άκαμπτο τρίπτυχο «θετικό-αρνητικό-ουδέτερο» και αναγνωρίζοντας ανεπαίσθητες διαβαθμίσεις έντασης. Αυτό με τη σειρά του άνοιξε τον δρόμο, σύμφωνα με τους Das & Singh [23], για την πρωτοποριακή Ανάλυση Πολυτροπικών Δεδομένων (Multimodal Sentiment Analysis), η οποία συνδυάζει ταυτόχρονα κείμενο, εικόνα και ήχο.


Ωστόσο, παρά την αδιαμφισβήτητη ακρίβεια των παραπάνω αρχιτεκτονικών, η σειριακή φύση επεξεργασίας των LSTMs εξακολουθούσε να αποτελεί σημαντικό υπολογιστικό εμπόδιο (bottleneck), αυξάνοντας δραματικά τον χρόνο εκπαίδευσης σε εκτενή σώματα κειμένων. Αυτός ακριβώς ο περιορισμός αποτέλεσε τον απόλυτο καταλύτη για την επόμενη μεγάλη επιστημονική τομή στο NLP.

2.4.3 Η Επανάσταση των Transformers και το Μοντέλο BERT

Αν και οι αρχιτεκτονικές βαθιάς μάθησης, όπως τα δίκτυα LSTM, προσέφεραν ισχυρές λύσεις στην ανάλυση κειμένου, η εφαρμογή τους σε πραγματικά, πολύπλοκα δεδομένα ανέδειξε σημαντικούς σημασιολογικούς περιορισμούς. Όπως αναλύουν οι Tabinda Kokab et al. [24], οι παλαιότερες τεχνικές εξαρτιόνταν σε μεγάλο βαθμό από στατικές μεθόδους διανυσματικής αναπαράστασης (word embeddings), όπως το Word2Vec και το GloVe. Το θεμελιώδες μειονέκτημα αυτών των προσεγγίσεων έγκειται στην αδυναμία τους να προσαρμοστούν στα εκάστοτε συμφραζόμενα: μια λέξη (π.χ. «τράπεζα») αντιστοιχούσε πάντα στο ίδιο ακριβώς διανυσματικό αποτύπωμα, ανεξάρτητα από το αν η πρόταση αναφερόταν σε χρηματοπιστωτικό ίδρυμα ή σε έπιπλο, οδηγώντας σε αναπόφευκτη απώλεια κρίσιμης νοηματικής πληροφορίας.

Την απόλυτη ανατροπή σε αυτό το τεχνολογικό αδιέξοδο έφερε η εισαγωγή του μηχανισμού Προσοχής (Self-Attention) και η θεμελίωση της αρχιτεκτονικής των Transformers από τους Vaswani et al. [25]. Σε πλήρη αντίθεση με τα αναδρομικά δίκτυα, που επεξεργάζονταν τη γλώσσα αυστηρά γραμμικά και σειριακά, η νέα αυτή δομή επέτρεψε στα μοντέλα να «βλέπουν» ολόκληρη την ακολουθία των λέξεων ταυτόχρονα. Αν και η αρχική αρχιτεκτονική διέθετε τόσο Κωδικοποιητή (Encoder) όσο και Αποκωδικοποιητή (Decoder), η πραγματική επανάσταση στην εξόρυξη συναισθήματος επήλθε με την αποκλειστική αξιοποίηση του πρώτου.

Αυτή η στρατηγική επιλογή οδήγησε στη δημιουργία του μοντέλου BERT (Bidirectional Encoder Representations from Transformers) από τους Devlin et al. [26]. Το BERT εισήγαγε την καινοτομία της πλήρους αμφίδρομης ανάγνωσης. Όπως αποτυπώνεται στην Εικόνα 2.2, η συγκεκριμένη προσέγγιση επιτρέπει στον αλγόριθμο να κατανοεί τη συντακτική και σημασιολογική δομή σε απρόσιτο μέχρι πρότινος βάθος, δημιουργώντας δυναμικές αναπαραστάσεις που μεταβάλλονται διαρκώς ανάλογα με το άμεσο λεκτικό περιβάλλον της κάθε φράσης.



Εικόνα 2.2: Συγκριτική απεικόνιση της αμφίδρομης αρχιτεκτονικής του BERT έναντι των μονόδρομων μοντέλων. Πηγή: Devlin et al. [26].

Η συγκεκριμένη τεχνολογική εξέλιξη αποδείχθηκε καθοριστική για την επεξεργασία δεδομένων προερχόμενων από τα μέσα κοινωνικής δικτύωσης, τα οποία χαρακτηρίζονται εγγενώς από υψηλά επίπεδα γλωσσικού θορύβου. Σύμφωνα με τους Sayeed et al. [27], τα συμβατικά συστήματα αποτύγχαναν συστηματικά να διαχειριστούν λέξεις που απουσίαζαν από το αρχικό λεξιλόγιο εκπαίδευσής τους (Out-of-Vocabulary – OOV), οδηγώντας σε κρίσιμα σφάλματα ταξινόμησης.

Αντιθέτως, αρχιτεκτονικές όπως το BERT αντιμετωπίζουν αυτό το πρόβλημα μέσω προηγμένων τεχνικών τεμαχισμού λέξεων (Subword Tokenization). Όπως τονίζεται από τους Mielke et al. [28], η χρήση αλγορίθμων όπως το WordPiece και το BPE (Byte-Pair Encoding) επιτρέπει στο μοντέλο, αντί να απορρίπτει μια άγνωστη ή ανορθόγραφη λέξη, να την αναλύει δυναμικά σε μικρότερα, γνωστά μορφολογικά υπο-μήματα (όπως ρίζες και καταλήξεις). Χάρη σε αυτόν τον καινοτόμο μηχανισμό, οι αρχιτεκτονικές τύπου Transformer επιδεικνύουν πρωτοφανή ανθεκτικότητα. Όπως απέδειξαν οι Pota et al. [29], κατορθώνουν να ερμηνεύσουν με εντυπωσιακή ακρίβεια την αργκό, τα τυπογραφικά λάθη ή τα ειρωνικά σχόλια, διασφαλίζοντας ότι ο συναισθηματικός προσδιορισμός παραμένει αξιόπιστος σε περιβάλλοντα όπου τα παλαιότερα μοντέλα κατέρρεαν πλήρως.

2.5 Αυτόματη Περίληψη Κειμένου (Automatic Text Summarization)

Στη σύγχρονη ψηφιακή πραγματικότητα, η αύξηση του αδόμητου κειμενικού περιεχομένου στον παγκόσμιο ιστό από ειδησεογραφικά άρθρα και επιστημονικές δημοσιεύσεις έως αναρτήσεις στα μέσα κοινωνικής δικτύωσης έχει οδηγήσει στο φαινόμενο της πληροφοριακής υπερφόρτωσης (information overload). Όπως επισημαίνουν οι El-Kassas et al. [30], η ανάγκη για ταχύτατη και αποδοτική ανάκτηση της ουσιαστικής γνώσης καθιστά τη χειροκίνητη σύνοψη εγγράφων πρακτικά αδύνατη, εξαιτίας του απαγορευτικού κόστους σε χρόνο και ανθρώπινους πόρους. Ως τεχνολογική διέξοδος σε αυτό το πρόβλημα αναδείχθηκε η Αυτόματη Περίληψη Κειμένου (Automatic Text Summarization - ATS), η οποία στοχεύει στην παραγωγή μιας περιεκτικής εκδοχής του αρχικού εγγράφου, διατηρώντας αναλλοίωτο τον σημασιολογικό του πυρήνα και ελαχιστοποιώντας τον υπερπληροφόρηση.

Είναι κρίσιμο να σημειωθεί ότι, σε αντίθεση με την Ανάλυση Συναισθήματος που προαναφέρθηκε, η οποία αποτελεί θεμελιωδώς ένα πρόβλημα στατιστικής ταξινόμησης (classification), η αυτόματη περίληψη συνιστά ένα εξαιρετικά πιο σύνθετο υπολογιστικό έργο. Απαιτεί όχι μόνο την επιφανειακή αναγνώριση λέξεων-κλειδιών, αλλά τη βαθιά κατανόηση του συγκεκριμένου και την ικανότητα νοηματικής συμπίκνωσης (compression).

Σύμφωνα με τους Khan et al. [31], τα συστήματα ATS διαφοροποιούνται σημαντικά ως προς την πολυπλοκότητά τους, με πρώτο βασικό άξονα διάκρισης τον αριθμό των πηγών εισόδου. Ενώ η σύνοψη ενός μεμονωμένου εγγράφου (Single-document summarization) αποτελεί μια σχετικά ελεγχόμενη διαδικασία, η ταυτόχρονη επεξεργασία πολλαπλών εγγράφων (Multi-document summarization) εισάγει σοβαρές αλγοριθμικές προκλήσεις. Στη δεύτερη περίπτωση,

το εκάστοτε μοντέλο καλείται να διαχειριστεί υψηλά επίπεδα αλληλεπικάλυψης πληροφοριών (redundancy) από διαφορετικές πηγές, να επιλύσει τυχόν χρονικές ή νοηματικές αντιφάσεις και να συνθέσει ένα τελικό κείμενο που διαθέτει λογική αλληλουχία, γεφυρώνοντας αρμονικά διαφορετικά συγγραφικά ύφη.


Ανεξαρτήτως του πλήθους των εγγράφων εισόδου, η κυρίαρχη βιβλιογραφική ταξινόμια διακρίνει τις προσεγγίσεις της αυτόματης περίληψης σε δύο θεμελιώδεις κατηγορίες, βάσει της μεθοδολογίας παραγωγής του τελικού κειμένου:

1. **Εξαγωγική Περίληψη (Extractive Summarization):** Η μεθοδολογία αυτή προσομοιάζει τη νοητική διαδικασία της «υπογράμμισης» των πιο καίριων σημείων. Ο εκάστοτε αλγόριθμος αναλύει το έγγραφο, υπολογίζει ένα σκορ σπουδαιότητας για κάθε πρόταση αξιοποιώντας συχνά στατιστικά, μορφολογικά ή γραφηματικά χαρακτηριστικά και επιλέγει τις πιο αντιπροσωπευτικές. Ακολουθώντας, τις συρράπτει γραμμικά (concatenate) για να συνθέσει το τελικό αποτέλεσμα. Το κύριο πλεονέκτημα αυτής της προσέγγισης είναι η διασφάλιση της συντακτικής και γραμματικής ορθότητας, καθώς χρησιμοποιούνται αυτούσια τμήματα του πρωτοτύπου. Εντούτοις, το βασικό της μειονέκτημα εντοπίζεται στη συχνή απουσία συνοχής (coherence), αφού οι επιλεγμένες προτάσεις αποκόπτονται από το αρχικό τους πλαίσιο και ενδέχεται να μη συνδέονται ομαλά μεταξύ τους.
2. **Αφαιρετική Περίληψη (Abstractive Summarization):** Αντιπροσωπεύει μια σαφώς πιο προηγμένη, αλλά και υπολογιστικά δαπανηρή διαδικασία, η οποία επιχειρεί να μιμηθεί τον ανθρώπινο τρόπο αποτίμησης της πληροφορίας. Το σύστημα ξεφεύγει από την απλή αντιγραφή: κατασκευάζει μια ενδιάμεση σημασιολογική αναπαράσταση και, μέσω αλγορίθμων Παραγωγής Φυσικής Γλώσσας (Natural Language Generation - NLG), συνθέτει εξολοκλήρου νέες προτάσεις. Η μέθοδος αυτή υιοθετεί νέο λεξιλόγιο και τεχνικές παράφρασης (paraphrasing). Αν και ιστορικά ήταν επιρρεπής σε σημασιολογικά σφάλματα, παράγει περιλήψεις με πιο συμπυκνωμένη δομή.

Τέλος, τα τελευταία χρόνια έχει κερδίσει έδαφος η ανάπτυξη Υβριδικών Μοντέλων (Hybrid). Οι συγκεκριμένες αρχιτεκτονικές επιχειρούν να γεφυρώσουν το χάσμα των δύο προαναφερθεισών τεχνικών. Συνδυάζουν την ασφαλή, στοχευμένη εξαγωγή κρίσιμων πληροφοριών (extractive) με την ικανότητα ομαλής αναδιατύπωσης (abstractive), αποσκοπώντας σε ένα τελικό κείμενο που εξισορροπεί τη νοηματική ακρίβεια με τη γλωσσική εκφραστικότητα.

2.5.1 Εξαγωγικές Μέθοδοι (Extractive Methods)

Η Εξαγωγική Περίληψη (Extractive Summarization) συνιστά την πλέον διαδεδομένη μεθοδολογία στα συστήματα αυτόματης σύνοψης, κυρίως χάρη στην υπολογιστική της αποδοτικότητα και την αμεσότητα της υλοποίησής της. Όπως αναλύουν οι Yadav et al. [32], η θεμελιώδης αρχή της συγκεκριμένης προσέγγισης δεν έγκειται στην παραγωγή νέου λόγου, αλλά στη στρατηγική επιλογή και συρραφή υφιστάμενων τμημάτων του κειμένου. Το σύστημα λειτουργεί ουσιαστικά ως ένα «έξυπνο» φίλτρο αξιολόγησης, το οποίο υπολογίζει την πληροφοριακή πυκνότητα κάθε πρότασης και αποφασίζει ποιες είναι απαραίτητες για τη συγκρότηση του τελικού αποτελέσματος.



Εικόνα 2.3: Τυπική αρχιτεκτονική και ροή εκτέλεσης ενός συστήματος εξαγωγικής περίληψης κειμένου.

Ο πυρήνας αυτής της διαδικασίας εντοπίζεται στον μηχανισμό Βαθμολόγησης Προτάσεων (Sentence Scoring). Ο αλγόριθμος αναθέτει ένα αριθμητικό σκορ βαρύτητας σε κάθε δομική μονάδα του κειμένου και προκρίνει τις N κορυφαίες. Οι τεχνικές που επιστρατεύονται για αυτόν τον σκοπό ταξινομούνται σε διακριτές κατηγορίες:

1. **Στατιστικές Μέθοδοι (Statistical Methods):** Η κλασικότερη εκπρόσωπος αυτής της κατηγορίας είναι η αλγοριθμική τεχνική TF-IDF (Term Frequency - Inverse Document Frequency). Η σημαντικότητα ενός όρου t σε ένα έγγραφο d , το οποίο ανήκει σε ένα ευρύτερο σώμα κειμένων D , υπολογίζεται μαθηματικά μέσω της εξής εξίσωσης:

$$TF - IDF(t, d, D) = TF(t, d) \times \log\left(\frac{N}{|\{d \in D : t \in d\}|}\right) \quad (2.1)$$

Όπου N αντιπροσωπεύει το συνολικό πλήθος των εγγράφων. Μέσω αυτού του τύπου, ο αλγόριθμος προτιμάει λέξεις που εμφανίζονται με υψηλή συχνότητα στο υπό εξέταση κείμενο αλλά παραμένουν σπάνιες στα υπόλοιπα, αναδεικνύοντάς τες ως ισχυρούς θεματικούς δείκτες.

2. **Μέθοδοι Γράφων (Graph-based Methods):** Εμπνευσμένες από τη θεωρία δικτύων, οι μέθοδοι αυτές μοντελοποιούν το έγγραφο ως έναν κατευθυνόμενο ή μη κατευθυνόμενο γράφο. Το πλέον ιστορικό και ευρέως χρησιμοποιούμενο μοντέλο είναι το TextRank, το οποίο εισήχθη από τους Mihalcea & Tarau [33], αντλώντας έμπνευση από τη λογική του αλγορίθμου PageRank της Google. Σε αυτή την αρχιτεκτονική, οι προτάσεις αντιμετωπίζονται ως κόμβοι και οι μεταξύ τους σημασιολογικές ομοιότητες ως ακμές. Μια πρόταση θεωρείται βαρύνουσας σημασίας, λαμβάνοντας υψηλότερο σκορ, αν συνδέεται στενά με πολλές άλλες, λειτουργώντας έτσι ως κεντρικός κόμβος (hub) πληροφορίας μέσα στο έγγραφο.

3. **Μέθοδοι Βασισμένες σε Συστάδες (Clustering-based Methods):** Ένα από τα σημαντικότερα μειονεκτήματα των αμιγώς στατιστικών προσεγγίσεων είναι η πιθανότητα επιλογής πολλαπλών προτάσεων με πανομοιότυπο νόημα, μειώνοντας την αποδοτικότητα της περίληψης. Προκειμένου να μετριάσει το φαινόμενο της πληροφοριακής επικάλυψης (redundancy), οι συγκεκριμένοι αλγόριθμοι, όπως ο K-Means, προβάλλουν τις προτάσεις σε έναν πολυδιάστατο διανυσματικό χώρο και τις ομαδοποιούν σε διακριτές νοηματικές ενότητες (clusters). Ακολουθώντας, το σύστημα εξαγεί την πιο αντιπροσωπευτική πρόταση από κάθε ομάδα (συνήθως το κέντρο βάρους - centroid). Αυτή η μεθοδολογία διασφαλίζει ότι η τελική περίληψη καλύπτει πολύπλευρα το θεματικό φάσμα του εγγράφου, προάγοντας την πληροφοριακή ποικιλομορφία (diversity).
4. **Μηχανική και Βαθιά Μάθηση (Machine & Deep Learning):** Ενώ οι παραδοσιακές τεχνικές στηρίζονταν σε χειροκίνητα ορισμένα χαρακτηριστικά (hand-crafted features), όπως η θέση μιας πρότασης στην παράγραφο ή το μήκος της, η έλευση των νευρωνικών δικτύων αναδιαμόρφωσε πλήρως το τοπίο. Σε αυτό το σύγχρονο πλαίσιο, η εξαγωγική περίληψη μοντελοποιείται αυστηρά ως ένα πρόβλημα δυαδικής ταξινόμησης ακολουθιών (binary sequence classification). Κάθε δομική μονάδα λαμβάνει την ετικέτα "1" (ένταξη στην περίληψη) ή "0" (απόρριψη). Αρχιτεκτονικές όπως τα Συνελικτικά (CNNs) και τα Αναδρομικά Νευρωνικά Δίκτυα (RNNs) εκπαιδεύονται σε εκτενή σώματα δεδομένων προκειμένου να εξαγουν αυτόματα κρυφά σημασιολογικά μοτίβα. Συνθέτοντας πυκνές διανυσματικές αναπαραστάσεις, τα μοντέλα αυτά υπερβαίνουν τους περιορισμούς των απλών ευρετικών μεθόδων, καθώς συνυπολογίζουν το ευρύτερο συντακτικό **συγκείμενο (context)** πριν λάβουν την τελική απόφαση εξαγωγής.


2.5.2 Αφαιρετικές Μέθοδοι (Abstractive Methods)

Στον αντίποδα των εξαγωγικών προσεγγίσεων, οι οποίες περιορίζονται σε μια μηχανιστική αναδιάταξη υφιστάμενων φράσεων, η Αφαιρετική Περίληψη (Abstractive Summarization) φιλοδοξεί να προσομοιώσει τη συνθετική και δημιουργική ικανότητα του ανθρώπινου νου. Κεντρική επιδίωξη της συγκεκριμένης μεθοδολογίας είναι η παραγωγή ενός εντελώς πρωτότυπου κειμένου, το οποίο αποδίδει το νοηματικό απόσταγμα της αρχικής πηγής με φυσικότητα και δομική συνοχή, αξιοποιώντας λεξιλόγιο ή συντακτικές δομές που ενδέχεται να απουσιάζουν από το έγγραφο εισόδου (παράφραση - paraphrasing).

Ιστορικά, η μετάβαση σε αυτό το ανώτερο επίπεδο γλωσσικής επεξεργασίας επιτεύχθηκε μέσω της υιοθέτησης αρχιτεκτονικών Βαθιάς Μάθησης. Σύμφωνα με τη μελέτη των Rush et al. [34], η αφαιρετική παραγωγή κειμένου μοντελοποιήθηκε επιτυχώς ως ένα πρόβλημα «μετάφρασης» (translation problem) από ένα εκτενές έγγραφο σε μια πιο συμπυκνωμένη μορφή, κάνοντας χρήση των δικτύων Sequence-to-Sequence (Seq2Seq).

Η συγκεκριμένη αρχιτεκτονική βασίζεται στη συνεργασία δύο διακριτών νευρωνικών υποσυστημάτων:

1. Τον **Κωδικοποιητή (Encoder)**, ο οποίος αναλύει σειριακά το αρχικό κείμενο εισόδου και το συμπιέζει σε μια πυκνή, πολυδιάστατη διανυσματική αναπαράσταση, γνωστή ως Διάνυσμα Συγκειμένου (Context Vector).
2. Τον **Αποκωδικοποιητή (Decoder)**, ο οποίος παραλαμβάνει αυτή τη σημασιολογική αναπαράσταση και αναλαμβάνει να δημιουργήσει την τελική περίληψη λέξη προς λέξη, με τρόπο αυτοπαλινδρομικό (autoregressive).



Εικόνα 2.4: Αρχιτεκτονική Κωδικοποιητή-Αποκωδικοποιητή (Encoder-Decoder) με ενσωμάτωση Μηχανισμού Προσοχής για την παραγωγή αφαιρετικής περίληψης.

Προκειμένου να αποφευχθεί η απώλεια κρίσιμων πληροφοριών κατά το στάδιο της συμπίεσης, ειδικά σε μεγάλα κείμενα, τα μοντέλα αυτά ενισχύθηκαν με τον Μηχανισμό Προσοχής (Attention Mechanism). Η συγκεκριμένη τεχνική επιτρέπει στον αποκωδικοποιητή να εστιάζει δυναμικά («να δίνει προσοχή») στα πιο καίρια τμήματα του αρχικού εγγράφου κατά την παραγωγή κάθε νέας λέξης, βελτιώνοντας ραγδαία τη ροή και την ακρίβεια του αποτελέσματος.

Παρά την καινοτομία των αρχικών αναδρομικών μοντέλων, η πραγματική αναβάθμιση στην αφαιρετική σύνοψη συντελέστηκε με την καθολική επικράτηση της αρχιτεκτονικής των Transformers. Ξεπερνώντας τους εγγενείς περιορισμούς της σειριακής επεξεργασίας, τα σύγχρονα δίκτυα αξιοποιούν τον μηχανισμό αυτο-προσοχής (self-attention) προκειμένου να χαρτογραφήσουν μακροπρόθεσμες συντακτικές εξαρτήσεις με πρωτοφανή παραλληλισμό και υπολογιστική ταχύτητα.

Ορόσημο σε αυτή την τεχνολογική εξέλιξη αποτελεί το μοντέλο BART (Bidirectional and Auto-Regressive Transformers), το οποίο αναπτύχθηκε από τους Lewis et al. [35]. Η συγκεκριμένη αρχιτεκτονική λειτουργεί ως ένας προηγμένος απαλοιφωτής θορύβου (denoising autoencoder). Η καινοτομία του έγκειται στο γεγονός ότι «παντρεύει» δύο κορυφαίες προσεγγίσεις: διαθέτει έναν αμφίδρομο κωδικοποιητή, παρόμοιο με αυτόν του BERT, για την εις βάθος σημασιολογική κατανόηση του κειμένου εισόδου, και έναν αυτοπαλινδρομικό αποκωδικοποιητή, αντίστοιχο του GPT, για την παραγωγή του νέου λόγου.


Αυτή η αυστηρά δομημένη, υβριδική φύση καθιστά το BART εξαιρετικά αποδοτικό σε εργασίες Παραγωγής Φυσικής Γλώσσας (NLG). Αντί να αναδιατάσσει στείρα τις υπάρχουσες πληροφορίες, το μοντέλο αφομοιώνει το αρχικό εννοιολογικό πλαίσιο και συνθέτει μια ρέουσα, γραμματικά άρτια και περιεκτική περίληψη, κατορθώνοντας να συγκεράσει την υπολογιστική ακρίβεια με τη γλωσσική φυσικότητα.

2.6 Αναγνώριση Οντοτήτων (Named Entity Recognition - NER)

Η Αναγνώριση Ονοματισμένων Οντοτήτων (Named Entity Recognition - NER) συνιστά έναν από τους θεμέλιους λίθους της Εξαγωγής Πληροφορίας (Information Extraction), λειτουργώντας ως συνδετικός κρίκος μεταξύ των αδόμητων κειμενικών δεδομένων και της δομημένης, μηχανικά αναγνώσιμης γνώσης. Σύμφωνα με τους Li et al. [36], ως πρωταρχικός στόχος της διαδικασίας ορίζεται ο εντοπισμός και η σημασιολογική ταξινόμηση των «άκαμπτων προσδιοριστών» (rigid designators) σε προκαθορισμένες κατηγορίες. Οι κατηγορίες αυτές περιλαμβάνουν, κατά κανόνα, κύρια ονόματα προσώπων (PER), οργανισμούς (ORG), γεωγραφικές τοποθεσίες (LOC), καθώς και διάφορες χρονικές ή αριθμητικές εκφράσεις.

Η σπουδαιότητα του συστήματος NER υπερβαίνει τα στενά όρια της απλής ανάκτησης δεδομένων. Αποτελεί κρίσιμο προαπαιτούμενο (prerequisite) για την εύρυθμη λειτουργία σύνθετων αρχιτεκτονικών Επεξεργασίας Φυσικής Γλώσσας. Συστήματα υψηλής πολυπλοκότητας, όπως η Μηχανική Μετάφραση, η Αυτόματη Περίληψη και τα Συστήματα Ερωταποκρίσεων (Question Answering), βασίζονται στην ακριβή αναγνώριση αυτών των οντοτήτων προκειμένου να αποκωδικοποιήσουν το εννοιολογικό πλαίσιο και να εξάγουν ορθά συμπεράσματα [36].

Σε αλγοριθμικό επίπεδο, το NER δεν αντιμετωπίζεται απλώς ως μια διαδικασία αναζήτησης λέξεων-κλειδιών, αλλά μοντελοποιείται αυστηρά ως ένα πρόβλημα Επισήμανσης Ακολουθιών (Sequence Labeling). Για να μπορέσει ένα υπολογιστικό σύστημα να αναγνωρίσει τα ακριβή όρια (boundaries) και τον τύπο μιας οντότητας μέσα σε συνεχή λόγο, επιστρατεύονται τυποποιημένα σχήματα κωδικοποίησης, με το πλέον επικρατέστερο να είναι το BIO Tagging (Begin, Inside, Outside). Στη συγκεκριμένη λογική, η ετικέτα "B" υποδηλώνει την αρχή μιας οντότητας, η ετικέτα "I" την απρόσκοπτη συνέχειά της (για οντότητες που απαρτίζονται από πολλαπλές λέξεις), ενώ η ετικέτα "O" (Outside) ανατίθεται σε όλα τα υπόλοιπα συντακτικά στοιχεία που δεν ανήκουν σε καμία κατηγορία ενδιαφέροντος.



Εικόνα 2.5: Παράδειγμα επισήμανσης ακολουθιών μέσω του σχήματος BIO για την αναγνώριση προσώπων και οργανισμών

Ιστορικά, η μεθοδολογική προσέγγιση για την επίλυση του προβλήματος της Αναγνώρισης Οντοτήτων ακολούθησε μια σταδιακή εξελικτική πορεία, η οποία αντικατοπτρίζει την ευρύτερη πρόοδο στον τομέα της Τεχνητής Νοημοσύνης. Οι πρώιμες προσπάθειες βασίστηκαν σε Συστήματα Κανόνων (Rule-based Systems), τα οποία αξιοποιούσαν πολύπλοκες κανονικές εκφράσεις (regular expressions) και χειροκίνητα κατασκευασμένα λεξικά. Αν και προσέφεραν υψηλή ακρίβεια σε πολύ συγκεκριμένους τομείς, υστερούσαν σε ευελιξία και γενίκευση.

Στη συνέχεια, η σκυτάλη πέρασε στην Παραδοσιακή Μηχανική Μάθηση (Feature-based Supervised Learning), με αλγόριθμους όπως τα Κρυφά Μαρκοβιανά Μοντέλα (HMM) και τα Υπό Συνθήκη Τυχαία Πεδία (CRF). Τα συστήματα αυτά μάθαιναν από επισημειωμένα δεδομένα, ωστόσο η απόδοσή τους εξαρτιόταν απόλυτα από τη κατασκευή χαρακτηριστικών (feature engineering) από γλωσσολόγους.

Σήμερα, το ερευνητικό τοπίο κυριαρχείται από τις αρχιτεκτονικές Βαθιάς Μάθησης (Deep Learning). Σύμφωνα με τους Li et al. [36], η υπεροχή των νευρωνικών δικτύων στο NER έγκειται στην ικανότητά τους να ανακαλύπτουν αυτόματα τις βέλτιστες αναπαραστάσεις μέσα από τα δεδομένα. Αξιοποιώντας μη γραμμικούς μετασχηματισμούς, εξαλείφουν πλήρως την ανάγκη για χειροκίνητη παρέμβαση, προσφέροντας end-to-end (από άκρο σε άκρο) εκπαίδευση.

Η αρχιτεκτονική των σύγχρονων νευρωνικών συστημάτων NER, ανεξαρτήτως του συγκεκριμένου αλγορίθμου που χρησιμοποιείται, αναλύεται σε τρία δομικά επίπεδα επεξεργασίας, τα οποία θα αναλυθούν στις επόμενες υποενότητες:

1. **Κατανεμημένες Αναπαραστάσεις Εισόδου (Distributed Representations):** Ο μηχανισμός μετατροπής των διακριτών λέξεων και χαρακτήρων σε συνεχή, πυκνά διανύσματα (embeddings), τα οποία κωδικοποιούν τη μορφολογική και σημασιολογική πληροφορία.

2. **Κωδικοποιητής Συγκειμένου (Context Encoder):** Η χρήση εξελιγμένων δικτύων (όπως BiLSTM ή Transformers) για την εξόρυξη συντακτικών εξαρτήσεων και την πλήρη κατανόηση του πλαισίου της πρότασης.
3. **Αποκωδικοποιητής Ετικετών (Tag Decoder):** Το τελικό επίπεδο πρόβλεψης, το οποίο αναλαμβάνει να αναθέσει την τελική ετικέτα (π.χ. μέσω του σχήματος BIO) σε κάθε λέξη, συνυπολογίζοντας τις πιθανότητες μετάβασης από την προηγούμενη κατάσταση.

2.6.1 Κατανεμημένες Αναπαραστάσεις Εισόδου (Distributed Representations for Input)

Η θεμελιώδης καινοτομία των συστημάτων Βαθιάς Μάθησης, σε σύγκριση με τις παραδοσιακές προσεγγίσεις Επεξεργασίας Φυσικής Γλώσσας, εντοπίζεται στον τρόπο κωδικοποίησης της γλωσσικής πληροφορίας. Όπως επισημαίνουν οι Li et al. [36], τα σύγχρονα μοντέλα NER εγκαταλείπουν τη συμβατική διαχείριση των λέξεων ως απομονωμένων, διακριτών συμβόλων, μια πρακτική που στηριζόταν συχνά στη μονοδιάστατη κωδικοποίηση (one-hot encoding) και έπασχε από το πρόβλημα της αραιότητας δεδομένων (data sparsity). Αντιθέτως, υιοθετούν τη μετατροπή τους σε συνεχή, πυκνά διανύσματα (dense embeddings) πραγματικών αριθμών. Στο στάδιο αυτό, το σύστημα επιχειρεί να συλλάβει τόσο τη σημασιολογία όσο και τη συντακτική δομή του κειμένου, συνδυάζοντας πολλαπλά επίπεδα πληροφορίας:

1. **Διανύσματα Επιπέδου Λέξης (Word-level Embeddings):** Πρόκειται για την πλέον διαδεδομένη μορφή αναπαράστασης, όπου κάθε λέξη αντιστοιχίζεται σε ένα μοναδικό σημείο εντός ενός πολυδιάστατου διανυσματικού χώρου. Η επανάσταση σε αυτόν τον τομέα συντελέστηκε με αρχιτεκτονικές όπως το Word2Vec, το οποίο εισήχθη από τους Mikolov et al. [37]. Βασική παραδοχή του Word2Vec (και ειδικότερα της αρχιτεκτονικής Skip-Gram) είναι ότι λέξεις που εμφανίζονται σε παρόμοια συμφραζόμενα τείνουν να μοιράζονται παραπλήσια σημασία. Μαθηματικά, ο αλγόριθμος εκπαιδεύεται ώστε να μεγιστοποιεί τη μέση λογαριθμική πιθανότητα πρόβλεψης των γειτονικών λέξεων (context words) δεδομένης μιας κεντρικής λέξης w_t :

$$\frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log P(w_{t+j} | w_t) \quad (2.2)$$


Όπου T αντιπροσωπεύει το συνολικό μέγεθος του σώματος κειμένων (corpus) και c την ακτίνα του παραθύρου των γειτονικών λέξεων. Μέσω αυτής της βελτιστοποίησης, το μοντέλο μαθαίνει γεωμετρικά ότι η λέξη «γιατρός» βρίσκεται διανυσματικά πιο κοντά στο «νοσοκομείο» παρά στο «αυτοκίνητο».

Το Πρόβλημα της Πολυσημίας και τα Συγκειμενικά Διανύσματα (Contextualized Embeddings): Παρά την τεράστια επιτυχία τους, παραδοσιακά μοντέλα όπως τα Word2Vec, GloVe και FastText παράγουν στατικές (static) αναπαραστάσεις. Αυτό πρακτικά σημαίνει ότι μια πολυσήμαντη λέξη (π.χ. «τράπεζα» ως οικονομικό ίδρυμα ή ως ιατρική μονάδα αίματος) λαμβάνει ακριβώς το ίδιο διάνυσμα, ανεξαρτήτως της πρότασης στην οποία ανήκει. Για την εξάλειψη αυτής της αδυναμίας, η σύγχρονη έρευνα στράφηκε στις συγκειμενικές (context-aware) αναπαραστάσεις. Εξελιγμένες αρχιτεκτονικές, όπως το μοντέλο BERT, παράγουν δυναμικά διανύσματα τα οποία μεταβάλλονται αλγοριθμικά ανάλογα με τα περιφερειακά συντακτικά στοιχεία, εξασφαλίζοντας απόλυτη σημασιολογική ακρίβεια πριν τα δεδομένα τροφοδοτηθούν στα βαθύτερα στρώματα του δικτύου.

2. **Διανύσματα Επιπέδου Χαρακτήρα (Character-level Embeddings):** Παρά την εκφραστικότητά τους, οι αναπαραστάσεις σε επίπεδο λέξης παρουσιάζουν εγγενείς αδυναμίες, με κυριότερη την αδυναμία διαχείρισης όρων που απουσιάζουν από το λεξιλόγιο εκπαίδευσης (Out-of-Vocabulary - OOV). Επιπλέον, αγνοούν πλήρως την εσωτερική μορφολογική δομή των λέξεων. Προκειμένου να καλυφθεί αυτό το κενό, η

ερευνητική κοινότητα, με πρωτοπόρους τους Ma & Hovy [38], εισήγαγε τη δυναμική εξαγωγή χαρακτηριστικών σε επίπεδο χαρακτήρων. Η λέξη τεμαχίζεται στα συστατικά της γράμματα και τροφοδοτείται συνήθως σε Συνελικτικά Νευρωνικά Δίκτυα (CNNs) ή Αμφίδρομα LSTMs. Η συγκεκριμένη προσέγγιση είναι ζωτικής σημασίας για τον εντοπισμό οντοτήτων βάσει καταλήξεων, προθημάτων ή ριζών (π.χ. η αναγνώριση μιας φαρμακευτικής ουσίας από την κατάληξη "-ίνη" ή "-όλη"). Μέσω αυτής της μεθόδου, το δίκτυο αποκτά την ικανότητα να "μαντεύει" σωστά την ετικέτα ακόμα και για άγνωστες, νεολογικές ή ανορθόγραφες λέξεις.

3. **Υβριδικές Αναπαραστάσεις (Hybrid Features):** Η βέλτιστη πρακτική στις υπερσύγχρονες αρχιτεκτονικές NER δεν επαφίεται σε μία μόνο πηγή γνώσης. Αντιθέτως, τα προαναφερθέντα διανύσματα συγχωνεύονται μέσω της μαθηματικής πράξης της συνένωσης (concatenation, η οποία συμβολίζεται ως $\oplus$). Στο τελικό, πολυδιάστατο διάνυσμα ενσωματώνονται συχνά και πρόσθετα μεταδεδομένα, όπως ετικέτες μέρους του λόγου (POS tags) ή ορθογραφικά χαρακτηριστικά (π.χ. Boolean τιμές για το αν η λέξη ξεκινά με κεφαλαίο γράμμα, γεγονός που αποτελεί ισχυρό στατιστικό δείκτη για τα κύρια ονόματα). Το παραγόμενο αποτέλεσμα είναι μια πυκνή και πληροφοριακά πλούσια αναπαράσταση, έτοιμη να τροφοδοτηθεί στο επόμενο δομικό επίπεδο του συστήματος.



Εικόνα 2.6: Διαδικασία εξαγωγής και συνένωσης υβριδικών χαρακτηριστικών (λέξης, χαρακτήρων και POS) για τη δημιουργία της τελικής κατανεμημένης αναπαράστασης.

2.6.2 Αρχιτεκτονικές Κωδικοποίησης Συγκειμένου (Context Encoder Architectures)

Αμέσως μετά τη μετατροπή των διακριτών λεξιλογικών μονάδων σε υβριδικές διανυσματικές αναπαραστάσεις, η ροή της πληροφορίας εισέρχεται στο στάδιο της κωδικοποίησης του συγκειμένου (context encoding). Σύμφωνα με την ταξινόμηση που προτείνουν οι Li et al. [36], ο πρωταρχικός ρόλος αυτού του νευρωνικού υποσυστήματος είναι να υπερβεί τη μεμονωμένη σημασία κάθε λέξης και να συλλάβει τις πολύπλοκες, μη γραμμικές συντακτικές εξαρτήσεις που αναπτύσσονται μέσα σε μια πρόταση. Ουσιαστικά, μετασχηματίζει τα αρχικά στατικά

embeddings σε δυναμικές αναπαραστάσεις, οι οποίες ενσωματώνουν πλέον πληροφορία από το ευρύτερο γλωσσικό περιβάλλον.

Στη σύγχρονη ερευνητική βιβλιογραφία, οι αρχιτεκτονικές που έχουν επικρατήσει για την επιτυχή εκτέλεση αυτού του έργου διακρίνονται, ιστορικά και λειτουργικά, σε δύο κυρίαρχες οικογένειες:


1. **Αναδρομικά Νευρωνικά Δίκτυα (Recurrent Neural Networks - RNN):** Επί σειρά ετών, η βέλτιστη πρακτική (gold standard) για την επεξεργασία σειριακών δεδομένων, όπως το κείμενο, ήταν η χρήση δικτύων LSTM (Long Short-Term Memory). Η συγκεκριμένη παραλλαγή, η οποία θεμελιώθηκε ιστορικά από τους Hochreiter & Schmidhuber [39], σχεδιάστηκε αλγοριθμικά με έναν ειδικό μηχανισμό πυλών (gating mechanism). Ο μηχανισμός αυτός έλυσε οριστικά το πρόβλημα της «εξάλειψης της κλίσης» (vanishing gradient problem) που περιόριζε τα απλά RNNs, επιτρέποντας στο δίκτυο να διατηρεί κρίσιμες πληροφορίες στη μνήμη του για πολύ μεγαλύτερα χρονικά διαστήματα (long-term dependencies).

Ειδικότερα στο πεδίο της Αναγνώρισης Οντοτήτων, η συμβατική, μονόδρομη ανάγνωση ενός κειμένου (από αριστερά προς τα δεξιά) αποδείχθηκε εγγενώς ανεπαρκής. Σε πολλές περιπτώσεις, η σημασιολογική ταυτότητα μιας λέξης εξαρτάται άμεσα από τα συντακτικά στοιχεία που έπονται αυτής (μελλοντικό συγκείμενο). Για την αντιμετώπιση αυτού του περιορισμού, καθιερώθηκε ευρέως η αρχιτεκτονική των Αμφίδρομων LSTMs (Bidirectional LSTMs - BiLSTM). Όπως υποδηλώνει η ονομασία του, το BiLSTM απαρτίζεται από δύο ανεξάρτητα υποδίκτυα: το πρώτο αναλύει την ακολουθία εισόδου ορθόδρομα (forward), ενώ το δεύτερο την επεξεργάζεται ανάδρομα (backward), από το τέλος προς την αρχή.

Μαθηματικά, για κάθε χρονικό βήμα (λέξη) t , το δίκτυο υπολογίζει μια ορθόδρομη κρυφή κατάσταση $\vec{h}_t$ και μια ανάδρομη $\overleftarrow{h}_t$. Η τελική, εμπλουτισμένη κρυφή κατάσταση h_t προκύπτει από τη συνένωση (concatenation) των δύο αυτών διανυσμάτων:

$$h_t = [\vec{h}_t \oplus \overleftarrow{h}_t] \quad (2.3)$$

Συνενώνοντας τις εξόδους τους, το μοντέλο αποκτά πλήρη εποπτεία του τι προηγείται και τι έπεται κάθε λεξιλογικής μονάδας. Αυτή η σφαιρική αντίληψη αποτελεί θεμελιώδη προϋπόθεση για την άρση της αμφισημίας, επιτρέποντας στο σύστημα να διακρίνει, για παράδειγμα, αν η λέξη "Washington" αναφέρεται στο ιστορικό πρόσωπο ή στη γεωγραφική τοποθεσία, βάσει της δομής ολόκληρης της πρότασης.



Εικόνα 2.7: Αρχιτεκτονική Αμφίδρομου Νευρωνικού Δικτύου (BiLSTM), όπου η τελική αναπαράσταση προκύπτει από τη συνένωση της ορθόδρομης και ανάδρομης ανάλυσης

2. **Μοντέλα Βασισμένα σε Transformers:** Παρά την επιτυχία των BiLSTMs, η εγγενώς σειριακή φύση τους (η ανάγκη να διαβαστεί η προηγούμενη λέξη για να υπολογιστεί η επόμενη) δημιουργούσε ένα υπολογιστικό εμπόδιο (bottleneck) και δυσχέραινε τη σύλληψη εξαρτήσεων σε πολύ μεγάλα κείμενα. Η απόλυτη παραδειγματική μετατόπιση

(paradigm shift) στο τοπίο της Επεξεργασίας Φυσικής Γλώσσας συντελέστηκε με την εισαγωγή της αρχιτεκτονικής των Transformers από τους Vaswani et al. (2017) [25].

Σε αντίθεση με τα αναδρομικά δίκτυα, οι Transformers εγκαταλείπουν τη σειριακή επεξεργασία υπέρ του απόλυτου παραλληλισμού. Ο πυρήνας της καινοτομίας τους εντοπίζεται στον μηχανισμό Αυτο-Προσοχής (Self-Attention). Μέσω αυτού του μηχανισμού, κατά την επεξεργασία μιας πρότασης, κάθε λέξη «κοιτάζει» ταυτόχρονα όλες τις υπόλοιπες λέξεις, υπολογίζοντας μαθηματικά ένα σκορ σχετικότητας (relevance score). Για κάθε λεξιλογική μονάδα δημιουργούνται τρία διανύσματα: Ερώτημα (Q - Query), Κλειδί (K - Key) και Τιμή (V - Value). Το τελικό βάρος προσοχής υπολογίζεται μέσω της παρακάτω θεμελιώδους εξίσωσης:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.4)$$

Όπου d_k είναι η διάσταση των κλειδιών, η οποία λειτουργεί ως παράγοντας κανονικοποίησης (scaling factor) για την αποφυγή ακραίων τιμών κατά τον υπολογισμό του εσωτερικού γινομένου.

Αυτή η ικανότητα δυναμικής εστίασης επιτρέπει στο σύστημα να εντοπίζει μακροχρόνιες εξαρτήσεις με ακρίβεια. Αρχιτεκτονικές που βασίζονται στον κωδικοποιητή (Encoder) των Transformers, με προεξάρχον το μοντέλο BERT, αξιοποιούν τον μηχανισμό αυτο-προσοχής πολλαπλών κεφαλών (Multi-Head Attention) για να εξαγάγουν βαθύτατα σημασιολογικά χαρακτηριστικά, αποτελώντας σήμερα την αιχμή του δόρατος (State-of-the-Art) στα συστήματα Αναγνώρισης Οντοτήτων.

2.6.3 Αποκωδικοποίηση Ετικετών (Tag Decoder Architectures)

Το τελικό στάδιο στην αρχιτεκτονική ενός ολοκληρωμένου συστήματος NER είναι η Αποκωδικοποίηση Ετικετών (Tag Decoding). Όπως αναλύεται από τους Li et al. (2022) [36], το συγκεκριμένο υποσύστημα παραλαμβάνει τις πλούσιες, συγκεκριμένες αναπαραστάσεις που παράγαγε ο κωδικοποιητής (encoder) και αναλαμβάνει το κρίσιμο έργο της αντιστοίχισής τους στον τελικό χώρο των προβλέψεων. Ουσιαστικός στόχος είναι η εξαγωγή της βέλτιστης δυνατής ακολουθίας ετικετών (π.χ. μέσω του σχήματος BIO) για το δοθέν κείμενο εισόδου. Στη σύγχρονη βιβλιογραφία, οι μεθοδολογικές προσεγγίσεις διαφοροποιούνται ανάλογα με το αν το μοντέλο συνυπολογίζει τις δομικές εξαρτήσεις μεταξύ γειτονικών ετικετών:

1. **Ταξινόμηση Softmax μέσω Πολυστρωματικού Perceptron (MLP):** Αποτελεί την πλέον στοιχειώδη και υπολογιστικά προσιτή προσέγγιση. Σε αυτή την αρχιτεκτονική, η κρυφή κατάσταση h_i κάθε λέξης τροφοδοτείται σε ένα πλήρως συνδεδεμένο νευρωνικό επίπεδο, και η τελική πιθανότητα για κάθε υποψήφια ετικέτα y_i υπολογίζεται ανεξάρτητα μέσω της συνάρτησης κανονικοποίησης Softmax:

$$P(y_i|h_i) = \frac{\exp(W_{y_i} h_i + b_{y_i})}{\sum_j \exp(W_j h_i + b_j)} \quad (2.5)$$

Όπου W και b αντιπροσωπεύουν τον πίνακα βαρών και το διάνυσμα πόλωσης (bias) του επιπέδου αντίστοιχα. Αν και η συγκεκριμένη τεχνική πλεονεκτεί σε ταχύτητα εκτέλεσης, πάσχει από ένα θεμελιώδες μειονέκτημα: αντιμετωπίζει την ταξινόμηση κάθε λέξης ως ένα μεμονωμένο, στατιστικά ανεξάρτητο γεγονός. Κατά συνέπεια, αγνοεί τους αυστηρούς γραμματικούς κανόνες της ακολουθίας. Για παράδειγμα, το δίκτυο αδυνατεί δομικά να αντιληφθεί ότι μια ετικέτα "I-PER" (Συνέχεια Προσώπου) είναι αλγοριθμικά παράλογο να διαδεχθεί μια ετικέτα "B-LOC" (Αρχή Τοποθεσίας). Αυτή η «τύφλωση» απέναντι στις τοπικές εξαρτήσεις οδηγεί συχνά στην παραγωγή ασυνάρτητων ή σημασιολογικά άκυρων προβλέψεων.

2. **Υπό Συνθήκη Τυχαία Πεδία (Conditional Random Fields - CRF):** Για την υπέρβαση των προαναφερθέντων περιορισμών, η ερευνητική κοινότητα στράφηκε σε πιθανοτικά γραφικά μοντέλα που αντιμετωπίζουν την αποκωδικοποίηση ολιστικά. Η πλέον διαδεδομένη και αποτελεσματική επιλογή για συστήματα υψηλών επιδόσεων είναι τα δίκτυα CRF, τα οποία θεμελιώθηκαν θεωρητικά από τους Lafferty et al. (2001) [40]. Σε αντίθεση με την τοπική ταξινόμηση, το επίπεδο CRF μοντελοποιεί το πρόβλημα ως μια ενιαία μαρκοβιανή αλυσίδα, αναζητώντας την πιθανότερη ακολουθία ετικετών (globally optimal sequence) για ολόκληρη την πρόταση ταυτόχρονα.

Μαθηματικά, για μια δοσμένη ακολουθία εισόδου $X = (x_1, x_2, \dots, x_n)$ και μια υποψήφια ακολουθία προβλέψεων $Y = (y_1, y_2, \dots, y_n)$, το μοντέλο CRF υπολογίζει ένα αθροιστικό σκορ $S(X, Y)$:

$$S(X, Y) = \sum_{i=1}^n (E_{i,y_i} + T_{y_{i-1},y_i}) \quad (2.6)$$


Στην εξίσωση αυτή, η παράμετρος E_{i,y_i} (Emission Score) αντιπροσωπεύει τη βαθμολογία που εξάγει ο κωδικοποιητής για την πιθανότητα η λέξη x_i να ανήκει στην κατηγορία y_i . Η πραγματική καινοτομία εδράζεται στον πίνακα μεταβάσεων T (Transition Matrix). Η τιμή T_{y_{i-1},y_i} κωδικοποιεί ρητά τη στατιστική πιθανότητα μετάβασης από την ετικέτα y_{i-1} στην ετικέτα y_i .

Μαθαίνοντας δυναμικά αυτά τα βάρη κατά τη φάση της εκπαίδευσης, το σύστημα επιβάλλει αυστηρούς «γραμματικούς» περιορισμούς. Πρακτικά, «τιμωρεί» (αναθέτοντας αρνητικά σκορ) σημασιολογικά άκυρους συνδυασμούς ετικετών, αποτρέποντας λανθασμένες μεταβάσεις και αυξάνοντας τη συνολική ακρίβεια (precision) και ανάκληση (recall) του αλγορίθμου.

Συνοψίζοντας την αρχιτεκτονική εξέλιξη των συστημάτων NER, η πραγματική τομή στο πεδίο δεν προήλθε από την απομόνωση αυτών των υποσυστημάτων, αλλά από τη στρατηγική τους συνένωση. Η μελέτη των Lample et al. (2016) [41] απέδειξε ότι η σύζευξη ενός ισχυρού κωδικοποιητή (όπως το BiLSTM) με έναν αποκωδικοποιητή CRF δημιουργεί ένα εύρωστο, υβριδικό νευρωνικό δίκτυο.

Σε αυτή τη διάταξη, ο κωδικοποιητής αναλαμβάνει την εξόρυξη των σημασιολογικών και συντακτικών χαρακτηριστικών από το κείμενο παρέχοντας τα σκορ εκπομπής (Emission Scores), ενώ το επίπεδο CRF λειτουργεί ως ο τελικός «γραμματικός επόπτης», φιλτράροντας τις προβλέψεις μέσα από το πρίσμα των επιτρεπτών μεταβάσεων (Transition Scores). Η συγκεκριμένη συλλογιστική δεν περιορίζεται στα αναδρομικά δίκτυα, καθώς η ίδια ακριβώς δομική φιλοσοφία εφαρμόζεται σήμερα και στα σύγχρονα μοντέλα (π.χ. BERT-CRF).

Ως εκ τούτου, ο συνδυασμός προηγμένων αναπαραστάσεων συγκεκριμένου με την αυστηρή, πιθανοτική αποκωδικοποίηση γραφημάτων έχει καθιερωθεί ως το απόλυτο πρότυπο αναφοράς (gold standard) για την ανάπτυξη συστημάτων Εξαγωγής Πληροφορίας κορυφαίων επιδόσεων.



Εικόνα 2.8: Συγκριτική απεικόνιση της ανεξάρτητης ταξινόμησης ετικετών (CRF, αριστερά) σε σχέση με την ολιστική μοντελοποίηση ακολουθίας και πιθανοτήτων μετάβασης (Softmax, δεξιά.)

2.7 Μετρικές Αξιολόγησης (Evaluation Metrics)

Η αντικειμενική αποτίμηση της γενικευτικής ικανότητας (generalization ability) των συστημάτων Επεξεργασίας Φυσικής Γλώσσας αποτελεί τον ακρογωνιαίο λίθο της σύγχρονης ερευνητικής

διαδικασίας. Όπως επισημαίνουν οι Li et al. (2022) [42], η ραγδαία μετάβαση από τα παραδοσιακά στατιστικά μοντέλα στις αρχιτεκτονικές Βαθιάς Μάθησης (Deep Learning) τα τελευταία χρόνια, οδήγησε σε μια εκθετική αύξηση νέων αλγορίθμων και πολύπλοκων συνόλων δεδομένων. Αυτή η τεχνολογική εξέλιξη καθιστά αναγκαία τη θέσπιση αυστηρών, ολοκληρωμένων και κοινά αποδεκτών κριτηρίων αξιολόγησης (benchmarks), ώστε οι επιδόσεις των διαφόρων συστημάτων να είναι άμεσα και δίκαια συγκρίσιμες.


Η αυτοματοποιημένη αποτίμηση μέσω ντετερμινιστικών μαθηματικών μετρικών εξασφαλίζει αξιόπιστα και πλήρως αναπαραγώγιμα (reproducible) αποτελέσματα, εξαλείφοντας τον αστάθμητο ανθρώπινο παράγοντα. Η χειροκίνητη αξιολόγηση εκατομμυρίων παραγόμενων ετικετών δεν είναι μόνο υπολογιστικά ανέφικτη, αλλά εισάγει και εγγενή υποκειμενικότητα. Ο εκάστοτε ανθρώπινος αξιολογητής επηρεάζεται άμεσα από παραμέτρους όπως η γνωστική κόπωση, η έλλειψη απόλυτης εξειδίκευσης στο εκάστοτε θεματικό πεδίο (domain expertise) ή ακόμα και οι προσωπικές γλωσσικές προκαταλήψεις. Επομένως, η προσφυγή σε αυστηρά στατιστικά μεγέθη αποτελεί μονόδρομο για την εξαγωγή σταθερών συμπερασμάτων.

Το Πρόβλημα της Ανισορροπίας Κλάσεων (Class Imbalance): Ωστόσο, η επιλογή του σωστού στατιστικού δείκτη δεν είναι μια τετριμμένη διαδικασία. Ένα από τα πιο συχνά σφάλματα στην αποτίμηση συστημάτων NLP είναι η τυφλή εμπιστοσύνη στη μετρική της απλής Ορθότητας (Accuracy). Στα περισσότερα προβλήματα, όπως η Αναγνώριση Οντοτήτων (NER), τα δεδομένα χαρακτηρίζονται από ακραία ανισορροπία. Για παράδειγμα, σε ένα τυπικό κείμενο, πάνω από το 85% των λέξεων ανήκουν συνήθως στην κατηγορία "Ο" (Outside - καμία οντότητα). Ένα αμιγώς "τεμπέλικο" μοντέλο που θα ταξινομούσε τα πάντα ως "Ο", θα πετύχαινε 85% Ορθότητα, δημιουργώντας την ψευδαίσθηση ενός εξαιρετικού συστήματος, ενώ στην πραγματικότητα δεν θα αναγνώριζε καμία οντότητα (Accuracy Paradox).

Για την υπέρβαση αυτής της παραπλανητικής εικόνας και την αντιμετώπιση της ανισορροπίας, η αξιολόγηση των μοντέλων ταξινόμησης δεν βασίζεται σε ένα ενιαίο ποσοστό, αλλά θεμελιώνεται πάνω στον Πίνακα Σύγχυσης (Confusion Matrix). Όπως τεκμηριώνουν οι Sokolova & Lapalme (2009) [43], ο πίνακας αυτός αποδομεί τις προβλέψεις του αλγορίθμου σε τέσσερα διακριτά, θεμελιώδη συστατικά:

1. **Αληθώς Θετικά (True Positives - TP):** Αποτελούν τις περιπτώσεις όπου το μοντέλο **αναγνώρισε ορθά** μια πραγματική οντότητα. Πρόκειται για τις απόλυτα επιτυχημένες ταξινομήσεις που επιθυμούμε να μεγιστοποιήσουμε.
2. **Ψευδώς Θετικά (False Positives - FP):** Γνωστά στη στατιστική και ως Σφάλματα Τύπου I (Type I Errors). Αντιπροσωπεύουν τις περιπτώσεις όπου το δίκτυο προέβλεψε λανθασμένα την ύπαρξη μιας οντότητας, ενώ στην πραγματικότητα επρόκειτο για απλό κείμενο (ή για διαφορετική κλάση). Αποτελούν τον δείκτη "υπερβολικής ευαισθησίας" του συστήματος.
3. **Ψευδώς Αρνητικά (False Negatives - FN):** Αναφέρονται ως Σφάλματα Τύπου II (Type II Errors). Πρόκειται για τις κρίσιμες αστοχίες του μοντέλου, όπου μια υπαρκτή οντότητα παραλείφθηκε και δεν εντοπίστηκε από τον αλγόριθμο.
4. **Αληθώς Αρνητικά (True Negatives - TN):** Είναι οι περιπτώσεις όπου το μοντέλο απέρριψε ορθά μια λέξη που πράγματι δεν αποτελούσε οντότητα (κλάση "Ο"). Στο NER, ο αριθμός αυτός είναι συνήθως τεράστιος και γι' αυτό τείνει να αγνοείται στους τελικούς υπολογισμούς.

Αυτά τα τέσσερα δομικά στοιχεία συνθέτουν τον μαθηματικό πυρήνα πάνω στον οποίο χτίζονται όλες οι προηγμένες μετρικές απόδοσης. Ανάλογα με το αν το πρόβλημα αφορά τον εντοπισμό μίας αποκλειστικής ετικέτας ή πολλαπλών χαρακτηριστικών, οι δείκτες αυτοί συνδυάζονται διαφορετικά, όπως αναλύεται στις υποενότητες που ακολουθούν.



Εικόνα 2.9: Οπτική αναπαράσταση του Πίνακα Σύγχυσης (Confusion Matrix), ο οποίος διαχωρίζει τις προβλέψεις του μοντέλου σε σχέση με την πραγματική κλάση των δεδομένων.)

2.7.1 Μετρικές Ταξινόμησης ενός Επιπέδου (Single-label Metrics)

Στα προβλήματα ταξινόμησης ενός επιπέδου (single-label classification), κάθε γλωσσική μονάδα (π.χ. λέξη ή φράση) αντιστοιχίζεται σε μία και μοναδική, αμοιβαία αποκλειόμενη κατηγορία. Καθίσταται, συνεπώς, περιττή η εξέταση πολύπλοκων συσχετίσεων μεταξύ πολλαπλών ετικετών. Η συστηματική αποτίμηση της απόδοσης των αλγορίθμων σε τέτοιες εφαρμογές εδράζεται στις τέσσερις θεμελιώδεις παραμέτρους του Πίνακα Σύγχυσης (TP, TN, FP, FN) που προαναφέρθηκαν. Αξιοποιώντας αυτές τις μεταβλητές, και ακολουθώντας τη μεθοδολογική προσέγγιση των Sokolova & Lapalme (2009) [43], προκύπτουν οι παρακάτω βασικές μαθηματικές μετρικές:

1. **Ορθότητα (Accuracy) & Ποσοστό Σφάλματος (Error Rate):** Η Ορθότητα αποτελεί την πλέον παραδοσιακή και διαισθητικά κατανοητή μετρική. Υπολογίζει το ποσοστό των συνολικά σωστών προβλέψεων (τόσο των θετικών όσο και των αρνητικών) επί του συνολικού μεγέθους του δείγματος. Μαθηματικά, εκφράζεται ως εξής:

$$\left(Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \right) \quad (2.7)$$

Αντίστοιχα, το Ποσοστό Σφάλματος (Error Rate) ορίζεται ως το συμπληρωματικό της μέγεθος, δηλαδή:

$$(ErrorRate = 1 - Accuracy) \quad (2.8)$$

Μολονότι η Ορθότητα προσφέρει μια γρήγορη γενική εικόνα, **αποτυγχάνει σε μη ισορροπημένα σύνολα δεδομένων (unbalanced datasets)**. Επειδή αντιμετωπίζει ισότιμα την κλάση ενδιαφέροντος (π.χ. μια οντότητα) και την κλάση του υποβάθρου (κλάση "Ο"), ένα μοντέλο μπορεί να επιτύχει πλασματικά υψηλή Ορθότητα, αγνοώντας τη μειοψηφούσα κλάση.

2. **Ακρίβεια (Precision):** Προκειμένου να αποτιμηθεί η «ποιότητα» και η αξιοπιστία των θετικών προβλέψεων του συστήματος, εισάγεται η μετρική της Ακρίβειας. Η συγκεκριμένη παράμετρος απαντά στο κρίσιμο ερώτημα: "Από το σύνολο των στοιχείων που ο αλγόριθμος ταξινόμησε ως θετικά, ποιο ποσοστό ήταν πράγματι ορθά;". Υπολογίζεται ως ο λόγος των Αληθώς Θετικών προς το άθροισμα όλων των θετικών προβλέψεων (σωστών και λανθασμένων):

$$(Precision = \frac{TP}{TP + FP}) \quad (2.9)$$

Ένα μοντέλο που χαρακτηρίζεται από υψηλό Precision θεωρείται συντηρητικό (conservative). Αυτό σημαίνει πως όταν προβαίνει σε μια πρόβλεψη, η πιθανότητα να είναι σωστή είναι εξαιρετικά υψηλή. Ωστόσο, για να διατηρήσει αυτό το υψηλό επίπεδο σιγουριάς και να αποφύγει τα Ψευδώς Θετικά (FP) σφάλματα, ενδέχεται να "διστάζει" να ταξινομήσει οριακές περιπτώσεις, χάνοντας έτσι την ευκαιρία να εντοπίσει πολλές πραγματικές οντότητες.

3. **Ανάκληση (Recall):** Σε αντίθεση με την Ακρίβεια, η Ανάκληση (γνωστή στη στατιστική και ως Ευαισθησία - Sensitivity) μετατοπίζει το κέντρο βάρους στα πραγματικά δεδομένα του συνόλου. Απαντά στο εξής ερώτημα: "Από όλες τις πραγματικές οντότητες που υπήρχαν κρυμμένες στο κείμενο, τι ποσοστό κατάφερε να ανακαλύψει το

μοντέλο;". Μαθηματικά, υπολογίζεται διαιρώντας τα Αληθώς Θετικά με το σύνολο των πραγματικά θετικών παραδειγμάτων (ανεξαρτήτως του πώς ταξινομήθηκαν):

$$\left(Recall = \frac{TP}{TP + FN} \right) (2.10)$$

Σε αντίθεση με το συντηρητικό Precision, ένα μοντέλο με υψηλό Recall θεωρείται «τολμηρό» (aggressive). Προσπαθεί να «πιάσει» όσες περισσότερες οντότητες μπορεί, ελαχιστοποιώντας τα κρίσιμα Ψευδώς Αρνητικά (FN), ακόμη κι αν αυτό σημαίνει ότι θα κάνει περισσότερα λάθη χαρακτηρίζοντας άσχετες λέξεις ως οντότητες. Μεταξύ Ακρίβειας και Ανάκλησης αναπτύσσεται εγγενώς μια αντισταθμιστική σχέση (trade-off): η αύξηση της μίας συνήθως επιφέρει τη μείωση της άλλης.

4. **F1-Score (F-Measure):** Επειδή σε μη ισορροπημένα σύνολα δεδομένων (unbalanced datasets) η μεμονωμένη εξέταση των παραπάνω δεικτών οδηγεί σε παραπλανητικά συμπεράσματα, η ερευνητική κοινότητα υιοθετεί τον συνδυασμό τους. Το F1-Score δεν είναι ένας απλός μέσος όρος, αλλά υπολογίζει τον Αρμονικό Μέσο (Harmonic Mean) της Ακρίβειας και της Ανάκλησης:

$$\left(F1 = 2 \times \frac{(\text{Precision} \times \text{Recall})}{(\text{Precision} + \text{Recall})} \right) (2.11)$$

Η μαθηματική ιδιότητα του αρμονικού μέσου είναι ότι τιμωρεί τις ακραίες αποκλίσεις. Για να επιτύχει ένα μοντέλο υψηλό F1-Score, δεν αρκεί να έχει 99% Recall και 10% Precision· απαιτείται ταυτόχρονη βελτιστοποίηση και των δύο παραμέτρων. Για τον λόγο αυτό, το F1-Score έχει καθιερωθεί ως η *de facto* και πλέον αξιόπιστη μετρική (gold standard) για την αξιολόγηση συστημάτων Αναγνώρισης Οντοτήτων.

2.7.2 Μετρικές Πολλαπλών Ετικετών (Multi-label Metrics)

Σε αντιδιαστολή με την ταξινόμηση ενός επιπέδου, τα προβλήματα πολλαπλών ετικετών (multi-label classification) χαρακτηρίζονται από εγγενή πολυπλοκότητα, καθώς επιτρέπουν την ταυτόχρονη αντιστοίχιση μιας γλωσσικής μονάδας σε περισσότερες από μία κατηγορίες. Σε αυτό το πλαίσιο, ο αριθμός των αποδιδόμενων ετικετών ανά παρατήρηση μεταβάλλεται δυναμικά. Σε τέτοιου είδους εφαρμογές (όπως η αναγνώριση πολλαπλών και επικαλυπτόμενων οντοτήτων σε ένα κείμενο), η χρήση συμβατικών στατιστικών δεικτών, όπως η απλή Ορθότητα, καθίσταται εξαιρετικά ανεπαρκής, διότι αδυνατεί να αποτυπώσει τη σημασιολογία των μερικών ταυτίσεων (partial matches). Σύμφωνα με τους Li et al. (2022) [42], για την αντικειμενική αξιολόγηση απαιτείται η χρήση προηγμένων μετρικών που διαχειρίζονται αποδοτικά την ανομοιογενή κατανομή των δεδομένων. Οι επικρατέστερες προσεγγίσεις είναι οι εξής:

1. **Micro-F1:** Αυτός ο δείκτης προσεγγίζει το πρόβλημα καθολικά. Συνυπολογίζει αθροιστικά τα Αληθώς Θετικά, Ψευδώς Θετικά και Ψευδώς Αρνητικά στοιχεία (TP, FP, FN) για όλες τις N ετικέτες συγκεντρωτικά, εξάγοντας μια παγκόσμια τιμή Ακρίβειας και Ανάκλησης. Επειδή αποδίδει ίσο βάρος σε κάθε μεμονωμένο δείγμα (instance) ανεξαρτήτως της κλάσης στην οποία ανήκει, το Micro-F1 αποτελεί την ενδεδειγμένη επιλογή όταν επικρατεί ακραία ανισορροπία μεγεθών. Μαθηματικά ορίζεται ως το τελικό F1-Score πάνω στα αθροίσματα των μεταβλητών:

$$Micro-F1 = F1 \left(\sum_{i=1}^N TP_i, \sum_{i=1}^N FP_i, \sum_{i=1}^N FN_i \right) (2.12)$$


2. **Macro-F1:** Στον αντίποδα, το Macro-F1 υπολογίζει την απόδοση (δηλαδή το μεμονωμένο $F1_i$) ανεξάρτητα για κάθε ετικέτα i και, ακολούθως, εξάγει τον απλό αριθμητικό μέσο όρο. Αντιμετωπίζει όλες τις κατηγορίες ως αυστηρά ισότιμες, αγνοώντας τον όγκο των παραδειγμάτων τους:

$$Macro.F1 = \frac{1}{N} \sum_{i=1}^N F1_i \quad (2.13)$$

Όπως καταγράφεται στη βιβλιογραφία [42], αυτή ακριβώς η ιδιότητα καθιστά το Macro-F1 εξαιρετικά ευαίσθητο, καθώς τείνει να επηρεάζεται δυσανάλογα (τιμωρείται) από σπάνιες κλάσεις που παρουσιάζουν φτωχές επιδόσεις.

3. **Σταθμισμένο F1 (Weighted-F1):** Για να γεφυρωθεί το χάσμα μεταξύ των δύο προηγούμενων προσεγγίσεων, η σύγχρονη βιομηχανική πρακτική υιοθετεί τη σταθμισμένη μετρική. Το Weighted-F1 υπολογίζει μεν το σκορ ανεξάρτητα για κάθε κλάση, αλλά κατά την εξαγωγή του μέσου όρου, πολλαπλασιάζει το εκάστοτε $F1_i$ με ένα ειδικό βάρος W_i , το οποίο αντιστοιχεί στο σχετικό πλήθος (support) των πραγματικών δειγμάτων της ετικέτας:

$$Weighted-F1 = \sum_{i=1}^N W_i \cdot F1_i \quad (2.14)$$



Εικόνα 2.10: Συγκριτική απεικόνιση της ροής υπολογισμού μεταξύ της στρατηγικής Micro-Averaging (αριστερά/κάτω) και Macro-Averaging (δεξιά/πάνω).

Πέραν των παραδοσιακών προσεγγίσεων υπολογισμού του F1-Score, στις σύγχρονες εφαρμογές Επεξεργασίας Φυσικής Γλώσσας αναδύεται όλο και συχνότερα η πρόκληση της Ακραίας Ταξινόμησης Πολλαπλών Ετικετών (Extreme Multi-label Classification - XMLC). Σε ρεαλιστικά σενάρια όπου ο διαθέσιμος χώρος των ετικετών (label space) ανέρχεται σε δεκάδες χιλιάδες κατηγορίες, τα προαναφερθέντα εργαλεία παρουσιάζουν σοβαρούς θεωρητικούς περιορισμούς. Λόγω της ακραίας αραιότητας (sparsity) των δεδομένων, ένα νευρωνικό δίκτυο σπάνια αποδίδει μια απόλυτη και αυστηρή απόφαση (hard thresholding) της μορφής "ναι ή όχι" για κάθε μεμονωμένη ετικέτα. Αντίθετα, εξάγει μια ταξινομημένη λίστα πιθανοτήτων (ranked list), ιεραρχώντας τις επικρατέστερες υποψήφιες κατηγορίες.

- Για την αντικειμενική αξιολόγηση αυτού του φαινομένου, η ερευνητική κοινότητα προκρίνει τη χρήση Μετρικών Βασισμένων στην Κατάταξη (Rank-based Metrics). Η πλέον διαισθητική εξ αυτών είναι η Ακρίβεια στους Κορυφαίους K όρους (Precision at K - $P@K$). Η συγκεκριμένη μετρική αξιολογεί το κατά πόσο οι κορυφαίες K προβλέψεις του αλγορίθμου, αυτές δηλαδή με τον υψηλότερο βαθμό βεβαιότητας (confidence), ευθυγραμμίζονται με την πραγματικότητα. Μαθηματικά υπολογίζεται ως εξής:

$$P@K = \frac{1}{K} \sum_{i=1}^K r_i \quad (2.15)$$

Όπου $r_i \in \{0,1\}$ αποτελεί μια δυαδική μεταβλητή-δείκτη (indicator variable) που υποδηλώνει εάν η i -οστή προβλεπόμενη ετικέτα είναι πράγματι σχετική (ορθή) ή λανθασμένη. Παρά την υπολογιστική της απλότητα, η συγκεκριμένη μετρική μειονεκτεί εγγενώς σε ένα κρίσιμο σημείο: αγνοεί πλήρως τη σχετική θέση της ορθής απάντησης μέσα στην κορυφαία K -άδα (για παράδειγμα, δεν διαχωρίζει αν η σωστή ετικέτα κατατάχθηκε στην 1η ή στη 10η θέση), αποδίδοντας εντελώς ομοιόμορφο βάρος σε όλες τις προβλέψεις του παραθύρου.

- Κανονικοποιημένο Προεξοφλημένο Αθροιστικό Κέρδος (Normalized Discounted Cumulative Gain - NDCG@K): Προκειμένου να επιλυθεί η εγγενής αδυναμία του $P@K$ να αξιολογήσει τη σειρά των αποτελεσμάτων, η σύγχρονη έρευνα προκρίνει τη χρήση του NDCG. Όπως ορίστηκε ιστορικά από τους Järvelin & Kekäläinen (2002) [44], το NDCG βασίζεται σε μια θεμελιώδη αρχή: οι ορθές ετικέτες που εμφανίζονται υψηλότερα στην κατάταξη έχουν πολύ μεγαλύτερη αξία (gain) για το σύστημα. Αρχικά υπολογίζεται το Προεξοφλημένο Αθροιστικό Κέρδος (DCG_K), το οποίο επιβάλλει μια λογαριθμική «ποινή» (discount) όσο χαμηλότερα εμφανίζεται η σχετική ετικέτα μέσα στην K -άδα:

$$DCG_K = \sum_{i=1}^K \frac{2^{r_i} - 1}{\log_2(i + 1)} \quad (2.16)$$

Στην εξίσωση αυτή, ο όρος $\log_2(i + 1)$ στον παρονομαστή λειτουργεί ως ο παράγοντας προεξόφλησης, μειώνοντας τη συνεισφορά της ετικέτας όσο αυξάνεται η θέση κατάταξης i . Το τελικό $NDCG_K$ προκύπτει διαιρώντας το DCG με την ιδανική του τιμή (Ideal DCG – $IDCG_K$), η οποία αντιστοιχεί στο μέγιστο δυνατό σκορ εάν όλες οι ορθές ετικέτες είχαν καταταχθεί τέλεια στις κορυφαίες θέσεις:

$$NDCG_K = \frac{DCG_K}{IDCG_K} \quad (2.17)$$

Η συγκεκριμένη διαδικασία εξασφαλίζει ότι η τελική μετρική αξιολόγησης θα κυμαίνεται πάντα στο απόλυτα κανονικοποιημένο διάστημα $[0,1]$. Ως εκ τούτου, ο συνδυασμός προηγμένων αναπαραστάσεων Micro/Macro F1 με τις εξειδικευμένες μετρικές κατάταξης, έχει καθιερωθεί ως η βέλτιστη πρακτική για την ολιστική αποτίμηση συστημάτων ταξινόμησης πολλαπλών ετικετών.

2.7.3 Μετρικές Παραγωγής Κειμένου (Text Generation Metrics)

Σε γλωσσικές εργασίες όπου το ζητούμενο δεν περιορίζεται στην απλή αντιστοίχιση σε μια προκαθορισμένη κατηγορία, αλλά απαιτεί την εξολοκλήρου σύνθεση νέου λόγου (όπως συμβαίνει στην Αυτόματη Περίληψη ή τη Μηχανική Μετάφραση), οι παραδοσιακοί δείκτες ταξινόμησης κρίνονται εγγενώς ανεπαρκείς. Η βασική τους αδυναμία πηγάζει από την ίδια την πολυμορφία της φυσικής γλώσσας: σε αντίθεση με ένα αυστηρό πρόβλημα πολλαπλών επιλογών, ένα αρχικό κείμενο μπορεί να μεταφραστεί ή να συνοψιστεί με δεκάδες διαφορετικούς, αλλά εξίσου ορθούς και περιεκτικούς τρόπους. Επομένως, απουσιάζει η έννοια της μίας και μοναδικής «απόλυτης αλήθειας» (ground truth).

Όπως αναλύεται από τους Yadav et al. (2023) [32], η αυτοματοποιημένη αξιολόγηση τέτοιων συστημάτων αναγκαστικά μετατοπίζεται από την απόλυτη σημασιολογική κατανόηση, στη μέτρηση της στατιστικής αλληλεπικάλυψης (n-gram overlap) μεταξύ του κειμένου που παρήγαγε

η μηχανή (candidate) και ενός συνόλου από πρότυπα κείμενα αναφοράς (references) που έχουν συνταχθεί από ανθρώπους.

1. **BLEU (Bilingual Evaluation Understudy):** Ιστορικά, το πρώτο μεγάλο ορόσημο στην αξιολόγηση παραγωγικών μοντέλων (κυρίως στη Μηχανική Μετάφραση) τέθηκε από τους Papineni et al. (2002) [45] με την εισαγωγή της μετρικής BLEU. Ο δείκτης αυτός είναι αυστηρά προσανατολισμένος στην Ακρίβεια (Precision). Ελέγχει πόσα από τα n-grams (λέξεις ή φράσεις) του παραγόμενου κειμένου υπάρχουν όντως στα κείμενα αναφοράς. Για να αποτραπεί το φαινόμενο όπου ένα μοντέλο παράγει μόνο *μία* σωστή λέξη για να πετύχει 100% Ακρίβεια, το BLEU ενσωματώνει μαθηματικά μια Ποινή Συντομίας (Brevity Penalty - BP):

$$BLEU = BP \times \exp \left(\sum_{n=1}^N w_n \log p_n \right) \quad (2.18)$$

Όπου p_n είναι η τροποποιημένη ακρίβεια για τα n-grams και w_n τα αντίστοιχα βάρη τους (συνήθως ομοιόμορφα έως $N = 4$). Το BP ενεργοποιείται (τιμωρώντας το συνολικό σκορ) εάν το μήκος του παραγόμενου κειμένου (c) είναι μικρότερο από το ενεργό μήκος του κειμένου αναφοράς (r), διασφαλίζοντας έτσι ισορροπία μεταξύ ακρίβειας και πληρότητας.

Στον αντίποδα της μετρικής BLEU, η οποία σχεδιάστηκε πρωτίστως με έμφαση στην Ακρίβεια (Precision), στο πεδίο της Αυτόματης Περίληψης (Text Summarization) το ακαδημαϊκό και βιομηχανικό πρότυπο αξιολόγησης είναι η οικογένεια μετρικών ROUGE (Recall-Oriented Understudy for Gisting Evaluation). Όπως καταδεικνύεται από την εργασία του Lin (2004) [46], το ROUGE εστιάζει κατά κύριο λόγο στην Ανάκληση (Recall). Η κεντρική του φιλοσοφία δεν αποσκοπεί στη βαθιά σημασιολογική κατανόηση, αλλά ποσοτικοποιεί τη στατιστική αλληλεπικάλυψη γλωσσικών μονάδων. Ουσιαστικά, αξιολογεί *πόση* από τη βασική πληροφορία των πρότυπων, ανθρώπινων περιλήψεων (reference summaries) κατάφερε να «διασώσει» το παραγόμενο μοντέλο.

- **ROUGE-N:** Η πλέον διαδεδομένη παραλλαγή αυτής της μεθοδολογίας είναι ο δείκτης, ο οποίος υπολογίζει το ποσοστό ταύτισης ακολουθιών μήκους N λέξεων (n-grams). Μαθηματικά, η εξίσωση του δείκτη διαμορφώνεται ως εξής:

$$ROUGE-N = \frac{\sum_{S \in \{References\}} \sum_{gram_n \in S} Count_{match}(gram_n)}{\sum_{S \in \{References\}} \sum_{gram_n \in S} Count(gram_n)} \quad (2.19)$$


Στον παραπάνω τύπο, ο παρονομαστής αθροίζει το συνολικό πλήθος των n-grams που υπάρχουν στα κείμενα αναφοράς, ενώ ο αριθμητής καταγράφει τις ακριβείς ταυτίσεις ($Count_{match}$) που εντοπίστηκαν στο κείμενο της μηχανής. Εφαρμόζοντας αυτή τη λογική, το ROUGE-1 εξετάζει την επικάλυψη μεμονωμένων λέξεων (unigrams), παρέχοντας μια ισχυρή ένδειξη για τη διατήρηση του βασικού λεξιλογίου. Αντίστοιχα, το ROUGE-2 αξιολογεί την ταύτιση γειτονικών ζευγών λέξεων (bigrams), ελέγχοντας εάν διατηρήθηκαν οι δομικές φράσεις και οι στοιχειώδεις συντακτικοί δεσμοί του πρωτοτύπου.

- **ROUGE-L (Longest Common Subsequence):** Προχωρώντας σε ένα πιο σύνθετο επίπεδο συντακτικής ανάλυσης, η συγκεκριμένη μετρική δεν περιορίζεται σε στατικά n-grams, αλλά στηρίζεται στην αλγοριθμική εύρεση της Μεγαλύτερης Κοινής Υπακολουθίας (LCS) μεταξύ των δύο κειμένων. Το θεμελιώδες πλεονέκτημα αυτής της μαθηματικής προσέγγισης είναι ότι δεν απαιτεί οι λέξεις να παρουσιάζουν αυστηρή χωρική γειτνίαση (να βρίσκονται δηλαδή η μία ακριβώς δίπλα στην άλλη). Αρκεί να διατηρούν τη σωστή σχετική (χρονική ή λογική) σειρά εμφάνισής τους. Ο δείκτης ανάκλησης για το ROUGE-L υπολογίζεται ως:

$$R_{LCS} = \frac{LCS(R, C)}{|R|} \quad (2.20)$$

Όπου R είναι το κείμενο αναφοράς (Reference), C το κείμενο που παρήγαγε η μηχανή (Candidate), $|R|$ το συνολικό μήκος του πρότυπου κειμένου, και $LCS(R, C)$ το μήκος της μεγαλύτερης ακολουθίας λέξεων που εμφανίζεται με την ίδια σειρά και στα δύο. Με αυτόν τον τρόπο, το ROUGE-L υπερβαίνει τη στείρα καταμέτρηση λέξεων, επιβεβαιώνοντας τη δομική ακεραιότητα και τη συντακτική συνεκτικότητα της παραγόμενης πρότασης.

Ανακεφαλαιώνοντας, οι μετρικές λεκτικής επικάλυψης (όπως το BLEU και το ROUGE) πάσχουν από έναν εγγενή περιορισμό: αδυνατούν να συλλάβουν τη βαθιά σημασιολογική ταύτιση. Για παράδειγμα, αν το μοντέλο χρησιμοποιήσει ένα άψογο συνώνυμο που δεν υπάρχει στο κείμενο αναφοράς, θα «τιμωρηθεί» άδικα με χαμηλό σκορ. Παρά το θεωρητικό αυτό μειονέκτημα, η υπολογιστική τους αποδοτικότητα, η απουσία ανάγκης για ανθρώπινη παρέμβαση και η άμεση κλιμακωσιμότητά τους (scalability), τις διατηρούν ακλόνητες ως το απόλυτο, αυτοματοποιημένο πρότυπο βαθμολόγησης (gold standard) για τα σύγχρονα συστήματα παραγωγής κειμένου.



Εικόνα 2.11: Εννοιολογική αναπαράσταση της λειτουργίας των μετρικών n-gram overlap, όπου ταυτοποιούνται κοινές λέξεις και ακολουθίες μεταξύ του Κειμένου Αναφοράς και της Πρόβλεψης του Μοντέλου.

2.8 Προκλήσεις και Ηθικά Ζητήματα (Challenges and Ethical Considerations)

Η ραγδαία εξέλιξη της Τεχνητής Νοημοσύνης (AI) και της Επεξεργασίας Φυσικής Γλώσσας (NLP) τα τελευταία χρόνια έχει οδηγήσει στην εμφάνιση εξελιγμένων Παραγωγικών Γλωσσικών Μοντέλων (Generative AI), με πλέον χαρακτηριστικό παράδειγμα τις διαλογικές αρχιτεκτονικές όπως το ChatGPT. Παρά την αποδεδειγμένη ικανότητα αυτών των συστημάτων να μετασχηματίζουν τον τρόπο διεξαγωγής της επιστημονικής έρευνας και να αυτοματοποιούν μια πληθώρα πολύπλοκων βιομηχανικών εφαρμογών, η μαζική υιοθέτησή τους εγείρει κρίσιμους κοινωνικούς και τεχνολογικούς προβληματισμούς.

Σύμφωνα με τον Ray (2023) [47], η ταχύτατη εμπορευματοποίηση αυτών των προηγμένων συστημάτων συνοδεύεται από μια σειρά εγγενών προκλήσεων, οι οποίες υπερβαίνουν κατά πολύ το αλγοριθμικό πλαίσιο. Πλέον, τα ζητήματα που ανακύπτουν αγγίζουν τον ίδιο τον πυρήνα της υπολογιστικής ηθικής (computer ethics) και της υπεύθυνης χρήσης της τεχνολογίας.


Καθώς τα σύγχρονα μοντέλα βασίζονται σε αρχιτεκτονικές βαθιάς μάθησης με δισεκατομμύρια παραμέτρους και εκπαιδεύονται σε αχανή, συχνά μη φιλτραρισμένα σύνολα δεδομένων (web corpora), καθίστανται επιρρεπή στην ενσωμάτωση και ανεξέλεγκτη αναπαραγωγή συστημικών προκαταλήψεων (data biases). Παράλληλα, η διασφάλιση της ανθεκτικότητας έναντι κακόβουλων επιθέσεων (robustness and security), η παραγωγή αναληθών πληροφοριών που παρουσιάζονται ως τεκμηριωμένες, καθώς και η γενικότερη καταπάτηση των ορίων της πνευματικής ιδιοκτησίας, συνιστούν θεμελιώδη εμπόδια.

Καθίσταται, συνεπώς, σαφές ότι η απρόσκοπτη ενσωμάτωση της Τεχνητής Νοημοσύνης στην καθημερινότητα προϋποθέτει την εξεύρεση μιας λεπτής ισορροπίας μεταξύ της τεχνολογικής καινοτομίας και της απαραίτητης ανθρώπινης εποπτείας (human-in-the-loop / human expertise).

Ο θεμελιώδης λόγος για τον οποίο ανακύπτουν οι προαναφερθέντες ηθικοί προβληματισμοί εντοπίζεται στην ίδια τη φύση των βαθιών νευρωνικών δικτύων, τα οποία λειτουργούν κατά κανόνα ως αδιαφανή «Μαύρα Κουτιά» (Black Box models). Η εγγενής αδυναμία πλήρους κατανόησης του τρόπου με τον οποίο εκατομμύρια διασυνδεδεμένοι νευρώνες συνθέτουν μια τελική απόφαση (decision-making process), στερεί από τους ερευνητές τη δυνατότητα άμεσου ελέγχου και διόρθωσης των σφαλμάτων.

Στο σημείο αυτό αναδεικνύεται η επιτακτική ανάγκη για τη μετάβαση στην Επεξηγήσιμη Τεχνητή Νοημοσύνη (Explainable AI - XAI). Όπως τονίζουν οι Arrieta et al. (2020) [48], η διαφάνεια (transparency) και η ερμηνευσιμότητα (interpretability) των αλγορίθμων δεν αποτελούν πλέον προαιρετικά τεχνικά χαρακτηριστικά, αλλά δομικές προϋποθέσεις για τη δημιουργία υπεύθυνων συστημάτων (Responsible AI). Χωρίς επεξηγησιμότητα, είναι αδύνατον να διασφαλιστεί η εμπιστοσύνη του χρήστη (user trust) ή να αποδοθούν νομικές και ηθικές ευθύνες σε περιπτώσεις αστοχίας.

Εξετάζοντας τον κύκλο ζωής ενός σύγχρονου γλωσσικού μοντέλου, διαπιστώνεται ότι οι κίνδυνοι διαπερνούν κάθε επιμέρους στάδιο της ανάπτυξής του. Κατά τη φάση της συλλογής των δεδομένων, ελλοχεύει ο κίνδυνος της Μεροληψίας (Bias). Κατά τη φάση της παραγωγής συμπερασμάτων, το μοντέλο ενδέχεται να εμφανίσει Παραισθήσεις (Hallucinations). Τέλος, κατά την ευρύτερη ανάπτυξη και χρήση του από το κοινό, εγείρονται σύνθετα Ηθικά Διλήμματα. Στις υποενότητες που ακολουθούν (2.8.1 - 2.8.3), αναλύονται αυτοί οι τρεις βασικοί πυλώνες κινδύνου, εξετάζοντας τους μηχανισμούς μέσω των οποίων υπονομεύεται η αλγοριθμική αξιοπιστία.



Εικόνα 2.12: Απεικόνιση των σταδίων ανάπτυξης ενός συστήματος Τεχνητής Νοημοσύνης και η αντιστοίχισή τους με τις κύριες ηθικές και τεχνικές προκλήσεις

2.8.1 Μεροληψία και Δικαιοσύνη (Bias and Fairness)


Η ραγδαία διείσδυση των αλγορίθμων Μηχανικής Μάθησης σε κρίσιμους τομείς της καθημερινότητας όπως οι διαδικασίες προσλήψεων, η έγκριση πιστώσεων και η λήψη

δικαστικών αποφάσεων, καθιστά πλέον επιτακτική την ανάγκη διασφάλισης της αλγοριθμικής δικαιοσύνης (algorithmic fairness). Αν και τα αυτοματοποιημένα συστήματα πλεονεκτούν στο ότι μπορούν να επεξεργαστούν ταχύτατα τεράστιους όγκους δεδομένων χωρίς να υπόκεινται σε ανθρώπινη κόπωση, παραμένουν ευάλωτα στην αναπαραγωγή και ενίσχυση κοινωνικών διακρίσεων. Σύμφωνα με τη μελέτη των Mehrabi et al. (2022) [49], η δικαιοσύνη στο υπολογιστικό πλαίσιο ορίζεται ως η απουσία κάθε μορφής προκατάληψης ή συστημικής ευνοιοκρατίας απέναντι σε άτομα ή ομάδες, βάσει των εγγενών ή επίκτητων χαρακτηριστικών τους. Η ερευνητική κοινότητα εντοπίζει τις ρίζες της μεροληψίας (bias) κυρίως σε δύο άξονες: στις κρυφές ατέλειες των δεδομένων εκπαίδευσης και στους εγγενείς μαθηματικούς μηχανισμούς των μοντέλων. Ένα ιστορικό παράδειγμα αλγοριθμικής αστοχίας αποτελεί το σύστημα COMPAS, ένα λογισμικό που αξιοποιήθηκε από αμερικανικά δικαστήρια για την πρόβλεψη της πιθανότητας υποτροπής κρατουμένων. Η επιστημονική ανάλυση απέδειξε ότι το αντίστοιχο εργαλείο ήταν έντονα προκατειλημμένο, παρουσιάζοντας δυσανάλογα υψηλά ποσοστά ψευδώς θετικών ενδείξεων (false positives) εις βάρος συγκεκριμένων φυλετικών ομάδων.

Μεταφέροντας τον προβληματισμό αυτό στο πεδίο της Επεξεργασίας Φυσικής Γλώσσας (NLP), η κατάσταση καθίσταται εξίσου περίπλοκη. Σύμφωνα με τους Blodgett et al. (2020) [50], η μεροληψία στα γλωσσικά μοντέλα διακρίνεται σε δύο κύριες κατηγορίες: στην Αδικία Κατανομής (Allocational Bias), όπου ένα σύστημα (π.χ. φιλτράρισμα βιογραφικών) απορρίπτει άδικα συγκεκριμένες ομάδες, και στην Αδικία Αναπαράστασης (Representational Bias), όπου το μοντέλο υποβαθμίζει την κοινωνική εικόνα ορισμένων πληθυσμών. Το φαινόμενο αυτό γίνεται έντονα ορατό στις διανυσματικές αναπαραστάσεις λέξεων (Word Embeddings). Καθώς οι αλγόριθμοι αφομοιώνουν ακατέργαστα κείμενα από το διαδίκτυο, μαθαίνουν αυτούσια τα ανθρώπινα στερεότυπα, καταλήγοντας συχνά να συσχετίζουν μαθηματικά έννοιες όπως «προγραμματιστής» αποκλειστικά με το ανδρικό φύλο και λέξεις όπως «νοσοκόμα» με το θηλυκό.

Πέρα από την άμεση κοινωνική αδικία, οι σύγχρονες μελέτες επισημαίνουν τον κίνδυνο της δημιουργίας ενός καταστροφικού «βρόχου ανατροφοδότησης» (feedback loop). Το πρόβλημα δεν περιορίζεται στην παθητική αποτύπωση των υφιστάμενων στερεοτύπων, αλλά επεκτείνεται στην ενεργή διαμόρφωση της κοινωνικής πραγματικότητας. Πιο συγκεκριμένα, οι μεροληπτικές αποφάσεις ενός αλγορίθμου, όπως η συστηματική υποβάθμιση μειονοτικών ομάδων κατά την αυτοματοποιημένη αξιολόγηση βιογραφικών, περιορίζουν τις πραγματικές ευκαιρίες αυτών των πληθυσμών, μειώνοντας τη μελλοντική τους εκπροσώπηση στο ψηφιακό οικοσύστημα.

Αυτή η συστημική αλλοίωση γεννά νέα, ήδη «μολυσμένα» (corrupted) δεδομένα. Όταν τα μελλοντικά μοντέλα μηχανικής μάθησης συλλέξουν αυτό το νέο ψηφιακό αποτύπωμα για την επανεκπαίδευσή τους, θα εκλάβουν τη μειωμένη εκπροσώπηση ως στατιστική κανονικότητα. Με αυτόν τον τρόπο, ο αρχικός πυρήνας της ανισότητας δεν διαιωνίζεται απλώς, αλλά μεγεθύνεται ανεξέλεγκτα, μετατρέποντας την αλγοριθμική μεροληψία σε μια αυτοεκπληρούμενη προφητεία (self-fulfilling prophecy). Συνεπώς, ο μετριασμός της προκατάληψης (bias mitigation) υπερβαίνει τα όρια του απλού καθαρισμού δεδομένων και αναδεικνύεται σε μια βαθιά κοινωνικοτεχνική πρόκληση.



Εικόνα 2.13: Ο κύκλος ανατροφοδότησης της αλγοριθμικής μεροληψίας, όπου τα μολυσμένα δεδομένα οδηγούν σε μεροληπτικές αποφάσεις, οι οποίες με τη σειρά τους παράγουν νέα προκατειλημμένα δεδομένα για μελλοντικά συστήματα

2.8.2 Παραισθήσεις των Μοντέλων (Hallucinations)

Η εξέλιξη των αρχιτεκτονικών Βαθιάς Μάθησης, με τη συμβολή των παραλλαγών των μοντέλων Transformer, έχει αναβαθμίσει την ικανότητα των υπολογιστικών συστημάτων να παράγουν ρέοντα και συντακτικά άρτιο φυσικό λόγο. Ωστόσο, η εντυπωσιακή αυτή πρόοδος επισκιάζεται από μια κρίσιμη εγγενή αδυναμία: την τάση των αλγορίθμων να «παραισθάνονται». Η ρίζα του προβλήματος εντοπίζεται στην ίδια τη λειτουργική φύση των σύγχρονων γλωσσικών μοντέλων. Καθώς λειτουργούν ως αμιγώς πιθανοθεωρητικές μηχανές (probabilistic engines) που υπολογίζουν στατιστικά το επόμενο λεκτικό σύμβολο (token), στερούνται πραγματικής σημασιολογικής αντίληψης και επαφής με τον φυσικό κόσμο (world grounding).


Όπως τεκμηριώνεται από τους Ji et al. (2023) [51], ως παραίσθηση (hallucination) ορίζεται το φαινόμενο κατά το οποίο ένα σύστημα συνθέτει κείμενο που είναι είτε νοηματικά ασυνάρτητο, είτε αναντίστοιχο (unfaithful) προς τα αρχικά δεδομένα εισόδου. Με απλά λόγια, το μοντέλο κατασκευάζει πληροφορίες που φαντάζουν πειστικές, αλλά είναι εντελώς αυθαίρετες.

Για την καλύτερη κατανόηση και τεχνική αντιμετώπιση αυτής της συμπεριφοράς, η σύγχρονη έρευνα έχει προχωρήσει στην κατηγοριοποίηση των αλγοριθμικών σφαλμάτων. Σύμφωνα με τους Maynez et al. [52] στον τομέα της παραγωγής κειμένου (όπως η αυτόματη περίληψη), οι παραισθήσεις διακρίνονται σε δύο βασικούς τύπους:

1. Εγγενής Παραίσθηση (Intrinsic Hallucination): Εμφανίζεται όταν η έξοδος του μοντέλου έρχεται σε ευθεία λογική αντίφαση με το κείμενο-πηγή (π.χ. αλλοίωση ενός ονόματος ή μιας ημερομηνίας που αναφέρεται ρητά).
2. Εξωγενής Παραίσθηση (Extrinsic Hallucination): Προκύπτει όταν το σύστημα εμπλουτίζει την απάντησή του με πρόσθετες, φαινομενικά αληθοφανείς λεπτομέρειες, οι οποίες όμως απουσιάζουν από τα δεδομένα εισόδου και είναι αδύνατον να επαληθευτούν (unverifiable additions).

Η εμφάνιση τέτοιων παραισθησιογόνων μοτίβων υποβαθμίζει την αξιοπιστία των αλγορίθμων, εγείροντας κρίσιμα ζητήματα ασφαλείας κατά την ενσωμάτωσή τους σε πραγματικές συνθήκες (real-world deployments). Ο κίνδυνος πολλαπλασιάζεται όταν τα μοντέλα αυτά εφαρμόζονται σε τομείς υψηλής κρισιμότητας (safety-critical domains), όπως η υγειονομική περίθαλψη. Για παράδειγμα, η παραγωγή μιας εσφαλμένης αυτόματης περίληψης για το ιατρικό ιστορικό ενός ασθενούς ή η αλλοιωμένη μηχανική μετάφραση κλινικών οδηγιών, εξαιτίας μιας εγγενούς παραίσθησης, δύναται να επιφέρει μη αναστρέψιμες συνέπειες.

Πέραν της ακρίβειας των πληροφοριών, η συγκεκριμένη δυσλειτουργία επεκτείνεται και στο ευαίσθητο πεδίο της προστασίας των προσωπικών δεδομένων. Όπως επισημαίνεται στη σχετική βιβλιογραφία, τα μεγάλα γλωσσικά μοντέλα τείνουν συχνά να «απομνημονεύουν» (memorize) θραύσματα από τον τεράστιο όγκο ανοιχτών δεδομένων στα οποία εκπαιδεύτηκαν. Υπό συγκεκριμένες συνθήκες αλληλεπίδρασης, ενδέχεται να ανακαλέσουν και να αποκαλύψουν αυθόρμητα άκρως εμπιστευτικές πληροφορίες (όπως διευθύνσεις, τηλεφωνικούς αριθμούς ή ηλεκτρονικά ταχυδρομεία) τις οποίες είχαν αφομοιώσει ακούσια. Η απρόβλεπτη ανάκτηση τέτοιων προσωπικών στοιχείων, ειδικά όταν αυτά δεν σχετίζονται με την αρχική προτροπή του χρήστη, συνιστά μια ακραία και εξωγενή μορφή παραίσθησης, η οποία παραβιάζει τα όρια της ιδιωτικότητας και τα σύγχρονα κανονιστικά πλαίσια.



Εικόνα 2.14: Παράδειγμα ταξινόμησης των παραισθήσεων κατά την παραγωγή κειμένου, αναδεικνύοντας τη διάκριση μεταξύ εγγενούς αλλοίωσης και εξωγενούς προσθήκης πληροφοριών

2.8.3 Ηθικά Ζητήματα και Τεχνολογικοί Περιορισμοί (Ethical Considerations and Limitations)

Η ταχεία ενσωμάτωση των Μεγάλων Γλωσσικών Μοντέλων (Large Language Models), τόσο των παραγωγικών (όπως οι διαλογικοί πράκτορες) όσο και των αναλυτικών (όπως οι αρχιτεκτονικές εξαγωγής πληροφορίας), έχει επιφέρει ριζικές αλλαγές στην αλληλεπίδραση ανθρώπου-μηχανής. Παρά ταύτα, όπως επισημαίνεται στη σχετική αρθρογραφία του Ray (2023) [47], η ραγδαία αυτή εξάπλωση αναδεικνύει κρίσιμα διλήμματα που υπερβαίνουν το τεχνικό επίπεδο.

Ένας από τους πρωταρχικούς προβληματισμούς αφορά την ευπάθεια αυτών των συστημάτων σε στοχευμένες κακόβουλες επιθέσεις (adversarial attacks). Παράλληλα, στους ακαδημαϊκούς κύκλους κυριαρχεί η ανησυχία για το λεγόμενο πρόβλημα της Διπλής Χρήσης (Dual-Use Dilemma). Εργαλεία Επεξεργασίας Φυσικής Γλώσσας τα οποία σχεδιάστηκαν αρχικά με αγαθά κίνητρα, όπως η ανάλυση συναισθήματος και η αναγνώριση οντοτήτων, δύναται να εργαλειοποιηθούν από αυταρχικά καθεστώτα για σκοπούς μαζικής παρακολούθησης (mass surveillance) ή για τη συστηματική παραγωγή παραπληροφόρησης. Καθίσταται, συνεπώς, επιτακτική η ανάγκη να βρεθεί η «χρυσή τομή» ανάμεσα στην τεχνολογική καινοτομία και την απαραίτητη ανθρώπινη εποπτεία.

Πέραν των αμιγώς ηθικών προκλήσεων, τα σύγχρονα συστήματα NLP καλούνται να υπερκεράσουν σημαντικούς δομικούς περιορισμούς προκειμένου να καταστούν πλήρως αξιόπιστα. Η ερευνητική κοινότητα υπογραμμίζει τη θεμελιώδη αδυναμία των αλγορίθμων να επιδείξουν πραγματική «κοινή λογική» (common sense reasoning) και συναισθηματική αντίληψη. Επιπροσθέτως, καταγράφονται σοβαρές δυσκολίες στη διαχείριση σημασιολογικών αμφισημιών (ambiguity), καθώς και στην επεξεργασία δεδομένων που αποκλίνουν σημαντικά από την αρχική κατανομή εκπαίδευσης (out-of-distribution queries). Η αδυναμία αυτή καθιστά τη συμπεριφορά των μοντέλων απρόβλεπτη όταν καλούνται να λειτουργήσουν σε νέα, άγνωστα περιβάλλοντα.

Πέρα από τα γνωστικά και λειτουργικά κενά, μια από τις πιο επιτακτικές, αλλά συχνά παραγνωρισμένες, διαστάσεις της σύγχρονης Επεξεργασίας Φυσικής Γλώσσας είναι το περιβαλλοντικό της αποτύπωμα. Όπως αναλύουν οι Schwartz et al. (2020) [53], η τάση της βιομηχανίας να εκπαιδεύει ολοένα και πιο ογκώδη μοντέλα, μια πρακτική που συχνά αποκαλείται "Red AI", απαιτεί τεράστιους υπολογιστικούς πόρους (όπως εκτεταμένες συστοιχίες GPU). Αυτό οδηγεί σε μια δραματική αύξηση της κατανάλωσης ενέργειας και των εκπομπών διοξειδίου του άνθρακα. Στο πλαίσιο αυτό, αναδεικνύεται η επιτακτική ανάγκη στροφής προς το

«Πράσινο AI» (Green AI), όπου η αξιολόγηση ενός αλγορίθμου δεν θα βασίζεται αποκλειστικά στην ακρίβειά του, αλλά εξίσου στην ενεργειακή του αποδοτικότητα.

Συμπερασματικά, η οριστική αντιμετώπιση αυτών των εμποδίων αποτελεί το βασικό διακύβευμα της μελλοντικής έρευνας. Προϋποθέτει τη μετάβαση από τη στείρα βελτιστοποίηση των συνόλων δεδομένων σε μια πιο ολιστική προσέγγιση, η οποία θα περιλαμβάνει την ανάπτυξη μηχανισμών παρακολούθησης (monitoring) και την προώθηση της υπολογιστικής βιωσιμότητας (sustainability). Μέσω αυτών των στοχευμένων παρεμβάσεων, η ερευνητική κοινότητα δεν στοχεύει απλώς στη δημιουργία ισχυρότερων συστημάτων, αλλά πρωτίστως στην ανάπτυξη εργαλείων που θα είναι ασφαλή, διαφανή και πραγματικά ωφέλιμα για το κοινωνικό σύνολο.



Εικόνα 2.15: Εννοιολογικός χάρτης (MindMap) που συνοψίζει τις τρεις κύριες κατηγορίες προκλήσεων κατά την ανάπτυξη και εφαρμογή σύγχρονων μοντέλων Επεξεργασίας Φυσικής Γλώσσας

2.9 Σύγχρονες Τάσεις: Μεγάλα Γλωσσικά Μοντέλα (Large Language Models)

Το τοπίο της Επεξεργασίας Φυσικής Γλώσσας έχει βιώσει τα τελευταία χρόνια μια άνευ προηγουμένου αλλαγή παραδείγματος (paradigm shift), μετατοπίζοντας το ερευνητικό βάρος από τις εξειδικευμένες, μεμονωμένες αρχιτεκτονικές σε μια νέα, ενοποιημένη γενιά αλγορίθμων. Στην αιχμή αυτής της τεχνολογικής επανάστασης βρίσκονται τα Μεγάλα Γλωσσικά Μοντέλα (Large Language Models - LLMs), τα οποία επαναπροσδιορίζουν τους μηχανισμούς με τους οποίους τα υπολογιστικά συστήματα κατανοούν, αναλύουν και παράγουν τον ανθρώπινο λόγο.

Όπως αναλύεται στη μελέτη των Bommasani et al. (2021) [54], τα δίκτυα αυτά εισάγουν στην ακαδημαϊκή βιβλιογραφία τον όρο των «Μοντέλων Θεμελίωσης» (Foundation Models). Η συγκεκριμένη ορολογία περιγράφει ογκώδη νευρωνικά δίκτυα τα οποία εκπαιδεύονται προκαταρκτικά (pre-trained) σε ασύλληπτες ποσότητες αδόμητων δεδομένων κειμένου (unlabeled web corpora) μέσω τεχνικών αυτο-εποπτευόμενης μάθησης (self-supervised learning). Η δομική τους καινοτομία έγκειται στο γεγονός ότι, αποκτώντας αυτή την τεράστια δεξαμενή γενικής γλωσσικής και πραγματολογικής γνώσης, καθίστανται ικανά να προσαρμοστούν (adapt) ταχύτατα σε μια ευρύτατη γκάμα ετερογενών υπολογιστικών προβλημάτων, λειτουργώντας πλέον ως ο κορμός για κάθε σύγχρονη NLP εφαρμογή.

Η θεαματική αυτή μετάβαση αναδιαμορφώνει πλήρως και τον ίδιο τον ρόλο του σύγχρονου ερευνητή ή μηχανικού δεδομένων. Αντί η υπολογιστική προσπάθεια να αναλώνεται αποκλειστικά στον σχεδιασμό και την εκπαίδευση εξειδικευμένων νευρωνικών δικτύων (task-specific networks) από το μηδέν, το επίκεντρο μετατοπίζεται πλέον στην αποτελεσματική επικοινωνία με το ήδη εκπαιδευμένο μοντέλο και τη στοχευμένη καθοδήγησή του. Αυτή η νέα

πραγματικότητα προάγει τον εκδημοκρατισμό της πρόσβασης σε προηγμένα εργαλεία Τεχνητής Νοημοσύνης, αλλά ταυτόχρονα γεννά ερωτήματα σχετικά με την αξιοπιστία, την ακρίβεια και τα όρια αυτών των αρχιτεκτονικών.

Προκειμένου να αποτυπωθεί πλήρως ο αντίκτυπος αυτής της εξέλιξης στο ευρύτερο οικοσύστημα του NLP, στις υποενότητες που ακολουθούν επιχειρείται μια εις βάθος θεωρητική ανάλυση. Συγκεκριμένα, ιχνηλατείται η τεχνολογική μετάβαση προς τις αρχιτεκτονικές Transformer (2.9.1), αναλύονται οι αναδυόμενες πρακτικές της Μάθησης Μηδενικής Βολής (Zero-Shot Learning) και της Μηχανικής Προτροπών (Prompt Engineering) (2.9.2), και τέλος, διερευνάται κριτικά το παράδοξο της γενίκευσης (2.9.3), αντιπαραβάλλοντας την ευελιξία των πολυδύναμων αυτών συστημάτων με την ανάγκη για εξειδίκευση.

2.9.1 Από τα Συμβατικά Μοντέλα στις Αρχιτεκτονικές Transformer


Η μετάβαση στο σύγχρονο επίπεδο γλωσσικής επεξεργασίας δεν προέκυψε εν κενώ, αλλά κατέστη εφικτή χάρη στη σταδιακή εγκατάλειψη των παραδοσιακών αναδρομικών αρχιτεκτονικών. Όπως περιγράφουν οι Shakil et al. (2024) [55], η τεχνολογική βαρύτητα μετατοπίστηκε αποφασιστικά από τα συμβατικά μοντέλα Ακολουθίας-προς-Ακολουθία (Sequence-to-Sequence / Seq2Seq) στις προηγμένες αρχιτεκτονικές Transformer.

Το κομβικό σημείο αυτής της εξέλιξης, το οποίο θεμελιώθηκε από τους Vaswani et al. (2017) [25] με την εισαγωγή του Μηχανισμού Προσοχής (Self-Attention), έγκειται στον τρόπο διαχείρισης της πληροφορίας. Αντίθετα με τα παλαιότερα νευρωνικά δίκτυα που επεξεργάζονταν το κείμενο αυστηρά γραμμικά (λέξη προς λέξη), ο μηχανισμός προσοχής επιτρέπει στο σύστημα να αξιολογεί ταυτόχρονα όλες τις λέξεις μιας πρότασης, σταθμίζοντας μαθηματικά τη σημασιολογική τους αλληλεξάρτηση. Αυτή η ικανότητα παράλληλης επεξεργασίας (parallelization) όχι μόνο εξάλειψε το πρόβλημα της απώλειας πληροφορίας σε μακροσκελή κείμενα, αλλά άνοιξε τον δρόμο για την αποτελεσματική εκπαίδευση μοντέλων μεγάλου μεγέθους.

Ως αποτέλεσμα, σύγχρονα συστήματα θεμελίωσης, όπως οι γνωστές οικογένειες GPT, BERT και T5, διαθέτουν πλέον την ικανότητα να αποκωδικοποιούν το βαθύτερο νοηματικό συγκείμενο (context). Κατ' επέκταση, δύνανται να φέρουν εις πέρας σύνθετες γλωσσικές διεργασίες, όπως η ανάλυση συναισθήματος και η εξαγωγή οντοτήτων, επιτυγχάνοντας γραμματική αρτιότητα και ρέουσα αφήγηση.

Η ουσιαστική τομή που επέφεραν οι αρχιτεκτονικές αυτές εντοπίζεται στην πλήρη ενοποίηση των γλωσσικών εργασιών (task unification). Στο παραδοσιακό παράδειγμα της μηχανικής μάθησης, η επίλυση διαφορετικών προβλημάτων, όπως η εξαγωγή πληροφοριών, η ανάλυση συναισθηματικής πολικότητας και η δημιουργία συνόψεων, απαιτούσε τον σχεδιασμό, την εξαντλητική εκπαίδευση και τη συντήρηση εντελώς ξεχωριστών, εξειδικευμένων μοντέλων.

Αντιθέτως, τα σύγχρονα Μεγάλα Γλωσσικά Μοντέλα λειτουργούν πλέον ως καθολικοί επεξεργαστές (universal processors). Μέσω της τεράστιας κλίμακας της προ-εκπαίδευσής τους, συγκεντρώνουν όλη την απαιτούμενη στατιστική και σημασιολογική γνώση σε ένα αυστηρά ενιαίο νευρωνικό δίκτυο. Αυτή η δομική απλοποίηση μετασχηματίζει την παραδοσιακή ροή εργασίας (pipeline) της Επεξεργασίας Φυσικής Γλώσσας, αντικαθιστώντας τα πολλαπλά, κατακερματισμένα στάδια εκπαίδευσης με μια κεντρική αρχιτεκτονική η οποία καθοδηγείται δυναμικά από τον χρήστη, όπως αποτυπώνεται οπτικά στο διάγραμμα που ακολουθεί.



Εικόνα 2.16: Σχηματική σύγκριση μεταξύ του παραδοσιακού παραδείγματος εξειδικευμένων μοντέλων (task-specific) και της σύγχρονης προσέγγισης των Μοντέλων Θεμελίωσης (LLMs), όπου μια ενιαία αρχιτεκτονική εξυπηρετεί πολλαπλές εργασίες NLP

2.9.2 Αναδυόμενες Ικανότητες: Μάθηση Μηδενικής Βολής (Zero-Shot Learning) και Μηχανική Προτροπών (Prompt Engineering)

Η αύξηση του μεγέθους των σύγχρονων νευρωνικών δικτύων δεν επέφερε απλώς μια ποσοτική βελτίωση στις μετρικές αξιολόγησης, αλλά πυροδότησε μια βαθιά ποιοτική μετάβαση, οδηγώντας στην εμφάνιση των λεγόμενων «αναδυόμενων ικανοτήτων» (emergent abilities). Το σημαντικότερο χαρακτηριστικό αυτής της νέας γενιάς αλγορίθμων, το οποίο ανατρέπει τα παραδοσιακά δεδομένα της μηχανικής μάθησης, είναι η απομάκρυνση από την ανάγκη για εξειδικευμένη μικρο-ρύθμιση (fine-tuning).

Ενώ οι προγενέστερες αρχιτεκτονικές απαιτούσαν τη χρονοβόρα συλλογή και τροφοδότηση χιλιάδων επισημειωμένων παραδειγμάτων (labeled data) για να εκπαιδευτούν σε μία και μόνο, απομονωμένη διεργασία, τα Μεγάλα Γλωσσικά Μοντέλα εισάγουν το παράδειγμα της μάθησης εντός συγκειμένου (in-context learning). Όπως τεκμηριώθηκε από τους Brown et al. (2020) [56] κατά την παρουσίαση της αρχιτεκτονικής GPT-3, ένα δίκτυο με επαρκή κλίμακα παραμέτρων αποκτά την εγγενή ικανότητα της μάθησης μηδενικής βολής (zero-shot learning).


Αυτό σημαίνει ότι το υπολογιστικό σύστημα είναι σε θέση να κατανοήσει και να επιλύσει εντελώς άγνωστα προβλήματα, όπως η ανάλυση συναισθηματικής πολικότητας ή η εξαγωγή συγκεκριμένων οντοτήτων, καθώς δέχεται αποκλειστικά λεκτικές οδηγίες σε φυσική γλώσσα, χωρίς να απαιτείται καμία απολύτως αναπροσαρμογή στα εσωτερικά συναπτικά του βάρη (weight updates). Με αυτόν τον τρόπο, ο αλγόριθμος αξιοποιεί την αχανή δεξαμενή προ-εκπαιδευμένης γνώσης του για να γενικεύσει απευθείας σε νέες, μη θεαθείσες (unseen) καταστάσεις.

Πάνω σε αυτό το θεωρητικό υπόβαθρο, η μελέτη των Kocsoh et al. (2023) [57] αναδεικνύει την ευελιξία των μοντέλων γενικού σκοπού (όπως το ChatGPT) σε ρεαλιστικές συνθήκες. Σύμφωνα με τα ευρήματά τους, τα συστήματα αυτά μπορούν να εκτελέσουν απαιτητικές διεργασίες, όπως η παραγωγή μιας εις βάθος αυτόματης περίληψης (zero-shot summarization), επιτυγχάνοντας επιδόσεις που συχνά προσεγγίζουν ή και ανταγωνίζονται εκείνες των ειδικά σχεδιασμένων αλγορίθμων.

Ωστόσο, για την πλήρη αξιοποίηση αυτών των λανθανουσών ικανοτήτων, ο ρόλος του μηχανικού δεδομένων μεταβάλλεται ριζικά. Η ερευνητική έμφαση δεν δίνεται πλέον στον σχεδιασμό πολύπλοκων μαθηματικών αρχιτεκτονικών, αλλά στη Μηχανική Προτροπών (Prompt

Engineering). Πρόκειται για την τέχνη της στρατηγικής και σημασιολογικής διατύπωσης της εντολής, με στόχο να «ξεκλειδωθεί» η βέλτιστη δυνατή απόκριση από το γλωσσικό μοντέλο.

Επιπροσθέτως, όταν η μηδενική βολή δεν επαρκεί για την επίλυση ενός εξαιρετικά εξειδικευμένου ή διφορούμενου προβλήματος, η σύγχρονη πρακτική επιτάσσει τη μετάβαση στη μάθηση ελάχιστων παραδειγμάτων (few-shot learning). Σε αυτή την περίπτωση, ο χρήστης ενσωματώνει στο κείμενο της προτροπής ένα μικρό, αντιπροσωπευτικό σύνολο παραδειγμάτων (ζεύγη εισόδου-εξόδου). Η τακτική αυτή παρέχει στο δίκτυο ένα άμεσο, αναγνωρίσιμο πρότυπο (pattern) προς μίμηση, αυξάνοντας κατακόρυφα την ακρίβεια της τελικής πρόβλεψης, χωρίς εκ νέου κοστοβόρες διαδικασίες εκπαίδευσης.



Εικόνα 2.17: Πρακτική σύγκριση των τεχνικών Μηδενικής Βολής (Zero-Shot) και Ελάχιστων Παραδειγμάτων (Few-Shot) κατά την καθοδήγηση ενός Μεγάλου Γλωσσικού Μοντέλου σε εργασία ανάλυσης συναισθήματος

2.9.3 Το Παράδοξο της Γενίκευσης: Ευελιξία έναντι Εξειδίκευσης

Παρά τον εύλογο ενθουσιασμό που συνοδεύει την ικανότητα των Μεγάλων Γλωσσικών Μοντέλων να προσαρμόζονται σε ετερόκλητα προβλήματα μέσω της μηδενικής βολής, η ακαδημαϊκή κοινότητα προσεγγίζει τη συγκεκριμένη καθολικότητα με επιστημονικό σκεπτικισμό. Η βίαιη μετάβαση από τα στενά καθορισμένα νευρωνικά δίκτυα στα υπερ-συστήματα γενικού σκοπού αναδεικνύει ένα θεμελιώδες ερευνητικό ζήτημα, το οποίο πλέον χαρακτηρίζεται ως το «παράδοξο της γενίκευσης» (paradox of generalization).


Σύμφωνα με τους Kocoh et al. (2023) [57], παραγωγικά μοντέλα όπως το ChatGPT συμπεριφέρονται πρακτικά ως «πολυτεχνίτες» (Jack of all trades). Μολονότι επιδεικνύουν την πρωτοφανή ευελιξία να διαχειρίζονται ταυτόχρονα πλήθος διαφορετικών διεργασιών Επεξεργασίας Φυσικής Γλώσσας, η τελική τους επίδοση υπολείπεται αισθητά όταν αντιπαραβάλλεται με στοχευμένες αρχιτεκτονικές. Ειδικότερα, η έρευνα καταδεικνύει ότι η απουσία ειδικής μικρο-ρύθμισης (fine-tuning) οδηγεί σε μια μέση πτώση της ποιότητας των προβλέψεων της τάξης του 25% συγκριτικά με τα τρέχοντα State-of-the-Art (SOTA) συστήματα, τα οποία έχουν εκπαιδευτεί αποκλειστικά για έναν διακριτό σκοπό.

Η συγκεκριμένη υστέρηση καθίσταται ιδιαίτερα κρίσιμη σε απαιτητικές εργασίες επιπέδου λέξης, όπως η Αναγνώριση Ονοματισμένων Οντοτήτων (NER), η οποία αποτελεί και κεντρικό πυλώνα της παρούσας πτυχιακής εργασίας. Σύμφωνα με τους Qin et al. (2023) [58], οι οποίοι αξιολόγησαν τις δυνατότητες των LLMs ως καθολικών μέσων επίλυσης προβλημάτων, αποδείχθηκε ότι οι παραγωγικές αρχιτεκτονικές υστερούν σε εργασίες χαρακτηρισμού ακολουθιών (sequence tagging). Ενώ αριστεύουν σε διεργασίες μετάφρασης και σύνοψης,

αδυνατούν να αγγίξουν τα κορυφαία επίπεδα ακρίβειας εξειδικευμένων κωδικοποιητών (όπως τα μοντέλα BERT και RoBERTa) στον ακριβή εντοπισμό και τη σημασιολογική ταξινόμηση οντοτήτων.

Πέρα από το θεμελιώδες ζήτημα της ακρίβειας, η ενσωμάτωση παραγωγικών μοντέλων σε διεργασίες εξόρυξης εγκυμονεί τον κίνδυνο των παραισθήσεων (hallucinations), ένα φαινόμενο που αναλύθηκε στην Ενότητα 2.8.2. Καθώς τα συστήματα αυτά είναι εγγενώς σχεδιασμένα να παράγουν ρέοντα, συνεκτικό λόγο, ενδέχεται να επινοήσουν ανύπαρκτες οντότητες ή να αλλοιώσουν τα πραγματικά δεδομένα της εισόδου. Σε αντίθεση με τους εξειδικευμένους ταξινομητές, οι οποίοι επιλέγουν αυστηρά από ένα προκαθορισμένο σύνολο ετικετών (closed-set classification), τα LLMs λειτουργούν με ανοιχτό λεξιλόγιο (open-ended generation), γεγονός που καθιστά τον συστηματικό έλεγχο των σφαλμάτων τους δυσχερή.

Παράλληλα, ανακύπτει ένα κρίσιμο ζήτημα υπολογιστικής αποδοτικότητας και βιωσιμότητας. Η κλήση ενός μοντέλου δισεκατομμυρίων παραμέτρων για την απλή αναγνώριση ονομάτων, οργανισμών ή τοποθεσιών μέσα σε ένα κείμενο συνιστά σπατάλη πόρων, επιβεβαιώνοντας τους προβληματισμούς περί «Red AI» (Ενότητα 2.8.3). Συνεπώς, στον πυρήνα του σύγχρονου NLP διαμορφώνεται μια σαφής σχέση αντιστάθμισης (trade-off) ανάμεσα στην απόλυτη προσαρμοστικότητα των συστημάτων γενικού σκοπού και τη μέγιστη αξιοπιστία, ταχύτητα και ασφάλεια των στοχευμένων αρχιτεκτονικών, όπως σχηματοποιείται στο διάγραμμα που ακολουθεί.



Εικόνα 2.18: Η σχέση αντιστάθμισης (trade-off) ανάμεσα στα Μεγάλα Γλωσσικά Μοντέλα γενικού σκοπού και τις εξειδικευμένες αρχιτεκτονικές, αποτυπώνοντας τα πλεονεκτήματα και τους περιορισμούς κάθε προσέγγισης

Κεφάλαιο 3: Μεθοδολογία

3.1 Εισαγωγή

Το παρόν κεφάλαιο σηματοδοτεί την κρίσιμη μετάβαση από τη θεωρητική τεκμηρίωση στην πρακτική εφαρμογή. Ο κεντρικός άξονας του πειραματικού σκέλους της παρούσας εργασίας επικεντρώνεται στον μεθοδολογικό σχεδιασμό, την προγραμματιστική υλοποίηση και την συγκριτική αξιολόγηση ετερογενών υπολογιστικών προσεγγίσεων.

Το ερευνητικό ενδιαφέρον εστιάζεται στην εμπειρική επίλυση τριών θεμελιωδών και απαιτητικών γλωσσικών προβλημάτων: της Αυτόματης Περίληψης (Text Summarization), της Αναγνώρισης Ονοματισμένων Οντοτήτων (Named Entity Recognition - NER) και της Ανάλυσης Συναισθήματος (Sentiment Analysis). Για την αντικειμενική διεξαγωγή του πειράματος, υιοθετήθηκε μια δομημένη εκτελεστική ροή (experimental pipeline), η οποία θωρακίζει τη διαδικασία και επιτρέπει την ασφαλή εξαγωγή αξιόπιστων συμπερασμάτων.

Στις υποενότητες που ακολουθούν, χαρτογραφείται βήμα προς βήμα η αρχιτεκτονική της προτεινόμενης λύσης. Αρχικά, προσδιορίζεται το ακριβές αντικείμενο της μελέτης και αναλύονται τα δομικά χαρακτηριστικά του συνόλου δεδομένων (dataset), το οποίο λειτουργεί ως το κεντρικό πεδίο δοκιμών των αλγορίθμων. Στη συνέχεια, παρατίθενται τα απαιτούμενα στάδια προεπεξεργασίας και εξυγίανσης (text preprocessing) του φυσικού λόγου. Η συγκεκριμένη φάση κρίνεται κομβικής σημασίας για την ελαχιστοποίηση του στατιστικού θορύβου και την εξασφάλιση της βέλτιστης δυνατής ποιότητας πληροφορίας που τροφοδοτεί τα συστήματα.

Ακολούθως, αναλύεται και τεκμηριώνεται η στρατηγική επιλογή των εργαλείων Μηχανικής και Βαθιάς Μάθησης που επιστρατεύτηκαν για την αντιμετώπιση του εκάστοτε γλωσσικού προβλήματος (tasks). Τέλος, το παρόν κεφάλαιο ολοκληρώνεται με την παρουσίαση της τεχνολογικής στοίβας (tech stack). Ειδικότερα, καταγράφονται το υπολογιστικό περιβάλλον ανάπτυξης, η γλώσσα προγραμματισμού και οι εξειδικευμένες βιβλιοθήκες ανοιχτού κώδικα που κατέστησαν εφικτή τη συγγραφή του κώδικα (scripts) και την αξιόπιστη εξαγωγή των τελικών μετρικών απόδοσης.

3.2 Σκοπός και Αντικείμενο της Πειραματικής Διαδικασίας

Ο προτεινόμενος πειραματικός σχεδιασμός αναπτύχθηκε με κεντρικό άξονα τη συστηματική σύζευξη του θεωρητικού υποβάθρου της Μηχανικής Μάθησης με τις πραγματικές, βιομηχανικές προκλήσεις που υπαγορεύει η σύγχρονη Επεξεργασία Φυσικής Γλώσσας (NLP). Βασική επιδίωξη της παρούσας εργασίας συνιστά η εμπειρική αξιολόγηση και η κριτική αντιπαράβολή ετερογενών αλγοριθμικών αρχιτεκτονικών. Μέσω αυτής της μεθοδολογίας, εξετάζεται η υπολογιστική τους αποδοτικότητα (computational efficiency) και η προσαρμοστικότητά τους κατά τη διαχείριση πραγματικών, αδόμητων δεδομένων (real-world unstructured data).

Ως ιδανικό πειραματικό πεδίο δοκιμών (testbed) επιστρατεύτηκε ένα εκτενές σώμα αγγλόφωνων ειδησεογραφικών κειμένων (news corpora). Τα συγκεκριμένα άρθρα διακρίνονται παραδοσιακά για την πληθώρα πληροφοριών τους, το πλούσιο και συχνά εξειδικευμένο λεξιλόγιο, καθώς και για τη συντακτική τους πολυπλοκότητα.

Αυτά ακριβώς τα δομικά στοιχεία διαμορφώνουν το πλέον απαιτητικό, αλλά και αντιπροσωπευτικό, περιβάλλον για την ταυτόχρονη προσέγγιση τριών διακριτών, πλην όμως στενά αλληλένδετων, υπολογιστικών προβλημάτων: της Αναγνώρισης Ονοματισμένων Οντοτήτων, της Αυτόματης Περίληψης και της Ανάλυσης Συναισθήματος. Όπως τεκμηριώνεται από τον Tu (2024) [59], η συνδυαστική εφαρμογή της αναγνώρισης οντοτήτων και της παρακολούθησης της συναισθηματικής οπτικής γωνίας (emotional viewpoint) σε δεδομένα διαδικτυακών ειδήσεων αποτελεί ένα από τα πιο κρίσιμα benchmarks για τα σύγχρονα μοντέλα τεχνητής νοημοσύνης.


Η ενασχόληση με τα προαναφερθέντα πεδία δεν εξαντλείται στη μεμονωμένη επίλυσή τους, αλλά συνθέτει ένα ολοκληρωμένο πλαίσιο δοκιμών για την εξαγωγή ποσοτικών και ποιοτικών ευρημάτων. Απώτερος σκοπός της παρούσας μελέτης είναι να υπερβεί τη στείρα εκτέλεση υπολογιστικού κώδικα (script execution) και να προχωρήσει σε μια συγκριτική ανάλυση (comparative analysis). Μέσα από αυτή τη διαδικασία, επιχειρείται η χαρτογράφηση των υπολογιστικών ορίων ανάμεσα στις παραδοσιακές προσεγγίσεις, όπως τα συστήματα βασισμένα σε κανόνες (rule-based baselines), και τα υπερσύγχρονα νευρωνικά δίκτυα Βαθιάς Μάθησης (Deep Learning).

Επομένως, η παρούσα έρευνα φιλοδοξεί να καταδείξει ποια αρχιτεκτονική ανταποκρίνεται με τη μέγιστη αξιοπιστία στις αυξημένες απαιτήσεις των σύγχρονων βιομηχανικών εφαρμογών (industry-standard applications), καθώς ευθυγραμμίζεται με τις πρόσφατες μελέτες που εξετάζουν τον αντίκτυπο του NLP στη λήψη αποφάσεων [60]. Μέσα από αυτή τη σύγκριση, θα δοθούν ουσιαστικές απαντήσεις στο ερώτημα εάν η υπολογιστική πολυπλοκότητα των νεότερων εργαλείων μεταφράζεται σε αναλογικά ανώτερη απόδοση στο πεδίο.

3.3 Περιγραφή και Ανάλυση Δεδομένων (Dataset Description)

Η άρτια διεξαγωγή και εγκυρότητα κάθε πειραματικής διαδικασίας στον τομέα της Μηχανικής Μάθησης προϋποθέτει, την επιλογή ενός αξιόπιστου και ποιοτικού συνόλου δεδομένων. Υπό αυτό το πρίσμα, για την εμπειρική αξιολόγηση των αναπτυχθέντων υποσυστημάτων προκρίθηκε το «BBC News Dataset». Το συγκεκριμένο σύνολο συνιστά ένα διαχρονικό και ευρέως αποδεκτό σημείο αναφοράς (benchmark dataset) στην ακαδημαϊκή έρευνα της Επεξεργασίας Φυσικής Γλώσσας. Όπως τεκμηριώνεται στην αρχική δημοσίευση των Greene & Cunningham (2006) [61], το αντίστοιχο σώμα κειμένων (text corpus) αντλήθηκε απευθείας από τον επίσημο ιστότοπο του βρετανικού ειδησεογραφικού δικτύου BBC (καλύπτοντας την περίοδο 2004-2005) και συγκεντρώνει συνολικά 2.225 πλήρη, αυτούσια δημοσιογραφικά άρθρα.

Ένα από τα ισχυρότερα πλεονεκτήματα του επιλεγμένου δείγματος είναι η δομική του αρτιότητα, σε συνδυασμό με την υψηλή θεματική του ποικιλομορφία (topic diversity). Τα αδόμητα κείμενα είναι αυστηρά ταξινομημένα σε πέντε διακριτές κατηγορίες, καλύπτοντας ένα αντιπροσωπευτικό φάσμα της επικαιρότητας. Ειδικότερα, το σώμα απαρτίζεται από άρθρα που αφορούν τον Αθλητισμό (Sport: 511), τις Επιχειρήσεις και την Οικονομία (Business: 510), την Πολιτική (Politics: 417), την Τεχνολογία (Tech: 401) και τη Διασκέδαση (Entertainment: 386). Η συγκεκριμένη, σχεδόν ισομερής κατανομή των εγγραφών ανά κατηγορία (class balance) κρίνεται ζωτικής σημασίας. Διασφαλίζει ότι τα νευρωνικά δίκτυα δεν θα αναπτύξουν αλγοριθμική μεροληψία (bias) ή στατιστική προτίμηση υπέρ μιας κυρίαρχης θεματολογίας, αποτρέποντας έτσι φαινόμενα υπερπροσαρμογής (overfitting) και προστατεύοντας τη γενικευτική ικανότητα του συστήματος [62].



Εικόνα 3.1: Κατανομή πλήθους άρθρων ανά θεματική κατηγορία στο σύνολο δεδομένων BBC News. Παρατηρείται η σχεδόν ισομερής αντιπροσώπευση (class balance) των εγγραφών.

Πέραν της στατιστικής ισορροπίας, η ίδια η υφολογία που αφορά τον δημοσιογραφικό λόγο εναρμονίζεται πλήρως με τις τεχνικές απαιτήσεις των τριών κεντρικών ερευνητικών αξόνων της παρούσας μελέτης:

1. **Αναγνώριση Ονοματισμένων Οντοτήτων (NER):** Η ειδησεογραφική γραφή συνδέεται με πληθώρα πληροφοριών και συνεχείς αναφορές σε πραγματικά πρόσωπα (π.χ. πολιτικούς ηγέτες, αθλητές), γεωγραφικές τοποθεσίες και θεσμικούς φορείς. Η αφθονία αυτών των στοιχείων καθιστά το αντίστοιχο σύνολο δεδομένων ένα ιδανικό οικοσύστημα (ideal testbed) για την εξόρυξη και σημασιολογική ταξινόμηση δομημένης γνώσης.
2. **Αυτόματη Περίληψη (Text Summarization):** Η ανάπτυξη των ρεπορτάζ σε πολλαπλές παραγράφους, προσφέρει το απαραίτητο υπόβαθρο για την αξιολόγηση παραγωγικών γλωσσικών μοντέλων. Τα άρθρα αυτά αποτελούν δείγματα για τη δοκιμή αλγορίθμων που καλούνται να επιτύχουν νοηματική συμπίκνωση (semantic condensation), φιλτράροντας αποτελεσματικά την πλεονάζουσα πληροφορία (redundancy) χωρίς να αλλοιώνεται το κεντρικό μήνυμα, όπως επισημαίνουν και οι Ma et al. (2022) [63]
3. **Ανάλυση Συναισθήματος (Sentiment Analysis):** Παρά τον κώδικα δημοσιογραφικής δεοντολογίας, στο πλαίσιο του οποίου επιτάσσεται η αντικειμενικότητα, τα κείμενα χαρακτηρίζονται από μια υποβόσκουσα συναισθηματική πολικότητα (underlying polarity) [64]. Για παράδειγμα, η αθλητική αρθρογραφία χαρακτηρίζεται από συναισθηματικά φορτισμένες λέξεις, οι οποίες έχουν συχνά θετικό πρόσημο, ενώ, στον αντίποδα, οι αναφορές σε υφέσεις των αγορών ή έντονες πολιτικές αντιπαραθέσεις εκπέμπουν εντονότερη αρνητικότητα.

Αξιοποιώντας, επομένως, αυτό το πολυδιάστατο και ρεαλιστικό σώμα κειμένων, εξασφαλίζεται η αρτιότητα της πειραματικής διαδικασίας. Διασφαλίζεται ότι οι αλγόριθμοι δεν θα αξιολογηθούν σε αποστειρωμένα, τεχνητά περιβάλλοντα, αλλά θα κληθούν να ανταπεξέλθουν σε συνθήκες που ομοιάζουν με τις πραγματικές, βιομηχανικές προκλήσεις (real-world industry challenges) της σύγχρονης Επεξεργασίας Φυσικής Γλώσσας.

3.4 Προεπεξεργασία και Καθαρισμός Δεδομένων (Data Preprocessing)

Εξαιτίας της εγγενώς αδόμητης φύσης και της υψηλής εντροπίας που χαρακτηρίζει τον δημοσιογραφικό λόγο, η απευθείας εισαγωγή των ακατέργαστων κειμενικών δεδομένων (raw data) σε αλγορίθμους Μηχανικής Μάθησης κρίνεται υπολογιστικά δαπανηρή και αλγοριθμικά αναποτελεσματική. Για την αντιμετώπιση αυτού του προβλήματος, σχεδιάστηκε και εφαρμόστηκε μια σειριακή ροή προεπεξεργασίας (preprocessing pipeline). Πρωταρχικός στόχος αυτής της αλγοριθμικής διασωλήνωσης είναι η δραστική εξάλειψη του περιττού γλωσσικού θορύβου και η ταυτόχρονη ανάδειξη των ουσιαστικών, πληροφοριακά πυκνών χαρακτηριστικών του δείγματος.

Η κρισιμότητα αυτού του προπαρασκευαστικού σταδίου τεκμηριώνεται στη σύγχρονη βιβλιογραφία, με χαρακτηριστικό παράδειγμα την έρευνα των Uysal & Gunal (2014) [65]. Σύμφωνα με τα ευρήματά τους, αλλά και σε απόλυτη συμφωνία με την μελέτη των Siino et al. (2024) [66], η ορθή και στοχευμένη εφαρμογή τεχνικών καθαρισμού (data cleansing) όχι μόνο μειώνει αισθητά τη διαστατικότητα (dimensionality reduction) του διανυσματικού χώρου των δεδομένων, αλλά παραμένει καθοριστικής σημασίας για τη μεγιστοποίηση της απόδοσης ακόμη και των πλέον σύγχρονων μοντέλων αρχιτεκτονικής Transformer. Έχοντας ως θεωρητικό υπόβαθρο αυτή τη διαπίστωση, η διαδικασία εξυγίανσης που εφαρμόστηκε στο ειδησεογραφικό σώμα του BBC News δομήθηκε πάνω στα εξής διακριτά στάδια:

- **Κανονικοποίηση (Text Normalization):** Περιλαμβάνει τη μετατροπή του συνόλου των χαρακτήρων σε πεζή γραφή (lowercasing) και τη συστηματική αφαίρεση ειδικών συμβόλων, αριθμητικών ψηφίων και σημείων στίξης. Αυτό το βήμα εγγυάται την


απόλυτη μορφολογική ομοιομορφία του λεξιλογίου, αποτρέποντας την εσφαλμένη πολλαπλή αναπαράσταση της ίδιας λέξης εξαιτίας της χρήσης κεφαλαίων γραμμάτων.

- **Τεμαχισμός (Tokenization):** Συνίσταται στη στοχευμένη διάσπαση των αδόμητων προτάσεων σε μεμονωμένες, διακριτές λεκτικές μονάδες (tokens). Η διαδικασία αυτή μετατρέπει το συνεχές κείμενο σε μια δομή δεδομένων άμεσα προσπελάσιμη για αλγοριθμική ανάλυση.
- **Απομάκρυνση Λέξεων Κενού Περιεχομένου (Stop-word Removal):** Εφαρμόζεται αυστηρό φιλτράρισμα για τη διαγραφή όρων που παρουσιάζουν εξαιρετικά υψηλή συχνότητα εμφάνισης, στερούνται όμως ουσιαστικής σημασιολογικής αξίας (όπως άρθρα, προθέσεις και αναφορικοί σύνδεσμοι). Μέσω αυτού του αποκλεισμού, τα μοντέλα εξωθούνται να εστιάσουν αποκλειστικά στις λέξεις-κλειδιά (keywords) που φέρουν το πραγματικό νοηματικό βάρος της είδησης.
- **Λημματοποίηση (Lemmatization):** Αφορά την αναγωγή των κλιτών λέξεων στην αρχική, λεξικογραφική τους μορφή (λήμμα), λαμβάνοντας υπόψη το πλήρες μορφολογικό και συντακτικό τους πλαίσιο. Η συγκεκριμένη τεχνική προτιμήθηκε έναντι της απλοϊκότερης ριζοτόμησης (stemming), με σκοπό τη διαφύλαξη της νοηματικής ακεραιότητας. Η προσέγγιση αυτή επιβάλλεται σε επίπεδο μεθοδολογίας λόγω της αναγκαιότητας κάλυψης των αυξημένων απαιτήσεων του υποσυστήματος Αναγνώρισης Ονοματισμένων Οντοτήτων (NER), γεγονός που επιβεβαιώνεται και από την μελέτη των Jabbar et al. (2023) [67].

Η επιτυχής ολοκλήρωση της προαναφερθείσας αλυσίδας μετασχηματισμών είχε ως τελικό αποτέλεσμα την παραγωγή ενός αυστηρά δομημένου και απαλλαγμένου από στατιστικό θόρυβο συνόλου δεδομένων. Το βελτιστοποιημένο αυτό corpus καθίσταται πλέον έτοιμο να τροφοδοτήσει τις προηγμένες νευρωνικές αρχιτεκτονικές που αναλύονται στην επόμενη ενότητα, αποτελώντας, όπως υπογραμμίζουν και οι Krishna et al. (2025) [68], το θεμέλιο για την αποδοτική εφαρμογή μοντέλων Βαθιάς Μάθησης στην ειδησεογραφική ανάλυση.

3.5 Επιλογή Μοντέλων και Αρχιτεκτονική (Model Selection & Architecture)

Η επιτυχής μετάβαση από το προπαρασκευαστικό στάδιο της προεπεξεργασίας των δεδομένων στον αλγοριθμικό πυρήνα της πειραματικής διάταξης, επιβάλλει τη στρατηγική επιλογή των κατάλληλων υπολογιστικών εργαλείων. Η συγκρότηση της τεχνολογικής στοίβας (technology stack) δεν υπήρξε αυθαίρετη, αλλά αποτέλεσε προϊόν αυστηρού αρχιτεκτονικού σχεδιασμού. Κύριος γνώμονας υπήρξε η βέλτιστη και πλέον αποδοτική επίλυση των τριών διακριτών ερευνητικών ζητούμενων: της Αναγνώρισης Ονοματισμένων Οντοτήτων, της Ανάλυσης Συναισθήματος και της Αυτόματης Περίληψης.



Εικόνα 3.2: Συνολική Αρχιτεκτονική του Προτεινόμενου Συστήματος. Απεικονίζεται η ροή των δεδομένων από το αρχικό dataset, τα στάδια προεπεξεργασίας, οι τρεις διακριτοί ερευνητικοί άξονες και η τελική εξαγωγή συμπερασμάτων.

Προς επίτευξη αυτού του στόχου, η συνολική αρχιτεκτονική του συστήματος (system architecture) θεμελιώθηκε πάνω στους εξής τρεις πυλώνες μεθοδολογίας:

- Εξειδίκευση ανά Πρόβλημα (Task-specific suitability):** Αναγνωρίζοντας την απουσία ενός «πανάκειου» αλγορίθμου (silver bullet) ικανού να διαχειριστεί ομοίμορφα όλες τις ετερογενείς γλωσσικές διεργασίες, κρίθηκε αναγκαία η υιοθέτηση μιας κατηγοριοποιημένης προσέγγισης. Ως εκ τούτου, εγκαταλείφθηκε η λογική της «μίας λύσης για όλα» και επιλέχθηκαν τα πλέον ενδεδειγμένα εργαλεία, απόλυτα προσαρμοσμένα στις εγγενείς μαθηματικές και σημασιολογικές απαιτήσεις του εκάστοτε επιμέρους NLP προβλήματος, μια στρατηγική που επιβεβαιώνεται από τους Min et al. (2023) [3] γύρω από τις εξειδικευμένες αρχιτεκτονικές των σύγχρονων γλωσσικών μοντέλων.
- Συγκριτική Αξιολόγηση (Comparative Benchmarking):** Σύμφωνα με τους Khan et al. (2023) [69], η έρευνα υιοθετεί τη λογική της άμεσης μεθοδολογικής αντιπαραβολής. Η αντικειμενική αποτίμηση των υπερσύγχρονων αρχιτεκτονικών Βαθιάς Μάθησης (Deep Learning) προϋποθέτει την ευθεία σύγκρισή τους με καθιερωμένες, παραδοσιακές τεχνικές, μια πρακτική που αναδεικνύεται ως αναγκαία και από τους Nair et al. (2025) [70] κατά την αντιπαραβολή παραδοσιακών συστημάτων (rule-based baselines) με υπερσύγχρονα νευρωνικά δίκτυα. Στη βάση αυτού του σκεπτικού, ορίστηκαν αυστηρά μοντέλα αναφοράς (baselines), τα οποία καλούνται να «αναμετρηθούν» με τους προηγμένους νευρωνικούς αλγορίθμους. Η πρακτική αυτή επιτρέπει την ποσοτικοποιημένη ανάδειξη των τεχνολογικών πλεονεκτημάτων, αλλά και τον εντοπισμό των περιορισμών της εκάστοτε προσέγγισης.
- Υπολογιστική Εφικτότητα (Computational Feasibility):** Η διαδικασία επιλογής είχε ως γνώμονα όχι μόνο την αλγοριθμική ισχύ, αλλά και τον υπολογιστικό ορθολογισμό. Προκρίθηκαν νευρωνικά δίκτυα τα οποία, μολονότι ενσαρκώνουν την αιχμή της τεχνολογικής καινοτομίας (state-of-the-art), διακρίνονται ταυτόχρονα για το διαχειρίσιμο λειτουργικό τους αποτύπωμα. Έτσι, εξασφαλίστηκε η δυνατότητα αποδοτικής και απρόσκοπτης εκτέλεσής τους εντός των προδιαγραφών του διαθέσιμου περιβάλλοντος ανάπτυξης, χωρίς να γίνονται εκπτώσεις στην ερευνητική ποιότητα. Η προσέγγιση αυτή εναρμονίζεται πλήρως με τις σύγχρονες επιταγές της «Πράσινης Τεχνητής Νοημοσύνης» (Green AI), όπως αυτές περιγράφονται από τους Barbierato & Gatti

(2024) [71], οι οποίοι υπογραμμίζουν την ανάγκη συνυπολογισμού του υπολογιστικού κόστους κατά την εφαρμογή μοντέλων Deep Learning.

Στις υποενότητες που ακολουθούν επιχειρείται η χαρτογράφηση των επιλεγμένων υπολογιστικών εργαλείων. Παρουσιάζονται αναλυτικά τα τεχνικά χαρακτηριστικά τους και αιτιολογείται η στρατηγική ενσωμάτωσης του εκάστοτε μοντέλου στην ευρύτερη αλυσίδα επεξεργασίας του συστήματος (processing pipeline).

3.5.1 Εξαγωγή Πληροφορίας: Αναγνώριση Οντοτήτων μέσω της βιβλιοθήκης spaCy

Για την υλοποίηση του υποσυστήματος Αναγνώρισης Ονοματισμένων Οντοτήτων (Named Entity Recognition - NER), επιλέχθηκε η ενσωμάτωση του προγραμματιστικού πλαισίου spaCy. Πρόκειται για μια κορυφαία, βιβλιοθήκη ανοιχτού κώδικα του οικοσυστήματος της Python, η οποία είναι σχεδιασμένη για την ανάπτυξη εφαρμογών Επεξεργασίας Φυσικής Γλώσσας σε απαιτητικά περιβάλλοντα παραγωγής (production-grade environments). Όπως επισημαίνουν οι Honnibal et al. (2020) [72], η υποκείμενη αρχιτεκτονική του αντίστοιχου εργαλείου διαφοροποιείται αισθητά από τα αμιγώς ερευνητικά ή ακαδημαϊκά λογισμικά. Ο σχεδιασμός του θέτει ως προτεραιότητα τη μεγιστοποίηση της ταχύτητας εκτέλεσης (execution speed) και τη βέλτιστη υπολογιστική αποδοτικότητα (computational efficiency) κατά τη διαχείριση ογκωδών συνόλων δεδομένων.

Στον πυρήνα της πειραματικής ροής ενσωματώθηκε η προεκπαιδευμένη αγγλική γλωσσική διασωλήνωση (pipeline) en_core_web_sm. Η συγκεκριμένη, ελαφριά έκδοση εδράζεται σε έναν προηγμένο μηχανισμό πυκνής διανυσματικής αναπαράστασης (dense word embeddings) και αξιοποιεί την αρχιτεκτονική των Συνελικτικών Νευρωνικών Δικτύων (Convolutional Neural Networks - CNNs). Χάρη σε αυτή τη νευρωνική δομή, το σύστημα δεν αναλύει τις λέξεις ως μεμονωμένες, αποκομμένες μονάδες, αλλά ενσωματώνει δυναμικά την πληροφορία από το ευρύτερο συντακτικό τους πλαίσιο (context window). Η εφαρμογή του συγκεκριμένου αλγορίθμου στο εκτενές ειδησεογραφικό σώμα του BBC News μεταφράζεται στον ταχύτατο εντοπισμό και την ακριβή σημασιολογική ταξινόμηση κρίσιμων πληροφοριακών κόμβων, επιτυγχάνοντας την μετατροπή του αδόμητου φυσικού λόγου σε αυστηρά δομημένη και ανακτήσιμη γνώση (structured knowledge), ένα πλεονέκτημα που επιβεβαιώνεται και από την μελέτη των Shelar et al. (2020) [73] σχετικά με την ανώτερη απόδοση της CNN αρχιτεκτονικής του spaCy σε εργασίες NER.



Εικόνα 3.3: Παράδειγμα οπτικοποίησης της Αναγνώρισης Ονοματισμένων Οντοτήτων (NER) με χρήση του ενσωματωμένου εργαλείου displaCy της βιβλιοθήκης spaCy.

Κατά την εκτέλεση της επεξεργαστικής διαδικασίας, δόθηκε ιδιαίτερη βαρύτητα στην ικανότητα του προεκπαιδευμένου αλγορίθμου να ταυτοποιεί εξειδικευμένες κλάσεις οντοτήτων, οι οποίες χαρακτηρίζουν το δημοσιογραφικό λεξιλόγιο. Πιο συγκεκριμένα, η παραμετροποίηση του συστήματος στόχευε στην αυτόματη απομόνωση και εξαγωγή ονομάτων φυσικών προσώπων ή πολιτικών ηγετών (PERSON), γεωπολιτικών τοποθεσιών και κρατών (GPE), καθώς και θεσμικών ή εταιρικών οργανισμών (ORG). Συμπληρωματικά, η πολυπλοκότητα των οικονομικών άρθρων (κατηγορία Business) του δείγματος, κατέστησε επιτακτική την ανάγκη ακριβούς ανίχνευσης νομισματικών δεικτών (MONEY) και αυστηρών χρονικών προσδιορισμών (DATE), μια μεθοδολογική αναγκαιότητα για την εξόρυξη πληροφοριών από οικονομικά και ειδησεογραφικά κείμενα που αναδεικνύεται και στην έρευνα των Torprak & Turan (2023) [74].

Μια ενδεικτική οπτικοποίηση αυτής της διαδικασίας αναγνώρισης και χρωματικής κωδικοποίησης (color-coded tagging) μέσω του υποσυστήματος displaCy παρατίθεται στην Εικόνα 3.3.

Αυτή η μεθοδολογική επιλογή διαδραματίζει στρατηγικό ρόλο στην ευρύτερη αρχιτεκτονική του πειράματος. Η χρήση της βιβλιοθήκης δεν περιορίζεται στη στείρα σημασιολογική τμηματοποίηση (semantic segmentation) της πληροφορίας, αλλά εγκαθιδρύει ένα αξιόπιστο και ελαφρύ υπολογιστικό θεμέλιο (lightweight computational baseline). Μέσω αυτής της αποδοτικής χαρτογράφησης, ανοίγει ο δρόμος για την εις βάθος ποσοτική ανάλυση (quantitative analysis) των συχνοτήτων εμφάνισης των διαφόρων οντοτήτων ανά θεματική κατηγορία ειδήσεων. Έτσι, διασφαλίζεται η εξαγωγή πολύτιμων στατιστικών ευρημάτων, προστατεύοντας παράλληλα τους διαθέσιμους πόρους του συστήματος (system resources) από περιττή υπερφόρτωση κατά τα αρχικά, προπαρασκευαστικά στάδια της επεξεργαστικής αλυσίδας, επιβεβαιώνοντας τη σύγχρονη τάση για υπολογιστικά αποδοτικά (resource-efficient) NER μοντέλα, όπως τεκμηριώνουν οι Salah et al. (2025) [75].

3.5.2 Ανάλυση Συναισθήματος: Συγκριτική Αξιολόγηση VADER και RoBERTa

Η δεύτερη ερευνητική πρόκληση του μεθοδολογικού σχεδιασμού επικεντρώνεται στο πεδίο της Ανάλυσης Συναισθήματος (Sentiment Analysis) και, ειδικότερα, στην εξαγωγή της συναισθηματικής πολικότητας (sentiment polarity) από το ειδησεογραφικό σώμα του BBC. Προκειμένου να διασφαλιστεί η μέγιστη δυνατή εγκυρότητα των εξαγόμενων συμπερασμάτων, υιοθετήθηκε μια αυστηρή διάταξη συγκριτικής αξιολόγησης (comparative benchmarking). Η συγκεκριμένη στρατηγική αντιπαραβάλλει δύο θεμελιωδώς ετερογενείς υπολογιστικές φιλοσοφίες: μια παραδοσιακή, λεξικογραφική προσέγγιση (lexicon-based approach) και ένα υπερσύγχρονο βαθύ νευρωνικό δίκτυο βασισμένο στην αρχιτεκτονική των Transformers.

Ως μοντέλο αναφοράς (baseline model) για την εκκίνηση των πειραμάτων ορίστηκε ο ευρετικός αλγόριθμος VADER (Valence Aware Dictionary and sEntiment Reasoner). Όπως τεκμηριώνεται από τους δημιουργούς του [76], το συγκεκριμένο εργαλείο υπολογίζει τον συναισθηματικό προσανατολισμό του κειμένου αξιοποιώντας ένα στατικό, προκαθορισμένο σύνολο γλωσσολογικών κανόνων, γεγονός που του επιτρέπει να λειτουργεί απρόσκοπτα χωρίς την ανάγκη πρότερης εκπαίδευσης (zero-shot inference).

Μολονότι το VADER πλεονεκτεί ως προς την ελάχιστη κατανάλωση υπολογιστικών πόρων και την ταχύτητα εκτέλεσης, παρουσιάζει δομικούς περιορισμούς. Η αδυναμία του να αποκωδικοποιήσει σημασιολογικά πολύπλοκα γλωσσικά φαινόμενα, όπως είναι η ειρωνεία, ο σαρκασμός, η πολυσημία και η εξάρτηση από τα ευρύτερα συμφραζόμενα (contextual dependencies), ένα δομικό κενό που καταδεικνύεται και στην ανάλυση των Bednarek & Taboada (2025) [77] για τα ειδησεογραφικά κείμενα, κατέστησε αναγκαία την αντιπαραβολή του με νεότερα, ισχυρότερα εργαλεία βαθιάς μάθησης.

Στον αντίποδα, για τη διεξαγωγή μιας εις βάθος σημασιολογικής ανάλυσης (deep semantic analysis), επιστρατεύτηκε το προηγμένο νευρωνικό μοντέλο RoBERTa (Robustly Optimized BERT Pretraining Approach). Όπως τεκμηριώνεται στην ιδρυτική δημοσίευση των Liu et al. (2019) [78], η συγκεκριμένη αρχιτεκτονική βελτιστοποιεί ριζικά τον αλγοριθμικό πυρήνα του BERT. Αυτό επιτυγχάνεται πρωτίστως μέσω της εφαρμογής καινοτόμων τεχνικών δυναμικής απόκρυψης λέξεων (dynamic masking) κατά τη φάση της εντατικής προεκπαίδευσής του, επιτρέποντας στο δίκτυο να αναπτύσσει πολύ πιο ρωμαλέες γλωσσικές αναπαραστάσεις (robust representations).

Σε αντίθεση με τη στατική, γραμμική λογική αξιολόγησης του VADER, το RoBERTa επεξεργάζεται την εισερχόμενη πληροφορία ταυτόχρονα και προς τις δύο κατευθύνσεις (bidirectionally). Η ικανότητα αυτή του επιτρέπει να συλλαμβάνει το πλήρες περιβάλλον πλαίσιο (context) κάθε λέξης, αποκωδικοποιώντας με επιτυχία τις λεπτές συντακτικές αποχρώσεις που συναντώνται στα επαγγελματικά κείμενα του BBC News. Η επιλογή αυτή εδράζεται στην

υπεροχή του RoBERTa στην κατανόηση βαθιών εννοιολογικών συσχετίσεων, όπως επιβεβαιώνεται και από τους Lak et al. (2024) [79].


Κατά συνέπεια, η παράλληλη εφαρμογή αυτών των δύο ετερόκλητων εργαλείων στην πειραματική διάταξη δεν εξυπηρετεί απλώς τη μηχανική εξαγωγή πολικότητας. Αντιθέτως, ο θεμελιώδης σκοπός αυτής της μεθοδολογικής επιλογής είναι η αυστηρή ποσοτικοποίηση του τεχνολογικού άλματος (technological leap quantification) που προσφέρουν τα υπερσύγχρονα, προεκπαιδευμένα γλωσσικά μοντέλα έναντι των παραδοσιακών τεχνικών της προηγούμενης δεκαετίας. Η ανάδειξη αυτής της υπεροχής στη διαχείριση απαιτητικού, αδόμητου δημοσιογραφικού λόγου ευθυγραμμίζεται με τα ευρήματα της μελέτης των Catelli et al. (2022) [80], οι οποίοι τεκμηριώνουν την αλματώδη διαφορά απόδοσης μεταξύ λεξικογραφικών προσεγγίσεων και μοντέλων αρχιτεκτονικής Transformer.

3.5.3 Αυτόματη Περίληψη Κειμένου: Η αρχιτεκτονική BART

Η τρίτη φάση του πειραματικού σχεδιασμού επικεντρώνεται στην επίλυση του προβλήματος της Αυτόματης Περίληψης Κειμένου (Text Summarization). Λαμβάνοντας υπόψη την υψηλή πληροφοριακή πυκνότητα (information density) που διακρίνει το ειδησεογραφικό σώμα του BBC News, η παραδοσιακή μέθοδος της εξορυκτικής σύνοψης (extractive summarization), δηλαδή η επιλεκτική παράθεση αυτούσιων προτάσεων από το πρωτότυπο έγγραφο, απορρίφθηκε. Η συγκεκριμένη τεχνική κρίνεται μεθοδολογικά ανεπαρκής, καθώς συχνά παράγει σημασιολογικά ασυνεχή και συντακτικά κατακερματισμένα αποτελέσματα, ένας περιορισμός που αναδεικνύεται και στην έρευνα των Alami Merrouni et al. (2023) [81].

Ως εκ τούτου, η παρούσα εργασία προσανατολίστηκε στην αφαιρετική προσέγγιση (abstractive summarization). Πρόκειται για μια προηγμένη διεργασία αιχμής στον τομέα της Υπολογιστικής Γλωσσολογίας, η οποία δεν αντιγράφει, αλλά «κατανοεί» σε βάθος το λανθάνον νόημα του κειμένου. Με αυτόν τον τρόπο, το σύστημα καθίσταται ικανό να συνθέσει νέο, σημασιολογικά συνεκτικό λεξιλόγιο, προσομοιώνοντας με υψηλή πιστότητα την ανθρώπινη γνωστική ικανότητα (human cognitive ability) της αφαίρεσης και της συμπύκνωσης, ένα επίτευγμα που πλέον καθίσταται εφικτό μέσω της αρχιτεκτονικής των Transformers, όπως τεκμηριώνεται από τους Rao et al. (2024) [82].

Για την διεκπεραίωση του έργου Παραγωγής Φυσικής Γλώσσας (Natural Language Generation - NLG), ενσωματώθηκε στην προγραμματιστική ροή το γλωσσικό μοντέλο BART (Bidirectional and Auto-Regressive Transformers). Όπως τεκμηριώνεται από τους Lewis et al. (2020) [35], η συγκεκριμένη νευρωνική τοπολογία (neural topology) αναπτύχθηκε ως μια καινοτόμος υβριδική στρατηγική, γεφυρώνοντας δύο εκ των ισχυρότερων παραδειγμάτων της Βαθιάς Μάθησης. Ειδικότερα, το BART αξιοποιεί έναν αμφίδρομο κωδικοποιητή (bidirectional encoder) στα πρότυπα του BERT, επιτυγχάνοντας την απόλυτη κατανόηση των αμφίπλευρων συμφραζομένων (bidirectional context) της εισόδου. Ταυτόχρονα, εξοπλίζεται με έναν αυτοπαλίνδρομο αποκωδικοποιητή (autoregressive decoder), εμπνευσμένο από τη σχεδιαστική φιλοσοφία της οικογένειας GPT. Ο συγκεκριμένος μηχανισμός αναλαμβάνει τη σταδιακή, λεκτική μονάδα προς λεκτική μονάδα (token-by-token), παραγωγή του παραδοτέου, διασφαλίζοντας την ομαλή και φυσική συντακτική ροή του τελικού κειμένου.



Εικόνα 3.4: Αρχιτεκτονική τοπολογία του μοντέλου BART (Bidirectional and Auto-Regressive Transformers). Πηγή: Lewis et al. [35]

Η ειδοποιός διαφορά του συγκεκριμένου μοντέλου, στην οποία βασίστηκε η επιλογή του για την παρούσα εργασία, έγκειται στη διαδικασία προεκπαίδευσής του ως αυτοκωδικοποιητής απαλοιφής θορύβου (denoising autoencoder). Έχοντας διδαχθεί να αναδομεί αλλοιωμένα ή ημιτελή κείμενα, το BART επιδεικνύει κορυφαίες επιδόσεις σε προβλήματα μετάφρασης ακολουθιών (sequence-to-sequence). Στο πλαίσιο του πειράματος, ο αλγόριθμος κλήθηκε να διαχειριστεί τον εκτενή δημοσιογραφικό λόγο, με απώτερο σκοπό την αυτοματοποιημένη εξαγωγή περιεκτικών συνόψεων. Οι παραγόμενες περιλήψεις οφείλουν να διατηρούν στο ακέραιο τον κεντρικό πυρήνα της είδησης και τα κρίσιμα γεγονότα, απορρίπτοντας ταυτόχρονα τις δευτερεύουσες περιγραφές ή τις επαναλαμβανόμενες λεπτομέρειες (redundancies), μια ικανότητα συμπύκνωσης και εξάλειψης των βερμπαλισμών (ειδικά σε πολιτικά και ειδησεογραφικά κείμενα) που επιβεβαιώνεται και από την μελέτη των Nie et al. (2025) [83].

3.6 Μετρικές Αξιολόγησης και Κριτήρια Απόδοσης (Evaluation Metrics & Performance Criteria)

Για να καταστεί εφικτή η μετάβαση από τον θεωρητικό σχεδιασμό των νευρωνικών αρχιτεκτονικών στην εμπειρική τους επικύρωση (empirical validation), η εξαγωγή συμπερασμάτων δεν νοείται να βασίζεται σε υποκειμενικές εκτιμήσεις ή αποσπασματικές, ευρετικές παρατηρήσεις (heuristic observations) επί του σώματος κειμένων. Αντιθέτως, αναδεικνύεται ως επιτακτική ανάγκη η υιοθέτηση αυστηρών, τυποποιημένων μετρικών (standardized metrics). Τα ποσοτικά αυτά κριτήρια οφείλουν να μην εφαρμόζονται οριζόντια, αλλά να εναρμονίζονται πλήρως με τις εγγενείς ιδιαιτερότητες και τις μαθηματικές απαιτήσεις του εκάστοτε αλγοριθμικού προβλήματος, μια θεμελιώδης αρχή που διασφαλίζει την ακεραιότητα της ερευνητικής διαδικασίας και αποτρέπει μεθοδολογικά σφάλματα, όπως τονίζουν οι Davoodijam & Alambardar Meybodi (2024) [84].

Η αρχιτεκτονική πολυπλοκότητα των εξεταζόμενων σεναρίων υπαγορεύει την υιοθέτηση μιας πολυδιάστατης στρατηγικής αξιολόγησης (multidimensional evaluation strategy). Λαμβάνοντας υπόψη τη ριζική υπολογιστική ετερογένεια (computational heterogeneity) των επιμέρους

εργασιών, τα συστήματα Μηχανικής Μάθησης κλήθηκαν να διεκπεραιώσουν δύο θεμελιωδώς διαφορετικές λειτουργίες. Αφενός, τον ακριβή εντοπισμό και την αυστηρή στατιστική ταξινόμηση (statistical classification) διακριτών πληροφοριών, όπως συμβαίνει στην Αναγνώριση Ονοματισμένων Οντοτήτων και την Ανάλυση Συναισθήματος. Αφετέρου, τη δυναμική σύνθεση νέου, σημασιολογικά συνεπούς φυσικού λόγου (generative synthesis), όπως προαπαιτείται στην περίπτωση της Αυτόματης Περίληψης.

Εξαιτίας αυτής της διττής φύσης του προβλήματος, η μεθοδολογία ποσοτικοποίησης της απόδοσης διαχωρίζεται υποχρεωτικά σε δύο ανεξάρτητους αναλυτικούς άξονες. Η συγκεκριμένη, μεθοδολογική διχοτόμηση (bipartite methodology) λειτουργεί εξισορροπητικά. Διασφαλίζει ότι κάθε υποσύστημα ελέγχεται αποκλειστικά βάσει των εξειδικευμένων μαθηματικών προτύπων (mathematical benchmarks) που είναι κατάλληλα σχεδιασμένα για να αναδεικνύουν την πραγματική του προβλεπτική ή παραγωγική ικανότητα, μια αναγκαιότητα που τεκμηριώνεται και από τους Sai et al. (2022) [85], οι οποίοι υπογραμμίζουν ότι η αξιολόγηση συστημάτων παραγωγής (NLG) απαιτεί διαφορετικές μετρικές έναντι των κλασικών συστημάτων κατανόησης και ταξινόμησης (NLU). Ως εκ τούτου, θωρακίζεται η αναλυτική διαδικασία, προσδίδοντας μέγιστη διαφάνεια (transparency) και επιστημονική εγκυρότητα (scientific validity) στην εξαγωγή και τελική ερμηνεία των πειραματικών αποτελεσμάτων.

3.6.1 Μετρικές Αξιολόγησης Ταξινόμησης (Classification Metrics)

Για την ολοκληρωμένη και αντικειμενική αποτίμηση των υποσυστημάτων Αναγνώρισης Ονοματισμένων Οντοτήτων (NER) και Ανάλυσης Συναισθήματος δύο διεργασίες που προσεγγίζονται αλγοριθμικά ως σύνθετα προβλήματα στατιστικής ταξινόμησης (statistical classification) αποφασίστηκε η υιοθέτηση ενός εξειδικευμένου συνόλου δεικτών απόδοσης. Όπως τεκμηριώνεται στην βιβλιογραφία, με παράδειγμα τη μελέτη των Sokolova & Lapalme (2009) [43], η αποκλειστική εξάρτηση από την απλή μετρική της Ορθότητας (Accuracy) κρίνεται μεθοδολογικά ανεπαρκής.

Το συγκεκριμένο στατιστικό μέγεθος τείνει να παράγει παραπλανητικές ενδείξεις υπερασιοδοξίας, ένα φαινόμενο γνωστό ως «παράδοξο της ορθότητας» (accuracy paradox), ιδίως σε περιπτώσεις όπου η κατανομή των κλάσεων στα δεδομένα εκπαίδευσης και ελέγχου παρουσιάζει έντονη ασυμμετρία (imbalanced datasets). Η μορφή αυτής της ανισορροπίας αποτελεί τον κανόνα παρά την εξαίρεση κατά την ανάλυση αδόμητου ειδησεογραφικού λόγου. Σε ένα τέτοιο περιβάλλον, οι στοχευμένες πληροφοριακές μονάδες, όπως είναι οι σπάνιες γεωπολιτικές οντότητες ή οι λέξεις ακραίας συναισθηματικής φόρτισης, συνιστούν τη συντριπτική μειοψηφία εντός του συνολικού κειμενικού όγκου, καθιστώντας τα επιφανειακά μοντέλα επιρρεπή σε επικίνδυνη μεροληψία υπέρ της πλειοψηφικής κλάσης (majority class bias). Η προβληματική αυτή φύση του Accuracy κατά την επεξεργασία ανισορροπών δεδομένων Φυσικής Γλώσσας επιβεβαιώνεται και αποδομείται στην έρευνα των Villa-Pérez et al. (2023) [86].

Για την αποτελεσματική υπέρβαση αυτού του στατιστικού σκοπέλου, η μεθοδολογία αξιολόγησης στράφηκε αρχικά στον δείκτη της Ακρίβειας (Precision). Η συγκεκριμένη παράμετρος ποσοτικοποιεί την ορθότητα των θετικών προβλέψεων, αποτυπώνοντας την ικανότητα του εκάστοτε μοντέλου να καταστέλλει τον παραγόμενο «θόρυβο». Πρακτικά, αυτό μεταφράζεται στην αποτροπή λανθασμένης απόδοσης ετικετών σε άσχετα τμήματα κειμένου, επιδιώκοντας την αυστηρή ελαχιστοποίηση των Ψευδώς Θετικών (False Positives) αποτελεσμάτων. Σε άμεση συνάρτηση με τα παραπάνω, ενσωματώθηκε συμπληρωματικά η μετρική της Ανάκλησης (Recall), η οποία μετατοπίζει το ερευνητικό ενδιαφέρον στην πληρότητα (completeness) της εξαγόμενης πληροφορίας. Ο πρωταρχικός της στόχος έγκειται στην καταμέτρηση του ποσοστού των πραγματικών συμβάντων που ταυτοποιήθηκαν επιτυχώς. Μέσω αυτής της προσέγγισης, το σύστημα «τιμωρείται» αλγοριθμικά για κάθε κρίσιμο πληροφοριακό στοιχείο που διέφυγε της αναλυτικής του διαδικασίας, στοχεύοντας έτσι στον περιορισμό των Ψευδώς Αρνητικών (False Negatives) ταξινομήσεων.

Δεδομένου, ωστόσο, ότι στο πεδίο της Μηχανικής Μάθησης η μεγιστοποίηση του ενός δείκτη λειτουργεί συχνά εις βάρος του άλλου (ένα φαινόμενο γνωστό ως αντιστάθμισμα Ακρίβειας-Ανάκλησης (Precision-Recall trade-off), η αναπόφευκτη ύπαρξη του οποίου κατά την ταξινόμηση κειμένων τεκμηριώνεται στη μελέτη των Ferrario et al. (2020) [87]) η τελική κρίση για την προβλεπτική ισχύ των αλγορίθμων συμπυκνώθηκε στο μέτρο F1 (F1-Score). Λειτουργώντας ως ο μαθηματικός αρμονικός μέσος (harmonic mean) των δύο προαναφερθεισών παραμέτρων, το F1-Score εξομαλύνει τις τυχόν ακραίες διακυμάνσεις και προσφέρει μια στιβαρή, μονοδιάστατη αποτίμηση. Μέσω αυτού του συνθετικού υπολογισμού, διασφαλίζεται με απόλυτη διαφάνεια ότι οι τελικές βαθμολογίες δεν συνιστούν συγκυριακά στατιστικά ευρήματα, αλλά αντανακλούν την ουσιαστική ικανότητα των δικτύων να γενικεύουν (generalization capability) με ασφάλεια κατά την εφαρμογή τους σε νέα, άγνωστα δεδομένα.

3.6.2 Μετρικές Αξιολόγησης Παραγωγής Κειμένου (Text Generation Metrics)

Διαμετρικά αντίθετη είναι η θεωρητική και μεθοδολογική φιλοσοφία που διέπει την αξιολόγηση του υποσυστήματος της Αυτόματης Περίληψης (Automatic Summarization). Δεδομένου ότι η Παραγωγή Φυσικής Γλώσσας (Natural Language Generation - NLG) χαρακτηρίζεται από εγγενή στοχαστικότητα (stochastic nature) και δεν περιορίζεται σε μια μοναδική, «απόλυτα ορθή» απάντηση, αλλά επιδέχεται πολλαπλές, εξίσου δόκιμες συντακτικές και σημασιολογικές προσεγγίσεις, η εφαρμογή των κλασικών στατιστικών δεικτών ταξινόμησης καθίσταται ανέφικτη. Αυτό το εμπόδιο στην αξιολόγηση των παραγωγικών μοντέλων, λόγω των πολλαπλών έγκυρων εξόδων, αναλύεται από τους Gehrmann et al. (2023) [88]. Προς αντιμετώπιση αυτής της πολυπλοκότητας, υιοθετήθηκε το καθιερωμένο ακαδημαϊκό και βιομηχανικό πρότυπο της δέσμης μετρικών ROUGE (Recall-Oriented Understudy for Gisting Evaluation).

Όπως ορίζεται στη δημοσίευση του δημιουργού της μεθόδου, Lin (2004) [46], η συγκεκριμένη οικογένεια αλγορίθμων ποσοτικοποιεί την ποιότητα της παραγόμενης σύνοψης (candidate/system summary) υπολογίζοντας τον βαθμό λεξιλογικής αλληλεπικάλυψης (lexical overlap) με μια ιδεατή, ανθρώπινα συντεταγμένη περίληψη αναφοράς (reference summary). Ο πυρήνας αυτού του μαθηματικού ελέγχου εδράζεται στην αυστηρή στατιστική καταμέτρηση κοινών n-γραμμάτων (n-grams).

Αναλυτικότερα, επιστρατεύονται πρωτίστως οι εξειδικευμένοι δείκτες ROUGE-1 και ROUGE-2. Ο πρώτος εστιάζει αποκλειστικά στην ταύτιση μεμονωμένων λέξεων (unigrams), ελέγχοντας επιτυχώς αν το παραγωγικό γλωσσικό μοντέλο (BART) κατάφερε να διατηρήσει το βασικό λεξιλόγιο και τον εννοιολογικό πυρήνα του πρωτότυπου δημοσιογραφικού άρθρου. Ο δεύτερος δείκτης εμβαθύνει περαιτέρω, αξιολογώντας την επικάλυψη διαδοχικών ακολουθιών δύο λέξεων (bigrams). Η συγκεκριμένη μέτρηση παρέχει μια ισχυρή μαθηματική ένδειξη για τη διατήρηση των τοπικών συντακτικών δομών (local syntactic structures) και τη συνοχή των νοηματικών φράσεων του κειμένου.

Προκειμένου, ωστόσο, να αποφευχθεί ο περιορισμός της ερευνητικής αξιολόγησης σε μια άκαμπτη και στατική καταμέτρηση μεμονωμένων λεξιλογικών μονάδων, η πειραματική διάταξη ενισχύεται δομικά μέσω του δείκτη ROUGE-L. Η συγκεκριμένη μετρική θεμελιώνεται στον προηγμένο αλγοριθμικό υπολογισμό της Μακρύτερης Κοινής Υποακολουθίας (Longest Common Subsequence - LCS). Το κύριο αναλυτικό της πλεονέκτημα έγκειται στο γεγονός ότι επιτρέπει την αποτελεσματική ανίχνευση της δομικής συνοχής και της συντακτικής αλληλουχίας επιπέδου πρότασης (sentence-level structure). Πρακτικά, αυτό σημαίνει πως ο αλγόριθμος ταυτοποιεί τη διατήρηση του ευρύτερου νοήματος, ανεξαρτήτως της πιθανής παρεμβολής δευτερευόντων όρων, δίχως δηλαδή να απαιτεί αυστηρά διαδοχική ταύτιση (strict consecutive matching) των λέξεων.

Μέσω αυτού του υπολογιστικού μηχανισμού, το σύστημα priμοδοτείται στοχευμένα για την παραγωγή κειμένου το οποίο δεν διαθέτει απλώς τις σωστές λέξεις-κλειδιά, αλλά χαρακτηρίζεται από ρεαλιστική γλωσσική ροή (natural fluency) και υψηλή αναγνωσιμότητα (readability). Υιοθετώντας αυτή την πολυδιάστατη μετρική στρατηγική (multidimensional evaluation strategy),

διασφαλίζεται ότι η ικανότητα αφαιρετικής σύνοψης (abstractive summarization capability) των νευρωνικών μοντέλων εξετάζεται ολιστικά, μια πρακτική που εφαρμόζεται και επικυρώνεται στην μελέτη των Daraghmi et al. (2025) [89], όπου αξιολογείται επιτυχώς το μοντέλο BART σε αντίστοιχα ειδησεογραφικά σύνολα δεδομένων. Με τον τρόπο αυτό, εξασφαλίζεται η απαραίτητη ποσοτική διαφάνεια (quantitative transparency) της μεθοδολογίας, θέτοντας τα θεμέλια για την ομαλή μετάβαση στο επόμενο κεφάλαιο, όπου θα παρουσιαστεί η επιστημονική ερμηνεία των τελικών πειραματικών ευρημάτων.

Κεφάλαιο 4: Αποτελέσματα και Συζήτηση

4.1 Εισαγωγή

Η παρούσα ενότητα σηματοδοτεί την μετάβαση στην εφαρμοσμένη πειραματική διάταξη (applied experimental setup). Γίνεται λόγος για την εμπειρική επικύρωση (empirical validation) και την αποτίμηση των επιλεγμένων αρχιτεκτονικών Μηχανικής Μάθησης. Μέσω της συστηματικής επεξεργασίας του ειδησεογραφικού συνόλου δεδομένων «BBC News», επιχειρείται η μετουσίωση της αφηρημένης αλγοριθμικής λογικής και του πηγαίου κώδικα σε απτά, μετρήσιμα και συγκρίσιμα στατιστικά μεγέθη.

Η αντίστοιχη ανάλυση συνίσταται σε μια σκόπιμη, σταδιακή κλιμάκωση της υπολογιστικής πολυπλοκότητας (incremental computational complexity), η οποία συνδέεται με τα διαδοχικά στάδια της αναπτυσσόμενης ροής εργασιών (end-to-end processing pipeline). Σε πρώτο επίπεδο, χαρτογραφούνται αναλυτικά οι τεχνικές προδιαγραφές και οι πόροι του περιβάλλοντος ανάπτυξης. Η συγκεκριμένη καταγραφή θέτει ως προτεραιότητα τη διασφάλιση της πλήρους υπολογιστικής αναπαραγωγιμότητας (computational reproducibility) του πειράματος [90], παρέχοντας όλα τα απαραίτητα εχέγγυα για την πιστή επανάληψή του από ανεξάρτητους μελετητές της επιστημονικής κοινότητας.

Ακολούθως, η προσοχή μετατοπίζεται στην παρουσίαση των υπολογιστικών επιδόσεων, οι οποίες διαρθρώνονται γύρω από τρεις διακριτούς ερευνητικούς άξονες (research axes). Πιο συγκεκριμένα, εξετάζεται αρχικά η αυτοματοποιημένη εξαγωγή Ονοματισμένων Οντοτήτων (NER) με την αξιοποίηση της βιβλιοθήκης spaCy. Έπεται η συγκριτική αντιπαραβολή (comparative benchmarking) της συναισθηματικής πολικότητας, αντιπαραθέτοντας την παραδοσιακή λεξικογραφική προσέγγιση του αλγορίθμου VADER με την ισχυρή νευρωνική αρχιτεκτονική του μοντέλου RoBERTa. Επιπλέον, δίνεται έμφαση παραγωγή αφαιρετικών περιλήψεων (abstractive summarization) μέσω του προηγμένου γλωσσικού μοντέλου BART.

Όσον αφορά την αντικειμενικότητα των συμπερασμάτων που εξάγονται, επιστρατεύεται η ποσοτική αξιολόγηση (quantitative evaluation), η οποία είναι βασισμένη σε καθιερωμένες μετρικές μηχανικής μάθησης όπως το F1-Score και η οικογένεια δεικτών ROUGE και πλαισιώνεται από εκτενείς οπτικοποιήσεις (data visualizations). Τα στοχευμένα γραφήματα και οι αναλυτικοί πίνακες προσφέρουν την δυνατότητα ολοκληρωμένης μελέτης των πολύπλοκων στατιστικών τάσεων. Συμπληρωματικά, η αμιγώς μαθηματική προσέγγιση εμπλουτίζεται με επιλεγμένες ποιοτικές αναλύσεις (qualitative case studies) δημοσιογραφικών άρθρων. Η πρακτική αυτή επιδιώκει να γεφυρώσει το εννοιολογικό χάσμα μεταξύ των αυστηρών αλγοριθμικών δεικτών και της ουσιαστικής σημασιολογικής κατανόησης (semantic understanding).

Το κεφάλαιο ολοκληρώνεται με μια συνθετική κριτική συζήτηση (critical discussion), όπου τα πειραματικά ευρήματα αντιπαραβάλλονται με το σύγχρονο ακαδημαϊκό γίνεσθαι (state-of-the-art literature). Μέσα από αυτό το πρίσμα, αναδεικνύονται τόσο οι τεχνολογικές εξελίξεις όσο και οι εγγενείς περιορισμοί που εξακολουθούν να υφίστανται στο ραγδαία εξελισσόμενο πεδίο της Επεξεργασίας Φυσικής Γλώσσας.

4.2 Περιβάλλον Ανάπτυξης και Εργαλεία Υλοποίησης

Η επιτυχής γεφύρωση του χάσματος μεταξύ του θεωρητικού αλγοριθμικού σχεδιασμού και της πρακτικής, εφαρμοσμένης υλοποίησής του, καθιστά αναγκαία την εγκαθίδρυση μιας πλήρως ελεγχόμενης τεχνολογικής στοίβας (technology stack). Οι αρχιτεκτονικές αποφάσεις ελήφθησαν με γνώμονα αφενός τη μεγιστοποίηση της υπολογιστικής αποδοτικότητας (computational efficiency) και αφετέρου τη διασφάλιση της υπολογιστικής αναπαραγωγιμότητας (computational reproducibility) των πειραματικών αποτελεσμάτων από την ευρύτερη ερευνητική κοινότητα.

Δεδομένης της μεγάλης κλίμακας (large-scale nature) του ειδησεογραφικού σώματος κειμένων του βρετανικού δικτύου (BBC News corpus) και της αρχιτεκτονικής πολυπλοκότητας που διέπει τα υπερσύγχρονα βαθιά νευρωνικά δίκτυα (deep neural networks), η προσφυγή σε συμβατικές μεθόδους εκτέλεσης κρίθηκε εκ των προτέρων ανεπαρκής. Ως εκ τούτου, κατέστη αναγκαία η επιστράτευση εξειδικευμένων, βιομηχανικού επιπέδου προγραμματιστικών υποδομών (enterprise-grade infrastructure).

Η υποκείμενη αρχιτεκτονική του αναπτυχθέντος λογισμικού υπερβαίνει κατά πολύ την απλοϊκή, σειριακή εκτέλεση μεμονωμένων εντολών (sequential scripting), συγκροτώντας αντίθετα μια πλήρως ενοποιημένη και αυτοματοποιημένη ροή επεξεργασίας δεδομένων (end-to-end data pipeline). Αυτή η αλληλουχία διεργασιών εκκινεί από την πρωτογενή άντληση (data ingestion) και τη δομική αναδιοργάνωση του ακατέργαστου υλικού, διατρέχει τα υπολογιστικά απαιτητικά στάδια της βαθιάς σημασιολογικής εξαγωγής (semantic feature extraction) μέσω των προεκπαιδευμένων μοντέλων, για να καταλήξει στη δυναμική, οπτική αποτύπωση των τελικών στατιστικών συμπερασμάτων (data visualization).

Στις υποενότητες που ακολουθούν, επιχειρείται μια αποδόμηση των δομικών πυλώνων που συνθέτουν το συγκεκριμένο πειραματικό περιβάλλον. Ειδικότερα, χαρτογραφούνται οι υπολογιστικοί πόροι (hardware resources) που απορρόφησαν τον βαρύ φόρτο επεξεργασίας και τεκμηριώνεται η επιλογή της κεντρικής γλώσσας προγραμματισμού, η οποία λειτούργησε ως συνδετικός κρίκος (glue language) των ετερογενών υποσυστημάτων. Τέλος, παρουσιάζονται αναλυτικά οι κορυφαίες βιβλιοθήκες ανοιχτού κώδικα (open-source frameworks) που επιστρατεύτηκαν για τη βέλτιστη απόδοση του εκάστοτε ερευνητικού σεναρίου.

4.2.1 Υπολογιστικοί Πόροι και Υποδομές (Hardware & Infrastructure)

Η πρακτική ανάπτυξη και υλοποίηση σύγχρονων αρχιτεκτονικών Βαθιάς Μάθησης (Deep Learning) και, ειδικότερα, η φόρτωση ογκωδών, προεκπαιδευμένων γλωσσικών μοντέλων όπως τα RoBERTa και BART, θέτουν υψηλές προδιαγραφές ως προς τους διαθέσιμους πόρους του συστήματος. Δεδομένου ότι τα συγκεκριμένα νευρωνικά δίκτυα απαρτίζονται από εκατοντάδες εκατομμύρια εκπαιδευσιμες παραμέτρους (trainable parameters), η αποκλειστική εκτέλεσή τους σε μια συμβατική Κεντρική Μονάδα Επεξεργασίας (CPU) καθίσταται στην πράξη υπολογιστικά ανεπαρκής.

Απουσία εξειδικευμένης επιτάχυνσης υλικού (hardware acceleration), οι βαριές αλγεβρικές λειτουργίες τανυστών (tensor computations) και οι εκτεταμένοι πολλαπλασιασμοί μητρώων (matrix multiplications), στους οποίους βασίζεται ο μηχανισμός προσοχής (attention mechanism), οδηγούν σε εκθετική αύξηση του απαιτούμενου χρόνου συμπερασμού (inference time). Υπό αυτές τις συνθήκες, η διεξαγωγή του πειράματος σε έναν τυπικό, τοπικό σταθμό εργασίας θα προκαλούσε υπολογιστική συμφόρηση (computational bottleneck), καθιστώντας τη μαζική επεξεργασία του ειδησεογραφικού συνόλου χρονικά απαγορευτική, όπως τεκμηριώνεται και από τις μελέτες συγκριτικής αξιολόγησης (benchmarking) των Emani et al. (2023) [91].

Για την υπέρβαση αυτών των τεχνολογικών περιορισμών (hardware constraints), η παρούσα εργασία υιοθέτησε μια σύγχρονη στρατηγική μετατόπισης του υπολογιστικού φόρτου (workload offloading) σε κατανεμημένες υποδομές νέφους (cloud computing). Ειδικότερα, το πείραμα φιλοξενήθηκε στο προγραμματιστικό περιβάλλον του Google Colaboratory (Colab). Όπως υπογραμμίζεται από τον Bisong (2019) [92], η επιλογή της συγκεκριμένης πλατφόρμας εξασφαλίζει άμεση πρόσβαση σε βιομηχανικού επιπέδου Μονάδες Επεξεργασίας Γραφικών (GPUs). Οι συγκεκριμένοι επιταχυντές υλικού (hardware accelerators) συνιστούν το θεμέλιο για τον μαζικό παραλληλισμό (massive parallelization) των πολύπλοκων διανυσματικών πράξεων, στις οποίες βασίζεται αποκλειστικά η αρχιτεκτονική των Transformers.

Χάρη στην αξιοποίηση αυτής της κατανεμημένης επεξεργαστικής ισχύος, επιτεύχθηκε η κατακόρυφη συμπίεση του χρόνου εκτέλεσης (execution time compression), τόσο κατά τη διαδικασία ταξινόμησης της συναισθηματικής πολικότητας όσο και κατά την παραγωγή των

αφαιρετικών περιλήψεων. Παράλληλα, η πλατφόρμα προσέφερε άφθονη και δυναμικά κατανοημένη Μνήμη Τυχαίας Προσπέλασης (RAM), αποσοβώντας κρίσιμα σφάλματα υπερχείλισης (Out-Of-Memory - OOM exceptions) κατά τη μαζική σάρωση του ειδησεογραφικού συνόλου. Επομένως, η πλήρης απεξάρτηση του πειραματικού κώδικα από τους περιορισμούς του τοπικού εξοπλισμού (local hardware) καθίσταται μεθοδολογικά αναγκαία. Η προσέγγιση αυτή παρέχει εγγυήσεις διαφάνειας και διασφαλίζει την αναπαραγωγιμότητα (reproducibility) των εξαγόμενων ευρημάτων από την ευρύτερη ερευνητική κοινότητα.

4.2.2 Γλώσσα Προγραμματισμού και Διαχείριση Δεδομένων

Ο σχεδιασμός, η αρχιτεκτονική δόμηση και η τελική ανάπτυξη του κεντρικού υπολογιστικού πυρήνα (backend infrastructure) της παρούσας πειραματικής διάταξης υλοποιήθηκαν εξ ολοκλήρου μέσω της γλώσσας προγραμματισμού Python. Πέραν της εγγενούς συντακτικής της ευελιξίας (syntactic flexibility) και της δυναμικής της τυποποίησης (dynamic typing), η Python συνιστά το αδιαμφισβήτητο ακαδημαϊκό και βιομηχανικό πρότυπο (de facto standard) στο σύγχρονο τοπίο της Επιστήμης Δεδομένων και της Τεχνητής Νοημοσύνης.

Το μείζον συγκριτικό της πλεονέκτημα (competitive advantage) εδράζεται στο ώριμο και αχανές οικοσύστημα βιβλιοθηκών ανοιχτού κώδικα (open-source ecosystem) που υποστηρίζει. Βασικό χαρακτηριστικό αυτής της αρχιτεκτονικής είναι η ικανότητα διαλειτουργικότητας (interoperability) με μεταγλωττισμένες γλώσσες χαμηλότερου επιπέδου (όπως η C και η C++), γεγονός που εξασφαλίζει κορυφαίες ταχύτητες εκτέλεσης σε απαιτητικούς μαθηματικούς υπολογισμούς, διατηρώντας ταυτόχρονα την ευκολία συγγραφής του κώδικα. Η ιδιότητα αυτή διευκολύνει τη ραγδαία ανάπτυξη λειτουργικών πρωτοτύπων (rapid prototyping) και επιτρέπει την απρόσκοπτη ενοποίηση (seamless integration) ετερογενών αλγοριθμικών διατάξεων (από την απλή εξόρυξη κειμένου έως την εκτέλεση πολύπλοκων μοντέλων μηχανικής μάθησης) κάτω από μια ενιαία, συνεκτική προγραμματιστική ομπρέλα.

Για τη διαχείριση του προπαρασκευαστικού σταδίου (το οποίο περιλαμβάνει την αρχική εισαγωγή (data ingestion), την Εξερευνητική Ανάλυση Δεδομένων (Exploratory Data Analysis - EDA) και τον δομικό μετασχηματισμό του συνόλου BBC News) ενσωματώθηκε η βιβλιοθήκη *pandas*. Σύμφωνα με τη δημοσίευση του δημιουργού της, McKinney (2010) [93], το συγκεκριμένο υπολογιστικό εργαλείο παρέχει βελτιστοποιημένες δομές δεδομένων στην κύρια μνήμη (in-memory data structures), με δεσπόζουσα την κλάση του *DataFrame*.

Αυτή η δισδιάστατη, πινακοποιημένη αναπαράσταση (tabular representation) επέτρεψε τη γρήγορη φόρτωση των χιλιάδων αδόμητων κειμενικών εγγραφών στο σύστημα. Παράλληλα, εξόπλισε την πειραματική ροή με τα απαραίτητα προγραμματιστικά εργαλεία για τη σαρωτική εκκαθάριση (data wrangling) και την προεπεξεργασία (preprocessing) του δείγματος. Συγκεκριμένα, κατέστησε εφικτή την αυτοματοποιημένη απαλοιφή διπλότυπων εγγραφών (deduplication), την ανίχνευση και διαχείριση ελλিপών τιμών (missing values handling), καθώς και τον μαθηματικά ακριβή διαχωρισμό του ειδησεογραφικού υλικού στις πέντε προκαθορισμένες θεματικές του κλάσεις.

Υπό αυτό το πρίσμα, η βιβλιοθήκη *pandas* λειτούργησε ως ο κεντρικός δίαυλος κανονικοποίησης (normalization pipeline), μετασχηματίζοντας τον ακατέργαστο φυσικό λόγο σε οργανωμένα, σχεσιακά σχήματα (relational schemas). Μέσω αυτής της μεθοδικής χαρτογράφησης, διασφαλίστηκε η δομική συμβατότητα των εισερχόμενων πληροφοριών με τις αυστηρές προδιαγραφές διαστάσεων (input tensor dimensions) που επιβάλλουν τα προηγμένα νευρωνικά μοντέλα στα μετέπειτα, υπολογιστικά βαρύτερα βήματα της επεξεργαστικής αλυσίδας.

4.2.3 Βιβλιοθήκες Μηχανικής Μάθησης και Οπτικοποίησης Δεδομένων

Η μετάβαση από το προπαρασκευαστικό στάδιο της δομικής διευθέτησης των δεδομένων στην εξαγωγή βαθιών σημασιολογικών χαρακτηριστικών (deep semantic features), κατέστησε αναγκαία την ενσωμάτωση προηγμένων υπολογιστικών υποδομών Τεχνητής Νοημοσύνης. Για την υλοποίηση του πυρήνα της πειραματικής διάταξης, επιλέχθηκε η βιβλιοθήκη ανοιχτού κώδικα Transformers της πλατφόρμας Hugging Face. Όπως τεκμηριώνεται από τους Wolf et al. (2020) [94], το εν λόγω οικοσύστημα έχει αναδιαμορφώσει το πεδίο της σύγχρονης Επεξεργασίας Φυσικής Γλώσσας, καθιερώνοντας νέα τεχνολογικά πρότυπα στην ανάπτυξη αρχιτεκτονικών βαθιάς μάθησης.

Ουσιαστικά, η συγκεκριμένη βιβλιοθήκη παρέχει μια υψηλού επιπέδου, ενοποιημένη διεπαφή προγραμματισμού εφαρμογών (API), η οποία γεφυρώνει το χάσμα μεταξύ της θεωρητικής ακαδημαϊκής έρευνας αιχμής και της εφαρμοσμένης μηχανικής (applied engineering). Μέσω αυτού του ευέλικτου πλαισίου εργασίας, κατέστη άμεσα εφικτή η εισαγωγή, η στοχευμένη μικρο-ρύθμιση (fine-tuning) και η εκτέλεση ογκωδών, προεκπαιδευμένων γλωσσικών μοντέλων (pre-trained language models), όπως τα RoBERTa και BART. Η αφαίρεση της προγραμματιστικής πολυπλοκότητας (abstraction of low-level boilerplate code) απάλλαξε την υλοποίηση από τη χειροκίνητη και υπολογιστικά δαπανηρή διαχείριση των τανυστών (tensors) ή τον περίπλοκο προγραμματισμό των μηχανισμών προσοχής (attention mechanisms). Η αρχιτεκτονική αυτή επιλογή όχι μόνο βελτιστοποίησε την κατανομή των πόρων, αλλά επιτάχυνε τον κύκλο ανάπτυξης, υποστηρίζοντας απρόσκοπτα τόσο την ταξινόμηση της συναισθηματικής πολικότητας όσο και την παραγωγή αφαιρετικών περιλήψεων (abstractive summarization) στο εκάστοτε ειδησεογραφικό κείμενο.

Στον αντίποδα αυτής της υπολογιστικής ανάλυσης, η ποσοτική αξιολόγηση των προαναφερθέντων γλωσσικών μοντέλων θα παρέμενε αμιγώς θεωρητική, ή ακόμα και δυσνόητη, δίχως την κατάλληλη οπτική αποτύπωση των εξαγόμενων συμπερασμάτων. Για τον σχεδιασμό των στατιστικών γραφικών παραστάσεων που πλαισιώνουν την Εξερευνητική Ανάλυση Δεδομένων (EDA) στις επόμενες υποενότητες, ενσωματώθηκε δομικά το πακέτο matplotlib. Όπως τεκμηριώνει ο θεμελιωτής του, Hunter (2007) [95], πρόκειται για την πλέον ώριμη και καθιερωμένη βιβλιοθήκη παραγωγής δισδιάστατων γραφικών (2D plotting) στο οικοσύστημα της Python. Η εγγενής παραμετροποισιμότητα (configurability) και η ευελιξία του συγκεκριμένου εργαλείου παρείχε τη δυνατότητα προγραμματιστικού ελέγχου επί των οπτικών χαρακτηριστικών της τελικής παρουσίασης.

Ανεξαρτήτως της μορφολογίας των εξεταζόμενων πληροφοριών (είτε επρόκειτο για ραβδογράμματα συχνοτήτων (bar charts) που απεικονίζουν την κυριαρχία συγκεκριμένων Ονοματισμένων Οντοτήτων (NER), είτε για κυκλικά διαγράμματα (pie charts) που χαρτογραφούν την αθροιστική κατανομή της συναισθηματικής πολικότητας) η βιβλιοθήκη *matplotlib* εξασφάλισε ότι η οπτικοποίηση ανταποκρίνεται με μαθηματική ακρίβεια στις προδιαγραφές σαφήνειας ενός σύγχρονου ακαδημαϊκού συγγράμματος. Μέσω αυτής της οπτικής μετάφρασης (visual translation), οι χαοτικοί πίνακες αριθμών και οι αδόμητες κειμενικές εγγραφές μετατράπηκαν σε άμεσα ερμηνεύσιμη ερευνητική γνώση (interpretable knowledge).

4.3 Πειραματική Εφαρμογή: Αναγνώριση Ονοματισμένων Οντοτήτων (NER)

Η εναρκτήρια φάση της πρακτικής υλοποίησης στο πλαίσιο της παρούσας εργασίας αφορά τη μετάβαση από το θεωρητικό υπόβαθρο στην εφαρμοσμένη Εξόρυξη Πληροφορίας (Information Extraction). Το επίκεντρο αυτού του πρώτου πειραματικού σταδίου είναι η διαχείριση και επεξεργασία αδόμητων κειμενικών δεδομένων (unstructured textual data), τα οποία συνιστούν την πλέον απαιτητική μορφή πληροφορίας στα σύγχρονα υπολογιστικά συστήματα. Ειδικότερα, ο πρωταρχικός ερευνητικός στόχος έγκειται στην ανάπτυξη μιας αυτοματοποιημένης ροής εκτέλεσης (pipeline) ικανής να επιτελέσει την ακριβή ανίχνευση, τον σημασιολογικό διαχωρισμό και, τελικά, την ποσοτική ανάλυση των κυρίαρχων Ονοματισμένων Οντοτήτων (Named Entities) που ενυπάρχουν στο ειδησεογραφικό σώμα κειμένων (corpus).

Σε αυτό το πλαίσιο, η διαδικασία της Αναγνώρισης Ονοματισμένων Οντοτήτων (NER) δεν αντιμετωπίζεται απλώς ως ένας μηχανισμός επιφανειακής αντιστοίχισης λέξεων, αλλά ως ένα εργαλείο σημασιολογικής απόσταξης (semantic distillation). Μέσω της εφαρμογής εξειδικευμένων αλγορίθμων Επεξεργασίας Φυσικής Γλώσσας, επιδιώκεται η χαρτογράφηση του ακατέργαστου δημοσιογραφικού λόγου και η εξαγωγή των κεντρικών δρώντων (όπως φυσικά πρόσωπα, γεωπολιτικές τοποθεσίες και θεσμοί). Αυτή η λειτουργία αποτελεί το αναγκαίο προαπαιτούμενο βήμα προκειμένου το αφηρημένο, συνεχές κείμενο να μετασχηματιστεί επιτυχώς σε δομημένη, κατηγορική πληροφορία (categorical data), πλήρως αξιοποιήσιμη για περαιτέρω στατιστική μοντελοποίηση.

Στα υποκεφάλαια που ακολουθούν αναπτύσσεται ο μεθοδολογικός άξονας (roadmap) της πειραματικής διαδικασίας. Αρχικά, παρατίθεται η αρχιτεκτονική της προγραμματιστικής υλοποίησης, με ιδιαίτερη έμφαση στις τεχνικές βελτιστοποίησης του κώδικα για την ταχεία επεξεργασία του συνόλου δεδομένων. Εν συνεχεία, παρουσιάζονται οι στατιστικές κατανομές και οι γραφικές αναπαραστάσεις (data visualizations) των παραγόμενων συχνοτήτων, επιτρέποντας την άμεση οπτική αποκωδικοποίηση των επικρατέστερων πληροφοριακών κόμβων.

Το κεφάλαιο κορυφώνεται με μια κριτική αποτίμηση (critical evaluation) των εξαγόμενων ευρημάτων. Στο πλαίσιο αυτό, δεν καταγράφονται απλώς οι επιτυχείς αντιστοιχίσεις, αλλά αναλύονται οι εγγενείς αλγοριθμικοί περιορισμοί (inherent limitations) και τα ταξινομικά σφάλματα που χαρακτηρίζουν την αρχιτεκτονική των ελαφρών γλωσσικών μοντέλων (lightweight NLP models). Μέσω αυτής της αντιπαραβολής δυνατοτήτων και αδυναμιών, προσφέρεται μια ρεαλιστική και πολυδιάστατη αξιολόγηση της αποδοτικότητάς τους σε πραγματικές συνθήκες (real-world scenarios).

4.3.1 Μεθοδολογική Προσέγγιση και Προγραμματιστική Υλοποίηση

Για την εκπλήρωση των ερευνητικών στόχων, αντλήθηκε και αξιοποιήθηκε το καθιερωμένο σύνολο δεδομένων «BBC News Dataset» [61]. Το συγκεκριμένο corpus απαρτίζεται από 2.225 αυθεντικά δημοσιογραφικά άρθρα, τα οποία καλύπτουν ένα ευρύ φάσμα θεματικών κατηγοριών. Η αρχιτεκτονική του μηχανισμού εξόρυξης πληροφορίας (information extraction engine) δομήθηκε εξ ολοκλήρου πάνω στο προγραμματιστικό οικοσύστημα της βιβλιοθήκης Επεξεργασίας Φυσικής Γλώσσας spaCy [96]. Ως πυρήνας της αναλυτικής διαδικασίας επιλέχθηκε το προεκπαιδευμένο αγγλικό γλωσσικό μοντέλο `en_core_web_sm`, το οποίο διακρίνεται για την ισορροπία μεταξύ υπολογιστικής ταχύτητας και προβλεπτικής ικανότητας (accuracy-speed trade-off) σε κείμενα γενικού σκοπού.

Δεδομένου του μεγάλου μεγέθους του σώματος κειμένων, η μαζική σάρωση (batch text processing) ενείχε τον κίνδυνο δημιουργίας σημαντικής υπολογιστικής συμφόρησης (computational bottleneck). Προκειμένου να ελαχιστοποιηθεί ο χρόνος εκτέλεσης (inference time) και να βελτιστοποιηθεί η διαχείριση της διαθέσιμης μνήμης (memory footprint), κρίθηκε αναγκαία η παραμετροποίηση της επεξεργαστικής αλυσίδας (NLP pipeline). Ειδικότερα, λειτουργικές συνιστώσες που κρίθηκαν περιττές για τον σκοπό της Αναγνώρισης Ονοματισμένων Οντοτήτων, όπως ο συντακτικός αναλυτής εξαρτήσεων (dependency parser) και ο αλγόριθμος ληματοποίησης (lemmatizer), απενεργοποιήθηκαν κατά τη φόρτωση του μοντέλου. Μέσω αυτής της πρακτικής ελάφρυνσης (pipeline pruning), οι πόροι του συστήματος δεσμεύτηκαν αποκλειστικά για την ταχεία αναγνώριση και ταξινόμηση των ζητούμενων πληροφοριακών στοιχείων.

Η προγραμματιστική λογική αυτής της βελτιστοποιημένης αρχιτεκτονικής αποτυπώνεται με σαφήνεια στο ακόλουθο απόσπασμα κώδικα (Εικόνα 4.1).


```
# Απενεργοποίηση περιττών στοιχείων για ταχύτερη εκτέλεση του NER
nlp = spacy.load("en_core_web_sm", disable=["parser", "lemmatizer",
"tok2vec"])

# Σάρωση των άρθρων και εξαγωγή οντοτήτων σε παρτίδες (batch
processing)
for doc in nlp.pipe(text_data, batch_size=50):
    for ent in doc.ents:
        clean_text = ent.text.strip().replace('\n', ' ')
        if len(clean_text) > 2:
            if ent.label_ == "PERSON":
                persons.append(clean_text)
            elif ent.label_ == "ORG":
                orgs.append(clean_text)
            elif ent.label_ == "GPE":
                gpes.append(clean_text)
```

Εικόνα 4.1: Βασικός προγραμματιστικός βρόχος για την ταχεία εξαγωγή οντοτήτων και την εφαρμογή κανόνων καθαρισμού.

Όπως αποτυπώνεται στο ανωτέρω προγραμματιστικό παράδειγμα, η εκτέλεση της αναλυτικής διεργασίας δεν πραγματοποιείται σειριακά (document-by-document), αλλά υιοθετείται η βελτιστοποιημένη στρατηγική της επεξεργασίας σε παρτίδες (batch processing) μέσω της γεννήτριας `nlp.pipe()`. Ο καθορισμός της παραμέτρου `batch_size=50` διασφαλίζει την ιδεατή διαχείριση της προσωρινής μνήμης (memory buffering) και τη μείωση του υπολογιστικού χρόνου, τροφοδοτώντας το γλωσσικό μοντέλο με έναν σταθερό και ελεγχόμενο όγκο πληροφορίας.

Παράλληλα, εντός του κεντρικού βρόχου επανάληψης (main iteration loop), ενσωματώθηκε ένας κρίσιμος μηχανισμός κανονικοποίησης και εξυγίανσης των δεδομένων (text sanitization & normalization). Σε πρώτο στάδιο, εφαρμόζεται δυναμική αφαίρεση των μη ορατών χαρακτήρων (όπως οι αλλαγές γραμμής `\n`) και των περιττών κενών. Αμέσως μετά, εισάγεται ένας αυστηρός ευρετικός κανόνας (heuristic rule) ο οποίος απορρίπτει αυτόματα κάθε εντοπισμένη οντότητα με μήκος μικρότερο ή ίσο των δύο χαρακτήρων.

Η συγκεκριμένη συνθήκη λειτουργεί ως δικλείδα ασφαλείας (safeguard) έναντι του στατιστικού θορύβου (noise). Αποτρέπει αποτελεσματικά την εσφαλμένη καταχώρηση μεμονωμένων γραμμάτων, καταλοίπων μορφοποίησης ή μεμονωμένων σημείων στίξης, τα οποία τα στατιστικά μοντέλα τείνουν ενίοτε να παρερμηνεύουν ως έγκυρα ονόματα (Ψευδώς Θετικά - false positives). Τέλος, τα εκκαθαρισμένα πλέον λήμματα ταξινομούνται αυτοματοποιημένα, προσαρτώντας σε τρεις διακριτές δομές δεδομένων (δυναμικές λίστες), οι οποίες αντιστοιχούν στις οντολογικές κλάσεις της μελέτης: Φυσικά Πρόσωπα (PERSON), Εταιρείες / Οργανισμοί (ORG) και Γεωπολιτικές Τοποθεσίες (GPE).


4.3.2 Οπτικοποίηση Ευρημάτων και Στατιστική Κατανομή

Μετά την επιτυχή ολοκλήρωση της αυτοματοποιημένης εξόρυξης πληροφορίας από το σύνολο των 2.225 εγγράφων, η πειραματική ροή (pipeline) μετέβη στο στάδιο της Εξερευνητικής Ανάλυσης Δεδομένων (Exploratory Data Analysis - EDA). Σε πρώτη φάση, ο τεράστιος όγκος των ασύνδετων οντοτήτων συγκεντρώθηκε σε δομές λεξικών (hash maps) και αθροιστικών μετρητών, με σκοπό τον ακριβή υπολογισμό της απόλυτης συχνότητας εμφάνισης (absolute frequency) για κάθε διακριτό λήμμα. Δεδομένου ότι η κατανομή των λέξεων και των οντοτήτων σε τέτοιας κλίμακας σώματα κειμένων εμφανίζει μια εκτενή «μακριά ουρά» (long tail distribution) σπάνιων αναφορών, η ανάλυση του συνόλου των δεδομένων σε πίνακα θα καθιστούσε αδύνατη την εξαγωγή ουσιαστικών συμπερασμάτων.

Προς αντιμετώπιση αυτής της πρόκλησης, κρίθηκε αναγκαία η οπτικοποίηση της πληροφορίας (data visualization) αξιοποιώντας τις προηγμένες δυνατότητες του


προγραμματιστικού περιβάλλοντος της βιβλιοθήκης Matplotlib. Ως βέλτιστη πρακτική για τη συγκριτική αξιολόγηση κατηγορικών μεταβλητών (categorical data), προκρίθηκε η χρήση ραβδογραμμάτων (bar charts). Εφαρμόζοντας ένα στατιστικό φίλτρο αποκοπής (cutoff filter), απομονώθηκαν συστηματικά και απεικονίζονται αποκλειστικά τα δέκα επικρατέστερα ευρήματα (Top-10) ανά εξεταζόμενη κλάση. Η συγκεκριμένη μεθοδολογική επιλογή επιτρέπει την αποτελεσματική συμπύκνωση της πληροφορίας (data summarization) και προσφέρει τη δυνατότητα στον αναγνώστη να κατανοήσει συνολικά τη θεματολογία του αδόμητου κείμενου.

Η Εικόνα 4.2 αποτυπώνει την ποσοτική ιεράρχηση των οντοτήτων που ταξινομήθηκαν ως Φυσικά Πρόσωπα (PERSON). Η συγκεκριμένη οπτικοποίηση διευκολύνει τον άμεσο εντοπισμό των κεντρικών δρώντων (key actors) οι οποίοι μονοπώλησαν το δημοσιογραφικό ενδιαφέρον και, κατ' επέκταση, διαμόρφωσαν τον πυρήνα του ειδησεογραφικού κύκλου (news cycle) κατά την εξεταζόμενη χρονική περίοδο.




Εικόνα 4.2: Στατιστική κατανομή των δέκα επικρατέστερων Φυσικών Προσώπων (PERSON) στο σύνολο δεδομένων.

Στη συνέχεια, η προσοχή μετατοπίζεται στον άξονα των θεσμικών και εταιρικών δομών. Όπως παρουσιάζεται στην Εικόνα 4.3, η κατανομή των Οργανισμών (ORG) αναδεικνύει τους συλλογικούς φορείς με την ισχυρότερη και πλέον επιδραστική παρουσία στον βρετανικό δημόσιο λόγο. Η ποικιλία των καταγραφών επιβεβαιώνει την πολυθεματική φύση (multitopic nature) του dataset, καλύπτοντας ένα ευρύ φάσμα πληροφορίας, από την κεντρική πολιτική σκηνή έως την ταχέως αναπτυσσόμενη βιομηχανία της τεχνολογίας.



Εικόνα 4.3: Στατιστική κατανομή των δέκα επικρατέστερων Οργανισμών (ORG) στο σύνολο δεδομένων.

Τέλος, η Εικόνα 4.4 εστιάζει στις αναφορές Γεωπολιτικών Οντοτήτων (GPE). Μέσω του συγκεκριμένου ραβδογράμματος, εξάγεται μια χωρική αποτύπωση (spatial mapping) του προσανατολισμού των συντακτών, υποδεικνύοντας με στατιστική ακρίβεια τα κράτη, τις περιφέρειες και τα αστικά κέντρα που βρέθηκαν στο επίκεντρο της κάλυψης των μέσων μαζικής ενημέρωσης (mass media coverage).



Εικόνα 4.4: Στατιστική κατανομή των δέκα επικρατέστερων Γεωπολιτικών Τοποθεσιών (GPE) στο σύνολο δεδομένων.

4.3.3 Κριτική Αποτίμηση Ευρημάτων και Διαπίστωση Αλγοριθμικών Περιορισμών

Η κριτική αποτίμηση των παραγόμενων οπτικοποιήσεων δεν περιορίζεται στην απλή παράθεση στατιστικών μεγεθών, αλλά προσφέρει πολύτιμα συμπεράσματα αναφορικά με τη δομική και σημασιολογική σύσταση του εξεταζόμενου σώματος κειμένων. Αξιολογώντας αρχικά τον άξονα των γεωπολιτικών τοποθεσιών (Εικόνα 4.4), επαληθεύεται ο βρετανοκεντρικός προσανατολισμός του ειδησεογραφικού δικτύου. Η υπεροχή τοπωνυμίων (Geopolitical Entities - GPE) όπως "England" και "London" αποδεικνύει την αναμενόμενη γεωγραφική πόλωση (spatial bias) του συγκεκριμένου dataset. Παράλληλα, η συχνότητα εμφάνισης ισχυρών πολιτικών προσώπων (π.χ. Blair, Brown) και σημαντικών εταιριών (π.χ. Microsoft, BBC) στις αντίστοιχες Εικόνες 4.2 και 4.3, συνδέεται κατά απόλυτο τρόπο με την τρέχουσα επικαιρότητα και την ιστορικότητα της περιόδου κατά την οποία συντάχθηκαν τα εν λόγω ρεπορτάζ.

Εντούτοις, παρά τη μακροσκοπική εγκυρότητα των παρατηρούμενων τάσεων, η λεπτομερής μικροσκοπική ανάλυση (micro-level analysis) των αποτελεσμάτων έφερε στην επιφάνεια συγκεκριμένες, επαναλαμβανόμενες ταξινομικές αστοχίες (classification anomalies) του συστήματος. Το πλέον χαρακτηριστικό παράδειγμα αλγοριθμικού σφάλματος εντοπίζεται στη λανθασμένη απόδοση της οντολογικής ετικέτας του "Φυσικού Προσώπου" (PERSON) στον πολιτικό σχηματισμό "Labour" (Εργατικό Κόμμα), καθώς και στην ενεργειακή βιομηχανία "Yukos". Καθίσταται σαφές πως το συγκεκριμένο φαινόμενο δεν συνιστά προγραμματιστικό σφάλμα λογικής (logic error) κατά την υλοποίηση του πειραματικού κώδικα. Αντιθέτως, αναδεικνύει τις αρχιτεκτονικές αδυναμίες και τους αυστηρούς υπολογιστικούς περιορισμούς του επιλεγμένου, ελαφρού γλωσσικού μοντέλου (en_core_web_sm).

Όπως τεκμηριώνεται στη σύγχρονη βιβλιογραφία [97], οι παραδοσιακές στατιστικές προσεγγίσεις Αναγνώρισης Οντοτήτων, όπως αυτές που ενσωματώνει στον πυρήνα της η τρέχουσα έκδοση της βιβλιοθήκης spaCy, υπολείπονται σε απαιτητικές δοκιμές αναφοράς (benchmarks) συγκριτικά με τα νεότερα, βαθιά νευρωνικά δίκτυα. Η γενεσιουργός αιτία αυτής της παράλειψης εντοπίζεται στη δομική απουσία προηγμένων μηχανισμών προσοχής (attention mechanisms). Συνεπώς, τα συγκεκριμένα «ελαφρά» (lightweight) μοντέλα αδυνατούν να διαχειριστούν αποτελεσματικά φαινόμενα σημασιολογικής αμφισημίας (semantic ambiguity). Πιο συγκεκριμένα, στερούνται της υπολογιστικής ικανότητας να αξιολογήσουν το δυναμικό βάρος μιας λέξης συναρτήσει του ευρύτερου εννοιολογικού πλαισίου (context) που διαμορφώνει η συνολική πρόταση.

Στον αντίποδα αυτής της στατικής αναπαράστασης, οι σύγχρονες αρχιτεκτονικές που βασίζονται στο πρότυπο Transformer (όπως η οικογένεια μοντέλων BERT) επιτυγχάνουν αύξηση της προβλεπτικής ακρίβειας. Το επίτευγμα αυτό καθίσταται εφικτό χάρη στην αμφίδρομη (bidirectional) ανάγνωση της φυσικής γλώσσας, η οποία επιτρέπει την προσαρμογή του νοήματος βάσει των συμφραζομένων [97].

Εφόσον έχει ολοκληρωθεί η διαδικασία εντοπισμού της δομημένης πληροφορίας (ποιος, πού), το ερευνητικό ενδιαφέρον μετατοπίζεται πλέον στο πεδίο της Ανάλυσης Συναισθήματος (Sentiment Analysis). Εκεί, θα επιχειρηθεί μια εκτενής, συγκριτική αντιπαράβολή μεταξύ ταχέων λεξικογραφικών προσεγγίσεων, κλασικών αλγορίθμων Μηχανικής Μάθησης και υπερσύγχρονων γλωσσικών μοντέλων βαθιάς εκμάθησης, με στόχο την ολιστική αποκωδικοποίηση της πληροφορίας που εμπεριέχεται στο εξεταζόμενο corpus.

4.4 Ανάλυση Συναισθήματος με Χρήση Λεξικογραφικών Μεθόδων (VADER)

Μετά την επιτυχή περάτωση της εξαγωγής δομημένης πληροφορίας μέσω της Αναγνώρισης Ονοματισμένων Οντοτήτων (NER), η παρούσα εργασία μεταβαίνει στο στάδιο επεξεργασίας του corpus: την Ανάλυση Συναισθήματος (Sentiment Analysis) ή Εξόρυξη Γνώμης (Opinion Mining). Ενώ το προηγούμενο πειραματικό στάδιο επικεντρώθηκε στην αντιστοίχιση του «ποιος» και του «πού» (καταγράφοντας απτά, αντικειμενικά δεδομένα), η τρέχουσα φάση της ερευνητικής ροής

(pipeline) επιδιώκει την αποκωδικοποίηση του «πώς». Το βασικό ζητούμενο πλέον δεν είναι η απλή ανίχνευση λέξεων, αλλά η συστηματική, μαθηματική ποσοτικοποίηση της υποβόσκουσας συναισθηματικής πολικότητας (emotional polarity) που ενυπάρχει στα επιλεγμένα ειδησεογραφικά άρθρα του δικτύου BBC.

Η εφαρμογή αλγορίθμων υπολογισμού συναισθήματος στον τομέα της δημοσιογραφίας συνιστά μια από τις πλέον απαιτητικές προκλήσεις (challenges) για τα σύγχρονα υπολογιστικά συστήματα Επεξεργασίας Φυσικής Γλώσσας. Σε αντίθεση με τα δεδομένα που αντλούνται από τα μέσα κοινωνικής δικτύωσης (social media) ή τις πλατφόρμες αξιολόγησης προϊόντων (όπου ο εκάστοτε συντάκτης εκφράζεται με απόλυτη ελευθερία, χρησιμοποιώντας συχνά ακραίο ή άτυπο λεξιλόγιο) ο επίσημος ειδησεογραφικός λόγος υπακούει σε αυστηρούς κανόνες αντικειμενικής αναφοράς (objective reporting) και θεσμικής επισημότητας [98]. Συνεπώς, η αλγοριθμική ανίχνευση της υποκείμενης στάσης (attitude) σε τέτοιου είδους κείμενα απαιτεί εργασία εξαιρετικής ευαισθησίας, ικανά να εντοπίσουν ανεπαίσθητες γλωσσικές αποχρώσεις πίσω από μια αυστηρά πληροφοριακή καταγραφή γεγονότων.

Προκειμένου να εγκαθιδρυθεί ένα αξιόπιστο μέτρο αναφοράς (baseline model) ενόψει της επικείμενης μετάβασης σε προηγμένες αρχιτεκτονικές Μηχανικής και Βαθιάς Μάθησης (Machine and Deep Learning), το εναρκτήριο ερευνητικό βήμα αυτής της φάσης εδράζεται σε μια αμιγώς λεξικογραφική, μη επιβλεπόμενη (unsupervised) μεθοδολογία. Συγκεκριμένα, τίθεται σε εφαρμογή το εργαλείο VADER (Valence Aware Dictionary and sEntiment Reasoner) [99]. Πρόκειται για ένα ευρέως καθιερωμένο, κανονιστικό σύστημα (rule-based framework), το οποίο εξασφαλίζει ταχύτατη εξαγωγή πολικότητας, παρακάμπτοντας την υπολογιστικά δαπανηρή απαίτηση για πρότερη εκπαίδευση κάποιου μοντέλου.

Στις υποενότητες που ακολουθούν, αναπτύσσεται η προγραμματιστική υλοποίηση της συγκεκριμένης μεθόδου και παρατίθενται οι οπτικοποιήσεις των εξαγόμενων στατιστικών κατανομών. Επιπρόσθετα, επιχειρείται μια ποιοτική αποτίμηση (qualitative evaluation) της πραγματικής αποτελεσματικότητας του αλγορίθμου, εστιάζοντας στις δομικές αδυναμίες που παρουσιάζει κατά την απόπειρα μοντελοποίησης του ιδιάζοντος δημοσιογραφικού κειμένου.

4.4.1 Προεπεξεργασία Δεδομένων και Υπολογισμός Πολικότητας

Η πρακτική υλοποίηση του πειράματος ξεκίνησε με τον καθαρισμό και τη δομική διευθέτηση (structural alignment) του πρωτογενούς συνόλου δεδομένων. Λόγω της φύσης του αρχείου (διαχωρισμός εγγραφών με στηλοθέτες - Tab-Separated Values), εντοπίστηκαν αναμενόμενες αστοχίες κατά τη διαδικασία ανάλυσης (parsing errors), οφειλόμενες συχνά σε μη τυποποιημένους χαρακτήρες διαφυγής (escape characters) εντός του ακατέργαστου δημοσιογραφικού κειμένου. Για την αντιμετώπιση αυτού του φαινομένου και την αποφυγή θορύβου, εφαρμόστηκαν αυστηρές προγραμματιστικές ρουτίνες απόρριψης συντακτικά κατεστραμμένων ή ελλιπών εγγραφών (data dropping). Η διαδικασία αυτή διασφάλισε την ακεραιότητα και την υψηλή ποιότητα των 2.225 έγκυρων ειδησεογραφικών εγγράφων που συγκροτούν το τελικό corpus. Η υπολογιστική διαχείριση αυτού του όγκου πληροφορίας, καθώς και η εισαγωγή των απαραίτητων λεξικογραφικών πόρων, υλοποιήθηκε μέσω της βιβλιοθήκης Natural Language Toolkit (NLTK), η οποία συνιστά το καθιερωμένο ακαδημαϊκό πρότυπο για εφαρμογές Επεξεργασίας Φυσικής Γλώσσας στο οικοσύστημα της Python [99].

Στον πυρήνα της προτεινόμενης μεθοδολογίας τοποθετείται ο αλγόριθμος VADER (Valence Aware Dictionary and sEntiment Reasoner), ένα εξειδικευμένο μοντέλο ανάλυσης συναισθήματος βασισμένο σε ένα λιτό αλλά αποδοτικό σύνολο κανόνων (parsimonious rule-based model) [76]. Το πλεονέκτημα της εν λόγω αρχιτεκτονικής έναντι των παραδοσιακών μεθόδων απλής αντιστοίχισης (bag-of-words lexicons) έγκειται στο γεγονός ότι δεν περιορίζεται στη γραμμική, δυαδική ταξινόμηση των λέξεων ως "θετικών" ή "αρνητικών". Αντιθέτως, ποσοτικοποιεί με ακρίβεια την ένταση του συναισθηματικού φορτίου (valence). Ο εσωτερικός μηχανισμός του VADER ενσωματώνει προηγμένους ευρετικούς κανόνες (heuristics), αναγνωρίζοντας την επίδραση ποικίλων συντακτικών και μορφολογικών φαινομένων. Ειδικότερα, λαμβάνει υπόψη τη χρήση ενισχυτικών σημείων στίξης, την κεφαλαιογράμματα

γραφή ως μέσο έμφασης, καθώς και την παρουσία προσδιορισμών βαθμού (degree modifiers ή intensifiers), οι οποίοι δύνανται να πολλαπλασιάσουν ή να αμβλύνουν την τελική σημασιολογική βαρύτητα μιας πρότασης.

Η τελική εξαγωγή συμπεράσματος για την εκάστοτε ειδησεογραφική εγγραφή εδράζεται στον υπολογισμό του σύνθετου σκορ (compound score). Πρόκειται για μια μαθηματικά κανονικοποιημένη (normalized), συνεχή μεταβλητή, η οποία προκύπτει από το σταθμισμένο άθροισμα των επιμέρους βαθμολογιών του κειμένου. Μέσω μιας εξειδικευμένης ευρετικής συνάρτησης, η τελική τιμή προσαρμόζεται κλιμακωτά ώστε να κυμαίνεται αυστηρά στο κλειστό μαθηματικό διάστημα από -1 (απόλυτα αρνητική πολικότητα) έως +1 (απόλυτα θετική πολικότητα). Υιοθετήθηκαν τα καθιερωμένα κατώφλια (standard thresholds) που προτείνει η διεθνής βιβλιογραφία για την ασφαλή κατηγοριοποίηση της συναισθηματικής τάσης. Ο συγκεκριμένος λογικός διαχωρισμός αποτυπώνεται στο παρακάτω απόσπασμα κώδικα (Εικόνα 4.5):

```
# Συνάρτηση ταξινόμησης συναισθήματος βάσει του VADER Compound Score
def get_sentiment_label(text):
    scores = sia.polarity_scores(str(text))
    compound = scores['compound']

    if compound >= 0.05:
        return 'Positive'
    elif compound <= -0.05:
        return 'Negative'
    else:
        return 'Neutral'
```


Εικόνα 4.5: Προγραμματιστική ρουτίνα υπολογισμού του κανονικοποιημένου δείκτη (compound score) και κατηγοριοποίησης της συναισθηματικής πολικότητας βάσει των καθιερωμένων κατωφλίων του αλγορίθμου VADER.

Η προαναφερθείσα προγραμματιστική ρουτίνα ενσωματώθηκε στον κύκλο εκτέλεσης και εφαρμόστηκε μαζικά, σαρώνοντας το σύνολο των άρθρων του αγγλικού δικτύου. Μέσω αυτής της αυτοματοποιημένης διεργασίας εξαγωγής χαρακτηριστικών (feature extraction), κάθε κείμενο εμπλουτίστηκε με ένα ακριβές αριθμητικό σκορ καθώς και την αντίστοιχη διακριτή ετικέτα πολικότητας (sentiment label). Αυτή η κρίσιμη μετατροπή της αδόμητης γλωσσικής πληροφορίας σε δομημένα, κατηγορικά δεδομένα (categorical data), δημιούργησε τη στέρεη βάση για τη στατιστική οπτικοποίηση και τη σε βάθος διασταυρούμενη ανάλυση που ακολουθεί στις επόμενες υποενότητες.

4.4.2 Οπτικοποίηση και Αξιολόγηση Συνολικής Κατανομής

Η εφαρμογή του αλγορίθμου VADER στο σύνολο του εξεταζόμενου σώματος κειμένων απέδωσε μια αρχική, μακροσκοπική εικόνα της συναισθηματικής τάσης που διέπει το δίκτυο BBC. Για την αποτελεσματική χαρτογράφηση και την ορθή ερμηνεία αυτών των συγκεντρωτικών αποτελεσμάτων, επιλέχθηκε η γραφική τους αναπαράσταση μέσω κυκλικού διαγράμματος (pie chart). Η συγκεκριμένη τεχνική οπτικοποίησης αποτυπώνεται στην Εικόνα 4.6 και κρίνεται κατάλληλη για την απεικόνιση αναλογιών επί ενός συνόλου (part-to-whole relationship), επιτρέποντας την άμεση οπτική σύγκριση των τριών διακριτών κλάσεων πολικότητας (Positive, Negative, Neutral) που προέκυψαν από τα προκαθορισμένα κατώφλια (thresholds).

Συνολική Κατανομή Συναισθήματος στο BBC News Dataset



Εικόνα 4.6: Συνολική κατανομή συναισθηματικής πολικότητας στο BBC News Dataset μέσω του αλγορίθμου VADER.

Αναλύοντας τα παραγόμενα ποσοστιαία μεγέθη, αναδύεται μια έντονη και απροσδόκητη στατιστική ασυμμετρία (statistical asymmetry). Η θετική πολικότητα κυριαρχεί στο εξεταζόμενο δείγμα, καταλαμβάνοντας το 71,4% του συνολικού όγκου των δεδομένων. Στον αντίποδα, τα άρθρα που ταξινομήθηκαν ως αρνητικά συγκεντρώνουν το 27,7%, ενώ η κλάση της απόλυτης ουδετερότητας περιθωριοποιείται σε ένα στατιστικά αμελητέο ποσοστό της τάξης του 0,9%.

Προσεγγίζοντας το συγκεκριμένο εύρημα από αλγοριθμική σκοπιά, η πρακτική «εξαφάνιση» της ουδέτερης κλάσης δεν αποτελεί σφάλμα των δεδομένων, αλλά φυσική απόρροια του εσωτερικού μηχανισμού υπολογισμού. Το VADER εξάγει το τελικό σύνθετο σκορ (compound score) μέσω μιας διαδικασίας αθροιστικής συσσώρευσης (cumulative summation) των τιμών πολικότητας κάθε μεμονωμένου λήμματος, εφαρμόζοντας μια μαθηματική συνάρτηση κανονικοποίησης (normalization function). Δεδομένου ότι τα άρθρα του BBC συνιστούν εκτενή έγγραφα (long-form texts) που απαρτίζονται από εκατοντάδες λέξεις, η στατιστική πιθανότητα το τελικό αλγεβρικό άθροισμα να παραμείνει εγκλωβισμένο στο στενό εύρος της ουδετερότητας (από -0,05 έως +0,05) τείνει στο μηδέν. Ακόμη και η παρουσία ελάχιστων επιθέτων ή ρημάτων με ασθενές συναισθηματικό φορτίο αρκεί για να ωθήσει τη συνολική βαθμολογία προς τα άκρα της κλίμακας, αναγκάζοντας πρακτικά το μοντέλο να εκφράσει ξεκάθαρη πόλωση.


Πέρα από τους προφανείς υπολογιστικούς περιορισμούς, η συγκεκριμένη κατανομή υπογραμμίζει μια θεμελιώδη αδυναμία της αμιγώς λεξικογραφικής μεθόδου όταν αυτή εφαρμόζεται στον ειδησεογραφικό λόγο. Η υπεροχή των θετικών ταξινομήσεων καταδεικνύει ότι το σύστημα λειτουργεί σε μεγάλο βαθμό αποσπασματικά. Εντοπίζει μεμονωμένους όρους με θετική σημασία (όπως «ανάπτυξη», «συμφωνία» ή «επίτευγμα») και τους αποδίδει δυσανάλογα υψηλή βαρύτητα. Με αυτόν τον τρόπο, παρακάμπτει πλήρως το ευρύτερο, αποστασιοποιημένο και αντικειμενικό συγκείμενο (context) εντός του οποίου οφείλει να εντάσσεται η δημοσιογραφική αφήγηση.

Επομένως, η αρχική μακροσκοπική αποτίμηση, μολοντί χρήσιμη ως γενική ένδειξη, δεν επαρκεί από μόνη της για την εξαγωγή ασφαλών συμπερασμάτων. Θεωρείται αναγκαία η περαιτέρω τμηματοποίηση (segmentation) του dataset, με γνώμονα να διερευνηθεί ο τρόπος με

τον οποίο αυτή η παρατηρούμενη συναισθηματική φόρτιση μεταβάλλεται και αναπροσαρμόζεται ανάλογα με τον ειδικότερο θεματικό άξονα (domain) του εκάστοτε ρεπορτάζ.

4.4.3 Διασταυρούμενη Ανάλυση ανά Θεματική Κατηγορία

Η μακροσκοπική εικόνα που παρείχε η συνολική κατανομή, αν και κατατοπιστική, υποκρύπτει σημαντικές εσωτερικές διαφοροποιήσεις. Προκειμένου να αποσαφηνιστούν τα βαθύτερα αίτια της επικράτησης της θετικής πολικότητας, το επόμενο μεθοδολογικό βήμα επιτάσσει μια πιο κοκκώδη ανάλυση (granular analysis). Η διαστρωμάτωση του συνόλου δεδομένων (data stratification) με βάση τις πέντε διαθέσιμες θεματικές κατηγορίες (business, entertainment, politics, sport, tech) προσφέρει ένα ευρύ πρίσμα παρατήρησης. Η συγκεκριμένη προσέγγιση μας επιτρέπει να αξιολογήσουμε την ευρωστία (robustness) του αλγορίθμου VADER και τη συμπεριφορά του μέσα σε ετερογενή σημασιολογικά περιβάλλοντα (domain-specific contexts). Το αποτέλεσμα αυτής της διασταυρούμενης αξιολόγησης αποτυπώνεται στο ομαδοποιημένο ραβδόγραμμα (grouped bar chart) που ακολουθεί.



Εικόνα 4.7: Κατανομή συναισθηματικής πολικότητας ανά θεματική κατηγορία στο BBC News Dataset.

Όπως καθίσταται προφανές από τη γραφική αναπαράσταση, η κατανομή του συναισθήματος δεν είναι ομοιόμορφη, αλλά παρουσιάζει στατιστικές διακυμάνσεις μεταξύ των κατηγοριών. Το γεγονός αυτό αποδεικνύει πως η επίδοση των λεξικογραφικών εργαλείων είναι άρρηκτα συνδεδεμένη και ενίοτε περιορίζεται από το εξειδικευμένο λεξιλόγιο του εκάστοτε τομέα. Η πλέον χαρακτηριστική στατιστική ανωμαλία (anomaly) εντοπίζεται στις κατηγορίες του αθλητισμού (sport) και της ψυχαγωγίας (entertainment), όπου ο όγκος των καταχωρήσεων που ταξινομήθηκαν ως «θετικές» υπερτερεί.

Αυτή η ασύμμετρη συγκέντρωση δεν συνεπάγεται απαραίτητα μια πιο «χαρούμενη» ή ανάλαφρη ειδησεογραφική πραγματικότητα. Αντιθέτως, ξεσκεπάζει την αδυναμία του μοντέλου να επιτελέσει αποτελεσματική Αποσαφήνιση της Έννοιας των Λέξεων (Word Sense Disambiguation - WSD). Εξετάζοντας το παράδειγμα της αθλητικής αρθρογραφίας, παρατηρείται ότι το δημοσιογραφικό ύφος δανείζεται συχνά όρους με έντονη, σχεδόν πολεμική ή θριαμβευτική χροιά. Λέξεις-κλειδιά όπως «νίκη», «κατάκτηση», «κυριαρχία» ή «πρωταθλητής» φέρουν εξαιρετικά υψηλό θετικό βάρος (valence score) στο στατικό λεξικό του VADER, ενώ

αντίστοιχα η «ήττα» φέρει αρνητικό. Κατά συνέπεια, ο αλγόριθμος ερμηνεύει εσφαλμένα αυτή την ορολογία ως εκδήλωση ακραίου συναισθήματος, παραβλέποντας το γεγονός ότι, στο συγκεκριμένο πλαίσιο, οι όροι αυτοί συνιστούν απλώς την ψυχρή και αντικειμενική καταγραφή του τελικού αποτελέσματος μιας αναμέτρησης.

Στον αντίποδα της παρουσίας έντονα θετικού λεξιλογίου που εντοπίζεται στον αθλητισμό, οι κατηγορίες της πολιτικής (politics) και των επιχειρήσεων (business) σκιαγραφούν μια πιο ισορροπημένη, αλλά εξίσου πολωμένη κατανομή. Σε αυτά τα πεδία, το ποσοστό των αρνητικών εγγραφών εμφανίζεται αυξημένο. Το φαινόμενο αυτό δικαιολογείται από τη φύση του πολιτικοοικονομικού ρεπορτάζ, το οποίο δομείται γύρω από όρους με αρνητικό σημασιολογικό πρόσημο. Λήμματα όπως «κρίση», «έλλειμμα», «σύγκρουση», «ύφεση» ή «παραίτηση» κυριαρχούν στα κείμενα. Αξιοσημείωτο, ωστόσο, παραμένει το γεγονός ότι, παρά τη διαφοροποίηση στη θεματολογία, η απουσία ουδετερότητας διατηρείται σταθερά σε σχεδόν μηδενικά επίπεδα. Αυτό επιβεβαιώνει την αρχιτεκτονική αδυναμία του VADER: ο αλγόριθμος λειτουργεί αυστηρά αθροιστικά (agglomeratively) και πολώνεται με χαρακτηριστική ευκολία από ισχυρές λέξεις-κλειδιά, αδυνατώντας να αναγνωρίσει τη διατήρηση μιας αυστηρά ενημερωτικής στάσης εκ μέρους του συντάκτη.

Παρόμοια μοτίβα ταξινόμησης παρατηρούνται και στην ειδησεογραφία της τεχνολογίας (tech). Στη συγκεκριμένη κατηγορία, η κατανομή γέρνει εκ νέου προς τη θετική πολικότητα, υποκινούμενη από την καθιερωμένη ορολογία της καινοτομίας (π.χ. «αναβάθμιση», «πρόοδος», «επαναστατικό»). Αντίστροφα, όταν ένα τεχνολογικό άρθρο περιγράφει ένα κενό ασφάλειας («παραβίαση», «ευπάθεια», «διαρροή»), το μοντέλο το κατατάσσει αυτομάτως ως έντονα αρνητικό, εγκλωβισμένο στο στατικό του λεξικό και αγνοώντας την καθαρά τεχνική και περιγραφική υφή της ανάλυσης.

Η παρούσα διασταυρούμενη εξέταση επιβεβαιώνει ένα από τα πλέον θεμελιώδη αξιώματα της σύγχρονης Επεξεργασίας Φυσικής Γλώσσας: η εξαγωγή συναισθήματος χωρίς την ενσωμάτωση του συγκεκριμένου (context-awareness) καθίσταται επιρρεπής σε παραπλανητικά συμπεράσματα. Η διαπίστωση ότι ένα σύστημα γενικού σκοπού (general-purpose lexicon) δυσκολεύεται να προσαρμοστεί σε εξειδικευμένους τομείς (domain adaptation), καθιστά αναγκαία την ενδελεχή, ποιοτική αξιολόγηση των παραγόμενων σφαλμάτων. Αυτή ακριβώς η διαδικασία αποδόμησης των αδυναμιών του μοντέλου επιχειρείται στην αμέσως επόμενη υποενότητα.

4.4.4 Ποιοτική Αξιολόγηση και Ανάλυση Σφαλμάτων (Error Analysis)

Η ποσοτική αποτίμηση των αποτελεσμάτων που παρήγαγε ο αλγόριθμος VADER αναδεικνύει, όπως αναλύθηκε προηγουμένως, μια ισχυρή στατιστική μετατόπιση προς τη θετική πολικότητα. Ωστόσο, στην Επιστήμη Δεδομένων, η άκριτη αποδοχή των αριθμητικών ευρημάτων εγκυμονεί σοβαρούς κινδύνους, ειδικά όταν τα παραγόμενα ποσοστά αποκλίνουν από την αναμενόμενη κατανομή του εκάστοτε πεδίου (domain). Προκειμένου να διασφαλιστεί η επιστημονική εγκυρότητα της παρούσας εργασίας, καθίσταται επιτακτική η μετάβαση από τη μακροσκοπική παρατήρηση στην εις βάθος, ποιοτική ανάλυση σφαλμάτων (error analysis). Ο πρωταρχικός στόχος αυτού του σταδίου είναι η αποδόμηση της αρχιτεκτονικής του μοντέλου και ο εντοπισμός των αιτιών που οδηγούν σε αυτή τη σημασιολογική παραφωνία κατά την επεξεργασία του δημοσιογραφικού λόγου.

Το πρόβλημα έγκειται σε μια δομική ασυμβατότητα μεταξύ του σχεδιασμού του εργαλείου και των δεδομένων εισόδου. Το VADER αναπτύχθηκε και βελτιστοποιήθηκε (fine-tuned) έχοντας ως γνώμονα μικρο-κειμενικά δεδομένα (micro-texts), και συγκεκριμένα αναρτήσεις από πλατφόρμες κοινωνικής δικτύωσης. Τα κείμενα αυτά χαρακτηρίζονται από υψηλή συμπύκνωση, αυθορμητισμό, άτυπο ύφος και, κυρίως, άμεση έκφραση προσωπικού συναισθήματος (explicit sentiment). Αντιθέτως, τα άρθρα του δικτύου BBC αποτελούν μακροσκελή, δομημένα έγγραφα (long-form documents) τα οποία υπακούουν σε αυστηρούς κανόνες συντακτικής ορθότητας και δημοσιογραφικής δεοντολογίας. Η απουσία ακραίων σημείων στίξης, emoticons ή

κεφαλαιογράμματος υπερβολών (παράγοντες τους οποίους το VADER αξιοποιεί ως πολλαπλασιαστές έντασης) στερεί από τον αλγόριθμο τα βασικά του κριτήρια αξιολόγησης.

Ακόμη σημαντικότερη, ωστόσο, είναι η αδυναμία του μοντέλου να διαχωρίσει τη συναισθηματική φόρτιση ενός αναφερόμενου γεγονότος από τη στάση του ίδιου του συντάκτη. Στο πλαίσιο της ειδησεογραφίας, ο δημοσιογράφος λειτουργεί ως αντικειμενικός παρατηρητής (objective reporter). Όταν ένα άρθρο περιγράφει μια φυσική καταστροφή, μια γεωπολιτική σύρραξη ή την ανακάλυψη ενός νέου εμβολίου, το κείμενο βρίσκεται λέξεων με ισχυρό αρνητικό ή θετικό φορτίο αντίστοιχα. Ο αθροιστικός κανόνας (rule-based aggregation) του VADER επιβάλλει τη σάρωση του κειμένου και την άθροιση αυτών των λεξικογραφικών βαρών, καταλήγοντας να αποδίδει συναισθηματική πολικότητα στον ίδιο τον αρθρογράφο. Ουσιαστικά, το σύστημα αξιολογεί το "γεγονός" και όχι το "κείμενο", παραβιάζοντας τον θεμελιώδη ορισμό της εξόρυξης γνώμης (opinion mining), η οποία προϋποθέτει την ανίχνευση υποκειμενικότητας (subjectivity).

Πέραν της προαναφερθείσας αδυναμίας διαχωρισμού του γεγονότος από την υποκειμενική άποψη, η ανάλυση των εσφαλμένων ταξινομήσεων (misclassifications) αποκαλύπτει περαιτέρω ελλείψεις στη διαχείριση πολύπλοκων γλωσσικών φαινομένων. Ο ειδησεογραφικός λόγος απαιτεί βαθιά κατανόηση του ευρύτερου συγκειμένου (contextual awareness) για την ορθή απόδοση νοήματος. Η πολυσημία των λέξεων, ο λανθάνων σαρκασμός, καθώς και δομικά στοιχεία όπως η ρητορική παραχώρηση (rhetorical concession), όπου ο αρθρογράφος παραθέτει μια αντίθετη άποψη μόνο και μόνο για να την αντικρούσει στην αμέσως επόμενη πρόταση, αποτελούν εμπόδια για μια λεξικογραφική προσέγγιση. Σε αυτές τις περιπτώσεις, το VADER εγκλωβίζεται στην επιφανειακή, λέξη προς λέξη ερμηνεία, αδυνατώντας να αποκωδικοποιήσει τη συνολική σημασιολογική τροχιά της παραγράφου.

Η συγκεκριμένη παρατήρηση δεν αποτελεί απλώς ένα εμπειρικό εύρημα του παρόντος πειράματος αλλά επιβεβαιώνεται και εναρμονίζεται με τον σύγχρονο ακαδημαϊκό διάλογο. Όπως τεκμηριώνεται στην βιβλιογραφία [77], η εφαρμογή εργαλείων βασισμένων σε κανόνες (rule-based) σε σώματα ειδησεογραφικών κειμένων (corpus pragmatics) εγείρει σοβαρούς μεθοδολογικούς προβληματισμούς. Η σύγχρονη κριτική υπογραμμίζει ότι τα εν λόγω συστήματα τείνουν να εξάγουν παραπλανητικά συμπεράσματα όταν καλούνται να μοντελοποιήσουν την έννοια της "στάσης" (attitude), καθώς αγνοούν τις λεπτές σημασιολογικές αποχρώσεις και τη διακριτική εναλλαγή οπτικών γωνιών που χαρακτηρίζουν τη δημοσιογραφική αφήγηση.

Συνοψίζοντας, η χρήση του αλγορίθμου VADER στο πλαίσιο της παρούσας εργασίας εκπλήρωσε τον αρχικό της σκοπό: παρέιχε ένα γρήγορο, μη επιβλεπόμενο (unsupervised) μέτρο σύγκρισης (baseline) και ταυτόχρονα ανέδειξε την πολυπλοκότητα του προς επίλυση προβλήματος. Καθίσταται, ωστόσο, προφανές ότι για την επίτευξη υψηλής ακρίβειας και την ουσιαστική "κατανόηση" της φυσικής γλώσσας από τη μηχανή, η εξάρτηση από στατικά λεξικά κρίνεται ανεπαρκής. Το συμπέρασμα αυτό λειτουργεί ως το ιδανικό θεωρητικό και πρακτικό εφαλτήριο για το επόμενο στάδιο της εργασίας. Προκειμένου να ξεπεραστούν οι προαναφερθέντες περιορισμοί, το κέντρο βάρους της μελέτης μετατοπίζεται στην υλοποίηση και εκπαίδευση επιβλεπόμενων (supervised) αλγορίθμων Μηχανικής Μάθησης, οι οποίοι διαθέτουν την αρχιτεκτονική ικανότητα να αναγνωρίζουν ανώτερα σημασιολογικά μοτίβα.

4.5 Ανάλυση Συναισθήματος με Βαθιά Μάθηση (RoBERTa)

Αν και οι παραδοσιακές λεξικογραφικές μέθοδοι διακρίνονται για την υπολογιστική τους ταχύτητα και την ευκολία υλοποίησης, αποδεικνύονται ανεπαρκείς όταν καλούνται να αποκωδικοποιήσουν το λεπτό σημασιολογικό πλαίσιο (context) του φυσικού λόγου. Χαρακτηριστικό παράδειγμα αποτέλεσε η εσφαλμένη ταξινόμηση πληθώρας αθλητικών και πολιτικών ρεπορτάζ ως "θετικών", καθώς το βασισμένο σε κανόνες (rule-based) σύστημα αδυνατούσε να διαχωρίσει την αντικειμενική δημοσιογραφική καταγραφή ενός γεγονότος από την πραγματική συναισθηματική φόρτιση του συντάκτη.

Η διαπίστωση αυτών των αδυναμιών κατέστησε αναγκαία τη μετάβαση σε πιο προηγμένες προσεγγίσεις, οι οποίες δεν περιορίζονται στην επιφανειακή αναζήτηση λέξεων-κλειδιών (keyword spotting). Για την αποτελεσματική υπέρβαση των παραπάνω εμποδίων, το επόμενο στάδιο της πειραματικής διάταξης επικεντρώνεται στην αξιοποίηση των Νευρωνικών Δικτύων Βαθιάς Μάθησης (Deep Learning) και, ειδικότερα, της αρχιτεκτονικής Transformers. Στο επίκεντρο αυτής της νέας φάσης τίθεται το υπερσύγχρονο, προεκπαιδευμένο γλωσσικό μοντέλο RoBERTa (Robustly Optimized BERT Pretraining Approach) [78].

Η ειδοποιός διαφορά του συγκεκριμένου μοντέλου, σε αντιδιαστολή με τις απλοϊκές μεθόδους καταμέτρησης λέξεων (bag-of-words) και τα στατικά λεξικά, έγκειται στην αμφίδρομη (bidirectional) ικανότητα επεξεργασίας του φυσικού λόγου. Μέσω του προηγμένου μηχανισμού αυτο-προσοχής (self-attention), το νευρωνικό δίκτυο παύει να αξιολογεί τα λήμματα ως απομονωμένες, ανεξάρτητες μονάδες. Αντιθέτως, υπολογίζει δυναμικά το σχετικό βάρος και τις περίπλοκες σημασιολογικές αλληλεξαρτήσεις κάθε λέξης από τα περιβάλλοντα συμφραζόμενα, ανεξαρτήτως της συντακτικής τους απόστασης μέσα στην ίδια την πρόταση.

Αυτή ακριβώς η βαθιά αντιληπτική ικανότητα, η οποία αποτελεί απόρροια της προεκπαίδευσής (pre-training) του σε μεγάλα σώματα κειμένων, συνιστά το "κλειδί" για την επιτυχή επίλυση της γλωσσικής αμφισημίας (linguistic ambiguity). Εφαρμόζοντας το RoBERTa στο υπό εξέταση ειδησεογραφικό corpus, η βασική ερευνητική προσδοκία είναι πως το σύστημα θα καταφέρει να "αποκωδικοποιήσει" το ουδέτερο ύφος του παραδοσιακού δημοσιογραφικού ρεπορτάζ. Φιλτράροντας τον επιφανειακό υπολογιστικό "θόρυβο" που προκαλούν οι μεμονωμένα φορτισμένες λέξεις, η νέα αρχιτεκτονική φιλοδοξεί να προσφέρει μια ρεαλιστική και αυστηρά αντικειμενική ανάλυση της συναισθηματικής πολικότητας των άρθρων του BBC.

4.5.1 Προγραμματιστική Υλοποίηση και Παραμετροποίηση

Η ενσωμάτωση της αρχιτεκτονικής RoBERTa στο προγραμματιστικό περιβάλλον υλοποιήθηκε μέσω της βιβλιοθήκης ανοιχτού κώδικα transformers (Hugging Face), ακολουθώντας τις προδιαγραφές που έχουν θέσει οι Wolf et al. (2020) [94]. Για την αυτοματοποίηση της διαδικασίας εξαγωγής συμπερασμάτων (inference), επιστρατεύτηκε η διεπαφή pipeline, η οποία επιτρέπει την ταχεία φόρτωση και εκτέλεση πολύπλοκων νευρωνικών δικτύων.

Στο πλαίσιο αυτό, επιλέχθηκε η έκδοση twitter-roberta-base-sentiment-latest, μια εξειδικευμένη παραλλαγή του γλωσσικού μοντέλου που αναπτύχθηκε από τους Barbieri et al. (2020) [100] για την ερευνητική ομάδα CardiffNLP. Το πλεονέκτημα της συγκεκριμένης υλοποίησης έγκειται στην εκτεταμένη μικρο-ρύθμιση (fine-tuning) που έχει ήδη υποστεί. Αντί να παράγει απλώς ακατέργαστες διανυσματικές αναπαραστάσεις λέξεων (word embeddings), το συγκεκριμένο δίκτυο έχει βελτιστοποιηθεί εξ αρχής ώστε να ταξινομεί την είσοδο απευθείας σε τρεις διακριτές συναισθηματικές κλάσεις (Θετική, Αρνητική, Ουδέτερη). Η σχεδιαστική αυτή επιλογή είναι σκόπιμη, καθώς διασφαλίζει την δομική συμβατότητα των νέων αποτελεσμάτων με τις αντίστοιχες μετρικές του VADER, δημιουργώντας ένα αξιόπιστο κοινό πλαίσιο αναφοράς (common baseline) για την επακόλουθη συγκριτική τους αξιολόγηση.

Ωστόσο, η αξιοποίηση αρχιτεκτονικών που βασίζονται στο πρότυπο Transformer συνοδεύεται από έναν τεχνολογικό περιορισμό: το μέγιστο όριο μήκους της ακολουθίας εισόδου (input sequence length limit). Συγκεκριμένα, το RoBERTa δύναται να επεξεργαστεί ταυτόχρονα έως και 512 λεκτικές μονάδες (tokens). Δεδομένου ότι η πλειονότητα των εξεταζόμενων δημοσιογραφικών κειμένων του BBC News υπερβαίνει κατά πολύ αυτό το κατώφλι, η απευθείας τροφοδότησή τους στο δίκτυο θα προκαλούσε σφάλμα υπερχείλισης μνήμης (Out-Of-Memory - OOM error).

Για την επιτυχή αντιμετώπιση αυτού του εμποδίου, ενεργοποιήθηκε η παράμετρος της δυναμικής περικοπής (truncation=True) κατά τη φάση αρχικοποίησης του μοντέλου. Η πρακτική αυτή εδράζεται στον θεμελιώδη δημοσιογραφικό κανόνα της «Ανεστραμμένης Πυραμίδας» (Inverted Pyramid), σύμφωνα με τον οποίο η κρίσιμότερη και πιο φορτισμένη πληροφορία (το ποιος, τι, πού, πότε, γιατί) συμπυκνώνεται πάντα στις εισαγωγικές παραγράφους (lead

paragraphs) του ρεπορτάζ. Επομένως, η απόρριψη του τελευταίου τμήματος του κειμένου κρίνεται στατιστικά ασφαλής και δεν αλλοιώνει το εξαγόμενο σημασιολογικό αποτέλεσμα.

Τέλος, λόγω του τεράστιου όγκου των απαιτούμενων αλγεβρικών πράξεων (tensor operations) από τους μηχανισμούς προσοχής του δικτύου, ο κώδικας σχεδιάστηκε ώστε να μετατοπίζει αυτόματα (offload) τον υπολογιστικό φόρτο στην κάρτα γραφικών (GPU). Η εκτέλεση πραγματοποιήθηκε στο περιβάλλον του Google Colab, αξιοποιώντας τον διαθέσιμο επιταχυντή υλικού (hardware accelerator), γεγονός που ελαχιστοποίησε τον συνολικό χρόνο συμπερασμού (inference time) για τα 2.225 άρθρα του συνόλου δεδομένων.

Στην Εικόνα 4.8 που ακολουθεί, παρατίθεται η προγραμματιστική ρουτίνα φόρτωσης του μοντέλου, η διαχείριση του υπολογιστικού πόρου (επιλογή συσκευής εκτέλεσης) καθώς και η συνάρτηση `get_roberta_sentiment`, η οποία αναλαμβάνει την ασφαλή εφαρμογή του ταξινομητή σε κάθε γραμμή του συνόλου δεδομένων, ενσωματώνοντας μηχανισμούς χειρισμού εξαιρέσεων (exception handling) για την αποφυγή διακοπής της εκτέλεσης.

```
# Έλεγχος διαθεσιμότητας GPU για επιτάχυνση του μοντέλου
device = 0 if torch.cuda.is_available() else -1

# Φόρτωση του RoBERTa μέσω της διεπαφής pipeline
roberta_pipeline = pipeline(
    "sentiment-analysis",
    model="cardiffnlp/twitter-roberta-base-sentiment-latest",
    device=device,
    truncation=True,      # Δυναμική περικοπή του κειμένου
    max_length=512        # Ανώτατο όριο tokens
)

# Συνάρτηση ασφαλούς εφαρμογής του μοντέλου ανά άρθρο
def get_roberta_sentiment(text):
    try:
        # Περιορισμός χαρακτήρων πριν το tokenization για εξοικονόμηση
        # μνήμης
        short_text = str(text)[:2000]
        result = roberta_pipeline(short_text)
        label = result[0]['label'].capitalize()
        return label
    except Exception as e:
        # Μηχανισμός fallback σε περίπτωση απρόσμενου σφάλματος
        return 'Neutral'

# Εφαρμογή του μοντέλου στη στήλη 'content' του DataFrame
df['roberta_sentiment'] = df['content'].apply(get_roberta_sentiment)
```

Εικόνα 4.8: Φόρτωση και εφαρμογή του γλωσσικού μοντέλου RoBERTa

4.5.2 Οπτικοποίηση Ευρημάτων και Στατιστική Κατανομή


Μετά την επιτυχή εκτέλεση του μοντέλου στο σύνολο των δεδομένων, το επόμενο στάδιο επικεντρώνεται στην οπτική αναπαράσταση και ερμηνεία των εξαγόμενων αποτελεσμάτων. Για την παραγωγή των διαγραμμάτων αξιοποιήθηκαν εκ νέου οι βιβλιοθήκες `matplotlib` και `seaborn` [95], διατηρώντας τα ίδια σχεδιαστικά και χρωματικά πρότυπα με τις προηγούμενες ενότητες.

Αρχικά, εξετάζεται η συνολική κατανομή της συναισθηματικής πολικότητας (sentiment polarity) για το σύνολο των 2.225 δημοσιογραφικών κειμένων. Όπως αποτυπώνεται στο κυκλικό διάγραμμα που ακολουθεί (Εικόνα 4.9), παρατηρείται μια αναδιάταξη των ταξινομήσεων. Η πλειοψηφία των άρθρων, τα οποία αγγίζουν το 58,9%, εντάχθηκε πλέον στην «Ουδέτερη»

(Neutral) κατηγορία. Το ποσοστό των εγγράφων που χαρακτηρίστηκαν ως «Θετικές» (Positive) περιορίστηκε στο 25,8%, ενώ η «Αρνητική» (Negative) κλάση συγκέντρωσε το 15,4% του συνολικού όγκου.

Η ανάδειξη της ουδετερότητας ως κυρίαρχου στοιχείου επιβεβαιώνει την αρχική ερευνητική υπόθεση του παρόντος κεφαλαίου. Το νευρωνικό δίκτυο, εκμεταλλευόμενο τη κατανόηση των συμφραζομένων (contextual awareness), δεν επηρεάζεται από μεμονωμένες λέξεις εντυπωσιασμού. Αντιθέτως, αναγνωρίζει το αποστασιοποιημένο ύφος το οποίο συνεπάγεται η δημοσιογραφική δεοντολογία στο πλαίσιο ενός ειδησεογραφικού οργανισμού όπως το BBC, ταξινομώντας την πλειονότητα των αναφορών ως αντικειμενική καταγραφή γεγονότων (objective reporting).


Συνολική Κατανομή Συναισθήματος στο BBC News Dataset (RoBERTa)



Εικόνα 4.9: Κυκλικό διάγραμμα συνολικής κατανομής συναισθήματος με χρήση του μοντέλου RoBERTa.

Προχωρώντας σε μια πιο λεπτομερή αποδόμηση των ευρημάτων, το ερευνητικό ενδιαφέρον στρέφεται στην ανάλυση της πολικότητας ανά επιμέρους δημοσιογραφική κατηγορία (category). Όπως αποτυπώνεται στο ραβδόγραμμα που ακολουθεί (Εικόνα 4.10), η υπεροχή της ουδέτερης κλάσης δεν αποτελεί ένα ομογενοποιημένο, τυχαίο στατιστικό φαινόμενο, αλλά διατρέχει οριζόντια τους περισσότερους θεματικούς άξονες του dataset.

Ειδικότερα, στους τομείς της Πολιτικής (Politics) και των Επιχειρήσεων (Business), η κυριαρχία της ουδετερότητας αναδεικνύει την ικανότητα του μοντέλου να αντιλαμβάνεται την ψυχρή παράθεση γεγονότων. Τα πολιτικά ρεπορτάζ, παρά την αντιπαραθετική τους φύση (adversarial nature) ή τις έντονες δηλώσεις των προσώπων, καθώς και οι οικονομικές αναλύσεις που χαρακτηρίζονται από διακυμάνσεις, ταξινομούνται ως πληροφοριακά κείμενα (informative texts). Με αυτόν τον τρόπο, αντιμετωπίζεται το πρόβλημα της εσφαλμένης ερμηνείας συναισθηματικά φορτισμένων όρων που τους απέδιδαν οι απλοϊκότερες προσεγγίσεις καταμέτρησης λέξεων.



Εικόνα 4.10: Κατανομή συναισθηματικής πολικότητας ανά θεματική κατηγορία (RoBERTa).

Μετατοπίζοντας την ανάλυση στις θεματικές της Ψυχαγωγίας (Entertainment), της Τεχνολογίας (Tech) και του Αθλητισμού (Sport), διαπιστώνεται μια σημαντική διαφοροποίηση στη συμπεριφορά του ταξινομητή (classifier). Βάσει της παραγόμενης οπτικοποίησης, η Ψυχαγωγία συνιστά τη μοναδική κατηγορία του συνόλου δεδομένων όπου το θετικό πρόσημο κατορθώνει να υπερκεράσει στατιστικά την ουδέτερη κλάση. Μια παρόμοια δυναμική καταγράφεται και στα τεχνολογικά ρεπορτάζ, παρουσιάζοντας μια οριακή ισοκατανομή μεταξύ θετικότητας και αντικειμενικότητας. Το συγκεκριμένο εύρημα κρίνεται συμβατό με τη δομή της εν λόγω αρθρογραφίας, η οποία παραδοσιακά εμπεριέχει διθυραμβικές κριτικές καλλιτεχνικών έργων ή ενθουσιώδεις παρουσιάσεις ψηφιακών καινοτομιών. Στον αντίποδα, παρόλο που τα αθλητικά κείμενα συγκεντρώνουν ένα σημαντικό ποσοστό θετικών εγγραφών, η ουδετερότητα αποκτά το προβάδισμα. Η εξέλιξη αυτή πιστοποιεί την ανώτερη σημασιολογική αντιληπτικότητα (superior semantic comprehension) του μοντέλου, το οποίο αναδεικνύει πώς η περιγραφή μιας αγωνιστικής αναμέτρησης (παρά την αναπόφευκτη χρήση λεκτικά φορτισμένων όρων όπως «νίκη» ή «θρίλαμπος») αποτελεί μια αμιγώς ειδησεογραφική καταγραφή γεγονότων.

4.5.3 Συγκριτική Ανάλυση (RoBERTa vs. VADER) και Ποιοτική Αποτίμηση

Η ολοκλήρωση της εξαγωγής συμπερασμάτων μέσω του προεκπαιδευμένου γλωσσικού μοντέλου επιτρέπει την άμεση αντιπαράβολή του με τον παραδοσιακό, βασισμένο σε κανόνες ταξινομητή (rule-based classifier). Συγκρίνοντας τα ευρήματα συνολικά, καθίσταται σαφές πως η μετάβαση από το VADER [76] στην αρχιτεκτονική RoBERTa [100] δεν επέφερε απλώς μια οριακή βελτίωση στις μετρικές, αλλά προκάλεσε ανατροπή στη στατιστική κατανομή του συναισθήματος.

Όπως φάνηκε στην υποενότητα 4.4, το λεξικογραφικό σύστημα απέδωσε θετικό πρόσημο στο 71,4% των εξεταζόμενων δημοσιογραφικών κειμένων, εγκλωβίζοντας ένα σχεδόν μηδαμινό 0,9% στην ουδέτερη κλάση και καταχωρώντας το εναπομείναν 27,7% ως αρνητικό. Στον αντίποδα, η εφαρμογή του Νευρωνικού Δικτύου Βαθιάς Μάθησης ανέδειξε μια διαφορετική εικόνα (Πίνακας 4.1). Η ουδετερότητα αναδείχθηκε ως η κυρίαρχη συναισθηματική κατάσταση, απορροφώντας το 58,9% του συνόλου δεδομένων. Παράλληλα, παρατηρήθηκε μια σημαντική συρρίκνωση της θετικότητας, η οποία περιορίστηκε στο 25,8%, ενώ οι αρνητικές εγγραφές ανήλθαν στο 15,4%.

Αυτή η στατιστική ασυμφωνία (statistical discrepancy) μεταξύ των δύο μεθόδων δεν υποδηλώνει μια απλή διαφορά ευαισθησίας, αλλά αποκαλύπτει τους περιορισμούς των στατικών προσεγγίσεων. Το VADER, λειτουργώντας αμιγώς αθροιστικά, "τυφλώνεται" από την παρουσία μεμονωμένων φορτισμένων λημμάτων, αδυνατώντας να συνθέσει τη συνολική εικόνα της πρότασης. Αντιθέτως, η αμφίδρομη αρχιτεκτονική του RoBERTa επιλύει το συγκεκριμένο πρόβλημα, αξιολογώντας το κάθε άρθρο ολιστικά (holistically).

Πίνακας 4.1: Συγκριτική κατανομή συναισθηματικής πολικότητας στο σύνολο των άρθρων του BBC News.

Συναισθηματική Κλάση	VADER (Ποσοστό %)	RoBERTa (Ποσοστό %)
Θετικό (Positive)	71,4%	25,8%
Ουδέτερο (Neutral)	0,9%	58,9%
Αρνητικό (Negative)	27,7%	15,4%

Προς επίρρωση των παραπάνω στατιστικών αποκλίσεων, η ποιοτική ανάλυση σε επίπεδο μεμονωμένων προτάσεων αναδεικνύει τους μηχανισμούς που προκαλούν αυτή τη διαφοροποίηση. Εξετάζοντας, για παράδειγμα, την κάλυψη ενός κρίσιμου αθλητικού αγώνα ή μιας έντονης κοινοβουλευτικής συζήτησης, η αρθρογραφία χαρακτηρίζεται από έντονα φορτισμένο λεξιλόγιο (όπως οι λέξεις «θρίαμβος», «συντριβή», «επίθεση» ή «κρίση»). Το VADER [76], λειτουργώντας πρακτικά ως ένας ντετερμινιστικός ανιχνευτής μοτίβων (pattern matcher), εντοπίζει αποσπασματικά αυτά τα λήμματα, αθροίζει τις προκαθορισμένες βαθμολογίες τους από το λεξικό και εξάγει ένα τεχνητά πολωμένο αποτέλεσμα. Αδυνατεί να αντιληφθεί τον παράγοντα της συγγραφικής πρόθεσης, ερμηνεύοντας τη δημοσιογραφική περιγραφή μιας έντασης ως συναισθηματική έκφραση του ίδιου του συντάκτη.

Στον αντίποδα, το RoBERTa επιδεικνύει μια ανώτερη ικανότητα σημασιολογικής αφαίρεσης (semantic abstraction). Μέσω των πολλαπλών επιπέδων προσοχής (attention layers), έχει εκπαιδευτεί να αναγνωρίζει τη δομή και το ύφος που αντιστοιχεί στην αντικειμενική ενημέρωση. Έτσι, το νευρωνικό δίκτυο αίρει τον λεκτικό "θόρυβο" και αντιμετωπίζει τις προαναφερθείσες λέξεις ως απλά δομικά στοιχεία μιας ειδησεογραφικής αναφοράς, κατατάσσοντας το τελικό κείμενο στην κατηγορία των αμιγώς πληροφοριακών (informative).

Συμπερασματικά, η διαχείριση πολύπλοκων, εκτενών και υφολογικά ουδέτερων συνόλων δεδομένων, όπως τα άρθρα του BBC News και οι αρχιτεκτονικές που βασίζονται σε Transformers, δεν συνιστούν απλώς μια υπολογιστικά ανώτερη επιλογή, αλλά τη μοναδική ενδεδειγμένη μεθοδολογία για την εξαγωγή ρεαλιστικών και αξιόπιστων συμπερασμάτων.

4.6 Αυτόματη Παραγωγή Περίληψης (Text Summarization)

Σε μια ψηφιακή εποχή όπου ο όγκος των δεδομένων που δημοσιεύονται καθημερινά από μεγάλους ειδησεογραφικούς οργανισμούς, όπως το BBC News, αυξάνεται, η χειροκίνητη ανάγνωση και αφομοίωση του συνόλου της αρθρογραφίας καθίσταται πρακτικά ανέφικτη. Η συγκεκριμένη συνθήκη αναδεικνύει την ανάγκη ενσωμάτωσης αυτοματοποιημένων υπολογιστικών συστημάτων, τα οποία διαθέτουν την ικανότητα να απομονώνουν γρήγορα τον σημασιολογικό πυρήνα (semantic core) μιας είδησης.

Η διαδικασία αυτή, γνωστή ως Αυτόματη Παραγωγή Περίληψης (Text Summarization), λειτουργεί ως ένας έξυπνος μηχανισμός φιλτραρίσματος (filtering mechanism). Πρωταρχικός της σκοπός είναι ο δομικός μετασχηματισμός μακροσκελών ρεπορτάζ σε περιεκτικά αποσπάσματα. Με αυτόν τον τρόπο, διασφαλίζεται η ακεραιότητα του κεντρικού μηνύματος, ενώ ταυτόχρονα ο αναγνώστης απαλλάσσεται από δευτερεύουσες, επαναλαμβανόμενες ή πλεονάζουσες λεπτομέρειες που απλώς προσθέτουν "θόρυβο" στην αρχική πληροφορία [30].

Εμβαθύνοντας στο θεωρητικό υπόβαθρο του συγκεκριμένου πεδίου, οι αρχιτεκτονικές που έχουν αναπτυχθεί για την παραγωγή περιλήψεων ταξινομούνται παραδοσιακά σε δύο διακριτές κατηγορίες. Η πρώτη προσέγγιση αφορά την εξαγωγική σύνοψη (extractive summarization). Η

συγκεκριμένη μέθοδος εδράζεται στην αλγοριθμική αξιολόγηση και απομόνωση των στατιστικά σημαντικότερων προτάσεων μέσα από το ίδιο το αρχικό έγγραφο. Το τελικό παραγόμενο αποτέλεσμα συντίθεται από προϋπάρχοντα τμήματα του κειμένου. Αν και υπολογιστικά αποδοτική, η συγκεκριμένη τεχνική συχνά υστερεί σε γλωσσική συνοχή, καταλήγοντας να θυμίζει περισσότερο μια μηχανική συρραφή ασύνδετων παραγράφων.

Στον αντίποδα, η δεύτερη και τεχνολογικά πιο εξελιγμένη μεθοδολογία είναι η αφαιρετική σύνοψη (abstractive summarization) [55]. Αξιοποιώντας προηγμένα νευρωνικά δίκτυα βαθιάς μάθησης (deep learning neural networks), τα μοντέλα αυτής της κατηγορίας υπερβαίνουν την απλή αντιγραφή. Αντιθέτως, αποκωδικοποιούν πλήρως το σημασιολογικό πλαίσιο (context) της εισόδου και παράγουν νέες λεκτικές διατυπώσεις. Πρόκειται για μια διαδικασία που προσομοιώνει την ανθρώπινη γνωστική ικανότητα της κατανόησης και αναδιήγησης ενός σύνθετου γεγονότος. Στα πλαίσια της παρούσας πτυχιακής εργασίας, επιλέχθηκε η υιοθέτηση της αφαιρετικής μεθόδου, καθώς κρίνεται ως η μόνη επιστημονικά ενδεδειγμένη λύση για τη δημιουργία ρέοντος, φυσικού λόγου, εναρμονισμένου με τα απαιτητικά πρότυπα ενός ειδησεογραφικού οργανισμού.

4.6.1 Προγραμματιστική Υλοποίηση και Μοντέλο BART

Μεταβαίνοντας στο στάδιο της πρακτικής εφαρμογής, η προγραμματιστική ανάπτυξη του συστήματος αυτόματης σύνοψης βασίστηκε στην αρχιτεκτονική BART (Bidirectional and Auto-Regressive Transformers), η οποία αναπτύχθηκε από τους Lewis et al. (2020) [35]. Το συγκεκριμένο νευρωνικό δίκτυο συνδυάζει δύο διαφορετικούς κόσμους της μηχανικής μάθησης: διαθέτει έναν αμφίδρομο κωδικοποιητή (bidirectional encoder) (παρόμοιο με το BERT) για τη βαθιά κατανόηση των εισερχόμενων συμφραζομένων και έναν αυτοπαλίνδρομο αποκωδικοποιητή (auto-regressive decoder) (αντίστοιχο του GPT), ο οποίος εξειδικεύεται στην παραγωγή φυσικού κειμένου. Η υβριδική αυτή δομή καθιστά το μοντέλο ικανό στη διεκπεραίωση πολύπλοκων εργασιών Παραγωγής Φυσικής Γλώσσας (Natural Language Generation - NLG).

Για τις ανάγκες της παρούσας πειραματικής διάταξης, ενσωματώθηκε η προεκπαιδευμένη έκδοση facebook/bart-large-cnn μέσω του οικοσυστήματος ανοιχτού κώδικα της Hugging Face. Το πλεονέκτημα της συγκεκριμένης παραλλαγής έγκειται στο γεγονός ότι έχει υποστεί εκτεταμένη μικρο-ρύθμιση (fine-tuning) σε ένα ογκώδες σώμα δεδομένων, προερχόμενο από διεθνή ειδησεογραφικά δίκτυα (CNN και DailyMail). Συνεπώς, το γλωσσικό μοντέλο διέθετε ήδη την απαραίτητη εξοικείωση με το δημοσιογραφικό ύφος και το απαιτούμενο λεξιλογικό υπόβαθρο. Αυτό του επέτρεψε να επεξεργαστεί τα 2.225 άρθρα του ομίλου BBC με μέγιστη πραγματολογική ακρίβεια, δίχως να προκύπτει η κοστοβόρα ανάγκη για περαιτέρω εκπαίδευση από το μηδέν (training from scratch).

Για την εφαρμογή του προεκπαιδευμένου μοντέλου στο περιβάλλον του Google Colab ήταν αναγκαία η υιοθέτηση προγραμματιστικών κανόνων για τη βέλτιστη διαχείριση των διαθέσιμων υπολογιστικών πόρων. Δεδομένου ότι η αρχιτεκτονική του BART υποστηρίζει μέγιστο μήκος ακολουθίας (sequence length) τα 1024 tokens ανά εισαγωγή, εφαρμόστηκε δυναμική περικοπή (dynamic truncation) στα μακροσκελή άρθρα. Η τακτική αυτή ήταν απαραίτητη προκειμένου να αποτραπούν κρίσιμα σφάλματα υπερχείλισης μνήμης (Out-of-Memory errors) κατά τη μεταφορά των δεδομένων στη μονάδα επεξεργασίας γραφικών (T4 GPU).

Αναφορικά με τον μηχανισμό παραγωγής του τελικού κειμένου, απορρίφθηκε η απλοϊκή μέθοδος της «άπληστης αποκωδικοποίησης» (greedy decoding). Στη θέση της επιστρατεύτηκε ο αλγόριθμος αναζήτησης ακτίνας (Beam Search), ρυθμισμένος να αξιολογεί παράλληλα τέσσερα εναλλακτικά μονοπάτια λέξεων (num_beams=4) πριν καταλήξει στην επικρατέστερη λεκτική αλληλουχία. Επιπρόσθετα, ορίστηκαν όρια (μεταξύ 30 και 130 tokens) και επιβλήθηκε σχετική ποινή μήκους (length_penalty=2.0). Με αυτές τις ρυθμίσεις διασφαλίστηκε ότι το σύστημα θα εξάγει σταθερά περιλήψεις τριών έως τεσσάρων προτάσεων, αποτρέποντας φαινόμενα παραγωγής είτε τηλεγραφικών διατυπώσεων είτε ατέρμωνων επαναλήψεων.

Η κεντρική λογική της αραπάνω παραμετροποίησης, καθώς και η απευθείας αλληλεπίδραση με τους τανυστές (tensors) της συσκευής, αποτυπώνεται στο ακόλουθο απόσπασμα κώδικα Python (Εικόνα 4.11):


```
# Μετατροπή κειμένου σε Tokens με δυναμική περικοπή στα 1024 tokens
inputs = tokenizer(str(text), return_tensors="pt", max_length=1024,
truncation=True).to(device)

# Παραγωγή αφαιρετικής περίληψης μέσω του αλγορίθμου Beam Search
summary_ids = model.generate(
    inputs["input_ids"],
    max_length=130,
    min_length=30,
    length_penalty=2.0,
    num_beams=4,
    early_stopping=True
)

# Αποκωδικοποίηση των παραγόμενων Tokens σε φυσική γλώσσα
summary = tokenizer.decode(summary_ids[0], skip_special_tokens=True)
```

Εικόνα 4.11: Υλοποίηση της αυτόματης παραγωγής περίληψης (BART) και εφαρμογή του αλγορίθμου Beam Search μέσω της βιβλιοθήκης Transformers.

4.6.2 Ποσοτική Αξιολόγηση μέσω Μετρικών ROUGE

Η αποτίμηση της ποιότητας των παραγόμενων περιλήψεων σε ένα τόσο εκτενές σώμα κειμένων καθιστά αδύνατη τη χειροκίνητη ανθρώπινη αξιολόγηση. Η εργασία στηρίχθηκε στην σουίτα μετρικών ROUGE (Recall-Oriented Understudy for Gisting Evaluation), η οποία εισήχθη από τον Lin (2004) [46]. Το συγκεκριμένο μετρικό σύστημα αποτελεί το ακαδημαϊκό και βιομηχανικό πρότυπο για την αξιολόγηση αλγορίθμων αυτόματης σύνοψης, καθώς υπολογίζει τον βαθμό λεκτικής και συντακτικής επικάλυψης (overlap) μεταξύ του παραγόμενου αποτελέσματος και μιας πρότυπης περίληψης αναφοράς (reference summary).

Ωστόσο, δεδομένου ότι το πρωτογενές corpus του BBC News αποτελείται από ειδησεογραφικά κείμενα δίχως να συνοδεύεται από προκαθορισμένες, ανθρώπινα συντεταγμένες, περιλήψεις, προέκυψε η ανάγκη δημιουργίας ενός αξιόπιστου «χρυσού κανόνα» (gold standard) για τις ανάγκες της σύγκρισης. Για την επίλυση αυτού του ζητήματος, υιοθετήθηκε η πρακτική του «Βασικού Κανόνα της Εισαγωγής» (Lead Baseline). Η συγκεκριμένη ερευνητική στρατηγική εδράζεται στη δημοσιογραφική αρχή της «ανεστραμμένης πυραμίδας», σύμφωνα με την οποία οι κρίσιμότερες πληροφορίες ενός γεγονότος τοποθετούνται συστηματικά στην έναρξη του ρεπορτάζ. Υπό αυτό το πρίσμα, ως κείμενο αναφοράς έναντι του οποίου αξιολογήθηκε η απόδοση του δικτύου BART, ορίστηκαν οι τρεις πρώτες προτάσεις κάθε αυθεντικού άρθρου.

Με βάση αυτή τη μεθοδολογική παραδοχή, τα συγκεντρωτικά ευρήματα της διαδικασίας αξιολόγησης για το σύνολο των 2.225 άρθρων παρατίθενται αναλυτικά στον Πίνακα 4.2:

Πίνακας 4.2: Μέσοι όροι απόδοσης του προεκπαιδευμένου μοντέλου BART βάσει των μετρικών ROUGE.

Μετρική Αξιολόγησης	Μέσος Όρος (Score)	Ερμηνεία
ROUGE-1	55,87%	Επικάλυψη μεμονωμένων λέξεων (Unigrams)
ROUGE-2	43,32%	Επικάλυψη ζευγών λέξεων (Bigrams)
ROUGE-L	47,91%	Διατήρηση της δομής και σειράς των λέξεων

Η παρατηρούμενη στατιστική επίδοση κρίνεται ικανοποιητική, ιδίως αν ληφθεί υπόψη ο βαθμός δυσκολίας που χαρακτηρίζει την αφαιρετική σύνοψη (abstractive summarization)

συγκριτικά με τις απλές εξαγωγικές μεθόδους. Ειδικότερα, η καταγραφή ποσοστού 55,87% στη μετρική ROUGE-1 αποδεικνύει πως το νευρωνικό δίκτυο κατόρθωσε να διατηρήσει, σε ποσοστό άνω του μισού, το κρίσιμο λεξιλόγιο του πρωτότυπου ρεπορτάζ. Παράλληλα, τα σκορ στα ROUGE-2 (43,32%) και ROUGE-L (47,91%) επιβεβαιώνουν ότι η αλληλουχία των όρων και η συντακτική δομή των παραγόμενων προτάσεων παρουσιάζουν νοηματική συνοχή (semantic coherence). Το γεγονός αυτό καταρρίπτει το ενδεχόμενο μιας τυχαίας, μηχανικής παράθεσης ασύνδετων λέξεων-κλειδιών, πιστοποιώντας πως το αρχιτεκτονικό πλαίσιο παραδίδει ένα τελικό κείμενο με φυσική ροή (fluency), το οποίο προσομοιάζει σε μεγάλο βαθμό την ανθρώπινη συγγραφική ικανότητα.

4.7 Μελέτη Περιπτώσεων (Case Studies)

Μετά την ολοκλήρωση της ποσοτικής αποτίμησης (quantitative evaluation) των γλωσσικών μοντέλων και την παράθεση των επιμέρους στατιστικών δεικτών, κρίνεται αναγκαία η μετάβαση στην ποιοτική αξιολόγηση (qualitative evaluation) των αποτελεσμάτων. Η αμιγώς αριθμητική προσέγγιση, μολονότι αποτελεί το βασικότερο κριτήριο της στατιστικής εγκυρότητας (statistical validity), αδυνατεί να αποτυπώσει την πραγματική αναγνωστική εμπειρία, τη συντακτική φυσικότητα (syntactic naturalness) και την ουσιαστική νοηματική συνοχή (semantic coherence) των παραγόμενων κειμένων. Κατά συνέπεια, μια ολοκληρωμένη ερευνητική οπτική προϋποθέτει την πρακτική επιβεβαίωση των μετρικών (όπως τα ROUGE scores) μέσω της άμεσης, ανθρώπινης παρατήρησης.

Για τον σκοπό αυτό, η παρούσα ενότητα εστιάζει στην εξέταση στοχευμένων Μελετών Περίπτωσης (Case Studies). Μέσω της συγκεκριμένης ερευνητικής τακτικής, επιδιώκεται η «μικροσκοπική» ανάλυση της συμπεριφοράς του προτεινόμενου υπολογιστικού συστήματος υπό ρεαλιστικές συνθήκες. Κεντρικός στόχος είναι να αναδειχθεί η απρόσκοπτη συνεργασία και η ροή εκτέλεσης (pipeline) ολόκληρης της αρχιτεκτονικής: από την αρχική πρόσληψη του ακατέργαστου δημοσιογραφικού ρεπορτάζ του BBC News, στην διάγνωση της συναισθηματικής του πολικότητας, έως την τελική αφαιρετική συμπίκνωση (abstractive summarization) της κρίσιμης πληροφορίας.

Προς επίρρωση της αξιοπιστίας του προτεινόμενου συστήματος και με γνώμονα την αποφυγή μεροληπτικών συμπερασμάτων (bias), η επιλογή των δειγμάτων που αναλύονται στις υποενότητες που ακολουθούν δεν υπήρξε τυχαία, αλλά βασίστηκε στην αρχή της θεματικής ετερογένειας (thematic heterogeneity). Συγκεκριμένα, αντλήθηκαν αντιπροσωπευτικά ρεπορτάζ από αποκλίνουσες κατηγορίες ειδήσεων (όπως, για παράδειγμα, η πολιτική σκηνή και η αθλητική επικαιρότητα) προκειμένου να ελεγχθεί η προσαρμοστικότητα (adaptability) των αλγορίθμων σε ποικίλα ορολογικά περιβάλλοντα και διαφορετικά συγγραφικά ύφη.

Σε κάθε εξεταζόμενη περίπτωση, παρατίθεται δομημένα ένα εκτενές απόσπασμα του πρωτότυπου δημοσιεύματος, η ετικέτα συναισθηματικής πολικότητας που αποδόθηκε αυτόματα από το μοντέλο RoBERTa, καθώς και το τελικό συμπυκνωμένο κείμενο που συνέθεσε το δίκτυο BART. Μέσω αυτής της άμεσης, συγκριτικής παραβολής, καθίσταται πλέον οπτικά και νοηματικά διακριτός ο βαθμός επιτυχίας του συνολικού εγχειρήματος, επιβεβαιώνοντας τη μετάβαση από τα ακατέργαστα δεδομένα στην παραγωγή δομημένης γνώσης (structured knowledge).

4.7.1 Μελέτη Περίπτωσης 1: Θεματική Κατηγορία «Αθλητισμός» (Sport)

Η πρώτη πρακτική εφαρμογή του υπολογιστικού συστήματος αφορά ένα δημοσίευμα το οποίο αντλήθηκε από τη δεξαμενή της αθλητικής ειδησεογραφίας (κατηγορία: sport). Το επιλεγμένο ρεπορτάζ πραγματεύεται μια πειθαρχική υπόθεση στο πλαίσιο του αγγλικού πρωταθλήματος ποδοσφαίρου, και πιο συγκεκριμένα την αλλαγή στάσης του προπονητή της Έβερτον αναφορικά με την αντιαθλητική συμπεριφορά και την επακόλουθη αποβολή ενός παίκτη της ομάδας του.

Για την πληρέστερη οπτική κατανόηση του δείγματος, παρατίθεται η εναρκτήρια παράγραφος (lead paragraph) του πρωτότυπου κειμένου, στην οποία παραδοσιακά συμπυκνώνεται ο ειδησεογραφικός πυρήνας του γεγονότος:

«Everton manager David Moyes will discipline striker James Beattie after all for his headbutt on Chelsea defender William Gallas. The Scot initially defended Beattie, whose dismissal put Everton on the back foot in a game they ultimately lost 1-0, saying Gallas overreacted. But he has had a rethink after looking over the video evidence again. He said: "I believe that I should set the record straight by conceding that the dismissal was right and correct."»

Στο πρώτο στάδιο της ανάλυσης, το σύνολο του κειμένου (περίπου 350 λέξεων) διοχετεύτηκε στο γλωσσικό μοντέλο RoBERTa με σκοπό την αναγνώριση της συναισθηματικής του πολικότητας. Η αρχιτεκτονική κατέταξε το συγκεκριμένο άρθρο στην κατηγορία «Ουδέτερο» (Neutral).

Αξιολογώντας κριτικά τη συγκεκριμένη ταξινόμηση, διαπιστώνεται πως είναι εύστοχη και αναδεικνύει την ωριμότητα του νευρωνικού δικτύου. Παρότι το περιεχόμενο της είδησης περιγράφει μια κατάσταση έντονης σύγκρουσης (σωματική επαφή, αποβολή, πειθαρχικά παραπτώματα), ο δημοσιογράφος παραμένει αντικειμενικός και ψύχραιμος. Απουσιάζουν οι συναισθηματικά φορτισμένες λέξεις ή οι υποκειμενικές τοποθετήσεις από την πλευρά του συντάκτη. Το σύστημα απέδειξε την ικανότητά του να διαχωρίζει το ίδιο το "αρνητικό" γεγονός από τον ουδέτερο, δημοσιογραφικό τρόπο προσέγγισής του.

Προχωρώντας στο δεύτερο της επεξεργασίας, το πρωτογενές υλικό τροφοδοτήθηκε στο μοντέλο BART με σκοπό τη συμπύκνωση του πληροφοριακού του φορτίου. Το τελικό παραγόμενο αποτέλεσμα (generated summary) που εξήγαγε το σύστημα έχει την ακόλουθη μορφή:

«Everton striker James Beattie was sent off for headbutting Chelsea's William Gallas. David Moyes initially defended the incident, saying Gallas overreacted. But Moyes has now conceded that the dismissal was right and correct. Moyes said Beattie's actions were unacceptable and detrimental to his team-mates.»

Η αντιπαραβολή της παραπάνω σύνοψης με το αρχικό ρεπορτάζ αναδεικνύει την αποδοτικότητα της αρχιτεκτονικής. Όπως καθίσταται σαφές, το νευρωνικό δίκτυο δεν περιορίστηκε σε μια απλοϊκή, μηχανική απόσπαση αυτούσιων φράσεων (extractive approach). Αντιθέτως, προχώρησε σε μια δομική και νοηματική ανασύνθεση του γεγονότος. Κατόρθωσε να εντοπίσει και να διατηρήσει ακέραιο τον δημοσιογραφικό πυρήνα (τα εμπλεκόμενα πρόσωπα, την αρχική τοποθέτηση και την τελική μεταστροφή του προπονητή), αποβάλλοντας ταυτόχρονα τις περιττές, δευτερεύουσες λεπτομέρειες.

Ιδιαίτερη μνεία πρέπει να γίνει στη συντακτική ομαλότητα και τη φυσική ροή (fluency) του παραγόμενου λόγου. Το μοντέλο απέδειξε την ικανότητά του να μετασχηματίζει τον ευθύ λόγο και τις μακροσκελείς δηλώσεις του προπονητή σε συμπαγείς, περιγραφικές προτάσεις τρίτου προσώπου. Η συγκεκριμένη γλωσσική συμπεριφορά επιβεβαιώνει στην πράξη τα υψηλά ποσοστά που καταγράφηκαν προηγουμένως στις μετρικές ROUGE, αποδεικνύοντας πως το παραγόμενο κείμενο αγγίζει τα επίπεδα ενός επαγγελματικού, ανθρώπινου συντακτικού αποτελέσματος.

4.7.2 Μελέτη Περίπτωσης 2: Θεματική Κατηγορία «Τεχνολογία» (Tech)

Προκειμένου να αξιολογηθεί η ευελιξία του υπολογιστικού συστήματος σε ετερογενή γνωστικά πεδία, η δεύτερη μελέτη περίπτωσης εστιάζει σε ένα ρεπορτάζ από τον τομέα της τεχνολογίας (κατηγορία: tech). Το επιλεγμένο δημοσίευμα περιγράφει μια αμφιλεγόμενη πρακτική της εταιρείας Lycos Europe, η οποία επιχείρησε να καταπολεμήσει την ανεπιθύμητη ηλεκτρονική

αλληλογραφία (spam) μέσω ενός λογισμικού που υπερφόρτωνε τους διακομιστές των αποστολέων, εγείροντας σοβαρά νομικά και ηθικά ζητήματα.

Όπως και στο προηγούμενο παράδειγμα, παρατίθεται η εισαγωγική παράγραφος (lead) του πρωτότυπου κειμένου, η οποία θέτει το εννοιολογικό και πληροφοριακό πλαίσιο της είδησης:

«A campaign by Lycos Europe to target spam-related websites appears to have been put on hold. Earlier this week the company released a screensaver that bombarded the sites with data to try to bump up the running costs of the websites. But the site hosting the screensaver now displays a pink graphic and the words "Stay tuned". No one at Lycos was available for comment on latest developments in its controversial anti-spam campaign.»

Κατά την επεξεργασία του συνολικού άρθρου από το μοντέλο RoBERTa για την εξαγωγή της συναισθηματικής πολικότητας, το δίκτυο απέδωσε στο κείμενο την ετικέτα «Αρνητικό» (Negative).

Η συγκεκριμένη ταξινόμηση κρίνεται επιτυχής και διαπνέεται από σημασιολογική ακρίβεια. Σε αντίθεση με το αθλητικό άρθρο όπου επικρατούσε η δηλωτική λειτουργία της γλώσσας, στο παρόν κείμενο εντοπίζεται ένα έντονο λεξιλογικό φορτίο που υποδηλώνει σύγκρουση, νομική αβεβαιότητα και αποτυχία (όπως οι όροι "bombarded", "controversial", "under fire", "vigilantism"). Το γλωσσικό μοντέλο κατόρθωσε να αποκωδικοποιήσει την ευρύτερη αρνητική χροιά της είδησης, η οποία επικεντρώνεται στην αναστολή μιας εκστρατείας, στις κατηγορίες για επικίνδυνες διαδικτυακές επιθέσεις (DDoS) και στις αντιδράσεις της τεχνολογικής κοινότητας. Αποδεικνύεται, συνεπώς, η ικανότητα του αλγορίθμου να ανιχνεύει την υποβόσκουσα ένταση και την κριτική διάσταση ενός ρεπορτάζ, υπερβαίνοντας το επιφανειακό επίπεδο της απλής αναγνώρισης μεμονωμένων λέξεων.

Μεταβαίνοντας στο τελικό στάδιο της επεξεργασίας, το ρεπορτάζ τροφοδοτήθηκε στο μοντέλο BART με σκοπό τη νοηματική του απόσταξη. Το παραγόμενο κείμενο που προέκυψε από τον αλγόριθμο έχει ως εξής:

«Lycos Europe released a screensaver that bombarded the sites with data. The idea was to generate big bandwidth bills for the spammers behind the sites. But the plan has proved controversial and some have said it could incite vigilantism.»

Η κριτική αποτίμηση της παραπάνω σύνοψης σε σχέση με το πρωτότυπο δημοσίευμα επιβεβαιώνει την υψηλή αναλυτική εμβέλεια της αρχιτεκτονικής. Το νευρωνικό δίκτυο επέδειξε ικανότητα φιλτραρίσματος του πληροφοριακού «θορύβου». Όπως παρατηρείται, αγνόησε τις δευτερεύουσες λεπτομέρειες που πλαισιώναν το ρεπορτάζ, όπως τα στατιστικά δεδομένα της εταιρείας μετρήσεων Netcraft, τις αλλαγές των διευθύνσεων IP, καθώς και τις μακροσκελείς δηλώσεις των εξωτερικών συμβούλων ασφαλείας.

Αντιθέτως, το σύστημα απομόνωσε με ακρίβεια τον κεντρικό θεματικό άξονα: την ενέργεια της εταιρείας (κυκλοφορία λογισμικού), τον απώτερο σκοπό της (οικονομική επιβάρυνση των spammers) και τον τελικό αντίκτυπο (έντονες αντιδράσεις περί ψηφιακής αυτοδικίας). Το εξαγόμενο αποτέλεσμα είναι ένα συμπαγές, αυτόνομο κείμενο τριών μόλις προτάσεων, το οποίο διακρίνεται για τη λεξιλογική του πυκνότητα και τη συντακτική του ορθότητα. Η συγκεκριμένη μελέτη αποδεικνύει πως το υπολογιστικό μοντέλο δεν περιορίζεται σε απλές καθημερινές ειδήσεις, αλλά προσαρμόζεται σε σύνθετα τεχνολογικά ζητήματα, διατηρώντας αναλλοίωτη την ακεραιότητα της πληροφορίας.

4.8 Συζήτηση Αποτελεσμάτων (Discussion)

Η ολοκλήρωση του πειραματικού σκέλους και η συστηματική παράθεση των ποσοτικών και ποιοτικών ευρημάτων της παρούσας εργασίας, οριοθετούν τη μετάβαση στην φάση της

κριτικής ερμηνείας των αποτελεσμάτων (critical interpretation of results). Η συγκεκριμένη ενότητα λειτουργεί ως συνδετικός κρίκος μεταξύ των παραγόμενων μετρικών απόδοσης και του θεωρητικού υποβάθρου που αναπτύχθηκε στα αρχικά κεφάλαια. Πρωταρχικός σκοπός δεν είναι η επανάληψη των στατιστικών δεδομένων ή των μελετών περίπτωσης που προηγήθηκαν, αλλά η συνθετική τους αξιολόγηση υπό το πρίσμα των κεντρικών ερευνητικών ερωτημάτων που διατυπώθηκαν κατά την αφετηρία της μελέτης.

Συγκεκριμένα, στο σημείο αυτό επιχειρείται μια ανασκόπηση γύρω από την πρακτική αξία και την πραγματική αποτελεσματικότητα των επιλεγμένων αρχιτεκτονικών της Επεξεργασίας Φυσικής Γλώσσας (NLP) στο πεδίο της ψηφιακής δημοσιογραφίας. Μέσα από την ανάλυση της συμπεριφοράς των μοντέλων (τόσο στο επίπεδο της αναγνώρισης της συναισθηματικής πολικότητας όσο και στο επίπεδο της αυτόματης παραγωγής περίληψης) αναδεικνύονται οι τεχνολογικές τομές που επιφέρουν τα σύγχρονα νευρωνικά δίκτυα (neural networks).

Η κριτική αποτίμηση που ακολουθεί διαρθρώνεται σε τρεις διακριτούς θεματικούς άξονες. Αρχικά, επιχειρείται η συγκριτική χαρτογράφηση των αλγορίθμων ανακάλυψης συναισθήματος, εξηγώντας τους λόγους για τους οποίους η εννοιολογική ευελιξία του RoBERTa υπερτερεί έναντι της στατικής, λεξικοκεντρικής προσέγγισης του VADER. Στη συνέχεια, το κέντρο του ενδιαφέροντος μετατοπίζεται στην αξιολόγηση του μηχανισμού συμπίκνωσης εγγράφων. Στο συγκεκριμένο στάδιο, τα στατιστικά σκορ των μετρικών ROUGE συγκεράζονται με τα συμπεράσματα των μελετών περίπτωσης, ώστε να πιστοποιηθεί η ικανότητα του δικτύου BART να συνθέτει ρέοντα, συμπαγή και αυτόνομο δημοσιογραφικό λόγο.

Τέλος, καταγράφονται οι περιορισμοί (limitations) του συνολικού πειραματικού σχεδιασμού. Η αναγνώριση των τεχνικών ή μεθοδολογικών εμποδίων (όπως οι στενωποί της διαθέσιμης υπολογιστικής μνήμης κατά την εκπαίδευση των μοντέλων ή τα «τυφλά σημεία» των προεκπαιδευμένων εργαλείων) σε καμία περίπτωση δεν υποβαθμίζει την αξία του εγχειρήματος. Αντιθέτως, μια τέτοια παραδοχή αποδεικνύει υψηλό δείκτη ερευνητικής συνείδησης (research awareness), οριοθετώντας με ακρίβεια την εμβέλεια των συμπερασμάτων και θέτοντας ασφαλή θεμέλια για μελλοντικές επεκτάσεις στον κλάδο της Υπολογιστικής Δημοσιογραφίας (Computational Journalism).

4.8.1 Αξιολόγηση των Μοντέλων Συναισθηματικής Ανάλυσης

Ξεκινώντας την αποτίμηση του πρώτου πειραματικού σκέλους, η αντιπαραβολή μεταξύ των εργαλείων εξαγωγής συναισθήματος ανέδειξε ένα τεχνολογικό χάσμα. Η εφαρμογή του αλγορίθμου VADER, ο οποίος εκπροσωπεί την παραδοσιακή γενιά συστημάτων που βασίζονται σε προκαθορισμένα λεξικά πολικότητας (lexicon-based approaches), επιβεβαίωσε στην πράξη τόσο τα θεωρητικά του πλεονεκτήματα όσο και τους δομικούς του περιορισμούς. Από τη μία πλευρά, το συγκεκριμένο εργαλείο διακρίθηκε για την ελάχιστη κατανάλωση υπολογιστικών πόρων και την υψηλή ταχύτητα εκτέλεσης, καθιστώντας το ιδανικό για γρήγορες, επιφανειακές σαρώσεις.

Από την άλλη πλευρά, ωστόσο, η στατική του φύση αποδείχθηκε ιδιαίτερα ευάλωτη απέναντι στην πολυπλοκότητα και τη νοηματική πυκνότητα του δημοσιογραφικού λόγου. Δεδομένου ότι η συγκεκριμένη μέθοδος αξιολογεί τη συναισθηματική βαρύτητα κάθε λέξης σχεδόν απομονωμένα, αγνοώντας σε μεγάλο βαθμό το ευρύτερο συντακτικό περιβάλλον, παρουσίασε εγγενή αδυναμία (inherent flaw) στη διαχείριση των γλωσσικών αποχρώσεων. Ειδικότερα, κατά την ανάλυση του απαιτητικού σώματος κειμένων του BBC News, το VADER συχνά "παγιδεύτηκε" στην απλοϊκή καταμέτρηση αρνητικών όρων. Το αποτέλεσμα ήταν να οδηγηθεί σε εσφαλμένες ταξινομήσεις (misclassifications) ρεπορτάζ τα οποία, ενώ περιέγραφαν δυσάρεστα γεγονότα (όπως ατυχήματα ή νομικές διαμάχες), είχαν αντικειμενικό και απρόσωπο ύφος.

Στον αντίποδα αυτής της περιοριστικής μεθοδολογίας, η ενσωμάτωση του προεκπαιδευμένου γλωσσικού μοντέλου RoBERTa επέφερε μια ποιοτική αναβάθμιση στην

εξαγωγή των αποτελεσμάτων. Βασισμένο στη σύγχρονη αρχιτεκτονική των Transformers, το εν λόγω νευρωνικό δίκτυο υπερέβη τη στείρα, μεμονωμένη ανάλυση λέξεων. Αξιοποιώντας τους εξελιγμένους μηχανισμούς αυτο-προσοχής (self-attention) και τη βαθιά, αμφίδρομη σάρωση των συμφραζομένων (bidirectional context), κατόρθωσε να σταθμίσει το σημασιολογικό «βάρος» κάθε όρου, συνυπολογίζοντας τη θέση και τον ρόλο του μέσα στην εκάστοτε πρόταση.

Το τεχνολογικό αυτό πλεονέκτημα αποδείχθηκε σημαντικό για την ορθή επεξεργασία του ειδησεογραφικού corpus. Όπως καταδείχθηκε τόσο από τα ποσοτικά δεδομένα όσο και από τις μελέτες περίπτωσης, το σύστημα επέδειξε την απαραίτητη αναλυτική ωριμότητα (analytical maturity) ώστε να διαχωρίσει το ίδιο το αναφερόμενο γεγονός από την υποκειμενική στάση του συντάκτη. Αναγνώρισε, δηλαδή, με ακρίβεια τη δημοσιογραφική ουδετερότητα, ταξινομώντας επιτυχώς ως "Neutral" πλήθος άρθρων τα οποία, μολονότι περιέγραφαν συγκρούσεις ή κρίσεις, διατηρούσαν ένα αντικειμενικό ύφος (objective reporting). Συμπερασματικά, για τις απαιτήσεις της σύγχρονης Υπολογιστικής Δημοσιογραφίας (Computational Journalism), τα μοντέλα βαθιάς μάθησης που έχουν υποστεί στοχευμένη μικρο-ρύθμιση (fine-tuning) αποτελούν τη μόνη ενδεδειγμένη ερευνητική επιλογή, εκτοπίζοντας οριστικά τα γραμμικά συστήματα παλαιότερης γενιάς.

4.8.2 Αξιολόγηση της Αυτόματης Παραγωγής Περίληψης

Μετατοπίζοντας τον άξονα της ανάλυσης από την ανίχνευση της πολικότητας στη συμπίκνωση του πληροφοριακού φορτίου, τα ευρήματα γύρω από τον αλγόριθμο συνόψισης είναι εξίσου ενθαρρυντικά. Η αξιολόγηση της αρχιτεκτονικής BART, όπως αυτή ποσοτικοποιήθηκε μέσω της καθιερωμένης σουίτας μετρικών ROUGE, καταδεικνύει την ικανότητα του συστήματος να φιλτράρει και να ανασυνθέτει τον δημοσιογραφικό λόγο. Πρέπει να επισημανθεί πως τα καταγεγραμμένα ποσοστά πρέπει να ερμηνευθούν υπό το πρίσμα των αυξημένων απαιτήσεων της αφαιρετικής σύνοψης (abstractive summarization). Πρόκειται για μια διαδικασία που παρουσιάζει μεγαλύτερη υπολογιστική και σημασιολογική πολυπλοκότητα συγκριτικά με τις απλές εξαγωγικές μεθόδους (extractive), καθώς απαιτεί από το νευρωνικό δίκτυο την παραγωγή εξ ολοκλήρου νέου, φυσικού κειμένου, και όχι τη μηχανική απόσπαση προϋπαρχουσών προτάσεων.

Υπό αυτή την οπτική, ο μέσος όρος του 55,87% που σημειώθηκε στον δείκτη ROUGE-1 αποτελεί σημαντικό τεχνολογικό επίτευγμα. Η συγκεκριμένη τιμή πιστοποιεί πως το παραγόμενο απόσταγμα κατόρθωσε να διασώσει πάνω από το ήμισυ του κρίσιμου, μεμονωμένου λεξιλογίου (unigrams) που εμπεριέχεται στο κείμενο αναφοράς (lead baseline), εξασφαλίζοντας τη διατήρηση του βασικού θεματικού πυρήνα της είδησης. Παράλληλα, οι επιδόσεις στις μετρικές ROUGE-2 (43,32%) και ROUGE-L (47,91%) προσφέρουν μια βαθύτερη, ποιοτική εικόνα. Αναδεικνύουν τον υψηλό βαθμό επικάλυψης σε ζεύγη λέξεων (bigrams) και τη διατήρηση της μακρύτερης κοινής υποακολουθίας αντίστοιχα, γεγονός που μεταφράζεται σε άρτια συντακτική δομή και ομαλή αλληλουχία εννοιών, αποτρέποντας τη δημιουργία ασύνδετου ή κατακερματισμένου λόγου.

Η αξιοπιστία αυτών των στατιστικών δεικτών επικυρώνεται μέσα από την επισκόπηση των μελετών περίπτωσης (case studies) που εξετάστηκαν προηγουμένως. Όπως φάνηκε κατά την παρατήρηση των επιμέρους δημοσιευμάτων (τόσο στην αθλητική όσο και στην τεχνολογική επικαιρότητα) η αρχιτεκτονική δεν παρήγαγε απλώς γραμματικά ορθές προτάσεις, αλλά επέδειξε ικανότητα σημασιολογικής αφαίρεσης (semantic abstraction). Εντόπισε το ειδησεογραφικό επίκεντρο κάθε γεγονότος και απέβαλε τον περιττό πληροφοριακό «θόρυβο», όπως δευτερεύουσες δηλώσεις τρίτων προσώπων ή επουσιώδεις τεχνικές λεπτομέρειες.

Το γεγονός ότι το εξαγόμενο αποτέλεσμα διατήρησε αμείωτη τη νοηματική του συνοχή (semantic coherence) ανεξαρτήτως της θεματικής κατηγορίας του αρχικού ρεπορτάζ, αναδεικνύει την προσαρμοστικότητα του αλγορίθμου σε εντελώς διαφορετικά λεξιλογικά περιβάλλοντα. Εν κατακλείδι, αποδεικνύεται πως η εφαρμογή του προεκπαιδευμένου δικτύου δεν αποτελεί απλώς ένα απομονωμένο εργαστηριακό πείραμα, αλλά συνιστά μια πραγματική λύση υψηλών προδιαγραφών. Το αντίστοιχο δίκτυο καθίσταται ικανό να ενσωματωθεί στην

καθημερινή ροή εργασίας (workflow) ενός σύγχρονου μέσου ενημέρωσης, βελτιστοποιώντας τον χρόνο που απαιτείται για την αφομοίωση του διαρκώς αυξανόμενου όγκου ψηφιακών δεδομένων.

4.8.3 Περιορισμοί της Έρευνας (Limitations)

Η ολοκλήρωση της κριτικής αποτίμησης καθιστά αναγκαία την καταγραφή των περιορισμών που διέπουν την παρούσα εργασία. Τα εμπόδια που εντοπίστηκαν κατά την υλοποίηση του πειραματικού σχεδιασμού σχετίζονται πρωτίστως με τις απαιτήσεις των υπολογιστικών πόρων και τις προδιαγραφές των ίδιων των νευρωνικών δικτύων.

Ειδικότερα, η βασική πρόκληση προήλθε από τον μεγάλο όγκο δεδομένων και τις υψηλές απαιτήσεις συστημικής μνήμης που χαρακτηρίζουν τα μοντέλα βαθιάς μάθησης (Deep Learning). Δεδομένης της εκτέλεσης του κώδικα στο νεφικό περιβάλλον του Google Colab και των περιορισμών της διαθέσιμης μονάδας επεξεργασίας γραφικών (T4 GPU), κατέστη αναπόφευκτη η εφαρμογή τεχνικών δυναμικής περικοπής (truncation) στα εισερχόμενα δεδομένα. Καθώς η αρχιτεκτονική του RoBERTa επιτρέπει μέγιστη είσοδο 512 tokens και το BART αγγίζει τα 1024, ορισμένα ιδιαίτερα μακροσκελή ειδησεογραφικά ρεπορτάζ του BBC News δεν αναλύθηκαν στη συνολική τους έκταση. Κατά συνέπεια, ενδέχεται δευτερεύουσες ή συμπληρωματικές πληροφορίες, οι οποίες χωροθετούνταν στις καταληκτικές παραγράφους των εκτενέστερων άρθρων, να έμειναν εκτός της εμβέλειας του αλγορίθμου, επηρεάζοντας τον βαθμό εξάντλησης του νοήματος.

Πέραν των τεχνικών ή υλισμικών προσκομμάτων, οφείλουν να συνυπολογιστούν και οι περιορισμοί που διέπουν την ίδια τη φύση των γλωσσικών αλγορίθμων. Παρά την πρόοδο των αρχιτεκτονικών Transformer, η προσομοίωση της ανθρώπινης γνωστικής αντίληψης (cognitive perception) αποτελεί ακόμη ένα ανοιχτό ερευνητικό στοίχημα. Για παράδειγμα, ενώ το δίκτυο RoBERTa διακρίνεται για τη σημασιολογική του οξυδέρκεια, ενδέχεται να αστοχήσει στην αποκωδικοποίηση λεπτών εκφραστικών αποχρώσεων. Φαινόμενα όπως ο βαθύς σαρκασμός, το έμμεσο δημοσιογραφικό χιούμορ ή οι πολιτικές αλληγορίες, απαιτούν συχνά ένα ευρύτερο κοινωνικό και ιστορικό υπόβαθρο (world knowledge), το οποίο δεν δύναται να ανακτηθεί αποκλειστικά μέσω της στατιστικής ανάλυσης των συμβόλων ενός κειμένου.

Επιπροσθέτως, μια κρίσιμη παράμετρος που περιορίζει την καθολικότητα των ευρημάτων αφορά τη γλωσσική εξάρτηση (language bias) των προεκπαιδευμένων εργαλείων. Τόσο το επιλεγμένο μοντέλο ανάλυσης συναισθήματος όσο και το σύστημα παραγωγής περιλήψεων έχουν βελτιστοποιηθεί αξιοποιώντας αγγλόφωνα σώματα δεδομένων. Αυτό συνεπάγεται πως η απευθείας μεταφορά της παρούσας μεθοδολογικής αλυσίδας (pipeline) σε ειδησεογραφικά δίκτυα που λειτουργούν σε διαφορετικές γλώσσες, όπως η ελληνική, προϋποθέτει αναγκαστικά τη χρήση εξειδικευμένων πολύγλωσσων παραλλαγών (όπως το mBART ή το XLM-RoBERTa). Ωστόσο, παρά τις προαναφερθείσες επιφυλάξεις, η εξαγόμενη αξία του συστήματος παραμένει αδιαμφισβήτητη, αποδεικνύοντας την αποτελεσματικότητα της προτεινόμενης λύσης στον αυτοματοποιημένο χειρισμό του ψηφιακού περιεχομένου.

Κεφάλαιο 5: Συμπεράσματα και Μελλοντική Έρευνα

5.1 Εισαγωγή

Η παρούσα εργασία ξεκίνησε με σκοπό τη διερεύνηση και την κριτική αξιολόγηση των δυνατοτήτων που προσφέρουν οι σύγχρονες τεχνολογίες Επεξεργασίας Φυσικής Γλώσσας (NLP) στο μεταβαλλόμενο τοπίο της ψηφιακής δημοσιογραφίας. Σε μια εποχή όπου ο όγκος της παραγόμενης ειδησεογραφίας αυξάνεται, η ανάγκη για αυτοματοποιημένα, ευφυή υπολογιστικά συστήματα διαχείρισης της πληροφορίας καθίσταται επιτακτική. Υπό αυτό το πρίσμα, η έρευνα επικεντρώθηκε στην πρακτική εφαρμογή και συγκριτική ανάλυση προηγμένων γλωσσικών μοντέλων, εστιάζοντας σε δύο πυλώνες: την ανάλυση της συναισθηματικής πολικότητας (Sentiment Analysis) και την αυτόματη παραγωγή αφαιρετικής περίληψης (Abstractive Text Summarization).

Μέσα από την εξέταση ενός εκτενούς σώματος κειμένων (corpus) προερχόμενου από το διεθνές δίκτυο του BBC, το παρόν εγχείρημα είχε ως στόχο τη γεφύρωση του χάσματος ανάμεσα στη θεωρητική μηχανική μάθηση και την καθημερινή δημοσιογραφική πρακτική. Στα κεφάλαια που προηγήθηκαν, καταγράφηκε βήμα προς βήμα η μετάβαση από τις παραδοσιακές, λεξικοκεντρικές προσεγγίσεις στις σύγχρονες αρχιτεκτονικές βαθιάς μάθησης (Deep Learning), αποτυπώνοντας τις μεθοδολογικές προκλήσεις, τις τεχνικές υπερβάσεις και τις στατιστικές επιδόσεις του εκάστοτε υπολογιστικού συστήματος.

Η συνέχεια της εργασίας διαρθρώνεται σε δύο στοχευμένους άξονες. Αρχικά, παρατίθεται το απόσπασμα της μελέτης, παραδίδοντας τις απαντήσεις στα ερευνητικά ερωτήματα που καθοδήγησαν την παρούσα εργασία από τη σύλληψή της. Στο σημείο αυτό, οι επιμέρους παρατηρήσεις συγκλίνουν για να συνθέσουν τη μεγάλη εικόνα: την δυναμική που προσδίδουν τα γλωσσικά μοντέλα μεγάλης κλίμακας (LLMs) στην οργάνωση των σύγχρονων αιθουσών σύνταξης (newsrooms).

Στη συνέχεια, αναγνωρίζοντας πως ο κλάδος της Τεχνητής Νοημοσύνης συνιστά ένα διαρκώς μεταβαλλόμενο οικοσύστημα, το κείμενο στρέφει το βλέμμα του στην επόμενη ημέρα. Κατατίθενται συγκεκριμένες, εφαρμόσιμες και καινοτόμες προτάσεις για μελλοντική έρευνα (future work), σκιαγραφώντας νέες επιστημονικές κατευθύνσεις. Μέσω αυτών των προτάσεων (οι οποίες εκτείνονται από την αναγκαιότητα ενσωμάτωσης πολύγλωσσων δικτύων έως τη διερεύνηση της ηθικής διάστασης των παραγόμενων κειμένων) επιδιώκεται να δοθεί το έναυσμα για την περαιτέρω εξέλιξη του πεδίου.

5.2 Βασικά Συμπεράσματα

Η συστηματική αξιολόγηση των πειραματικών δεδομένων οδήγησε στη συναγωγή κρίσιμων πορισμάτων, τα οποία επιβεβαιώνουν την κεντρική ερευνητική υπόθεση της εργασίας. Όσον αφορά την αναγνώριση συναισθηματικής πολικότητας, προκύπτει το συμπέρασμα ότι η μετάβαση από τις γραμμικές μεθόδους στα προηγμένα νευρωνικά δίκτυα συνιστά αναγκαιότητα για την ψηφιακή δημοσιογραφία. Το αλγοριθμικό εργαλείο VADER, μολονότι παραμένει χρήσιμο σε εφαρμογές χαμηλής υπολογιστικής έντασης, αποδείχθηκε ότι δεν δύναται να αποκωδικοποιήσει το σύνθετο ύφος των ρεπορτάζ, εξαιτίας της επιφανειακής, λεξικογραφικής καταμέτρησης.

Στον αντίποδα, η ενσωμάτωση του μοντέλου RoBERTa ανέδειξε την ανωτερότητα των αρχιτεκτονικών βαθιάς μάθησης (deep learning architectures). Το συγκεκριμένο δίκτυο απέδειξε την ικανότητά του να κατανοεί το ευρύτερο σημασιολογικό πλαίσιο (context), διαχωρίζοντας με επιτυχία το αρνητικό περιεχόμενο μιας είδησης από τη συντακτική ουδετερότητα του δημοσιογράφου. Το τελικό συμπέρασμα που ανακύπτει είναι πως η σύγχρονη βιομηχανία των μέσων ενημέρωσης οφείλει να στραφεί αποκλειστικά σε μοντέλα τα οποία αξιολογούν δυναμικά τα συμφοραζόμενα, απορρίπτοντας τα στατικά συστήματα κανόνων (rule-based systems).

Σε ανάλογο επίπεδο επιτυχίας κυμάνθηκε και η αποτίμηση του δεύτερου ερευνητικού πυλώνα, ο οποίος επικεντρώθηκε στη σημασιολογική συμπύκνωση των μακροσκελών ρεπορτάζ. Η πρακτική δοκιμή του αλγορίθμου BART απέδειξε πως η αντιμετώπιση του φαινομένου της πληροφοριακής υπερφόρτωσης (information overload) καθίσταται πλέον εφικτή μέσω της έξυπνης αυτοματοποίησης. Το συγκεκριμένο υπολογιστικό σύστημα ανταποκρίθηκε στις απαιτήσεις της αφαιρετικής σύνοψης (abstractive summarization), αποδεικνύοντας γνήσια συνθετική ικανότητα. Δεν περιορίστηκε σε μια μηχανική αναπαραγωγή ή στείρα παράθεση προϋπαρχόντων εδαφίων από το αρχικό έγγραφο. Αντίθετα, κατόρθωσε να αναδιατυπώσει τον ειδησεογραφικό πυρήνα του εκάστοτε γεγονότος με φυσικό λόγο, διασώζοντας την κεντρική πληροφορία και φιλτράροντας αποτελεσματικά τις επουσιώδεις λεπτομέρειες.

Συνοψίζοντας, το τελικό πόρισμα της παρούσας μελέτης τεκμηριώνει με σαφήνεια πως η συνδυαστική αξιοποίηση αυτών των προηγμένων γλωσσικών εργαλείων υπερβαίνει τα όρια ενός εργαστηριακού πειράματος. Η διττή διαδικασία (άμεση διάγνωση της συναισθηματικής τάσης και ταχύτατη παραγωγή περιεκτικών συνόψεων) αναδεικνύεται σε μια βιώσιμη λύση. Πρόκειται για μια τεχνολογική τομή ικανή να μετασχηματίσει την καθημερινή ροή εργασίας (workflow) στις αίθουσες σύνταξης, προσφέροντας στους δημοσιογραφικούς οργανισμούς τα απαραίτητα εφόδια για να διαχειριστούν τον αυξανόμενο όγκο του ψηφιακού περιεχομένου με ταχύτητα, ακρίβεια και αναλυτικό βάθος.

5.3 Προτάσεις για Μελλοντική Έρευνα

Η ολοκλήρωση της παρούσας εργασίας δεν σηματοδοτεί το τέλος της αναζήτησης, αλλά την αφετηρία για νέες, πιο σύνθετες επιστημονικές προσεγγίσεις. Δεδομένης της ταχύτητας με την οποία εξελίσσεται το οικοσύστημα της Επεξεργασίας Φυσικής Γλώσσας (NLP), αναδύεται πλήθος ευκαιριών για την περαιτέρω επέκταση και βελτιστοποίηση του προτεινόμενου συστήματος.

Μια κατεύθυνση για μελλοντική μελέτη συνιστά η μεταφορά της υλοποιημένης μεθοδολογίας σε μη αγγλόφωνα περιβάλλοντα, με προτεραιότητα την εγχώρια, ελληνική ειδησεογραφία. Η πειραματική εφαρμογή πολύγλωσσων εκδόσεων (multilingual variants), όπως τα δίκτυα XLM-RoBERTa και mBART, θα προσέφερε πολύτιμα συμπεράσματα. Θα επέτρεπε τη διερεύνηση του κατά πόσο οι αλγόριθμοι διατηρούν την ίδια σημασιολογική οξυδέρκεια όταν καλούνται να επεξεργαστούν μια γλώσσα με πιο περίπλοκη μορφολογική δομή σε σύγκριση με την αγγλική.

Παράλληλα, ενδιαφέρον παρουσιάζει η ενδεχόμενη αντιπαράβολή των παρόντων ευρημάτων με τις επιδόσεις που καταγράφουν τα Μεγάλα Γλωσσικά Μοντέλα (Large Language Models - LLMs) νεότερης γενιάς, όπως, για παράδειγμα, οι ανοιχτές αρχιτεκτονικές τύπου LLaMA. Η αξιολόγηση της ικανότητάς τους να εκτελούν τις ίδιες δημοσιογραφικές εργασίες βασισμένα αποκλειστικά σε έξυπνες υποδείξεις (prompt engineering) (χωρίς την κοστοβόρα ανάγκη για εκτεταμένη μικρο-ρύθμιση (zero-shot ή few-shot learning)) ενδέχεται να αναδείξει νέα, ακόμη πιο ευέλικτα πρότυπα στην Υπολογιστική Δημοσιογραφία.

Πέραν της αμιγώς θεωρητικής ή αλγοριθμικής εξέλιξης, μια εξίσου κρίσιμη προοπτική για το μέλλον συνιστά η μεταφορά του πειραματικού σχεδιασμού από το απομονωμένο εργαστηριακό περιβάλλον σε συνθήκες πραγματικής παραγωγής (production environment). Συγκεκριμένα, προτείνεται η αρχιτεκτονική και η ανάπτυξη μιας ολοκληρωμένης, εύχρηστης διαδικτυακής πλατφόρμας (Web Application), η οποία θα ενσωματώνει τα εκπαιδευμένα μοντέλα μέσω κατάλληλων Διεπαφών Προγραμματισμού Εφαρμογών (APIs). Μια τέτοια λύση θα παρείχε στους δημοσιογράφους τη δυνατότητα να διοχετεύουν το ακατέργαστο υλικό τους στο σύστημα και να λαμβάνουν, σε πραγματικό χρόνο (real-time), τόσο τον δείκτη συναισθηματικής φόρτισης όσο και πολλαπλές εναλλακτικές εκδοχές συνόψεων, προσαρμοσμένες στις εκάστοτε χωροταξικές απαιτήσεις του μέσου.

Με την ολοκλήρωση της παρούσας μελέτης, αναδεικνύεται μια διαπίστωση που υπερβαίνει τα όρια του κώδικα: η ενσωμάτωση της Τεχνητής Νοημοσύνης (Artificial Intelligence) στις

σύγχρονες αίθουσες σύνταξης δεν αποσκοπεί στην υποβάθμιση ή την αντικατάσταση της ανθρώπινης δημοσιογραφικής κρίσης, αλλά στην ενδυνάμωσή της. Ευελπιστούμε πως τα συμπεράσματα και τα ευρήματα που αποτυπώθηκαν στις σελίδες αυτής της εργασίας, θα αποτελέσουν ένα γόνιμο επιστημονικό υπόβαθρο.

Κεφάλαιο 6: Μεθοδολογία Βιβλιογραφικής Αναζήτησης και Βιβλιομετρική Ανάλυση

6.1 Πρωτόκολλο Αναζήτησης και Κριτήρια Ένταξης

Για τον εντοπισμό και τη συλλογή των 100 συνολικά επιστημονικών άρθρων που απαρτίζουν τη βιβλιογραφία, αξιοποιήθηκαν δύο αναγνωρισμένες ψηφιακές δεξαμενές ακαδημαϊκών δεδομένων. Η πρωτογενής στρατηγική αναζήτησης διεξήχθη μέσω του Google Scholar, από το οποίο αντλήθηκε το 70% του τελικού υλικού. Το υπόλοιπο 30% των άρθρων ανακτήθηκε επίσης με στοχευμένα ερωτήματα (Boolean search strings) από τη βάση δεδομένων Scopus.

Κατά τη φάση της διαλογής, εφαρμόστηκαν συγκεκριμένα κριτήρια ένταξης και αποκλεισμού (inclusion and exclusion criteria). Το σημαντικότερο από αυτά αφορούσε τον χρονολογία των δημοσιεύσεων. Δεδομένου ότι ο τομέας της Επεξεργασίας Φυσικής Γλώσσας (NLP) και των Μεγάλων Γλωσσικών Μοντέλων (LLMs) εξελίσσεται με γρήγορους ρυθμούς, κρίθηκε αναγκαία η εστίαση στην περίοδο 2020 έως 2026. Ο αποκλεισμός παλαιότερων μελετών εγγυάται ότι η εργασία αποτυπώνει την τρέχουσα τεχνολογική αιχμή (state-of-the-art). Μοναδική εξαίρεση σε αυτόν τον κανόνα αποτέλεσαν επιλεγμένα, θεμελιώδη άρθρα (original works) (όπως οι αρχικές δημοσιεύσεις για τον μηχανισμό Προσοχής (Attention), το BERT και τα στατικά διανύσματα) τα οποία κρίθηκαν αναγκαία για την ιστορική και νοηματική συνοχή του κειμένου.

Πέρα από τον περιορισμό που αφορά τη χρονολογία, καθοριστικό ρόλο στην τελική επιλογή της βιβλιογραφίας διαδραμάτισε η ποιοτική αξιολόγηση (quality assessment) των πηγών. Στόχος ήταν η διασφάλιση της μέγιστης δυνατής επιστημονικής εγκυρότητας. Για τον λόγο αυτό, η πλειοψηφία των άρθρων που συμπεριλήφθηκαν προέρχεται από διεθνή περιοδικά της κορυφαίας βαθμίδας Q1 (βάσει του Scimago Journal Rank) και από πρακτικά συνεδρίων με την διάκριση Core A*. Η συγκεκριμένη επιλογή εγγυάται ότι οι μεθοδολογίες και τα θεωρητικά μοντέλα που εξετάζονται έχουν περάσει από αυστηρό έλεγχο από την ερευνητική κοινότητα.

Παράλληλα, προκειμένου να διατηρηθεί η ισορροπία και το απαραίτητο θεματικό εύρος, ενσωματώθηκε ένας μικρότερος, αλλά σημαντικός αριθμός δημοσιεύσεων κατηγορίας Q2 και Core A. Οι εν λόγω πηγές επιλέχθηκαν επειδή κάλυπταν σημαντικές πτυχές της ανάλυσης συναισθήματος ή παρείχαν πρόσβαση σε εξειδικευμένες συγκριτικές μελέτες εργαλείων (όπως το VADER και το RoBERTa) που ήταν άμεσα εφαρμόσιμες στο πειραματικό σενάριο της εργασίας.

Τέλος, μια μεθοδολογική προσθήκη αφορούσε τη συμπερίληψη επιλεγμένων προδημοσιεύσεων (pre-prints) από το ανοιχτό αποθετήριο arXiv, οι οποίες δεν έχουν επίσημη ακαδημαϊκή κατάταξη. Η έρευνα γύρω από τα σύγχρονα αρχιτεκτονικά πρότυπα, όπως οι Transformers και τα Μεγάλα Γλωσσικά Μοντέλα, κινείται με ταχύτητες που συχνά ξεπερνούν τους παραδοσιακούς, χρονοβόρους κύκλους έκδοσης. Με την άντληση δεδομένων από το arXiv, η παρούσα εργασία κατάφερε να αφομοιώσει τις πλέον καινοτόμες εξελίξεις της Τεχνητής Νοημοσύνης, τη στιγμή που αυτές διαμορφώνουν το νέο τεχνολογικό τοπίο.

6.2 Χρονική Κατανομή Βιβλιογραφικών Πηγών

Προχωρώντας στην ποσοτική αποτίμηση του ερευνητικού υλικού, κρίνεται σκόπιμο να αναλυθεί η χρονική κατανομή των εκατό δημοσιεύσεων που απαρτίζουν τη βιβλιογραφία. Δεδομένου ότι η Επεξεργασία Φυσικής Γλώσσας αναδιαμορφώνεται ριζικά, η παλαιότητα των πηγών αποτελεί κρίσιμο δείκτη εγκυρότητας.

Από την επεξεργασία των ετών έκδοσης (Πίνακας 6.1), προκύπτει μια εσκεμμένη ασυμμετρία υπέρ της τρέχουσας δεκαετίας. Ειδικότερα, παρατηρείται μια μαζική συγκέντρωση επιστημονικών άρθρων στο χρονικό παράθυρο 2020-2026, το οποίο αντιπροσωπεύει σχεδόν


το 80% της συνολικής βιβλιογραφίας. Αυτή η ερευνητική παραγωγή ταυτίζεται απόλυτα με την «έκρηξη» των Μεγάλων Γλωσσικών Μοντέλων (Large Language Models) και την καθολική επικράτηση των αρχιτεκτονικών Transformer.

Πίνακας 6.1: Χρονική κατανομή των βιβλιογραφικών αναφορών

Χρονική Περίοδος / Έτος	Αριθμός Δημοσιεύσεων	Ποσοστό (%)
Πριν το 2015 (Θεμελιώδεις Έρευνες)	14	14%
2015 – 2019 (Πρώιμα Νευρωνικά / BERT)	8	8%
2020	13	13%
2021	9	9%
2022	12	12%
2023	22	22%
2024	10	10%
2025	10	10%
2026 (Προδημοσιεύσεις)	2	2%
Σύνολο	100	100%

Όπως αποτυπώνεται και στο ραβδόγραμμα που ακολουθεί, η καμπύλη ενδιαφέροντος κορυφώνεται κατά το έτος 2023, αντικατοπτρίζοντας την ακαδημαϊκή στροφή προς την αξιολόγηση μοντέλων ανοιχτού κώδικα και τη βελτιστοποίηση της ανάλυσης συναισθήματος (όπως τα συγκριτικά πειράματα RoBERTa έναντι VADER που μελετώνται εδώ).

Αριθμός Δημοσιεύσεων



Εικόνα 6.1: Χρονική κατανομή των βιβλιογραφικών αναφορών

Από την άλλη πλευρά, η διατήρηση είκοσι δύο πηγών που εκδόθηκαν πριν το 2020 δεν συνιστά μεθοδολογική ασυνέπεια, αλλά θεωρητική δικλείδα ασφαλείας. Οι συγκεκριμένες αναφορές αποτελούν θεμελιώδη έργα (seminal papers) που καθόρισαν την ιστορική πορεία της

Υπολογιστικής Γλωσσολογίας. Η συμπερίληψή τους κρίθηκε σημαντική προκειμένου να χαρτογραφηθεί η εξελικτική μετάβαση από τα παραδοσιακά στατιστικά μοντέλα στα σύγχρονα νευρωνικά δίκτυα.

Χαρακτηριστικό παράδειγμα αυτής της προσέγγισης αποτελεί η μελέτη των Hutto & Gilbert (2014) για το VADER, η οποία πλαισιώνει τον έναν από τους δύο βασικούς πυλώνες του πειραματικού σχεδιασμού. Αντίστοιχα, πρωτοποριακές έρευνες όπως η εισαγωγή των LSTM (Hochreiter & Schmidhuber, 1997), η δημιουργία του Word2Vec (Mikolov et al., 2013) και η θεμελίωση της αρχιτεκτονικής Transformer (Vaswani et al., 2017), δεν διαθέτουν ημερομηνία λήξης. Αποτελούν τον θεωρητικό πυρήνα πάνω στον οποίο δομήθηκαν εργαλεία όπως το RoBERTa και το BART. Συνεπώς, τα παλαιότερα αυτά άρθρα προσφέρουν το αναγκαίο συγκριτικό μέτρο, αναδεικνύοντας τις τεχνολογικές αδυναμίες του παρελθόντος που τα σύγχρονα μοντέλα καλούνται σήμερα να επιλύσουν.

6.3 Προέλευση και Κατανομή Επιστημονικών Πηγών

Αξιολογώντας το σύνολο των δεδομένων, διαπιστώνεται ότι οι πληροφορίες αντλούνται από πηγές με ακαδημαϊκό κύρος. Στην κορυφή της λίστας των επιστημονικών περιοδικών κυριαρχεί το ACM Computing Surveys, καταγράφοντας οκτώ συνολικά εμφανίσεις. Το συγκεκριμένο έντυπο αποτέλεσε τον βασικό θεωρητικό πυλώνα της εργασίας, παρέχοντας εκτενείς, κριτικές ανασκοπήσεις (surveys) γύρω από την αρχιτεκτονική των σύγχρονων γλωσσικών μοντέλων, τις μετρικές αξιολόγησης και τις προκλήσεις της μηχανικής μάθησης.


Ακολουθεί το IEEE Access, με επτά δημοσιεύσεις. Η επιλογή του συγκεκριμένου περιοδικού εξασφάλισε άμεση πρόσβαση σε καινοτόμες, ανοιχτής πρόσβασης (open-access) τεχνικές υλοποιήσεις, προσφέροντας εφαρμοσμένες λύσεις στη σύγκριση παραδοσιακών τεχνικών NLP με τα Μεγάλα Γλωσσικά Μοντέλα (LLMs). Επιπρόσθετα, συμπεριλαμβάνονται στις πηγές περιοδικά αυστηρής επιστημονικής κρίσης (peer-reviewed), όπως τα Artificial Intelligence Review και Multimedia Tools and Applications. Οι πηγές αυτές εισέφεραν το απαραίτητο αλγοριθμικό βάθος, ειδικά στις ενότητες που διαπραγματεύονται τη μετάβαση από τα απλά στατιστικά μοντέλα στα πολύπλοκα νευρωνικά δίκτυα. Παράλληλα με την αξιοποίηση των ακαδημαϊκών περιοδικών, βαρύνουσα σημασία είχαν τα πρακτικά συνεδρίων (conference proceedings).

Όπως φαίνεται στον Πίνακα 6.2, ακαδημαϊκά γεγονότα υψηλού κύρους (κατηγορίας Core A*), όπως το ACL (Association for Computational Linguistics) και το EMNLP (Empirical Methods in Natural Language Processing), καταλαμβάνουν σημαντικό μερίδιο στη βιβλιογραφία, με επτά και έξι αναφορές αντίστοιχα. Μέσα από τις συγκεκριμένες διοργανώσεις αντλήθηκαν τα πρωταρχικά άρθρα που εισήγαγαν την αρχιτεκτονική των Transformers, καθώς και σύγχρονες μελέτες πάνω στην αξιολόγηση παραγωγικών γλωσσικών μοντέλων.

Πίνακας 6.2: Οι οκτώ κορυφαίες πηγές προέλευσης της βιβλιογραφίας.

Πηγή	Αριθμός Εμφανίσεων
ACM Computing Surveys	8
IEEE Access	7
EMNLP	7
ACL/NAACL	6
arXiv Preprints	4
Multimedia Tools and Applications	3
Artificial Intelligence Review	3
NeurIPS	3

Η συνολική κατανομή, η οποία οπτικοποιείται στο ραβδόγραμμα που ακολουθεί, επιβεβαιώνει την ισορροπία της ερευνητικής προσέγγισης. Η συνύπαρξη εκτενών θεωρητικών ανασκοπήσεων, εφαρμοσμένης τεχνολογικής βιβλιογραφίας και αδημοσίεωτων, πρωτοποριακών ανακοινώσεων (*arXiv*), διασφαλίζει την εγκυρότητα του πλαισίου στο οποίο στηρίχθηκε η παρούσα εργασία.



Εικόνα 6.2: Οι οκτώ κορυφαίες πηγές προέλευσης της βιβλιογραφίας.

6.4 Ποιοτική Αξιολόγηση και Επιστημονικός Αντίκτυπος Πηγών

Ως γνώμονας για την αξιολόγηση των επιστημονικών περιοδικών χρησιμοποιήθηκε ο διεθνής δείκτης SCImago Journal Rank (SJR), ενώ για την αποτίμηση των πρακτικών συνεδρίων εφαρμόστηκε το καθιερωμένο σύστημα κατάταξης CORE.


Τα αποτελέσματα αυτής της ανάλυσης καταδεικνύουν την υπεροχή των κορυφαίων επιστημονικών εκδόσεων. Ειδικότερα, το 80% του ερευνητικού υλικού εντάσσεται στην υψηλότερη δυνατή ακαδημαϊκή βαθμίδα. Αναλυτικά, πενήντα εννέα (59) δημοσιεύσεις προέρχονται από περιοδικά του πρώτου τεταρτημορίου (Q1), αποτελώντας τον βασικό κορμό της θεωρητικής τεκμηρίωσης. Επιπρόσθετα, είκοσι μία (21) αναφορές αντλήθηκαν από συνέδρια κατηγορίας Core A*, τον χώρο δηλαδή όπου ανακοινώνονται και ελέγχονται οι πιο σημαντικές ανακαλύψεις στην Επεξεργασία Φυσικής Γλώσσας, πριν λάβουν τη μορφή εκτενών άρθρων. Η συγκέντρωση ενός τόσο μεγάλου όγκου πληροφοριών υψηλού κύρους όσον αφορά την παγκόσμια έρευνα διασφαλίζει ότι οι τεχνολογικές συγκρίσεις της παρούσας μελέτης εδράζονται σε επιστημονικά ελεγμένα (*peer-reviewed*) και κοινώς αποδεκτά πρότυπα.

Συμπληρωματικά, ένα επιπλέον 10% της βιβλιογραφίας απαρτίζεται από πηγές της βαθμίδας Q2 (εννέα δημοσιεύσεις) και Core A (μία δημοσίευση). Τα συγκεκριμένα άρθρα επιλέχθηκαν επειδή εμβαθύνουν σε πιο στοχευμένες πτυχές της ανάλυσης συναισθήματος. Συχνά, τέτοιας κλίμακας περιοδικά φιλοξενούν εξειδικευμένες πειραματικές υλοποιήσεις, γεφυρώνοντας το χάσμα μεταξύ της αφηρημένης θεωρίας και της πρακτικής εφαρμογής στον κώδικα.

Ιδιαίτερη μνεία, ωστόσο, οφείλει να γίνει στο υπολειπόμενο 10% των αναφορών, οι οποίες τυπικά στερούνται επίσημης ακαδημαϊκής κατάταξης (N/A). Στην πλειονότητά τους, οι πηγές αυτές αφορούν προδημοσιεύσεις (*pre-prints*) από το ανοιχτό αποθετήριο *arXiv*, καθώς και

τεχνικές αναφορές εργαλείων λογισμικού (όπως τα αποθετήρια Zenodo για τη βιβλιοθήκη spaCy). Η ενσωμάτωση τέτοιου υλικού δεν συνιστά ελάττωμα, αλλά αποτελεί τον "χρυσό κανόνα" στη σύγχρονη έρευνα της Τεχνητής Νοημοσύνης. Δεδομένου ότι τα μοντέλα NLP εξελίσσονται με μεγάλες ταχύτητες, οι παραδοσιακοί κύκλοι αξιολόγησης (peer-review) αδυνατούν να συμβαδίσουν. Μέσω αυτών των προδημοσιεύσεων, η παρούσα πτυχιακή διατηρεί στο ακέραιο τον σύγχρονο χαρακτήρα της.

Η συνολική εικόνα του επιστημονικού αντίκτυπου αποτυπώνεται στο διάγραμμα που ακολουθεί.



Εικόνα 6.3: Τα Rankings των αναφορών

6.5 Συγγραφική Παραγωγή και Ερευνητική Διασπορά

Αναδείχθηκαν δώδεκα (12) διακριτά ονόματα που παρουσιάζουν επαναλαμβάνονται, έχοντας συμμετοχή σε περισσότερες από μία δημοσιεύσεις. Στην κορυφή της σχετικής λίστας συναντάμε τον Cambria Erik με τρεις (3) συνολικά εμφανίσεις στο διαμορφωμένο θεωρητικό πλαίσιο της παρούσας εργασίας. Το γεγονός ότι η πλειονότητα των υπόλοιπων ερευνητών εντοπίζεται μόλις μία φορά, αποτυπώνει με σαφήνεια τη διασπορά του ακαδημαϊκού ενδιαφέροντος γύρω από το συγκεκριμένο αντικείμενο. Πρακτικά, αυτό υποδηλώνει ότι διαφορετικοί επιστήμονες συνεισφέρουν ενεργά στην έρευνα για την Επεξεργασία Φυσικής Γλώσσας. Η απουσία μιας κλειστής ερευνητικής ομάδας που να κυριαρχεί στη βιβλιογραφία, επιβεβαιώνει τον πολυδιάστατο χαρακτήρα του αντίστοιχου ερευνητικού πεδίου.

Πίνακας 6.3: Κατάταξη των συγγραφέων με τη μεγαλύτερη ερευνητική παρουσία στη βιβλιογραφία.

Επώνυμο	Όνομα	Αριθμός Εμφανίσεων
Cambria	Erik	3
Catelli	Rosario	2
Esposito	Massimo	2
Honnibal	Matthew	2
Montani	Ines	2

Boyd	Adriane	2
Lewis	Mike	2
Liu	Yinhan	2
Goyal	Naman	2
Levy	Omer	2
Stoyanov	Veselin	2
Zettlemoyer	Luke	2

Παράρτημα

Πηγαίος Κώδικας:

#κώδικας 1

```
# Λήψη του προεκπαιδευμένου γλωσσικού μοντέλου
!python -m spacy download en_core_web_sm

import pandas as pd
import spacy
from collections import Counter
import matplotlib.pyplot as plt

print("Φόρτωση δεδομένων από το αρχείο...")
# Φόρτωση του dataset με διαχωριστικό στηλοθέτη (Tab)
df = pd.read_csv("bbc-news-data.csv", sep='\t')
print(f"Διαβάστηκαν {len(df)} άρθρα.")

# Εξαγωγή της στήλης περιεχομένου
text_data = df['content'].dropna().astype(str).tolist()

print("Φόρτωση μοντέλου spaCy...")
# Απενεργοποίηση περιττών στοιχείων του pipeline για βελτιστοποίηση
απόδοσης
nlp = spacy.load("en_core_web_sm", disable=["parser", "lemmatizer",
"tok2vec"])

persons, orgs, gpes = [], [], []

print("Εκτέλεση Αναγνώρισης Ονοματισμένων Οντοτήτων (NER)...")
# Επεξεργασία των κειμένων σε παρτίδες (batch processing)
for doc in nlp.pipe(text_data, batch_size=50):
    for ent in doc.ents:
        # Καθαρισμός κειμένου από αλλαγές γραμμής και κενά
        clean_text = ent.text.strip().replace('\n', ' ')

        # Φιλτράρισμα θορύβου (οντότητες με μήκος > 2 χαρακτήρες)
        if len(clean_text) > 2:
            if ent.label_ == "PERSON":
                persons.append(clean_text)
            elif ent.label_ == "ORG":
                orgs.append(clean_text)
            elif ent.label_ == "GPE":
                gpes.append(clean_text)

# Εύρεση των 10 συχνότερων οντοτήτων ανά κλάση
top_persons = Counter(persons).most_common(10)
top_orgs = Counter(orgs).most_common(10)
top_gpes = Counter(gpes).most_common(10)

print("\nΔημιουργία Γραφημάτων...")

# Συνάρτηση παραγωγής ραβδογραμμάτων
def plot_top_entities(data, title, color):
    labels, values = zip(*data)
    plt.figure(figsize=(10, 6))
```

```

plt.bar(labels, values, color=color, edgecolor='black')
plt.title(title, fontsize=14, fontweight='bold')
plt.xlabel("Οντότητες", fontsize=12)
plt.ylabel("Συχνότητα Εμφάνισης", fontsize=12)
plt.xticks(rotation=45, ha='right')
plt.tight_layout()
plt.show()

# Οπτικοποίηση των αποτελεσμάτων
plot_top_entities(top_persons, "Top 10 Πρόσωπα (PERSON) στο BBC News",
'skyblue')
plot_top_entities(top_orgs, "Top 10 Οργανισμοί (ORG) στο BBC News",
'lightgreen')
plot_top_entities(top_gpes, "Top 10 Τοποθεσίες (GPE) στο BBC News",
'salmon')

#κώδικας 2

import nltk
from nltk.sentiment.vader import SentimentIntensityAnalyzer
import matplotlib.pyplot as plt
import seaborn as sns

# Λήψη του απαραίτητου λεξικού για τον αλγόριθμο VADER
nltk.download('vader_lexicon')

# Αρχικοποίηση του αναλυτή συναισθήματος
sia = SentimentIntensityAnalyzer()

# Συνάρτηση ταξινόμησης πολικότητας βάσει του δείκτη Compound
def get_sentiment_label(text):
    scores = sia.polarity_scores(str(text))
    compound = scores['compound']

    # Εφαρμογή καθιερωμένων κατωφλίων βιβλιογραφίας
    if compound >= 0.05:
        return 'Positive'
    elif compound <= -0.05:
        return 'Negative'
    else:
        return 'Neutral'

# Υπολογισμός πολικότητας και εξαγωγή σκορ για το σύνολο του dataset
df['sentiment'] = df['content'].apply(get_sentiment_label)
df['compound_score'] = df['content'].apply(lambda x:
sia.polarity_scores(str(x))['compound'])

# Παραγωγή κυκλικού διαγράμματος για τη συνολική κατανομή
plt.figure(figsize=(8, 6))
sentiment_counts = df['sentiment'].value_counts()
plt.pie(sentiment_counts, labels=sentiment_counts.index,
autopct='%1.1f%%',
        colors=['#2ecc71', '#e74c3c', '#95a5a6'], startangle=140,
        explode=(0.05, 0.05, 0.05))
plt.title('Συνολική Κατανομή Συναισθήματος στο BBC News Dataset')
plt.show()

# Παραγωγή ραβδογράμματος για την κατανομή ανά θεματική κατηγορία

```

```
plt.figure(figsize=(10, 6))
sns.countplot(x='category', hue='sentiment', data=df,
              palette={'Positive': '#2ecc71', 'Negative': '#e74c3c',
                       'Neutral': '#95a5a6'})
plt.title('Κατανομή Συναισθήματος ανά Θεματική Κατηγορία (VADER)')
plt.xlabel('Θεματική Κατηγορία')
plt.ylabel('Αριθμός Άρθρων')
plt.legend(title='Συναίσθημα')
plt.show()
```

#κώδικας 3

Εγκατάσταση απαιτούμενων βιβλιοθηκών βαθιάς μάθησης

```
!pip install transformers torch
```

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from transformers import pipeline
import torch
```

Επαναφόρτωση του συνόλου δεδομένων

```
df = pd.read_csv("bbc-news-data.csv", sep='\t')
```

Έλεγχος διαθεσιμότητας GPU για επιτάχυνση υλικού

```
device = 0 if torch.cuda.is_available() else -1
```

Αρχικοποίηση του μοντέλου RoBERTa μέσω της διεπαφής pipeline

```
roberta_pipeline = pipeline(
    "sentiment-analysis",
    model="cardiffnlp/twitter-roberta-base-sentiment-latest",
    device=device,
    truncation=True,          # Δυναμική περικοπή κειμένου
    max_length=512           # Μέγιστο όριο tokens
)
```

Συνάρτηση εξαγωγής συναισθηματικής πολικότητας

```
def get_roberta_sentiment(text):
```

```
    try:
```

Περιορισμός χαρακτήρων πριν το tokenization για αποφυγή υπερχειρίσης μνήμης

```
        short_text = str(text)[:2000]
```

```
        result = roberta_pipeline(short_text)
```

Κανονικοποίηση της παραγόμενης ετικέτας

```
        label = result[0]['label'].capitalize()
```

```
        return label
```

```
    except Exception as e:
```

Εναλλακτική λύση (fallback) σε περίπτωση σφάλματος

```
        return 'Neutral'
```

Εφαρμογή του μοντέλου στο σύνολο των δεδομένων

```
df['roberta_sentiment'] = df['content'].apply(get_roberta_sentiment)
```

Παραγωγή κυκλικού διαγράμματος για τη συνολική κατανομή

```
plt.figure(figsize=(8, 6))
```

```
roberta_counts = df['roberta_sentiment'].value_counts()
```



```

# Σταθερή αντιστοίχιση χρωμάτων ανά κλάση για οπτική συνέπεια
color_map = {'Positive': '#2ecc71', 'Negative': '#e74c3c', 'Neutral': '#95a5a6'}

# Δυναμική δημιουργία λίστας χρωμάτων βάσει της τρέχουσας κατανομής
pie_colors = [color_map[label] for label in roberta_counts.index]

plt.pie(roberta_counts, labels=roberta_counts.index,
        autopct='%1.1f%%',
        colors=pie_colors, startangle=140, explode=[0.05] *
        len(roberta_counts))
plt.title('Συνολική Κατανομή Συναισθήματος στο BBC News Dataset
        (RoBERTa)')
plt.show()

# Παραγωγή ραβδογράμματος για την κατανομή ανά θεματική κατηγορία
plt.figure(figsize=(10, 6))
sns.countplot(x='category', hue='roberta_sentiment', data=df,
              palette=color_map)
plt.title('Κατανομή Συναισθήματος ανά Θεματική Κατηγορία (RoBERTa)')
plt.xlabel('Θεματική Κατηγορία')
plt.ylabel('Αριθμός Άρθρων')
plt.legend(title='Συναίσθημα')
plt.show()

#κώδικας 4

# Εγκατάσταση απαραίτητων βιβλιοθηκών
!pip install transformers torch rouge-score pandas matplotlib seaborn

import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from transformers import pipeline, AutoTokenizer,
AutoModelForSeq2SeqLM
import torch
from rouge_score import rouge_scorer
import time

# Φόρτωση συνόλου δεδομένων
try:
    df = pd.read_csv("bbc-news-data.csv", sep='\t')
except Exception as e:
    print(f"Σφάλμα κατά την ανάγνωση του αρχείου: {e}")

# Αναγνώριση συσκευής εκτέλεσης (χρήση GPU εφόσον είναι διαθέσιμη)
device_id = 0 if torch.cuda.is_available() else -1
device_str = "cuda" if torch.cuda.is_available() else "cpu"

# 1: Ανάλυση Συναισθήματος (RoBERTa)

# Αρχικοποίηση μοντέλου RoBERTa
roberta_pipeline = pipeline(
    "sentiment-analysis",
    model="cardiffnlp/twitter-roberta-base-sentiment-latest",
    device=device_id,
    truncation=True,
    max_length=512

```

```

)

# Συνάρτηση εξαγωγής συναισθηματικής πολικότητας
def get_roberta_sentiment(text):
    try:
        # Δυναμική περικοπή κειμένου για αποτροπή σφαλμάτων μνήμης
        short_text = str(text)[:2000]
        result = roberta_pipeline(short_text)
        label = result[0]['label'].capitalize()
        return label
    except Exception as e:
        return 'Neutral'

# Εκτέλεση ανάλυσης συναισθήματος
start_roberta = time.time()
df['roberta_sentiment'] = df['content'].apply(get_roberta_sentiment)
end_roberta = time.time()

# Οπτικοποίηση κατανομής συναισθήματος (RoBERTa)
plt.figure(figsize=(8, 6))
roberta_counts = df['roberta_sentiment'].value_counts()
color_map = {'Positive': '#2ecc71', 'Negative': '#e74c3c', 'Neutral': '#95a5a6'}
pie_colors = [color_map.get(label, '#34495e') for label in roberta_counts.index]

plt.pie(roberta_counts, labels=roberta_counts.index,
        autopct='%1.1f%%',
        colors=pie_colors, startangle=140, explode=[0.05] * len(roberta_counts))
plt.title('Συνολική Κατανομή Συναισθήματος (RoBERTa)')
plt.show()

plt.figure(figsize=(10, 6))
sns.countplot(x='category', hue='roberta_sentiment', data=df,
              palette=color_map)
plt.title('Κατανομή Συναισθήματος ανά Θεματική Κατηγορία (RoBERTa)')
plt.xlabel('Θεματική Κατηγορία')
plt.ylabel('Αριθμός Άρθρων')
plt.legend(title='Συναίσθημα')
plt.show()

# 2: Παραγωγή Περίληψης (BART)

# Εκκαθάριση προσωρινής μνήμης GPU πριν τη φόρτωση νέου μοντέλου
if torch.cuda.is_available():
    torch.cuda.empty_cache()

# Αρχικοποίηση Tokenizer και μοντέλου BART
model_name = "facebook/bart-large-cnn"
tokenizer = AutoTokenizer.from_pretrained(model_name)
model = AutoModelForSeq2SeqLM.from_pretrained(model_name).to(device_str)

# Συνάρτηση παραγωγής αφαιρετικής περίληψης
def generate_summary(text):
    try:
        # Μετατροπή κειμένου σε tokens με δυναμική περικοπή

```

```

inputs = tokenizer(str(text), return_tensors="pt",
max_length=1024, truncation=True).to(device_str)

# Παραγωγή σύνοψης μέσω αλγορίθμου Beam Search
summary_ids = model.generate(
    inputs["input_ids"],
    max_length=130,
    min_length=30,
    length_penalty=2.0,
    num_beams=4,
    early_stopping=True
)

# Αποκωδικοποίηση των παραγόμενων tokens σε φυσική γλώσσα
summary = tokenizer.decode(summary_ids[0],
skip_special_tokens=True)
return summary
except Exception as e:
    return "Σφάλμα κατά την παραγωγή περίληψης."

# Εκτέλεση παραγωγής περιλήψεων
start_bart = time.time()
df['bart_summary'] = df['content'].apply(generate_summary)
end_bart = time.time()

# 3: Υπολογισμός ROUGE και αποθήκευση

# Αρχικοποίηση υπολογιστή ROUGE scores
scorer = rouge_scorer.RougeScorer(['rouge1', 'rouge2', 'rougeL'],
use_stemmer=True)

# Συνάρτηση αξιολόγησης βάσει της μεθόδου "Lead Baseline"
def calculate_rouge(row):
    # Εξαγωγή των πρώτων τριών προτάσεων ως κείμενο αναφοράς
    original_lead = " ".join(str(row['content']).split('.')[3]) + "."
    generated = str(row['bart_summary'])

    # Υπολογισμός F-measure για ROUGE-1, ROUGE-2 και ROUGE-L
    scores = scorer.score(original_lead, generated)
    return pd.Series({
        'ROUGE-1': scores['rouge1'].fmeasure,
        'ROUGE-2': scores['rouge2'].fmeasure,
        'ROUGE-L': scores['rougeL'].fmeasure
    })

# Εφαρμογή υπολογισμού ROUGE στο dataset
rouge_scores_df = df.apply(calculate_rouge, axis=1)
df = pd.concat([df, rouge_scores_df], axis=1)

# Εξαγωγή μέσων όρων
print("- ΜΕΣΟΙ ΟΡΟΙ ROUGE -")
print(f"Average ROUGE-1: {df['ROUGE-1'].mean():.4f}")
print(f"Average ROUGE-2: {df['ROUGE-2'].mean():.4f}")
print(f"Average ROUGE-L: {df['ROUGE-L'].mean():.4f}")

# Αποθήκευση του τελικού αποτελέσματος σε μορφή CSV
output_filename = 'bbc_news_complete_analysis.csv'
df.to_csv(output_filename, index=False)

```

Πίνακας συντομεύσεων – αρτικόλεξο

Ακρωνύμιο	Πλήρης όρος
AI	Artificial Intelligence
NLP	Natural Language Processing
BBC	British Broadcasting Corporation
ROUGE	Recall-Oriented Understudy for Gisting Evaluation
NER	Named Entity Recognition
SVM	Support Vector Machines
TF-IDF	Term Frequency - Inverse Document Frequency
VADER	Valence Aware Dictionary and Sentiment Reasoner
BoW	Bag-of-Words
RNN	Recurrent Neural Networks
LSTM	Long Short-Term Memory
CNN	Convolutional Neural Networks
ABSA	Aspect-based Sentiment Analysis
BERT	Bidirectional Encoder Representations from Transformers
OOV	Out-of-Vocabulary
BPE	Byte-Pair Encoding
ATS	Automatic Text Summarization
NLG	Natural Language Generation
Seq2Seq	Sequence-to-Sequence
BART	Bidirectional and Auto-Regressive Transformers
PER	Person
ORG	Organization
LOC	Location
BIO	Begin, Inside, Outside
HMM	Hidden Markov Models
CRF	Conditional Random Fields
BiLSTM	Bidirectional Long Short-Term Memory
POS	Part of Speech
MLP	Multilayer Perceptron
TP	True Positives
FP	False Positives
FN	False Negatives
TN	True Negatives
XMLC	Extreme Multi-label Classification
NDCG	Normalized Discounted Cumulative Gain
DCG	Discounted Cumulative Gain
BLEU	Bilingual Evaluation Understudy
LCS	Longest Common Subsequence
XAI	Explainable AI
LLM	Large Language Models
GPU	Graphics Processing Unit
GPE	Geopolitical Entity

RoBERTa	Robustly Optimized BERT Pretraining Approach
NLU	Natural Language Understanding
EDA	Exploratory Data Analysis
API	Application Programming Interface
OOM	Out-Of-Memory
NLTK	Natural Language Toolkit
WSD	Word Sense Disambiguation
DDoS	Distributed Denial of Service

Πίνακας ορολογίας

Ξενόγλωσσος όρος	Ελληνικός όρος
Artificial Intelligence	Τεχνητή Νοημοσύνη
Natural Language Processing	Επεξεργασία Φυσικής Γλώσσας
British Broadcasting Corporation	Βρετανική Εταιρεία Μεταδόσεων
Newsrooms	Αίθουσες σύνταξης
Information overload	Πληροφοριακή υπερφόρτωση
Computational Journalism	Υπολογιστική Δημοσιογραφία
Rule-based (approach)	Προσεγγίσεις βασισμένες σε στατικούς κανόνες
Lexicon-based (approach)	Προσεγγίσεις βασισμένες σε προκαθορισμένα λεξικά (ή λεξικοκεντρικές)
Deep Learning	Βαθιά Μάθηση
Context	Ευρύτερα συμφραζόμενα
Dataset	Σύνολο δεδομένων
Sentiment Analysis	Εξόρυξη Συναισθήματος
Sentiment polarity	Συναισθηματική πολικότητα
Text Summarization	Αυτόματη Παραγωγή Περίληψης
Extractive (summarization)	Εξακτική (σύνοψη)
Abstractive (summarization)	Αφαιρετική (σύνοψη)
Pipeline	Ενιαία ροή εργασίας
Sentiment detection	Ανίχνευση πολικότητας/ συναισθήματος
Open-source	Ανοιχτού κώδικα
Attention mechanisms	Μηχανισμοί προσοχής
Case studies	Μελέτες περίπτωσης
Future work	Μελλοντική έρευνα/ εργασία
Computational linguistics	Υπολογιστική γλωσσολογία
Statistical models	Στατιστικά μοντέλα
Self-attention	Αυτό-προσοχή
Machine Learning	Μηχανική Μάθηση
Morphology	Μορφολογία
Stemming	Θεματική αποκοπή
Lemmatization	Λημματοποίηση
Syntax	Σύνταξη
Parsing	Συντακτική ανάλυση

Syntax Trees	Συντακτικά δέντρα
Semantics	Σημασιολογία
Word Sense Disambiguation	Αποσαφήνιση έννοιας της λέξης
Pragmatics	Πραγματολογία
Discourse Analysis	Ανάλυση λόγου
Coreference Resolution	Επίλυση συμπεραναφοράς
Named Entity Recognition	Αναγνώριση Οντοτήτων
Support Vector Machines	Μηχανές Διανυσμάτων Υποστήριξης
Symbolic NLP	Συμβολικό NLP
Pattern matching	Αναγνώριση μοτίβων
Conversational AI	Συνομιλική Τεχνητή Νοημοσύνη
Bottlenecks	Τελματώδη σημεία (ή Σημεία συμφόρησης)
Statistical NLP	Στατιστικό NLP
Corpora	Σώματα κειμένων
n-grams	n-γράμματα (ή n-grams)
Hidden Markov Models	Κρυφά Μαρκοβιανά Μοντέλα
Neural NLP	Νευρωνικό NLP
Word embeddings	Πυκνές διανυσματικές αναπαραστάσεις
Information Extraction	Εξαγωγή Πληροφοριών
Opinion Mining	Εξόρυξη Γνώμης
Data-driven decision making	Λήψη αποφάσεων βάσει δεδομένων
Sentiment lexicons	Γλωσσικοί πόροι (ή Λεξικά συναισθήματος)
Dictionary-based	Βασισμένες σε έτοιμα λεξικά
Corpus-based	Βασισμένες σε σώματα κειμένων
Classification	Ταξινόμηση
Supervised learning	Επιβλεπόμενη μάθηση
Labeled datasets	Επισημειωμένα σύνολα δεδομένων
Naive Bayes	Αφελής Ταξινομητής Bayes
Hybrid	Υβριδικές (προσεγγίσεις)
Bag-of-Words	Σάκος Λέξεων
Recurrent Neural Networks	Αναδρομικά Νευρωνικά Δίκτυα
Long Short-Term Memory	Μακράς Βραχυπρόθεσμης Μνήμης
Convolutional Neural Networks	Συνελκτικά Νευρωνικά Δίκτυα
Aspect-based Sentiment Analysis	Ανάλυση συναισθήματος βασισμένη σε Χαρακτηρηστικά
Out-of-Vocabulary	Εκτός Λεξιλογίου
Byte-Pair Encoding	Κωδικοποίηση Ζευγών Byte
Feature engineering	Μηχανική χαρακτηριστικών
Feature extraction	Εξαγωγή χαρακτηριστικών
Domain adaptation	Προσαρμογή πεδίου
Transfer learning	Μεταφορά γνώσης
Document-level	Σε επίπεδο εγγράφου
Fine-grained	Λεπτομερέστερη / Υψηλής ανάλυσης
Multimodal Sentiment Analysis	Ανάλυση πολυτροπικών δεδομένων
Encoder	Κωδικοποιητής

Decoder	Αποκωδικοποιητής
Subword Tokenization	Τεμαχισμός λέξεων (σε υπο-λέξεις)
Automatic Text Summarization	Αυτόματη Περίληψη Κειμένου
Natural Language Generation	Παραγωγή Φυσικής Γλώσσας
Sequence-to-Sequence	Ακολουθία σε Ακολουθία
Compression	Συμπύκνωση
Single-document summarization	Σύνοψη μεμονωμένου εγγράφου
Multi-document summarization	Σύνοψη πολλαπλών εγγράφων
Redundancy	Αλληλεπικάλυψη πληροφοριών
Concatenate	Συρράπτω γραμμικά
Coherence	Συνοχή
Paraphrasing	Παράφραση
Sentence Scoring	Βαθμολόγηση προτάσεων
Graph-based Methods	Μέθοδοι γράφων
Hub	Κεντρικός κόμβος
Clustering-based Methods	Μέθοδοι βασισμένες σε συστάδες
Clusters	Συστάδες
Centroid	Κέντρο βάρους
Diversity	Ποικιλομορφία
Hand-crafted features	Χειροκίνητα χαρακτηριστικά
Binary sequence classification	Δυαδική ταξινόμηση ακολουθιών
Translation problem	Πρόβλημα μετάφρασης
Context Vector	Διάνυσμα συγκεκριμένου
Autoregressive	Αυτοπαλινδρομικός
Denoising autoencoder	Απαλοιφωτής θορύβου
Person	Πρόσωπο
Organization	Οργανισμός
Location	Τοποθεσία
Begin, Inside, Outside	Αρχή, Εντός, Εκτός
Conditional Random Fields	Υπό Συνθήκη Τυχαία Πεδία
Bidirectional Long Short-Term Memory	Αμφίδρομο Μακράς Βραχυπρόθεσμης Μνήμης
Part of Speech	Μέρος του Λόγου
Rigid designators	Άκαμπτοι προσδιοριστές
Question Answering	Συστήματα Ερωταποκρίσεων
Sequence Labeling	Επισήμανση Ακολουθιών
Boundaries	Όρια
Regular expressions	Κανονικές εκφράσεις
Feature-based Supervised Learning	Επιβλεπόμενη Μάθηση βασισμένη σε χαρακτηριστικά
End-to-end	Από άκρο σε άκρο
Distributed Representations	Καταναμημένες αναπαραστάσεις
Context Encoder	Κωδικοποιητής συγκεκριμένου
Tag Decoder	Αποκωδικοποιητής ετικετών
One-hot encoding	Μονοδιάστατη κωδικοποίηση

Data sparsity	Αραιότητα δεδομένων
Dense embeddings	Πυκνά διανύσματα
Word-level Embeddings	Διανύσματα επιπέδου λέξης
Context words	Γειτονικές λέξεις / Συμφραζόμενα
Contextualized Embeddings	Συγκειμενικά διανύσματα
Context aware	Επίγνωση συγκειμένου
Static	Στατικές
Character-level Embeddings	Διανύσματα επιπέδου χαρακτήρα
Concatenation	Συνένωση
Boolean	Λογικές τιμές
Multilayer Perceptron	Πολυεπίπεδο Νευρωνικό Δίκτυο
Gold standard	Πρότυπο αναφοράς
Gating mechanism	Μηχανισμός πυλών
Vanishing gradient problem	Πρόβλημα εξάλειψης της κλίσης
Long-term dependencies	Μακροχρόνιες εξαρτήσεις
Forward	Ορθόδρομη
Backward (analysis)	Ανάδρομη
Hidden state	Κρυφή κατάσταση
Paradigm shift	Παραδειγματική μετατόπιση
Relevance score	Σκορ σχετικότητας
Query	Ερώτημα
Key	Κλειδί
Value	Τιμή
Scaling factor	Παράγοντας κανονικοποίησης
Multi-Head Attention	Προσοχή πολλαπλών κεφαλών
State-of-the-Art (SotA)	Αιχμή του δόρατος
Fully connected neural layer	Πλήρως συνδεδεμένο νευρωνικό επίπεδο
Globally optimal sequence	Συνολικά βέλτιστη ακολουθία
Emission Score	Σκορ εκπομπής
Transition Matrix	Πίνακας μεταβάσεων
Transition Scores	Σκορ μετάβασης
Precision	Ακρίβεια
Recall	Ανάκληση
True Positives	Αληθώς Θετικά
False Positives	Ψευδώς Θετικά
False Negatives	Ψευδώς Αρνητικά
True Negatives	Αληθώς Αρνητικά
Extreme Multi-label Classification	Ακραία Ταξινόμηση Πολλαπλών Ετικετών
Normalized Discounted Cumulative Gain	Κανονικοποιημένο Προεξοφλημένο Αθροιστικό Κέρδος
Discounted Cumulative Gain	Προεξοφλημένο Αθροιστικό Κέρδος
Longest Common Subsequence	Μεγαλύτερη Κοινή Υπακολουθία
Generalization ability	Γενικευτική ικανότητα
Benchmarks	Σημεία αναφοράς

Reproducible	Αναπαραγώγιμα
Domain expertise	Εξειδίκευση στο θεματικό πεδίο
Class Imbalance	Ανισορροπία κλάσεων
Accuracy	Ορθότητα
Accuracy Paradox	Παράδοξο της Ορθότητας
Confusion Matrix	Πίνακας Σύγχυσης
Type I Errors	Σφάλματα Τύπου I
Type II Errors	Σφάλματα Τύπου II
Single-label classification	Ταξινόμηση ενός επιπέδου
Error Rate	Ποσοστό Σφάλματος
Unbalanced datasets	Μη ισορροπημένα σύνολα δεδομένων
Sensitivity	Ευαισθησία
Trade-off	Αντισταθμιστική σχέση
Harmonic Mean	Αρμονικός Μέσος
Multi-label classification	Προβλήματα πολλαπλών ετικετών
Partial matches	Μερικές ταυτίσεις
Instance	Δείγμα / Περίπτωση
Support	Σχετικό πλήθος
Hard thresholding	Απόλυτη απόφαση
Ranked list	Ταξινομημένη λίστα
Rank-based Metrics	Μετρικές βασισμένες στην κατάταξη
Confidence	Βαθμός βεβαιότητας
Indicator variable	Δυαδική μεταβλητή-δείκτης
Gain	Κέρδος
Discount	Προεξόφληση
Ground truth	Απόλυτη αλήθεια
Candidate	Υποψήφιο
References	Αναφορές
Brevity Penalty	Ποινή συντομίας
Unigrams	Μεμονωμένες λέξεις / Μονογράμματα
Bigrams	Ζεύγη λέξεων / Διγράμματα
Scalability	Κλιμακωσιμότητα
Explainable AI	Επεξηγήσιμη Τεχνητή Νοημοσύνη
Large Language Models	Μεγάλα Γλωσσικά Μοντέλα
Graphics Processing Unit	Μονάδα Επεξεργασίας Γραφικών
Generative AI	Παραγωγική Τεχνητή Νοημοσύνη
Computer ethics	Υπολογιστική ηθική
Web corpora	Μη φιλτραρισμένα σύνολα δεδομένων
Data biases	Συστημικές προκαταλήψεις
Robustness	Ανθεκτικότητα
Human-in-the-loop (ή Human expertise)	Ανθρώπινη εποπτεία
Black Box models	Μοντέλα «Μαύρου Κουτιού»
Decision-making process	Διαδικασία λήψης αποφάσεων
Transparency	Διαφάνεια

Interpretability	Ερμηνευσιμότητα
Responsible AI	Υπεύθυνη Τεχνητή Νοημοσύνη
User trust	Εμπιστοσύνη του χρήστη
Bias	Μεροληψία / Προκατάληψη
Fairness	Δικαιοσύνη
Algorithmic fairness	Αλγοριθμική δικαιοσύνη
Allocational Bias	Αδικία Κατανομής
Representational Bias	Αδικία Αναπαράστασης
Feedback loop	Βρόχος ανατροφοδότησης
Corrupted	Μολυσμένα
Self-fulfilling prophecy	Αυτοεκπληρούμενη προφητεία
Bias mitigation	Μετριασμός της προκατάληψης
Hallucinations	Παραισθήσεις
Probabilistic engines	Πιθανοθεωρητικές μηχανές
Token	Λεκτικό σύμβολο
World grounding	Επαφή με τον φυσικό κόσμο
Unfaithful	Αναντίστοιχο
Intrinsic Hallucination	Εγγενής Παραίσθηση
Extrinsic Hallucination	Εξωγενής Παραίσθηση
Unverifiable additions	Μη επαληθεύσιμες προσθήκες
Real-world deployments	Εφαρμογές σε πραγματικές συνθήκες
Safety-critical domains	Τομείς υψηλής κρισιμότητας
Memorize	Απομνημονεύουν
Adversarial attacks	Κακόβουλες επιθέσεις
Dual-Use Dilemma	Πρόβλημα της Διπλής Χρήσης
Mass surveillance	Μαζική παρακολούθηση
Common sense reasoning	Κοινή λογική
Ambiguity	Αμφισημία
Out-of-distribution queries	Ερωτήματα εκτός κατανομής
Red AI	Κόκκινη Τεχνητή Νοημοσύνη
Green AI	Πράσινη Τεχνητή Νοημοσύνη
Monitoring	Παρακολούθηση
Sustainability	Υπολογιστική βιωσιμότητα
Foundation Models	Μοντέλα Θεμελίωσης
Pre-trained	Προ-εκπαιδευμένα
Unlabeled web corpora	Αδόμητα ιστικά σώματα
Self-supervised learning	Αυτο-εποπτευόμενη μάθηση
Task-specific networks	Εξειδικευμένα νευρωνικά δίκτυα
Parallelization	Παράλληλη επεξεργασία
Task unification	Ενοποίηση γλωσσικών εργασιών
Universal processors	Καθολικοί επεξεργαστές
Emergent abilities	Αναδυόμενες ικανότητες
Fine-tuning	Μικρο-ρύθμιση
In-context learning	Μάθηση εντός συγκεκριμένου

Zero-Shot Learning	Μάθηση Μηδενικής Βολής
Few-shot learning	Μάθηση ελάχιστων παραδειγμάτων
Prompt Engineering	Μηχανική Προτροπών
Weight updates	Αναπροσαρμογή στα εσωτερικά συναπτικά βάρη
Unseen	Μη θεαθείσες
Zero-shot summarization	Αυτόματη περίληψη μηδενικής βολής
Paradox of generalization	Παράδοξο της γενίκευσης
Jack of all trades	Πολυτεχνίτες
Sequence tagging	Χαρακτηρισμός ακολουθιών
Closed-set classification	Ταξινόμηση κλειστού συνόλου
Open-ended generation	Παραγωγή ανοιχτού λεξιλογίου
Geopolitical Entity	Γεωπολιτική Οντότητα
Experimental pipeline	Πειραματική ροή
Text preprocessing	Προεπεξεργασία κειμένου
Tech stack (Technology stack)	Τεχνολογική στοίβα
Scripts	Κώδικας / Σενάρια εντολών
Computational efficiency	Υπολογιστική αποδοτικότητα
Real-world unstructured data	Πραγματικά, αδόμητα δεδομένα
Testbed	Πειραματικό πεδίο δοκιμών
News corpora	Σώματα ειδησεογραφικών κειμένων
Emotional viewpoint	Συναισθηματική οπτική γωνία
Script execution	Εκτέλεση υπολογιστικού κώδικα
Comparative analysis	Συγκριτική ανάλυση
Rule-based baselines	Συστήματα αναφοράς βασισμένα σε κανόνες
Industry-standard applications	Εφαρμογές βιομηχανικών προδιαγραφών
Benchmark dataset	Σύνολο δεδομένων αναφοράς
Text corpus	Σώμα κειμένων
Topic diversity	Θεματική ποικιλομορφία
Class balance	Ισορροπία κλάσεων
Overfitting	Υπερπροσαρμογή
Semantic condensation	Νοηματική συμπίκνωση
Underlying polarity	Υποβόσκουσα συναισθηματική πολικότητα
Raw data	Ακατέργαστα δεδομένα
Preprocessing pipeline	Ροή προεπεξεργασίας
Data cleansing	Καθαρισμός δεδομένων
Dimensionality reduction	Μείωση διαστατικότητας
Text Normalization	Κανονικοποίηση κειμένου
Lowercasing	Μετατροπή σε πεζή γραφή
Tokens	Λεκτικές μονάδες
Keywords	Λέξεις-κλειδιά
System architecture	Συνολική αρχιτεκτονική συστήματος
Task-specific suitability	Καταλληλότητα για συγκεκριμένη εργασία
Silver bullet	Πανάκεια / Απόλυτη λύση
Comparative Benchmarking	Συγκριτική αξιολόγηση

Computational Feasibility	Υπολογιστική εφικτότητα
Processing pipeline	Αλυσίδα επεξεργασίας
Production-grade environments	Περιβάλλοντα παραγωγής
Execution speed	Ταχύτητα εκτέλεσης
Context window	Παράθυρο συγκειμένου
Structured knowledge	Δομημένη γνώση
Color-coded tagging	Χρωματική κωδικοποίηση
Semantic segmentation	Σημασιολογική τμηματοποίηση
Lightweight computational baseline	Ελαφρύ υπολογιστικό θεμέλιο
Quantitative analysis	Ποσοτική ανάλυση
System resources	Πόροι του συστήματος
Resource-efficient	Υπολογιστικά αποδοτικά
Baseline model	Μοντέλο αναφοράς
Zero-shot inference	Συμπερασμός μηδενικής βολής
Contextual dependencies	Συγκειμενικές εξαρτήσεις
Deep semantic analysis	Εις βάθος σημασιολογική ανάλυση
Dynamic masking	Δυναμική απόκρυψη
Robust representations	Εύρωστες αναπαραστάσεις
Bidirectionally	Αμφίδρομα
Technological leap quantification	Ποσοτικοποίηση του τεχνολογικού άλματος
Natural Language Understanding	Κατανόηση Φυσικής Γλώσσας
Information density	Πληροφοριακή πυκνότητα
Human cognitive ability	Ανθρώπινη γνωστική ικανότητα
Neural topology	Νευρωνική τοπολογία
Bidirectional context	Αμφίπλευρα συμφραζόμενα
Token-by-token	Λεκτική μονάδα προς λεκτική μονάδα
Empirical validation	Εμπειρική επικύρωση
Heuristic observations	Ευρετικές παρατηρήσεις
Standardized metrics	Τυποποιημένες μετρικές
Multidimensional evaluation strategy	Πολυδιάστατη στρατηγική αξιολόγησης
Computational heterogeneity	Υπολογιστική ετερογένεια
Statistical classification	Στατιστική ταξινόμηση
Generative synthesis	Παραγωγική σύνθεση
Bipartite methodology	Μεθοδολογική διχοτόμηση
Mathematical benchmarks	Μαθηματικά πρότυπα
Scientific validity	Επιστημονική εγκυρότητα
Majority class bias	Μεροληψία υπέρ της πλειοψηφικής κλάσης
Completeness	Πληρότητα
Precision-Recall trade-off	Αντιστάθμισμα Ακρίβειας-Ανάκλησης
Generalization capability	Ικανότητα γενίκευσης
Stochastic nature	Στοχαστική φύση
Lexical overlap	Λεξιλογική αλληλεπικάλυψη
Reference summary	Περίληψη αναφοράς

Local syntactic structures	Τοπικές συντακτικές δομές
Sentence-level structure	Δομή επιπέδου πρότασης
Strict consecutive matching	Αυστηρά διαδοχική ταύτιση
Natural fluency	Φυσική ροή
Readability	Αναγνωσιμότητα
Quantitative transparency	Ποσοτική διαφάνεια
Exploratory Data Analysis	Εξερευνητική Ανάλυση Δεδομένων
Application Programming Interface	Διεπαφή Προγραμματισμού Εφαρμογών
Out-Of-Memory	Εξάντληση μνήμης / Υπερχείλιση μνήμης
Applied experimental setup	Εφαρμοσμένη πειραματική διάταξη
Incremental computational complexity	Σταδιακή κλιμάκωση της υπολογιστικής πολυπλοκότητας
End-to-end processing pipeline	Ενοποιημένη ροή επεξεργασίας
Computational reproducibility	Υπολογιστική αναπαραγωγιμότητα
Research axes	Ερευνητικοί άξονες
Quantitative evaluation	Ποσοτική αξιολόγηση
Data visualizations	Οπτικοποιήσεις δεδομένων
Qualitative case studies	Ποιοτικές αναλύσεις περίπτωσης
Semantic understanding	Σημασιολογική κατανόηση
Critical discussion	Κριτική συζήτηση
State-of-the-art literature	Σύγχρονη βιβλιογραφία
Large-scale nature	Μεγάλη κλίμακα
Enterprise-grade infrastructure	Υποδομές βιομηχανικού επιπέδου
Sequential scripting	Σειριακή εκτέλεση εντολών
Data ingestion	Εισαγωγή δεδομένων
Semantic feature extraction	Βαθιά σημασιολογική εξαγωγή χαρακτηριστικών
Hardware resources	Υπολογιστικοί πόροι
Glue language	Συνδετική γλώσσα
Open-source frameworks	Πλαίσια ανοιχτού κώδικα
Trainable parameters	Εκπαιδεύσιμες παράμετροι
Hardware acceleration	Επιτάχυνση υλικού
Tensor computations	Λειτουργίες τανυστών
Matrix multiplications	Πολλαπλασιασμοί μητρώων
Inference time	Χρόνος συμπερασμού
Computational bottleneck	Υπολογιστική συμφόρηση
Workload offloading	Μετατόπιση υπολογιστικού φόρτου
Cloud computing	Υπολογιστικό νέφος
Hardware accelerators	Επιταχυντές υλικού
Massive parallelization	Μαζικός παραλληλισμός
Execution time compression	Συμπίεση χρόνου εκτέλεσης
Local hardware	Τοπικός εξοπλισμός
Backend infrastructure	Υποδομή υποστήριξης
Syntactic flexibility	Συντακτική ευελιξία
Dynamic typing	Δυναμική τυποποίηση

De facto standard	Καθιερωμένο πρότυπο
Competitive advantage	Συγκριτικό πλεονέκτημα
Open-source ecosystem	Οικοσύστημα ανοιχτού κώδικα
Interoperability	Διαλειτουργικότητα
Rapid prototyping	Ταχεία ανάπτυξη πρωτοτύπων
Seamless integration	Απρόσκοπτη ενοποίηση
In-memory data structures	Δομές δεδομένων στην κύρια μνήμη
Tabular representation	Πινακοποιημένη αναπαράσταση
Data wrangling	Διαχείριση δεδομένων
Deduplication	Απαλοιφή διπλότυπων εγγραφών
Missing values handling	Ανίχνευση και διαχείριση ελλειπών τιμών
Normalization pipeline	Ροή κανονικοποίησης
Relational schemas	Σχεσιακά σχήματα
Input tensor dimensions	Προδιαγραφές διαστάσεων τανυστών εισόδου
Deep semantic features	Βαθιά σημασιολογικά χαρακτηριστικά
Applied engineering	Εφαρμοσμένη μηχανική
Pre-trained language models	Προεκπαιδευμένα γλωσσικά μοντέλα
Abstraction of low-level boilerplate code	Αφαίρεση πολυπλοκότητας χαμηλού επιπέδου
Tensors	Τανυστές
2D plotting	Παραγωγή δισδιάστατων γραφικών
Configurability	Παραμετροποιησιμότητα
Bar charts	Ραβδογράμματα
Pie charts	Κυκλικά διαγράμματα
Visual translation	Οπτική μετάφραση
Interpretable knowledge	Ερμηνεύσιμη γνώση
Unstructured textual data	Αδόμητα κειμενικά δεδομένα
Semantic distillation	Σημασιολογική απόσταξη
Categorical data	Κατηγορική πληροφορία
Roadmap	Οδικός χάρτης
Critical evaluation	Κριτική αποτίμηση
Inherent limitations	Εγγενείς περιορισμοί
Lightweight NLP models	Ελαφρά γλωσσικά μοντέλα
Real-world scenarios	Σενάρια πραγματικού κόσμου
Information extraction engine	Μηχανισμός εξόρυξης πληροφορίας
Accuracy-speed trade-off	Ισορροπία ακρίβειας και ταχύτητας
Batch text processing	Μαζική σάρωση κειμένου
Memory footprint	Ίχνος μνήμης
Dependency parser	Συντακτικός αναλυτής εξαρτήσεων
Lemmatizer	Αλγόριθμος λημματοποίησης
Pipeline pruning	Πρακτική ελάφρυνσης ροής
Document-by-document	Έγγραφο προς έγγραφο
Memory buffering	Διαχείριση προσωρινής μνήμης
Main iteration loop	Κεντρικός βρόχος επανάληψης
Text sanitization & normalization	Κανονικοποίηση και εξυγίανση δεδομένων

Heuristic rule	Ευρετικός κανόνας
Safeguard	Δικλείδα ασφαλείας
Noise	Στατιστικός θόρυβος
Hash maps	Πίνακες κατακερματισμού
Absolute frequency	Απόλυτη συχνότητα εμφάνισης
Long tail distribution	Κατανομή «μακριάς ουράς»
Cutoff filter	Φίλτρο αποκοπής
Data summarization	Συμπύκνωση πληροφορίας
Key actors	Κεντρικοί δρώντες
News cycle	Ειδησεογραφικός κύκλος
Multitopic nature	Πολυθεματική φύση
Spatial mapping	Χωρική αποτύπωση
Mass media coverage	Κάλυψη μέσω μαζικής ενημέρωσης
Spatial bias	Γεωγραφική πόλωση
Micro-level analysis	Μικροσκοπική ανάλυση
Classification anomalies	Ταξινομικές αστοχίες
Logic error	Σφάλμα λογικής
Semantic ambiguity	Σημασιολογική αμφισημία
Abstract	Αφηρημένο
Emotional polarity	Συναισθηματική πολικότητα
Objective reporting	Αντικειμενική αναφορά
Attitude	Υποκείμενη στάση
Unsupervised	Μη επιβλεπόμενη
Qualitative evaluation	Ποιοτική αποτίμηση
Structural alignment	Δομική διευθέτηση
Parsing errors	Αστοχίες ανάλυσης
Escape characters	Χαρακτήρες διαφυγής
Data dropping	Απόρριψη εγγραφών
Valence	Ένταση συναισθηματικού φορτίου
Degree modifiers	Προσδιορισμοί βαθμού
Compound score	Σύνθετο σκορ
Standard thresholds	Καθιερωμένα κατώφλια
Sentiment label	Ετικέτα πολικότητας
Part-to-whole relationship	Αναλογίες επί ενός συνόλου
Statistical asymmetry	Στατιστική ασυμμετρία
Cumulative summation	Αθροιστική συσσώρευση
Normalization function	Συνάρτηση κανονικοποίησης
Long-form texts	Εκτενή έγγραφα
Granular analysis	Λεπτομερέστερη ανάλυση
Data stratification	Διαστρωμάτωση δεδομένων
Grouped bar chart	Ομαδοποιημένο ραβδόγραμμα
Anomaly	Ανωμαλία
Agglomeratively	Αθροιστικά
Context-awareness	Επίγνωση/Κατανόηση του συγκεκριμένου

General-purpose lexicon	Λεξικό γενικού σκοπού
Error analysis	Ανάλυση σφαλμάτων
Micro-texts	Μικρο-κειμενικά δεδομένα
Explicit sentiment	Άμεση έκφραση συναισθήματος
Objective reporter	Αντικειμενικός παρατηρητής
Rule-based aggregation	Αθροιστικός κανόνας
Subjectivity	Υποκειμενικότητα
Misclassifications	Εσφαλμένες ταξινομήσεις
Rhetorical concession	Ρητορική παραχώρηση
Keyword spotting	Επιφανειακή αναζήτηση λέξεων-κλειδιών
Linguistic ambiguity	Γλωσσική αμφισημία
Inference	Εξαγωγή συμπερασμάτων
Common baseline	Κοινό πλαίσιο αναφοράς
Input sequence length limit	Μέγιστο όριο μήκους της ακολουθίας εισόδου
Dynamic truncation	Δυναμική περικοπή
Inverted Pyramid	Ανεστραμμένη Πυραμίδα
Lead paragraphs	Εισαγωγικές παράγραφοι
Exception handling	Μηχανισμός χειρισμού εξαιρέσεων
Fallback	Μηχανισμός ασφαλείας
Adversarial nature	Αντιπαραθετική φύση
Informative texts	Πληροφοριακά κείμενα
Classifier	Ταξινομητής
Superior semantic comprehension	Ανώτερη σημασιολογική αντιληπτικότητα
Statistical discrepancy	Στατιστική ασυμφωνία
Holistically	Ολιστικά
Pattern matcher	Ντετερμινιστικός ανιχνευτής μοτίβων
Semantic abstraction	Σημασιολογική αφαίρεση
Attention layers	Επίπεδα προσοχής
Semantic core	Σημασιολογικός πυρήνας
Filtering mechanism	Μηχανισμός φιλτραρίσματος
Training from scratch	Εκπαίδευση από το μηδέν
Sequence length	Μήκος ακολουθίας
Greedy decoding	Άπληστη αποκωδικοποίηση
Beam Search	Αναζήτηση ακτίνας
Length penalty	Ποινή μήκους
Lead Baseline	Βασικός Κανόνας της Εισαγωγής
Semantic coherence	Νοηματική συνοχή
Distributed Denial of Service	Κατανεμημένη Επίθεση Άρνησης Εξυπηρέτησης
Statistical validity	Στατιστική εγκυρότητα
Syntactic naturalness	Συντακτική φυσικότητα
Thematic heterogeneity	Θεματική ετερογένεια
Adaptability	Προσαρμοστικότητα
Generated summary	Παραγόμενη σύνοψη
Spam	Ανεπιθύμητη ηλεκτρονική αλληλογραφία

Critical interpretation of results	Κριτική ερμηνεία των αποτελεσμάτων
Neural networks	Νευρωνικά δίκτυα
Research awareness	Ερευνητική συνείδηση
Inherent flaw	Δομικό ελάττωμα
Analytical maturity	Αναλυτική ωριμότητα
Workflow	Ροή εργασίας
Cognitive perception	Γνωστική αντίληψη
World knowledge	Παγκόσμια γνώση
Language bias	Γλωσσική μεροληψία
Multilingual variants	Πολύγλωσσες παραλλαγές
Production environment	Συνθήκες πραγματικής παραγωγής
Web Application	Εφαρμογή Ιστού
Real-time	Πραγματικός χρόνος
Boolean search strings	Λογικές συμβολοσειρές αναζήτησης
Inclusion and exclusion criteria	Κριτήρια ένταξης και αποκλεισμού
Original works	Πρωτότυπα έργα
Quality assessment	Ποιοτική αξιολόγηση
Pre-prints	Προδημοσιεύσεις
Seminal papers	Θεμελιώδη έργα
Surveys	Κριτικές ανασκοπήσεις
Open-access	Ανοιχτής πρόσβασης
Conference proceedings	Πρακτικά συνεδρίων

Βιβλιογραφία

- [1] J. Matthes, K. Karsay, D. Schmuck και A. Stevic, «Too much to handle: Impact of mobile social networking sites on information overload,» *Computers in Human Behavior*, τόμ. 105, p. 106217, 2020.
- [2] R. E. & S. S. J. Moran, «Robots in the news and newsrooms: Unpacking meta-journalistic discourse on the use of artificial intelligence in journalism,» *Digital Journalism*, τόμ. 10, αρ. 10, pp. 1756-1774, 2022.
- [3] B. Min, H. Ross, E. Sulem, A. P. B. Veyseh, T. H. Nguyen, O. Sainz, E. Agirre, I. Heintz και D. Roth, «Recent advances in natural language processing via large pre-trained language models: A survey,» *ACM Computing Surveys*, τόμ. 56, αρ. 2, pp. 1-40, 2023.
- [4] D. Khurana, A. Koli, K. Khatter και S. Singh, «Natural language processing: state of the art, current trends and challenges,» *Multimedia Tools and Applications*, pp. 3713-3744, 2023.
- [5] D. Jurafsky και J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*, Stanford University (Draft), 2024.
- [6] M. Bevilacqua, T. Pasini, A. Raganato και R. Navigli, «Recent trends in word sense disambiguation: A survey,» σε *IJCAI*, 2021.
- [7] R. Liu, R. Mao, A. T. Luu και E. Cambria, «A brief survey on recent advances in coreference resolution,» *Artificial Intelligence Review*, τόμ. 56, αρ. 12, pp. 14439-14481, 2023.
- [8] D. W. Otter, J. R. Medina και J. K. Kalita, «A Survey of the Usages of Deep Learning for Natural Language Processing,» *IEEE Transactions on Neural Networks and Learning Systems*, τόμ. 32, αρ. 2, pp. 604-624, 2021.
- [9] T. Adewumi, F. Liwicki και M. Liwicki, «State-of-the-art in Open-domain Conversational AI: A Survey,» *Information*, τόμ. 13, αρ. 6, p. 298, 2022.
- [10] U. Naseem, I. Razzak, S. K. Khan και M. Prasad, «A comprehensive survey on word representation models: From classical to state-of-the-art word representation language models,» *ACM Transactions on Asian and Low-Resource Language Information Processing*, τόμ. 20, αρ. 5, pp. 1-35, 2021.
- [11] M. Wankhade, A. C. S. Rao και C. Kulkarni, «A survey on sentiment analysis methods, applications, and challenges,» *Artificial Intelligence Review*, τόμ. 55, αρ. 7, pp. 5731-5780, 2022.
- [12] P. Nandwani και R. Verma, «A review on sentiment analysis and emotion detection from text,» *Social Network Analysis and Mining*, τόμ. 11, αρ. 1, p. 81, 2021.
- [13] M. Nkongolo Wa Nkongolo, «News classification and categorization with smart function sentiment

- analysis,» *International Journal of Intelligent Systems*, τόμ. 1, p. p1784394, 2023.
- [14] M. A. Jassim, D. H. Abd και M. N. Omri, «A survey of sentiment analysis from film critics based on machine learning, lexicon and hybridization,» *Neural Computing and Applications*, τόμ. 35, αρ. 13, pp. 9437-9461, 2023.
- [15] M. Birjali, M. Kasri και A. Beni-Hssane, «A comprehensive survey on sentiment analysis: Approaches, challenges and trends,» *Knowledge-Based Systems*, p. 107134, 2021.
- [16] W. Van Atteveldt, M. A. Van der Velden και M. Boukes, «The Validity of Sentiment Analysis: Comparing Manual Annotation, Crowd-Coding, Dictionary Approaches, and Machine Learning Algorithms,» *Communication Methods and Measures*, τόμ. 15, αρ. 2, pp. 121-140, 2021.
- [17] C. Dervenis, G. Kanakis και P. Fitsilis, «Sentiment analysis of student feedback: A comparative study employing lexicon and machine learning techniques,» *Studies in Educational Evaluation*, τόμ. 83, p. 101406, 2024.
- [18] R. K. Singh, A. Saini και E. Cambria, «Transfer Learning for Cross-Domain Sentiment Classification via Domain Adaptation,» *IEEE Transactions on Computational Social Systems*, 2025.
- [19] S. Minaee, N. Kalchbrenner, E. Cambria, N. Nikzad, M. Chenaghlu και J. Gao, «Deep Learning-Based Text Classification,» *ACM Computing Surveys*, τόμ. 54, αρ. 3, pp. 1-40, 2021.
- [20] T. Diwan και J. V. Tembhurne, «Sentiment analysis: a convolutional neural networks perspective,» *Multimedia Tools and Applications*, τόμ. 81, αρ. 30, pp. 44405-44429, 2022.
- [21] A. Yadav και D. K. Vishwakarma, «Sentiment analysis using deep learning architectures: a review,» *Artificial Intelligence Review*, τόμ. 53, αρ. 6, pp. 4335-4385, 2020.
- [22] G. S. Chauhan, R. Nahta και Y. K. Meena, «Aspect based sentiment analysis using deep learning approaches: A survey,» *Computer Science Review*, τόμ. 49, p. 100576, 2023.
- [23] R. Das και T. D. Singh, «Multimodal sentiment analysis: a survey of methods, trends, and challenges,» *ACM Computing Surveys*, τόμ. 55, αρ. 13s, pp. 1-38, 2023.
- [24] S. Tabinda Kokab, S. Asghar και S. Naz, «Transformer-based deep learning models for the sentiment analysis of social media data,» *Array*, p. 100157, 2022.
- [25] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser και I. Polosukhin, «Attention is all you need,» *Advances in Neural Information Processing Systems*, 2017.
- [26] J. Devlin, M.-W. Chang, K. Lee και K. Toutanova, «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,» *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*, 2019.
- [27] M. S. Sayeed, V. Mohan και K. S. Muthu, «BERT: A Review of Applications in Sentiment Analysis,» *HighTech and Innovation Journal*, τόμ. 4, αρ. 2, pp. 453 - 462, 2023.

- [28] S. J. Mielke, Z. Alyafeai, E. Salesky, C. Raffel, M. Dey, M. Gallé, A. Raja, C. Si, W. Y. Lee, B. Sagot και S. Tan, «Between words and characters: A brief history of open-vocabulary modeling and tokenization in NLP,» *arXiv preprint*, 2021.
- [29] M. Pota, M. Ventura, R. Catelli και M. Esposito, «An effective BERT-based pipeline for Twitter sentiment analysis: A case study in Italian,» *Sensors*, τόμ. 21, αρ. 1, p. 133, 2020.
- [30] W. S. El-Kassas, C. R. Salama, A. A. Rafea και H. K. Mohamed, «Automatic text summarization: A comprehensive survey,» *Expert Systems with Applications*, p. 113679, 2021.
- [31] B. Khan, Z. A. Shah, M. Usman, I. Khan και B. Niazi, «Exploring the Landscape of Automatic Text Summarization: A Comprehensive Survey,» *IEEE Access*, pp. 109819-109840, 2023.
- [32] A. K. Yadav, Ranvijay, R. S. Yadav και A. K. Maurya, «State-of-the-art approach to extractive text summarization: a comprehensive review,» *Multimedia Tools and Applications*, τόμ. 82, αρ. 19, p. 29135–29197, 2023.
- [33] R. Mihalcea και P. Tarau, «TextRank: Bringing order into text,» σε *Proceedings of the 2004 conference on empirical methods in natural language processing (EMNLP)*, 2004.
- [34] A. M. Rush, S. Chopra και J. Weston, «A Neural Attention Model for Abstractive Sentence Summarization,» σε *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2015.
- [35] M. Lewis, Y. Liu, N. Goyal, M. Ghazvininejad, A. Mohamed, O. Levy, V. Stoyanov και L. Zettlemoyer, «BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension,» σε *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020.
- [36] J. Li, A. Sun, J. Han και C. Li, «A Survey on Deep Learning for Named Entity Recognition,» *IEEE Transactions on Knowledge and Data Engineering*, p. 50–70, 2022.
- [37] T. Mikolov, I. Sutskever, K. Chen, G. S. Corrado και J. Dean, «Distributed representations of words and phrases and their compositionality,» σε *Advances in Neural Information Processing Systems (NeurIPS)*, 2013.
- [38] X. Ma και E. Hovy, «End-to-end Sequence Labeling via Bi-directional LSTM-CNNs-CRF,» σε *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2016.
- [39] S. Hochreiter και J. Schmidhuber, «Long short-term memory,» *Neural Computation*, pp. 1735-1780, 1997.
- [40] J. Lafferty, A. McCallum και F. C. Pereira, «Conditional random fields: Probabilistic models for segmenting and labeling sequence data,» σε *Proceedings of the 18th International Conference on Machine Learning (ICML)*, 2001.

- [41] G. Lample, M. Ballesteros, S. Subramanian, K. Kawakami και C. Dyer, «Neural architectures for named entity recognition,» σε *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*, 2016.
- [42] Q. Li, H. Peng, J. Li, C. Xia, R. Yang, L. Sun, P. S. Yu και L. He, «A Survey on Text Classification: From Traditional to Deep Learning,» *ACM Transactions on Intelligent Systems and Technology (TIST)*, pp. 13(2), Article 31, 2022.
- [43] M. Sokolova και G. Lapalme, «A systematic analysis of performance measures for classification tasks,» *Information Processing & Management*, τόμ. 45, αρ. 4, pp. 427-437, 2009.
- [44] K. K. J. Järvelin, «Cumulated gain-based evaluation of IR techniques,» *ACM Transactions on Information Systems (TOIS)*, τόμ. 20, αρ. 4, p. 422–446, 2002.
- [45] K. R. S. W. T. & Z. W. J. Papineni, «BLEU: a method for automatic evaluation of machine translation,» σε *Proceedings of the 40th annual meeting of the Association for Computational Linguistics (ACL)*, 2002.
- [46] C.-Y. Lin, «ROUGE: A Package for Automatic Evaluation of Summaries,» σε *Text Summarization Branches Out*, 2004.
- [47] P. P. Ray, «ChatGPT: A comprehensive review on background, applications, key challenges, bias, ethics, limitations and future scope,» *Internet of Things and Cyber-Physical Systems*, τόμ. 3, pp. 121-154, 2023.
- [48] A. B. Arrieta, N. Díaz-Rodríguez, J. Del Ser, A. Benetot, S. Tabik, A. Barbado, S. Garcia, S. Gil-Lopez, D. Molina, R. Benjamins, R. Chatila και F. Herrera, «Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI,» *Information Fusion*, τόμ. 58, p. 82–115, 2020.
- [49] N. Mehrabi, F. Morstatter, N. Saxena, K. Lerman και A. Galstyan, «A Survey on Bias and Fairness in Machine Learning,» *ACM Computing Surveys*, τόμ. 54, αρ. 6, pp. 1-35, 2022.
- [50] S. L. Blodgett, S. Barocas, H. D. III και H. Wallach, «Language (Technology) is Power: A Critical Survey of "Bias" in NLP,» σε *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020.
- [51] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su και Y. Xu, «Survey of Hallucination in Natural Language Generation,» *ACM Computing Surveys*, τόμ. 55, αρ. 12, p. 3571730, 2023.
- [52] J. Maynez, S. Narayan, B. Bohnet και R. McDonald, «On Faithfulness and Factuality in Abstractive Summarization,» σε *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020.
- [53] R. Schwartz, J. Dodge, N. A. Smith και O. Etzioni, «Green AI,» *Communications of the ACM*, τόμ. 63, αρ. 12, pp. 54-63, 2020.

- [54] R. Bommasani, D. A. Hudson, E. Adeli, R. Altman, S. Arora, S. v. Arx, M. S. Bernstein, J. Bohg, A. Bosselut, E. Brunskill, E. Brynjolfsson, S. Buch, D. Card και R. Castellon, «On the Opportunities and Risks of Foundation Models,» 2021. [Ηλεκτρονικό]. Available: <https://arxiv.org/abs/2108.07258>.
- [55] H. Shakil, A. Farooq και J. Kalita, «Abstractive text summarization: State of the art, challenges, and improvements,» *Neurocomputing*, p. 128255, 2024.
- [56] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry και A. Askell, «Language Models are Few-Shot Learners,» σε *Advances in neural information processing systems*, 2020.
- [57] J. Kocon, I. Cichecki, O. Kaszyca, M. Kochanek, D. Szydło, J. Baran, J. Bielaniewicz, M. Gruza, A. Janz, K. Kanclerz, K. A. Kazienko, B. Koptyra, W. Mieszczenko-Kowszewicz, P. Miłkowski, M. Oleksy, M. Piasecki, Ł. Radliński, K. Wojtasik, S. Woźniak και P. Kazienko, «ChatGPT: Jack of all trades, master of none,» *Information Fusion*, p. 101861, 2023.
- [58] C. Qin, A. Zhang, Z. Zhang, J. Chen, M. Yasunaga και D. Yang, «Is ChatGPT a General-Purpose Natural Language Processing Task Solver?,» σε *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, Singapore, 2023.
- [59] M. Tu, «Named entity recognition and emotional viewpoint monitoring in online news using artificial intelligence,» *PeerJ Computer Science*, τόμ. 10, p. e1715, 2024.
- [60] A. Choudhary, S. Pamidimokkala, K. R και B. R. M., «Impact of Natural Language Processing models on diagnosis and decision-making in healthcare, business, education, and sports: a review,» *Frontiers in Artificial Intelligence*, τόμ. 9, p. 1706369, 2026.
- [61] D. Greene και P. Cunningham, «Practical Solutions to the Problem of Diagonal Dominance in Kernel Document Clustering,» σε *Proceedings of the 23rd International Conference on Machine Learning (ICML)*, Pittsburgh, PA, 2006.
- [62] H. Liu, M. Sheng, Z. Sun, Y. Yao, X.-S. Hua και H.-T. Shen, «Learning with Imbalanced Noisy Data by Preventing Bias in Sample Selection,» *IEEE Transactions on Multimedia*, τόμ. 26, pp. 7426-7437, 2024.
- [63] C. Ma, W. E. Zhang, M. Guo, H. Wang και Q. Z. Sheng, «Multi-document summarization via deep learning techniques: A survey,» *ACM Computing Surveys*, τόμ. 55, αρ. 5, pp. 1-37, 2022.
- [64] E. Ghobain, H. Al-Nofaie, F. Alhazmi, R. Bosli και M. Shamakhi, «A Triangulated Digital Approach to News Sentiment Analysis: Insights from Media Coverage,» *Journalism and Media*, τόμ. 7, αρ. 1, 2026.
- [65] A. K. Uysal και S. Gunal, «The impact of preprocessing on text classification,» *Information Processing & Management*, τόμ. 50, αρ. 1, pp. 104-112, 2014.
- [66] M. Siino, I. Tinnirello και M. La Cascia, «Is text preprocessing still worth the time? A comparative survey on the influence of popular preprocessing methods on Transformers and traditional

- classifiers,» *Information Systems*, τόμ. 121, p. 102342, 2024.
- [67] A. Jabbar, S. Iqbal, M. I. Tamimy, A. Rehman, S. A. Bahaj και T. Saba, «An analytical analysis of text stemming methodologies in information retrieval and natural language processing systems,» *IEEE Access*, τόμ. 11, pp. 133681-133702, 2023.
- [68] K. M. R. Krishna, K. Somasundaram, P. Arulmozhivarman, S. A. Immanuel και E. R. Rajkumar, «Deep learning for text summarization using NLP for automated news digest,» *Scientific Reports*, τόμ. 15, p. 36343, 2025.
- [69] W. Khan, A. Daud, K. Khan, S. Muhammad και R. Haq, «Exploring the frontiers of deep learning and natural language processing: A comprehensive overview of key challenges and emerging trends,» *Natural Language Processing Journal*, τόμ. 4, p. 100026, 2023.
- [70] R. P. Nair, M. G. Thushara και V. Sugumaran, «Fine-Tuned LLMs vs. Rule-Based NLP for UML Diagram Generation: An Educational Evaluation,» *IEEE Access*, τόμ. 13, pp. 211605 - 211619, 2025.
- [71] E. Barbierato και A. Gatti, «Toward green ai: A methodological survey of the scientific literature,» *IEEE Access*, τόμ. 12, pp. 23989 - 24013, 2024.
- [72] M. Honnibal, I. Montani, S. Van Landeghem και A. Boyd, «spaCy: Industrial-strength Natural Language Processing in Python,» 2020. [Ηλεκτρονικό]. Available: <https://doi.org/10.5281/zenodo.1212303>.
- [73] H. Shelar, G. Kaur, N. Heda και P. Agrawal, «Named entity recognition approaches and their comparison for custom NER model,» *Science & Technology Libraries*, τόμ. 39, αρ. 3, pp. 324-337, 2020.
- [74] A. Toprak και M. Turan, «Enhanced Named Entity Recognition algorithm for financial document verification,» *The Journal of Supercomputing*, τόμ. 79, p. 19431–19451, 2023.
- [75] R. Salah, M. Mukred, L. Q. b. Zakaria, F. A. M. Al-Yarimi, I. T. N. Khasro και A. S. Sadiq, «Resource efficient hybrid baseline for named entity recognition in classical Arabic,» *Scientific Reports*, τόμ. 16, p. 570, 2025.
- [76] C. J. Hutto και E. Gilbert, «VADER: A Parsimonious Rule-Based Model for Sentiment Analysis of Social Media Text,» σε *Proceedings of the International AAAI Conference on Web and Social Media*, 2014.
- [77] M. Bednarek και M. Taboada, «Attitude in reported and non-reported news: A critique of sentiment analysis in corpus pragmatics,» *Corpus Pragmatics*, τόμ. 9, pp. 111-133, 2025.
- [78] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer και V. Stoyanov, «RoBERTa: A Robustly Optimized BERT Pretraining Approach,» arXiv preprint, 2019.
- [79] A. J. Lak, R. Boostani, F. A. Alenizi, A. S. Mohammed και S. M. Fakhrahmad, «RoBERTa, ResNeXt and BiLSTM with self-attention: The ultimate trio for customer sentiment analysis,» *Applied Soft*

- Computing*, τόμ. 164, p. 112018, 2024.
- [80] R. Catelli, S. Pelosi και M. Esposito, «Lexicon-based vs. Bert-based sentiment analysis: A comparative study in Italian,» *Electronics (MDPI)*, τόμ. 11, αρ. 3, p. 374, 2022.
- [81] Z. Alami Merrouni, B. Frikh και B. Ouhbi, «EXABSUM: a new text summarization approach for generating extractive and abstractive summaries,» *Journal of Big Data*, τόμ. 10, p. 163, 2023.
- [82] A. Rao, S. Aithal και S. Singh, «Single-Document Abstractive Text Summarization: A Systematic Literature Review,» *ACM Computing Surveys*, τόμ. 57, αρ. 3, pp. 1-37, 2024.
- [83] Z. Nie, M. Arshad, S. K. Khurshid, A. Javed, T. Waheed και Q. Zhang, «Domain-Specific Multi-Document Political News Summarization Using BART and ACT-GAN,» *IEEE Access*, τόμ. 13, pp. 143737-143750, 2025.
- [84] E. Davoodijam και M. Alambardar Meybodi, «Evaluation metrics on text summarization: comprehensive survey,» *Knowledge and Information Systems*, τόμ. 66, αρ. 12, p. 7717–7738, 2024.
- [85] A. B. Sai, A. K. Mohankumar και M. M. Khapra, «A Survey of Evaluation Metrics Used for NLG Systems,» *ACM Computing Surveys*, τόμ. 55, αρ. 2, pp. 1-39, 2022.
- [86] M. E. Villa-Pérez, L. A. Trejo, M. B. Moin και E. Stroulia, «Extracting Mental Health Indicators From English and Spanish Social Media: A Machine Learning Approach,» *IEEE Access*, τόμ. 11, pp. 128135 - 128152, 2023.
- [87] A. Ferrario, B. Demiray, K. Yordanova, M. Luo και M. Martin, «Social Reminiscence in Older Adults' Everyday Conversations: Automated Detection Using Natural Language Processing and Machine Learning,» *Journal of Medical Internet Research*, τόμ. 22, αρ. 9, p. e19133, 2020.
- [88] S. Gehrmann, E. Clark και T. Sellam, «Repairing the Cracked Foundation: A Survey of Obstacles in Evaluation Practices for Generated Text,» *Journal of Artificial Intelligence Research (JAIR)*, τόμ. 77, pp. 103-166, 2023.
- [89] E. Daraghmi, L. Atwe και A. Jaber, «A Comparative Study of PEGASUS, BART, and T5 for Text Summarization Across Diverse Datasets,» *Future Internet*, τόμ. 17, αρ. 9, p. 389, 2025.
- [90] M. Arvan, L. Pina και N. Parde, «Reproducibility in Computational Linguistics: Is Source Code Enough?,» *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, p. 2350–2361, 2022.
- [91] M. Emani, S. Foreman, V. Sastry, Z. Xie, S. Raskar, W. Arnold, R. Thakur, V. Vishwanath και M. E. Papka, «A comprehensive performance study of large language models on novel AI accelerators,» arXiv preprint, 2023.
- [92] E. Bisong, «Google Colaboratory,» σε *Building Machine Learning and Deep Learning Models on Google Cloud Platform*, Berkeley, CA, Apress, 2019, pp. 59-64.

- [93] W. McKinney, «Data structures for statistical computing in python,» σε *Proceedings of the 9th Python in Science Conference*, 2010.
- [94] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz, J. Davison, S. Shleifer, P. von Platen, C. Ma, Y. Jernite, J. Plu, C. Xu, T. Le Scao, S. Gugger, M. Drame, Q. Lhoest και A. Rush, «Transformers: State-of-the-Art Natural Language Processing,» σε *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 2020.
- [95] J. D. Hunter, «Matplotlib: A 2D graphics environment,» *Computing in Science & Engineering*, τόμ. 9, αρ. 3, pp. 90-95, 2007.
- [96] I. Montani, M. Honnibal και A. Boyd, «explosion/spaCy: v3.7.2: Fixes for APIs and requirements,» 2023. [Ηλεκτρονικό]. Available: <https://zenodo.org>.
- [97] S. Sharma και M. Mohania, «Comparative analysis of entity identification and classification of Indian epics,» σε *Proceedings of the 2022 International Conference on Management of Data*, 2022.
- [98] N. Raghunathan και K. Saravanakumar, «Challenges and Issues in Sentiment Analysis: A Comprehensive Survey,» *IEEE Access*, τόμ. 11, pp. 69626-69642, 2023.
- [99] S. Bird, E. Klein και E. Loper, *Natural Language Processing with Python: Analyzing Text with the Natural Language Toolkit*, Sebastopol, CA: O'Reilly Media, Inc., 2009.
- [100] F. Barbieri, J. Camacho-Collados, L. Espinosa Anke και L. Neves, «TweetEval: Unified Benchmark and Comparative Evaluation for Tweet Classification,» σε *Findings of the Association for Computational Linguistics: EMNLP 2020*, 2020.